深度學習講義

第一章　深度學習革命

Chapter 1: The Deep Learning Revolution

授課教師：王和盛　國立臺灣海洋大學通訊與導航工程學系

講義依據 C. M. Bishop & H. Bishop, *Deep Learning: Foundations and Concepts* (Springer, 2024) 第一章整理

版本：2026 年 8 月 26 日

本章學習目標

1. 透過四個跨領域案例，理解深度學習作為**通用學習框架**的廣度，並掌握監督式、非監督式、自監督式學習與遷移學習等基本詞彙。
2. 以**多項式曲線擬合**為教學範例，建立線性模型、誤差函數、最小平方閉式解、過度擬合、正則化(權重衰減)、超參數與交叉驗證等核心觀念，並完成相關數學推導。
3. 沿著**單層網路** → **反向傳播** → **深度網路**三個階段，理解類神經網路的歷史脈絡，以及規模化(資料、參數、算力)在當代深度學習中的角色。
4. 能將本章觀念連結到後續章節 (機率論、決策論、梯度優化、反向傳播、CNN、Transformer 與大型語言模型)。

目次

引言：從手工演算法到從資料中學習 2

1.1 深度學習的影響 2
1.1.1 醫學診斷：皮膚癌影像分類 . . . 2
1.1.2 蛋白質結構預測 . . . 3
1.1.3 影像合成 . . . 3
1.1.4 大型語言模型 . . . 4

1.2 教學範例：多項式曲線擬合 4
1.2.1 合成資料 . . . 5
1.2.2 線性模型 . . . 5
1.2.3 誤差函數 . . . 6
1.2.4 模型複雜度 . . . 7
1.2.5 正則化 . . . 8
1.2.6 模型選擇 . . . 10

1.3 機器學習簡史 12
1.3.1 從生物神經元到數學模型 . . . 12
1.3.2 第一階段：單層網路 . . . 13
1.3.3 第二階段：反向傳播 . . . 13
1.3.4 第三階段：深度網路 . . . 14

課後習題 16

附錄 A 中英名詞對照表 19

附錄 B 延伸閱讀與參考文獻 20

引言：從手工演算法到從資料中學習

機器學習（machine learning）是當今最重要、成長最快的技術領域之一。其核心轉變在於：過去我們必須**由人手工設計**演算法來解決問題，如今則改由**從資料中學習**的解法逐步取而代之。這不僅提升了既有技術的表現，更開啟了一整片過去難以想像的新能力——若一切演算法都必須由人明確寫出，這些能力根本無從出現。

在眾多機器學習分支中，**深度學習**（deep learning）已成為一個極為強大且通用的框架。它建立在稱為**類神經網路**（neural networks）的計算模型之上，其靈感最初來自人腦的學習與資訊處理機制。**人工智慧**（artificial intelligence, AI）追求在機器上重現大腦的強大能力；今天「機器學習」與「AI」兩詞經常被交替使用。不過，目前大多數 AI 系統只針對非常特定、聚焦的問題，與人腦能力的廣度相去甚遠，因此有人提出**通用人工智慧**（artificial general intelligence, AGI）一詞，用以描述打造具備更大彈性之機器的願景。近年來，稱為**大型語言模型**（large language models, LLM）的巨型深度學習系統已展現驚人能力，甚至被描述為 AGI 的初步徵兆（Bubeck et al., 2023）。

本章在全書中的定位

本章以「說故事」的方式導覽整個領域：先看應用（§1.1），再用一個小到可以完全用紙筆分析的例子建立詞彙（§1.2），最後回顧歷史（§1.3）。後續章節會嚴格地從機率論（Ch. 2）、決策論（Ch. 5）、線性模型（Ch. 4）、梯度下降（Ch. 7）、反向傳播（Ch. 8）、正則化（Ch. 9）、CNN（Ch. 10）與 Transformer ／ LLM（Ch. 12）逐一展開。本章出現的每個觀念，都會在後面「再出現一次」。

1.1 深度學習的影響

我們先考察四個來自不同領域的例子，說明深度學習的廣泛適用性，並藉此引入基本觀念與術語。最值得注意的是：這些問題**全都以同一套深度學習框架的變體**來解決。這與傳統做法形成鮮明對比——過去每種應用往往需要截然不同的專門技術。這裡的四個例子只是冰山一角；幾乎任何「計算」能扮演角色的領域，都可能被深度學習所翻轉。

1.1.1 醫學診斷：皮膚癌影像分類

考慮以機器學習診斷皮膚癌。黑色素瘤（melanoma）是最危險的皮膚癌，但若能及早發現則可治癒。要區分「惡性黑色素瘤」與「良性痣」的影像極為困難，幾乎不可能**手工**寫出一個具有合理準確率的分類演算法。

此問題已由深度學習成功解決（Esteva et al., 2017）。解法使用一大批已標註為「惡性」或「良性」的病灶影像，稱為**訓練集**（training set）；標籤來自被視為「真實類別」的切片檢查（biopsy）。訓練集用來決定一個深度神經網路中約 **2,500 萬個**可調參數，稱為**權重**（weights）。由資料決定參數值的過程稱為**學習**（learning）或**訓練**（training）。目標是讓訓練後的網路僅憑影像即可預測新病灶的正確標籤，省去耗時的切片步驟。

基本術語 I：監督式學習、分類與迴歸

- **監督式學習**（supervised learning）：每筆訓練樣本都附有「正確答案」（標籤）。皮膚病灶分類即屬此類。
- **分類**（classification）：輸出屬於離散的類別集合（如良性／惡性）。
- **迴歸**（regression）：輸出為一個或多個連續變數。例如以溫度、壓力與反應物濃度預測化工製程的產率。

此應用有一個有趣之處：可用的標註影像約 129,000 張，在深度學習的尺度下算是**相對少量**。因此網路先在一個更大的資料集——128 萬張日常物件（狗、建築、蘑菇等）影像——上訓練，再於病灶影像資料集上**微調**（fine-tune）。這就是**遷移學習**（transfer learning）：網路先從大量日常影像學到自然影像的一般性質，再專門化到病灶分類這個特定問題。透過深度學習，皮膚病灶影像分類的準確率已超越專業皮膚科醫師（Brinker et al., 2019）。

1.1.2 蛋白質結構預測

蛋白質常被稱為生物體的「建築磚塊」。它由一條或多條**胺基酸**長鏈構成（胺基酸共 22 種），蛋白質由其胺基酸序列所決定。蛋白質在細胞內合成後會摺疊成複雜的三維結構，其行為與交互作用強烈取決於形狀。「給定胺基酸序列，計算其 3D 結構」是生物學半世紀以來的基本開放問題，在深度學習出現前進展甚微。

3D 結構可用 X 光晶體繞射、冷凍電子顯微鏡或核磁共振等實驗方法測得，但極為耗時，對某些蛋白質甚至難以進行；相對地，胺基酸序列的測定成本低、通量高。因此，人們極希望能**直接從序列預測 3D 結構**，以理解生物過程或應用於藥物開發。深度學習模型可以「序列為輸入、3D 結構為輸出」來訓練，訓練資料為一批序列與結構皆已知的蛋白質——這又是一個**監督式學習**問題。訓練完成後，模型即可對新序列預測其結構（Jumper et al., 2021，即 AlphaFold）。原書圖 1.2 比較了 AlphaFold 對蛋白質 T1044/6VR4 的預測結構與 X 光晶體繞射的真實結構，兩者幾乎重合。

1.1.3 影像合成

前兩個應用中，網路學習將輸入（皮膚影像、胺基酸序列）轉換為輸出（分類、3D 結構）。現在看一個不同的例子：訓練資料**只是一批樣本影像**，目標是讓網路**生成同類型的新影像**。由於影像沒有標籤，這是**非監督式學習**（unsupervised learning）。以攝影棚、素色背景下拍攝的人臉影像訓練的深度網路，可以生成品質極高的合成人臉，難以與真人照片區分（原書圖 1.3）。

基本術語 II：生成模型與生成式 AI

- **生成模型**（generative model）：能產生「與訓練樣本不同、但具有相同統計性質」的新輸出。
- 若生成內容依賴一段輸入文字（稱為**提示**，prompt），使影像內容反映文字語意，即為「文生圖」的變體（Ch. 10）。
- **生成式 AI**（generative AI）泛指輸出為影像、影片、音訊、文字、候選藥物分子等各種模態的深度學習模型。

1.1.4 大型語言模型

近年機器學習最重要的進展之一，是處理自然語言與其他序列資料（如程式原始碼）的強大模型。**大型語言模型**（LLM）利用深度學習建立能捕捉語言語意性質的豐富內部表徵。其中一類重要模型稱為**自迴歸語言模型**（autoregressive language model），能以語言作為輸出，因此屬於生成式 AI。

範例 1.1.1 (自迴歸式文字生成). 模型以「一串詞」為輸入，輸出**一個**代表序列中「下一個詞」的詞。把新詞接在序列末端後再餵回模型，即可產生下一個詞；重複此程序便能生成長文。模型也能輸出一個特殊的「停止」詞以結束生成，因此輸出長度有限。此時使用者可再接上自己的一串詞、餵回模型以觸發後續生成——人與神經網路的「對話」即由此而來。

這類模型可在龐大的文字資料集上訓練：從文本中隨機抽取一段詞序列作為輸入，以已知的「下一個詞」作為目標輸出，構成訓練配對。這是**自監督式學習**（self-supervised learning）的例子——雖然學的是「輸入 $\to$ 輸出」的函數，但標籤是**自動**從輸入資料中取得，無須額外的人工標註。由於多種來源都有大量文本，此方法得以擴展到極大的訓練集與極大的神經網路。

LLM 展現的非凡能力被描述為「通用人工智慧的初步徵兆」（Bubeck et al., 2023），本書第 12 章將詳細討論。原書以 GPT-4（OpenAI, 2023）為例，輸入提示「以莎士比亞戲劇的風格、透過兩人對質數無限性證明的爭辯，寫出一段證明」，模型即生成一段押韻的對白，內容正確重現了歐幾里得的反證法：假設最大質數為 P，令 $Q = (2 \cdot 3 \cdots P) + 1$，則 Q 不被任何 $\le P$ 的質數整除，矛盾。

基本術語 III：三種學習典範的對照

典範	訓練資料的形式	本章案例
監督式	輸入 + 人工標註的目標	皮膚病灶分類、蛋白質結構預測
非監督式	只有輸入，無標籤	人臉影像合成（生成模型）
自監督式	目標從輸入自動導出	LLM 的「預測下一個詞」

遷移學習則是跨越典範的**訓練策略**：先在大資料上預訓練（pre-train），再於目標任務上微調。

教學補充：與本系研究方向的連結

本章四個案例的共同結構是「以資料決定一個有數百萬至數兆參數之函數」。在通訊與導航領域中，同樣的框架已用於：以歷史觀測預測電離層總電子含量（VTEC）以修正 GNSS 單頻定位誤差（迴歸問題）；雷達／聲學陣列的到達方向（DOA）估計（可視為分類或迴歸）；以及海事網路入侵偵測（分類）。值得思考的是：在這些問題中，「標籤」從何而來？是否可以像 LLM 一樣採用自監督的方式（例如以過去的時間序列預測未來值），從而免除人工標註？

1.2 教學範例：多項式曲線擬合

對初學者而言，機器學習的許多基本概念與術語，都可以在一個簡單的例子中引入：**以多項式擬合一組小型合成資料**（Bishop, 2006）。這是一個監督式學習問題：給定輸入變數的值，預測目標變數的值。

1.2.1 合成資料

以 x 表示輸入變數、t 表示目標變數，兩者皆為實數。設訓練集含 N 筆觀測 $x_1, \dots, x_N$，及對應的目標值 $t_1, \dots, t_N$。目標是對某個**新的** x 預測 t。「對未曾見過的輸入做出準確預測」是機器學習的核心目標，稱為**泛化**(generalization)。

我們用正弦函數取樣產生合成資料：在 $[0, 1]$ 上均勻取 $N = 10$ 個 x_n，計算 $\sin(2\pi x_n)$ 後加上少量高斯雜訊(§2.3)，得到 t_n(圖 1)。這樣產生的資料捕捉了真實資料集的重要性質——**存在我們想學習的底層規律，但個別觀測受隨機雜訊干擾**。雜訊可能來自本質上隨機的過程(如放射性衰變)，但更常來自**未被觀測到**的變異來源。

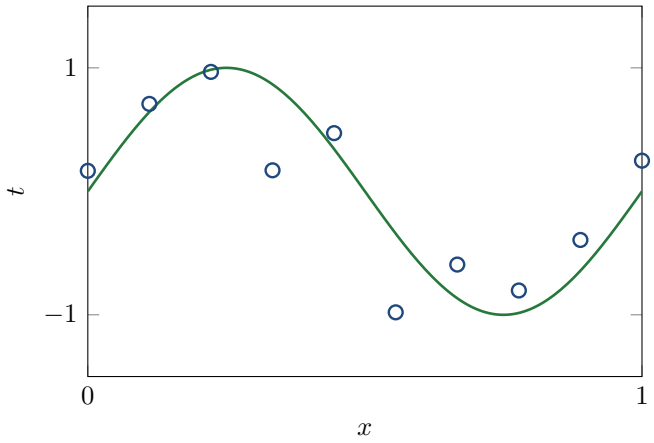


圖 1: $N = 10$ 筆訓練資料(藍圈)，每筆包含輸入 x 與目標 t。綠線為產生資料所用的函數 $\sin(2\pi x)$。我們的目標是在**不知道綠線**的情況下，對新的 x 預測 t。(本講義所有圖形皆以 pgfplots 依同一程序重新產生，數值與原書略有差異。)

在本教學範例中，我們**知道**產生資料的真實過程(正弦函數)；在實際應用中，目標正是從有限的訓練集中發現底層趨勢。知道真實過程，讓我們得以清楚說明機器學習的重要概念。

1.2.2 線性模型

我們要利用訓練集，對新的輸入 $\widehat{x}$ 預測目標值 $\widehat{t}$。這其實是在隱含地嘗試找出底層函數 $\sin(2\pi x)$——本質上是困難的：我們必須從**有限資料**推廣到**整個函數**，而且資料受雜訊污染，因此對給定的 $\widehat{x}$，$\widehat{t}$ 的適當值存在**不確定性**。機率論(Ch. 2)提供了精確、量化地表達這種不確定性的框架，決策論(Ch. 5)則讓我們利用此機率表徵做出依適當準則為最佳的預測。**從資料學習機率**是機器學習的核心。

不過，我們先以非正式的**曲線擬合**切入。考慮多項式函數

$$y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^{M} w_j x^j, \tag{1}$$

其中 M 為多項式的**階數**(order)，x^j 為 x 的 j 次冪。係數 $w_0, \dots, w_M$ 合稱向量 $\mathbf{w}$。

關鍵觀察：「線性」指的是對參數線性

雖然 $y(x, \mathbf{w})$ 是 x 的**非線性**函數，它卻是係數 $\mathbf{w}$ 的**線性**函數。對未知參數為線性的函數(如此多項式)具有重要性質，也有顯著限制，統稱為**線性模型**(linear models，Ch. 4)。以矩陣語言來說，令 $\boldsymbol{\phi}(x) = (1, x, x^2, \dots, x^M)^{\mathsf{T}}$，則 $y(x, \mathbf{w}) = \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(x)$：模型是「固定基底函數的線性組合」，可學習的只有組合係數。

1.2.3 誤差函數

係數的值由「將多項式擬合到訓練資料」決定，做法是最小化一個衡量「$y(x,\mathbf{w})$ 與訓練資料點之間不吻合程度」的**誤差函數**（error function）。一個簡單且廣泛使用的選擇是**平方和誤差**（sum-of-squares error）：

$$E(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}\{y(x_n,\mathbf{w}) - t_n\}^2, \tag{2}$$

係數 $1/2$ 是為了後續運算方便。第 2.3.4 節將從機率論（高斯雜訊下的最大概似）推導出此誤差函數；這裡只需注意它是**非負**的，且**若且唯若**函數 $y(x,\mathbf{w})$ 恰好通過每個訓練資料點時為零。其幾何意義如圖 2：每個資料點到曲線的**垂直**位移平方之和的一半。

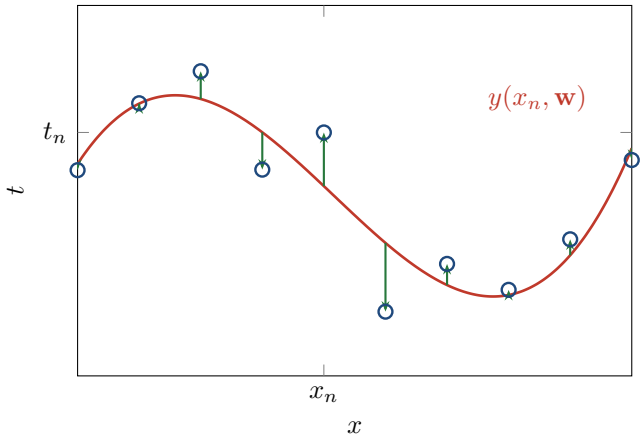


圖 2: 誤差函數 (2) 對應到各資料點到函數 $y(x,\mathbf{w})$ 之垂直位移（綠色箭頭）平方和的一半。

我們選取使 $E(\mathbf{w})$ 最小的 $\mathbf{w}$ 來解曲線擬合問題。由於誤差函數是係數 $\mathbf{w}$ 的**二次**函數，其對係數的導數為 $\mathbf{w}$ 的**線性**函數，因此最小化有**唯一解** $\mathbf{w}^\star$，且可用閉式（closed form）求得（習題 4.1）。所得多項式即為 $y(x,\mathbf{w}^\star)$。

推導 (最小平方閉式解（正規方程）)**.** 令 $\boldsymbol{\Phi}$ 為 $N\times(M+1)$ 的**設計矩陣**（design matrix），$\boldsymbol{\Phi}_{nj} = x_n^j$，$\mathbf{t} = (t_1,\dots,t_N)^{\mathsf{T}}$。則 (2) 可寫成

$$E(\mathbf{w}) = \tfrac{1}{2}\,\|\boldsymbol{\Phi}\mathbf{w} - \mathbf{t}\|^2 = \tfrac{1}{2}\big(\mathbf{w}^{\mathsf{T}}\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w} - 2\mathbf{w}^{\mathsf{T}}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t} + \mathbf{t}^{\mathsf{T}}\mathbf{t}\big).$$

對 $\mathbf{w}$ 取梯度並令其為零：

$$\nabla_{\mathbf{w}}E = \boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w} - \boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t} = \mathbf{0} \quad\Longrightarrow\quad \boxed{\mathbf{w}^\star = (\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}}$$

此即**正規方程**（normal equations）。Hessian 為 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi} \succeq 0$，且當 $\boldsymbol{\Phi}$ 行滿秩（$N \ge M+1$ 且 x_n 互異）時為正定，故 $\mathbf{w}^\star$ 為唯一的全域極小值。$(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}$ 稱為 $\boldsymbol{\Phi}$ 的 Moore–Penrose 偽反矩陣。

教學補充：訊號處理觀點

正規方程正是通訊與導航領域中反覆出現的結構：GNSS 定位中的最小平方解算（線性化後的觀測方程 $\mathbf{H}\delta\mathbf{x} = \delta\boldsymbol{\rho}$）、Wiener 濾波器的最佳係數、以及陣列訊號處理中的線性估計，都是同一個 $\mathbf{w}^\star = (\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}$。差別只在於「基底函數 $\boldsymbol{\phi}$」的選取：多項式、正弦／餘弦（Fourier）、或幾何投影矩陣。深度學習的關鍵一步，是讓**基底函數本身也從資料中學得**（§1.3.3 的表徵學習）。

1.2.4 模型複雜度

接著要決定多項式的階數 M——這是**模型比較**(model comparison)或**模型選擇**(model selection)此重要概念的一個實例。圖 3 顯示以 $M = 0, 1, 3, 9$ 擬合圖 1 資料的結果。

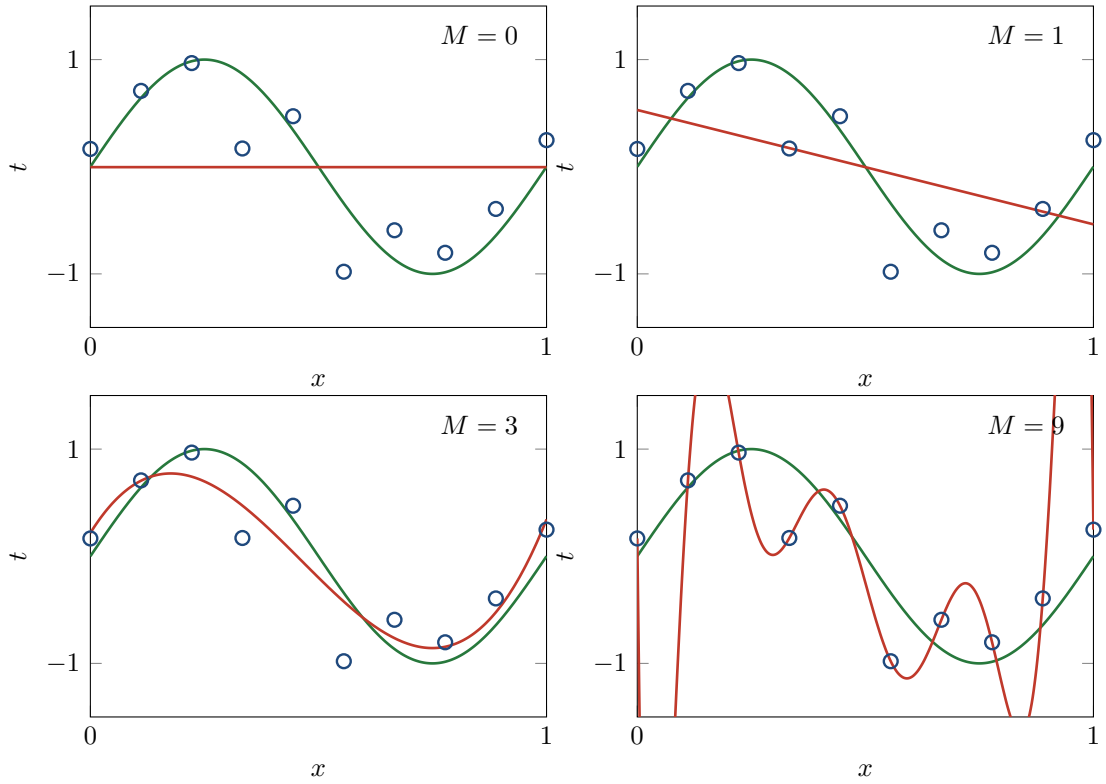


圖 3: 以最小化誤差函數 (2) 擬合不同階數 M 之多項式(紅線)到圖 1 的資料。

常數($M = 0$)與一階($M = 1$)多項式擬合不佳，因此也無法良好表示 $\sin(2\pi x)$；三階($M = 3$)似乎給出最好的近似；至於高階的 $M = 9$，它對**訓練資料**擬合得極好——事實上精確通過每個資料點，$E(\mathbf{w}^\star) = 0$——但曲線劇烈震盪，對 $\sin(2\pi x)$ 的表示反而極差。後者稱為**過度擬合**(over-fitting)。

我們的目標是**良好的泛化**。為了量化泛化表現與 M 的關係，另取一組以相同程序產生、含 100 筆資料的**測試集**(test set)。對每個 M，分別在訓練集與測試集上計算 $E(\mathbf{w}^\star)$。實務上更常用**均方根誤差**(root-mean-square error, RMS)：

$$E_{\mathrm{RMS}} = \sqrt{\frac{1}{N}\sum_{n=1}^{N}\{y(x_n, \mathbf{w}) - t_n\}^2}, \tag{3}$$

除以 N 使不同大小的資料集可以公平比較，開根號則使 E_{RMS} 與目標變數 t 具有相同的尺度與單位。圖 4 顯示訓練集與測試集的 RMS 誤差隨 M 的變化。

測試集誤差衡量的是我們對**新資料**預測 t 的表現。從圖 4 可見：M 很小時測試誤差偏大，因為對應的多項式太不靈活，無法捕捉 $\sin(2\pi x)$ 的震盪；$3 \le M \le 8$ 時測試誤差小，也能合理表示產生函數；$M = 9$ 時訓練誤差歸零——這是意料中事，因為此多項式有 10 個自由度$(w_0, \ldots, w_9)$，恰可精確調到 10 個訓練點上——但測試誤差變得很大，對應圖 3 中劇烈震盪的函數。

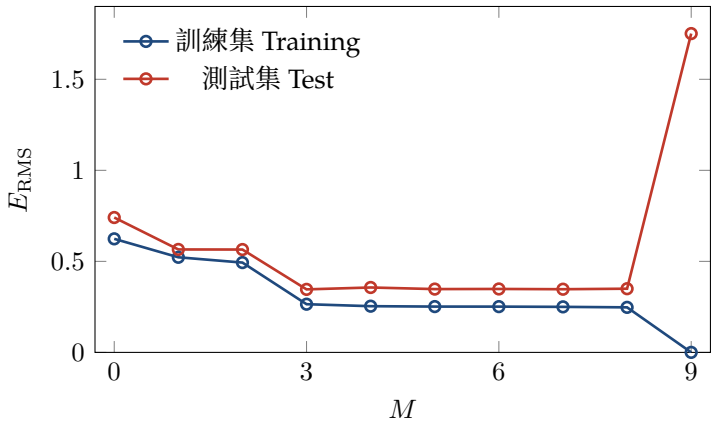


圖 4: RMS 誤差 (3) 在訓練集與獨立測試集上隨 M 的變化。

一個看似弔詭的問題

給定階數的多項式包含所有較低階多項式為特例，$M = 9$ 的多項式**至少**能產生和 $M = 3$ 一樣好的結果。此外，$\sin(2\pi x)$ 的冪級數展開含所有階的項，我們或許會預期結果應隨 M 增加而單調改善。為何實際上不然？

檢視各階多項式所得係數 $\mathbf{w}^\star$ 的值（表 1）可得到一些洞見：隨 M 增加，係數的量級通常變大。$M = 9$ 時，係數已被**精細地調到資料上**——它們有巨大的正負值，使多項式精確吻合每個資料點，但在資料點之間（尤其是區間兩端）出現劇烈震盪。直觀地說，越靈活的多項式（M 越大）越是**在擬合目標值上的隨機雜訊**。

表 1: 各階多項式的係數 $\mathbf{w}^\star$。注意係數的典型量級隨階數急遽增大。

	$M=0$	$M=1$	$M=3$	$M=9$
$w_0^\star$	−0.00	0.53	0.22	0.17
$w_1^\star$		−1.07	6.84	−374.59
$w_2^\star$			−23.98	8,781.65
$w_3^\star$			17.27	−79,006.74
$w_4^\star$				369,642.57
$w_5^\star$				−1,002,582.44
$w_6^\star$				1,634,413.51
$w_7^\star$				−1,578,398.99
$w_8^\star$				831,584.04
$w_9^\star$				−184,058.92

另一個角度是觀察**資料集大小**改變時模型的行為（圖 5）：對固定的模型複雜度，隨資料集增大，過度擬合問題減輕。換言之，**資料越多，越能負擔更複雜（更靈活）的模型**。古典統計中有一個粗略的經驗法則：資料點數不應少於可學習參數個數的某個倍數（例如 5 或 10 倍）。然而在深度學習中，我們將看到**參數數量遠多於訓練資料點數**的模型仍可得到極佳結果（§9.3.2）。

1.2.5 正則化

「必須依訓練集大小來限制參數數量」令人不甚滿意——更合理的做法應是**依問題本身的複雜度**來選擇模型複雜度。控制過度擬合的一個常用技術是**正則化**（regularization）：在誤差函數 (2) 中加

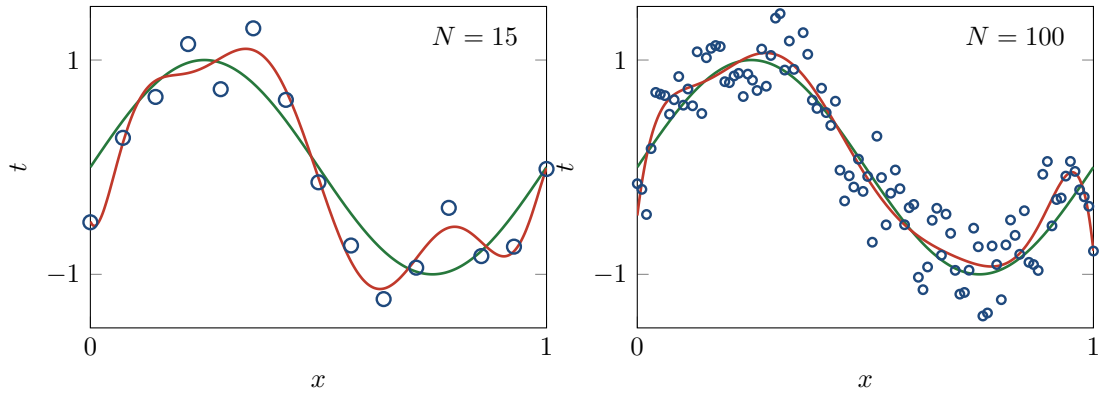


圖 5: 以 $M = 9$ 多項式最小化 (2) 所得的解：$N = 15$(左)與 $N = 100$(右)。增加資料量可減輕過度擬合。

入一個**懲罰項**，抑制係數取得過大的量級。最簡單的懲罰項是所有係數的平方和：

$$\widetilde{E}(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}\{y(x_n,\mathbf{w}) - t_n\}^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2, \tag{4}$$

其中 $\|\mathbf{w}\|^2 \equiv \mathbf{w}^{\mathsf{T}}\mathbf{w} = w_0^2 + w_1^2 + \cdots + w_M^2$，係數 λ 決定正則化項相對於平方和誤差項的重要性。常見做法是把 w_0 排除在正則化項之外，因為納入它會使結果依賴目標變數原點的選擇(Hastie, Tibshirani, and Friedman, 2009)，或者給 w_0 一個獨立的正則化係數(§9.2.1)。式 (4) 同樣可以閉式精確最小化(習題 4.2)。這類技術在統計文獻中稱為**收縮法**(shrinkage methods)，因為它們縮小係數的值；在神經網路中則稱為**權重衰減**(weight decay)，因為網路的參數稱為權重，而此正則化項促使權重朝零衰減。

推導 (正則化最小平方的閉式解)**.**

$$\widetilde{E}(\mathbf{w}) = \tfrac{1}{2}\|\mathbf{\Phi w} - \mathbf{t}\|^2 + \tfrac{\lambda}{2}\mathbf{w}^{\mathsf{T}}\mathbf{w}, \qquad \nabla_{\mathbf{w}}\widetilde{E} = (\mathbf{\Phi}^{\mathsf{T}}\mathbf{\Phi} + \lambda\mathbf{I})\mathbf{w} - \mathbf{\Phi}^{\mathsf{T}}\mathbf{t} = \mathbf{0}$$

$$\Longrightarrow \qquad \boxed{\mathbf{w}_\lambda^\star = (\mathbf{\Phi}^{\mathsf{T}}\mathbf{\Phi} + \lambda\mathbf{I})^{-1}\mathbf{\Phi}^{\mathsf{T}}\mathbf{t}}$$

即使 $\mathbf{\Phi}^{\mathsf{T}}\mathbf{\Phi}$ 奇異(例如 $M + 1 > N$)，只要 $\lambda > 0$，$\mathbf{\Phi}^{\mathsf{T}}\mathbf{\Phi} + \lambda\mathbf{I}$ 恆為正定、可逆——正則化同時解決了「數值病態」與「過度擬合」兩個問題。這也是統計學中的**脊迴歸**(ridge regression)。

教學補充：權重衰減的貝氏詮釋(預告 §2.6 與 Ch. 9)

若假設 $t_n = y(x_n,\mathbf{w}) + \epsilon_n$、$\epsilon_n \sim \mathcal{N}(0,\sigma^2)$，並對權重放一個高斯先驗 $p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \alpha^{-1}\mathbf{I})$，則後驗機率的負對數為

$$-\ln p(\mathbf{w}\mid\mathbf{t}) = \frac{1}{2\sigma^2}\sum_n\{y(x_n,\mathbf{w}) - t_n\}^2 + \frac{\alpha}{2}\|\mathbf{w}\|^2 + \text{常數}.$$

最大化後驗(MAP)等價於最小化 (4)，其中 $\lambda = \alpha\sigma^2$。因此**正則化 = 先驗知識**：λ 越大，代表我們越相信「真實的權重應該很小」。這是「歸納偏差」(§1.3.2)的一個精確實例。

圖 6 顯示以正則化誤差函數 (4) 擬合 $M = 9$ 多項式的結果。當 $\ln\lambda = -18$ 時，過度擬合已被抑制，曲線與 $\sin(2\pi x)$ 相當接近；若 λ 太大($\ln\lambda = 0$)，則又得到不佳的擬合。表 2 列出對應的係數，可見正則化確實達到縮小係數量級的效果。

正則化項對泛化誤差的影響，可由訓練集與測試集的 RMS 誤差對 $\ln\lambda$ 作圖看出(圖 7)：λ 現

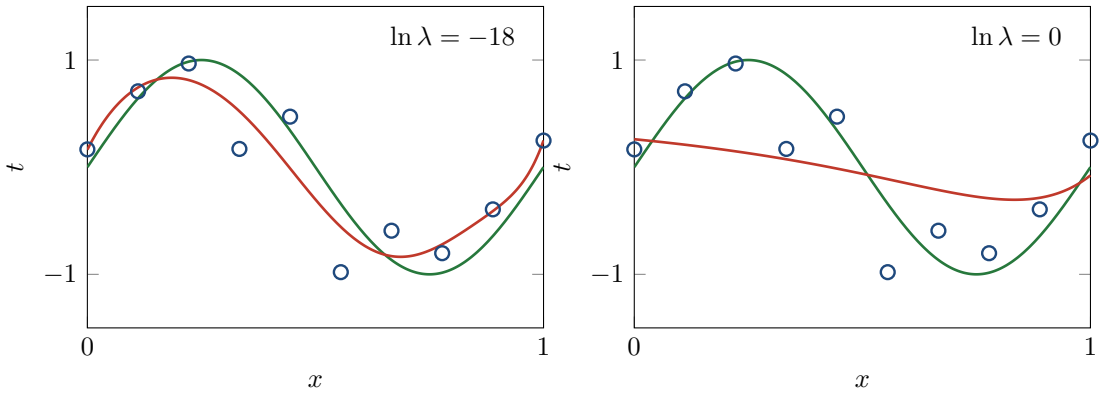


圖 6: 以正則化誤差函數 (4) 擬合 $M = 9$ 多項式：$\ln\lambda = -18$（左）與 $\ln\lambda = 0$（右）。無正則化（$\lambda = 0$，即 $\ln\lambda = -\infty$）的情形見圖 3 右下。

表 2: $M = 9$ 多項式在不同 λ 下的係數 $\mathbf{w}^\star$。$\ln\lambda = -\infty$ 對應無正則化。隨 λ 增大，典型係數的量級變小。

	$\ln\lambda = -\infty$	$\ln\lambda = -18$	$\ln\lambda = 0$
$w_0^\star$	0.17	0.16	0.26
$w_1^\star$	−374.59	8.50	−0.42
$w_2^\star$	8,781.65	−36.30	−0.35
$w_3^\star$	−79,006.74	75.66	−0.20
$w_4^\star$	369,642.57	−131.95	−0.07
$w_5^\star$	−1,002,582.44	57.07	0.03
$w_6^\star$	1,634,413.51	143.36	0.10
$w_7^\star$	−1,578,398.99	−52.52	0.15
$w_8^\star$	831,584.04	−172.88	0.19
$w_9^\star$	−184,058.92	109.15	0.22

在控制模型的**有效複雜度**（effective complexity），從而決定過度擬合的程度。

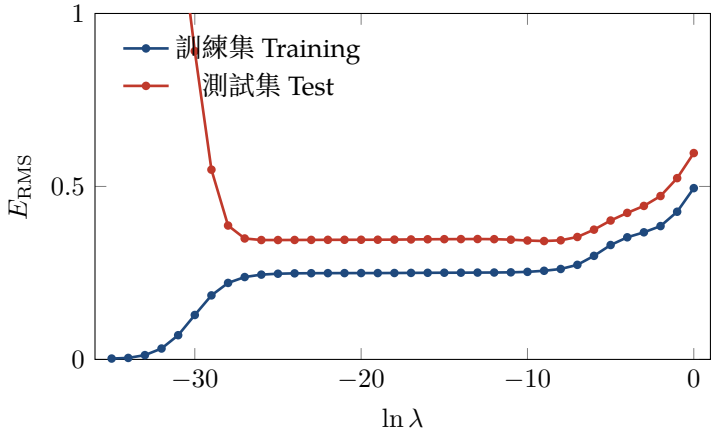


圖 7: $M = 9$ 多項式的 RMS 誤差 (3) 隨 $\ln\lambda$ 的變化。

1.2.6 模型選擇

λ 是**超參數**（hyperparameter）的一個例子：在最小化誤差函數以決定模型參數 $\mathbf{w}$ 的過程中，其值**固定不變**。我們**不能**把 λ 和 $\mathbf{w}$ 一起對誤差函數做聯合最小化——那會導致 $\lambda \to 0$，得到訓練誤差

極小甚至為零的過度擬合模型。同理，階數 M 也是超參數，直接對 M 最小化訓練誤差會導致 M 過大而過度擬合。因此我們需要另闢蹊徑決定超參數。

上述結果提示了一個簡單方法：把可用資料分成**訓練集**（用來決定 $\mathbf{w}$）與獨立的**驗證集**（validation set，又稱 hold-out set 或 development set），選擇在驗證集上誤差最低的模型。若以有限資料反覆迭代模型設計多次，可能對驗證資料也產生某種程度的過度擬合，此時需再保留第三組**測試集**，用來對最終選定的模型做**最後**的效能評估。

三份資料的分工

資料集	用途	決定的對象
訓練集 (training)	最小化誤差函數	參數 $\mathbf{w}$
驗證集 (validation)	比較不同超參數設定	超參數 M、λ、架構等
測試集 (test)	只用一次，報告最終效能	（不用來做任何選擇）

某些應用中訓練與測試資料的供應有限。要建立好模型，應盡量把資料用於訓練；但驗證集若太小，對預測效能的估計會相當雜亂。解決此兩難的一個方法是**交叉驗證**（cross-validation，圖 8）：把資料分成 S 組等大的群組，取其中 $S-1$ 組訓練、剩下 1 組評估，對 S 種留出方式各做一次，再將 S 次的效能分數平均。如此可用 $(S-1)/S$ 比例的資料訓練，同時**所有**資料都被用於評估。資料特別稀少時，可取 $S = N$，即**留一法**（leave-one-out）。

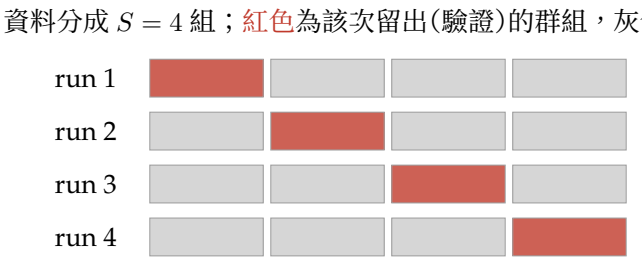


圖 8: S 折交叉驗證（此處 $S = 4$）：每次以 $S-1$ 組訓練、1 組評估，重複 S 次後平均效能分數。

交叉驗證的主要缺點是訓練次數增加 S 倍，對訓練本身就很昂貴的模型會成問題。另一個問題是：一個模型可能有**多個**複雜度超參數（例如多個正則化係數），要探索其組合，最壞情況下所需的訓練次數會隨超參數個數呈**指數**成長。現代機器學習的最先進模型極其龐大、訓練資料也極其龐大，因此探索超參數設定的空間有限，多半仰賴小模型上累積的經驗與各種啟發式法則。

從玩具問題到真實世界

這個「用多項式擬合正弦資料」的例子已說明了機器學習的許多核心觀念，後續章節仍會反覆使用。但真實應用在幾個重要方面不同：訓練資料可能大上許多個數量級；輸入變數可能多達數百萬個（例如影像分析），輸出也可能有多個；連結輸入與輸出的可學習函數由**神經網路**這類模型決定，其參數可能多達數千億個；誤差函數是參數的高度**非線性**函數，無法閉式最小化，必須以**迭代式最佳化**（依據誤差函數對參數的導數）求解，並需要專門的計算硬體與可觀的計算成本。

1.3 機器學習簡史

機器學習有漫長而豐富的歷史，期間曾探索多種不同取徑。這裡聚焦於**以神經網路為基礎**的方法之演進，因為它們是深度學習的基礎，也已證明是真實應用中最有效的機器學習方法。

1.3.1 從生物神經元到數學模型

神經網路模型最初受人類與其他哺乳動物大腦資訊處理的研究啟發。大腦的基本處理單元是稱為**神經元**（neuron）的電活性細胞。神經元「放電」（fire）時，會沿著**軸突**（axon）送出電脈衝，抵達稱為**突觸**（synapse）的接點，與其他神經元相連；突觸釋放的**神經傳導物質**可以刺激或抑制後續神經元的放電。人腦約有 900 億個神經元，每個平均與其他神經元有數千個突觸，整體約有 10^{14} 個突觸。一個神經元若從其他神經元的放電接收到足夠刺激，它也會被誘發放電；但有些突觸具有負的、抑制性的效果。一個神經元能使另一個神經元放電的程度取決於**突觸強度**，而**突觸強度的改變**正是大腦儲存資訊、從經驗學習的關鍵機制。

這些性質被非常簡單的數學模型——**人工神經網路**（artificial neural networks，McCulloch and Pitts, 1943）——所捕捉。多數此類模型以「其他神經元輸出的線性組合，再經一個非線性函數轉換」來描述單一神經元：

$$a = \sum_{i=1}^{M} w_i x_i, \tag{5}$$

$$y = f(a), \tag{6}$$

其中 $x_1, \dots, x_M$ 為 M 個輸入（對應其他神經元的活性），$w_1, \dots, w_M$ 為連續變數，稱為**權重**（weights），代表對應突觸的強度。a 稱為**前激活**（pre-activation），非線性函數 $f(\cdot)$ 稱為**激活函數**（activation function），輸出 y 稱為**激活**（activation）。式 (5)–(6) 的簡單形式自 1960 年代至今一直是神經網路模型的基礎，圖示如圖 9。

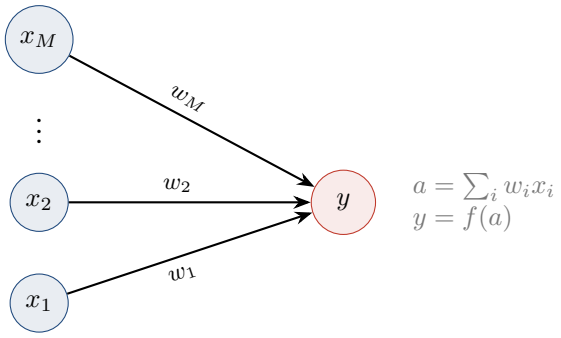


圖 9: 描述單一神經元之轉換 (5)–(6) 的簡單網路圖。多項式 (1) 可視為此模型的特例。

多項式其實就是一個「神經元」

把 (1) 與 (5)–(6) 對照：令輸入 x_i 為單一變數 x 的各次冪（$x_0 = 1, x_1 = x, x_2 = x^2, \dots$），激活函數取恆等 $f(a) = a$，多項式模型就是圖 9 的一個實例。「線性模型」與「神經網路」的分野，僅在於基底（特徵）是固定還是可學習，以及 f 是否非線性。

1.3.2 第一階段：單層網路

人工神經網路的歷史可依「處理層數」所衡量的複雜程度，大致分為**三個階段**。由 (5)–(6) 描述的簡單神經模型可視為只有**單層**處理（對應圖 9 的單層連結）。此類模型中最重要者是**感知器**（perceptron，Rosenblatt, 1962），其激活函數為階梯函數：

$$f(a) = \begin{cases} 0, & a \le 0, \\ 1, & a > 0. \end{cases} \tag{7}$$

這可視為神經放電的簡化模型：若且唯若加權輸入總和超過閾值 0 時神經元才放電。Rosenblatt 提出了專門的訓練演算法，具有一個有趣性質：**若存在**一組權重使感知器能完美分類其訓練資料，則此演算法**保證在有限步內**找到解（Bishop, 2006）。感知器還有專屬的類比硬體實作（Mark 1 感知器）：輸入來自一個簡單的攝影系統，將印刷字元投影到 20×20 的硫化鎘光電池陣列上，形成原始的 400 像素影像；每個權重以馬達驅動的可變電阻（電位計）實作，使學習演算法能自動調整權重值。典型的感知器配置雖有多層處理，但**只有一層可從資料學習**，因此被視為「單層」神經網路。

起初，感知器能以類腦方式從資料學習被視為非凡之事，但很快就發現其重大限制。Minsky 與 Papert（1969）分析了感知器的性質，對單層網路能力的限制給出形式證明；不幸的是，他們也**臆測**類似限制會延伸到具有多層可學習參數的網路。後一項臆測後來證明大錯特錯，但當時的效果是澆熄了對神經網路的熱情，導致 1970 年代至 1980 年代初對神經網路的興趣與經費都付之闕如。此外，由於缺乏訓練多層網路的有效演算法（感知器演算法只適用於單層模型），研究者也無法探索多層網路的性質。雖然感知器早已從實用的機器學習中消失，但名稱仍留存至今：現代神經網路有時也稱為**多層感知器**（multilayer perceptron, MLP）。

教學補充：感知器的限制：XOR 問題

單層感知器只能實現**線性可分**的決策邊界（在輸入空間中為一超平面 $\mathbf{w}^{\mathsf{T}}\mathbf{x} = 0$）。經典反例是 XOR：四個點 $(0,0) \mapsto 0$、$(1,1) \mapsto 0$、$(0,1) \mapsto 1$、$(1,0) \mapsto 1$ 無法以任何一條直線分開（習題 9）。加入一層隱藏單元後即可解決——這正是多層網路價值所在，也是 Minsky–Papert 的臆測失準之處。

1.3.3 第二階段：反向傳播

訓練具有多層可學習參數之神經網路的解法，來自**微分學**與**梯度式最佳化**的應用。一個重要改變是把階梯函數 (7) 換成**連續可微、梯度非零**的激活函數；另一個關鍵修改是引入**可微的誤差函數**，定義給定參數對訓練集目標變數的預測好壞——我們在 §1.2.3 以平方和誤差 (2) 擬合多項式時已見過一例。

有了這些改變，誤差函數對網路中每個參數的導數都可以計算，於是可以考慮多層參數的網路。圖 10 是一個具有兩層處理的簡單網路。中間層的節點稱為**隱藏單元**（hidden units），因為它們的值不出現在訓練集中（訓練集只提供輸入與輸出的值）。每個隱藏單元與輸出單元都計算 (5)–(6) 形式的函數。給定輸入值，所有隱藏單元與輸出單元的狀態可透過重複套用 (5)–(6) 求得，資訊沿箭頭方向**向前**流動，因此此類模型也稱為**前饋神經網路**（feed-forward neural networks）。

訓練此類網路時，參數先以亂數產生器初始化，再以梯度式最佳化技術**迭代更新**。這需要計算誤差函數的導數，可用稱為**誤差反向傳播**（error backpropagation，Ch. 8）的程序有效率地完成：資訊從輸出端**向後**流經網路到輸入端（Rumelhart, Hinton, and Williams, 1986）。利用梯度的最佳化演算法有很多，但機器學習中最普遍的也是最簡單的——**隨機梯度下降**（stochastic gradient

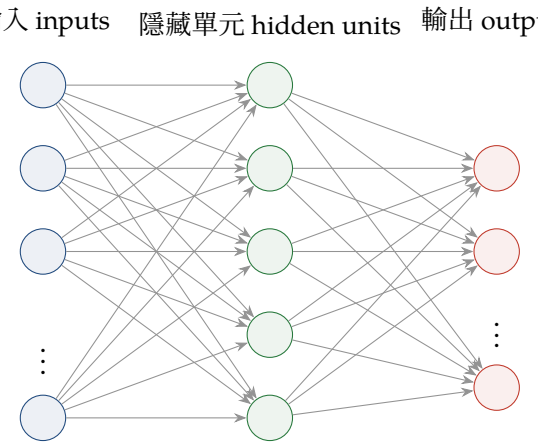


圖 10: 具有兩層參數的神經網路，箭頭表示資訊在網路中流動的方向。每個隱藏單元與輸出單元都計算 (5)–(6) 形式的函數，其中激活函數 $f(\cdot)$ 可微。

descent，Ch. 7）。

訓練迴圈的骨架

$$\text{初始化}\mathbf{w} \xrightarrow{\text{前向傳播}} \text{計算}E(\mathbf{w}) \xrightarrow{\text{反向傳播}} \nabla_{\mathbf{w}}E \xrightarrow{\text{更新}} \mathbf{w} \leftarrow \mathbf{w} - \eta\nabla_{\mathbf{w}}E \longrightarrow \text{重複}$$

η 為學習率（超參數）。與 §1.2 的多項式相比，差別只在 E 不再是二次函數，因此沒有閉式解，必須迭代。

能訓練多層權重的神經網路是一大突破，自 1980 年代中期起帶動此領域的復興。這也是一個超越「神經生物學靈感」、建立更嚴謹原則性基礎的時期（Bishop, 1995b）。特別是人們認識到**機率論**與**統計學**的觀念在神經網路與機器學習中扮演核心角色。一個關鍵洞見是：從資料學習必然涉及背景假設，有時稱為**先驗知識**（prior knowledge）或**歸納偏差**（inductive biases）。它們可以被**明確**納入（例如設計網路結構，使皮膚病灶的分類不依賴病灶在影像中的位置——平移不變性），也可能是模型數學形式或訓練方式所隱含的假設。

反向傳播與梯度式最佳化的發展，大幅提升了神經網路解決實際問題的能力。然而人們也觀察到：在多層的網路中，**只有最後兩層的權重會學到有用的值**。除少數例外——特別是用於影像分析的**卷積神經網路**（convolutional neural networks，LeCun et al., 1998；Ch. 10）——超過兩層的網路幾乎沒有成功應用。這限制了可有效處理的問題複雜度。為在許多應用中達到合理表現，必須使用**手工設計的前處理**，把輸入變數轉換到某個新空間，寄望在那裡機器學習問題較易解決。此前處理階段有時也稱為**特徵萃取**（feature extraction）。這種做法有時有效，但顯然**若特徵能從資料中學得而非手工打造**會好得多。

到了新千禧年之初，可用的神經網路方法再次觸及能力極限。研究者開始探索神經網路以外的諸多替代方案，如核方法（kernel methods）、支援向量機（SVM）、高斯過程等，神經網路再度失寵——雖然仍有一群熱忱的核心研究者持續追求真正有效地訓練多層網路的方法。

1.3.4 第三階段：深度網路

神經網路發展的第三個、也是目前的階段，始於 21 世紀的第二個十年。一系列進展使具有**多層權重**的神經網路得以有效訓練，移除了先前對這些技術能力的限制。多層權重的網路稱為**深度神經網路**（deep neural networks），聚焦於此類網路的機器學習子領域稱為**深度學習**（LeCun, Bengio,

and Hinton, 2015)。

規模。 深度學習起源的一個重要主題是神經網路**規模**(以參數數量衡量)的顯著增加。1980 年代常見的網路只有數百或數千個參數，之後穩定上升到百萬、十億，而當前最先進的模型可達約 10^{12}(一兆)個參數。參數眾多的網路需要相應龐大的資料集，才能讓訓練訊號為這些參數產生好的值；而巨型模型與巨型資料集的結合，又需要巨量的訓練計算。原為電玩等圖形快速渲染而開發的專用處理器——**圖形處理器**(GPU)——被證明非常適合訓練神經網路，因為網路中同一層各單元所計算的函數可以**平行**求值，正好對應 GPU 的大規模平行架構(Krizhevsky, Sutskever, and Hinton, 2012)。今天，最大模型的訓練在數千顆 GPU 以專用高速互連組成的陣列上進行。

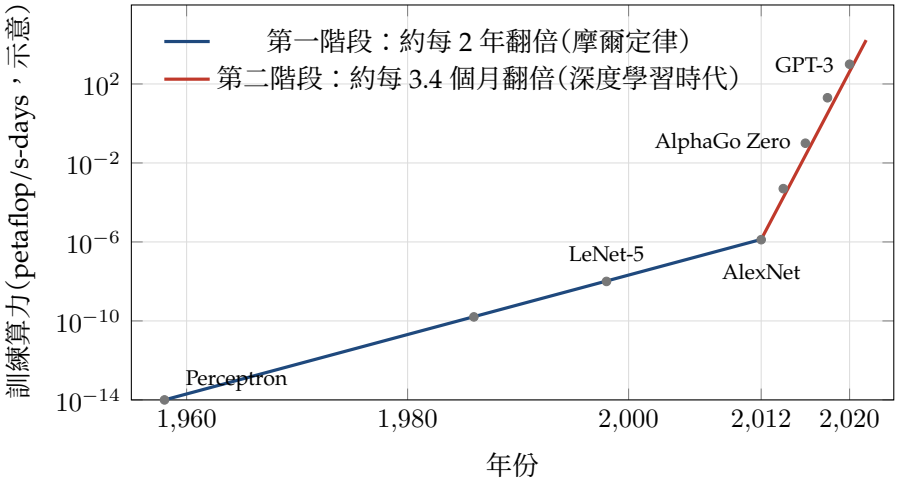


圖 11: 訓練最先進神經網路所需算力隨年代的成長(縱軸為對數尺度，示意重繪；里程碑位置為概略)。直線代表指數成長：2012 年前翻倍時間約 2 年，2012 年後約 3.4 個月——每年約增加 10 倍。原圖來自 OpenAI。

圖 11 說明訓練最先進神經網路所需的計算週期數如何隨年代成長，呈現**兩個明顯的階段**。縱軸為指數尺度，單位是 petaflop/s-days：一個 petaflop 為 10^{15} 次浮點運算，petaflop/s 是每秒一個 petaflop；一個 petaflop/s-day 代表以此速率持續 24 小時，約 10^{20} 次浮點運算，因此圖上最高處代表驚人的 10^{24} 次浮點運算。圖上的直線代表指數成長：從感知器時代到約 2012 年，翻倍時間約 2 年，與摩爾定律下運算能力的一般成長一致；2012 年起(深度學習時代)仍為指數成長，但翻倍時間縮短為 **3.4 個月**，相當於**每年算力增加 10 倍**(習題 10)！

人們經常發現，架構創新或更精巧的歸納偏差所帶來的效能改進，很快就被**單純擴大訓練資料量**(連同模型規模與訓練算力的相應擴大)所超越(Sutton, 2019，即著名的《苦澀的教訓》*The Bitter Lesson*)。大模型不僅在特定任務上表現更佳，同一個訓練好的網路還可能解決更廣泛的不同問題。大型語言模型是顯著的例子：單一網路不僅能力極廣，甚至能勝過為特定問題設計的專門網路(§12.3.5)。

表徵學習。 深度在讓神經網路達到高效能上扮演重要角色。理解深度網路中隱藏層角色的一種方式是**表徵學習**(representation learning，Bengio, Courville, and Vincent, 2012)：網路學習把輸入資料轉換成**語意上有意義**的新表徵，使最後一層(或幾層)要解的問題變得容易得多。這些內部表徵可以**重新利用**於相關問題，即遷移學習——如同前述皮膚病灶分類的例子。有趣的是，處理影像的神經網路所學得的內部表徵，與哺乳動物視覺皮質中觀察到的表徵驚人地相似(§10.3)。可針對一系列下游任務調適或微調的大型神經網路稱為**基礎模型**(foundation models)，能利用大型、異質的資料集創造出應用廣泛的模型(Bommasani et al., 2021)。

其他關鍵進展。 除了規模化之外，還有其他發展促成深度學習的成功。例如在簡單的神經網路中，訓練訊號在向後傳播經過深層網路的連續各層時會逐漸**變弱**（梯度消失）；解決此問題的一項技術是引入**殘差連結**（residual connections，He et al., 2015a；§9.5），使數百層的網路也能訓練。另一項關鍵發展是**自動微分**（automatic differentiation）：執行反向傳播以計算誤差函數梯度的程式碼，可由**指定前向傳播的程式碼自動產生**。這讓研究者能快速嘗試不同的網路架構、以多種方式組合各種架構元件——因為只需明確撰寫相對簡單的前向傳播函數。此外，機器學習研究多以**開源**方式進行，讓研究者能站在他人工作的基礎上，進一步加速了領域的進展。

三階段總覽

階段	年代	代表性技術	瓶頸／突破
單層網路	1940s–1960s	McCulloch–Pitts 神經元、感知器	只能學線性可分問題；Minsky–Papert（1969）後陷入低潮
反向傳播	1980s–2000s	可微激活、平方和誤差、反向傳播、SGD、CNN	深層難訓練，仰賴手工特徵；2000 年代讓位給核方法／SVM
深度網路	2010s–	GPU、大資料、殘差連結、自動微分、Transformer、基礎模型	規模化 $\rightarrow$ 表徵學習、遷移學習、LLM

教學補充：對「可解釋性」的一點反思

規模化帶來能力，也帶來**黑盒子**問題：一個 10^{12} 參數的模型很難讓人理解它「為何」做出某個預測。這正是符號迴歸（symbolic regression）與可解釋 AI 的動機——尋找像 §1.2 那樣「參數少、形式明確」卻仍能泛化的模型。當你在後續章節看到愈來愈大的網路時，不妨同時問：在我的應用（例如電離層 VTEC 建模）裡，可解釋的簡潔公式與高容量的黑盒子模型之間，該如何取捨？

課後習題

以下習題分為**觀念題**（○）、**推導題**（⋆）與**延伸題**（⋆⋆）。推導題請完整寫出過程；延伸題可搭配程式（NumPy 即可）作答。

習題 1 (○ 學習典範辨識)**.** 下列各問題屬於監督式、非監督式或自監督式學習？屬於分類還是迴歸？並說明其「標籤」從何而來。

(a) 以船舶 AIS 軌跡資料預測其 10 分鐘後的位置；

(b) 將海量衛星影像分群，找出彼此相似的海況；

(c) 從 GNSS 觀測量判斷某接收機是否遭受欺騙（spoofing）攻擊；

(d) 以過去 24 小時的 VTEC 序列預測下一小時的 VTEC。

習題 2 (⋆ 正規方程)**.** 設 $\boldsymbol{\Phi} \in \mathbb{R}^{N\times(M+1)}$ 為設計矩陣，$\boldsymbol{\Phi}_{nj} = x_n^j$。

(a) 證明 (2) 可寫成 $E(\mathbf{w}) = \frac{1}{2}\|\boldsymbol{\Phi}\mathbf{w} - \mathbf{t}\|^2$。

(b) 對 $\mathbf{w}$ 微分，導出正規方程 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w}^\star = \boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}$。

(c) 證明當 $x_1, \dots, x_N$ 互異且 $N \geq M+1$ 時，$\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}$ 為正定，因此 $\mathbf{w}^\star$ 唯一。(提示：$\boldsymbol{\Phi}$ 的前 $M+1$ 列構成 Vandermonde 矩陣。)

(d) 說明為何當 $N = M+1$ 時，最小平方解必滿足 $E(\mathbf{w}^\star) = 0$，並與圖 3 的 $M = 9$ 情形對照。

習題 3 ($\star$ 正則化閉式解與收縮效應).

(a) 由 (4) 導出 $\mathbf{w}_\lambda^\star = (\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi} + \lambda\mathbf{I})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}$。

(b) 令 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}$ 的特徵分解為 $\mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^{\mathsf{T}}$，特徵值 $\mu_j \geq 0$。證明在特徵基底下，正則化解的第 j 個分量是無正則化解對應分量乘以收縮因子 $\mu_j/(\mu_j + \lambda)$。由此解釋：為何正則化對「小特徵值方向」(資料資訊少的方向)的抑制最強？

(c) 證明 $\|\mathbf{w}_\lambda^\star\|$ 是 λ 的非增函數，並與表 2 對照。

習題 4 ($\star$ RMS 誤差與尺度).

(a) 說明 (3) 中「除以 N」與「開根號」分別解決了什麼問題。

(b) 若把目標變數改為 $t' = 100\,t$(例如單位由公尺改為公分)，$E(\mathbf{w})$、E_{RMS} 與最佳解 $\mathbf{w}^\star$ 各如何改變？正則化解 $\mathbf{w}_\lambda^\star$ 是否也只是等比例縮放？若否，λ 應如何調整？

習題 5 ($\star$ 權重衰減的 MAP 詮釋). 設 $t_n = y(x_n, \mathbf{w}) + \epsilon_n$，$\epsilon_n \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$，先驗 $p(\mathbf{w}) = \mathcal{N}(\mathbf{w} \mid \mathbf{0}, \alpha^{-1}\mathbf{I})$。

(a) 寫出對數概似 $\ln p(\mathbf{t} \mid \mathbf{w})$ 與對數後驗 $\ln p(\mathbf{w} \mid \mathbf{t})$(略去與 $\mathbf{w}$ 無關的常數)。

(b) 證明最大化後驗等價於最小化 (4)，並求出 λ 與 α, σ^2 的關係。

(c) 若改用 Laplace 先驗 $p(\mathbf{w}) \propto \exp(-\beta\|\mathbf{w}\|_1)$，對應的正則化項是什麼？此即 LASSO；試從幾何上說明為何它傾向產生**稀疏**的 $\mathbf{w}$。

習題 6 ($\circ$ 超參數不能用訓練誤差決定). 說明為何「對 $\mathbf{w}$ 與 λ 聯合最小化 $\widetilde{E}$」必然得到 $\lambda = 0$，以及「對 M 最小化訓練誤差」必然選到最大的 M。接著說明驗證集與測試集的角色為何不能合併。

習題 7 ($\star$ 交叉驗證的計算成本).

(a) S 折交叉驗證需要幾次訓練？留一法呢？

(b) 對線性模型，證明留一法的殘差可由**一次**完整最小平方解得到：令帽子矩陣 $\mathbf{H} = \boldsymbol{\Phi}(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}$，則

$$t_n - y_{(-n)}(x_n) = \frac{t_n - y(x_n, \mathbf{w}^\star)}{1 - H_{nn}},$$

其中 $y_{(-n)}$ 為去掉第 n 點後的擬合。(提示：Sherman–Morrison 公式。)

(c) 若一個模型有 K 個超參數、每個嘗試 G 個值，格點搜尋加 S 折交叉驗證共需幾次訓練？

習題 8 ($\star$ 多項式是神經元的特例).

(a) 明確寫出使 (5)–(6) 退化為 (1) 的 x_i、w_i 與 f。

(b) 若改取 $f(a) = \tanh(a)$，模型 $y = \tanh(\sum_j w_j x^j)$ 仍是 $\mathbf{w}$ 的線性函數嗎？平方和誤差仍是 $\mathbf{w}$ 的二次函數嗎？這對「閉式解」有何影響？

習題 9 ($\star$ 感知器與 XOR).

(a) 證明不存在 w_1, w_2, w_0 使感知器 $f(w_1x_1 + w_2x_2 + w_0)$（f 為 (7)）實現 XOR 函數。

(b) 設計一個含兩個隱藏單元（同樣用階梯激活）的兩層網路實現 XOR，寫出所有權重。

(c) 說明為何 Rosenblatt 的收斂保證對 (b) 的網路不適用。

習題 10 ($\star$ 算力成長的算術)**.**

(a) 若翻倍時間為 3.4 個月，計算一年內的成長倍數，驗證「每年約 10 倍」。

(b) 若翻倍時間為 2 年，從 1958 到 2012 共成長多少倍？

(c) 一個 petaflop/s-day 約為多少次浮點運算？在圖 11 的尺度下，10^{24} 次浮點運算對應多少 petaflop/s-days？

(d) 假設某 GPU 持續輸出 10^{15} flop/s，訓練需 10^{24} 次運算，用 1,000 顆 GPU 需要多少天？

習題 11 ($\star\star$ 動手重現本章圖形)**.** 以 NumPy 重現圖 1–7：

(a) 產生 $N = 10$ 筆資料（x_n 均勻、$t_n = \sin 2\pi x_n + \epsilon_n$，$\epsilon_n \sim \mathcal{N}(0, 0.3^2)$），以正規方程擬合 $M = 0, 1, 3, 9$，畫圖並列出係數。

(b) 另產生 100 筆測試資料，畫出 E_{RMS} 對 M 的曲線。

(c) 固定 $M = 9$，掃描 $\ln\lambda \in [-35, 0]$，畫出 E_{RMS} 對 $\ln\lambda$ 的曲線；找出最佳 λ。

(d) 把 N 改為 15 與 100 重做 (a)，觀察過度擬合如何隨 N 改變。

(e) **延伸**：把多項式基底換成 Fourier 基底 $\{1, \sin 2\pi kx, \cos 2\pi kx\}_{k=1}^{K}$，重做 (a)–(c)。為何此時 $K = 1$ 就幾乎完美？這說明「歸納偏差」什麼道理？

習題 12 ($\star\star$ 多參數也能泛化？)**.** 在 (a) $N = 10$、$M = 9$、無正則化，與 (b) $N = 10$、$M = 30$、以最小範數解 $\mathbf{w}^\star = \boldsymbol{\Phi}^{+}\mathbf{t}$（$\boldsymbol{\Phi}^{+}$ 為偽反矩陣）兩種設定下，比較測試誤差。你觀察到什麼？查閱「double descent」一詞，用一段話說明它與本章「參數不應多於資料」之古典法則的關係（§9.3.2）。

附錄 A　中英名詞對照表

英文	中文	簡要說明
machine learning	機器學習	從資料中學得解法，而非手工設計演算法
deep learning	深度學習	以多層權重之神經網路為基礎的機器學習
neural network	(類)神經網路	受大腦啟發的計算模型
artificial general intelligence (AGI)	通用人工智慧	具備接近人腦廣度與彈性的機器智慧之願景
large language model (LLM)	大型語言模型	處理語言等序列資料的巨型深度學習模型
training set / test set / validation set	訓練集／測試集／驗證集	分別用於決定參數、最終評估、選擇超參數
weights	權重	網路中可調整的參數
learning / training	學習／訓練	由資料決定參數值的過程
supervised learning	監督式學習	每筆訓練樣本附有正確標籤
unsupervised learning	非監督式學習	訓練資料無標籤
self-supervised learning	自監督式學習	標籤自動由輸入資料導出
classification / regression	分類／迴歸	輸出為離散類別／連續變數
transfer learning	遷移學習	先在大資料上預訓練，再於目標任務微調
fine-tuning	微調	以目標任務資料進一步調整預訓練模型
generative model / generative AI	生成模型／生成式 AI	能產生與訓練資料同分布之新樣本
autoregressive model	自迴歸模型	以已生成的序列預測下一個元素
prompt	提示	給生成模型的輸入文字
generalization	泛化	對未見過的輸入做出準確預測的能力
linear model	線性模型	對未知參數為線性的函數
basis function	基底函數	線性模型中固定的特徵函數 $\phi_j(x)$
design matrix	設計矩陣	各列為各樣本之基底函數值的矩陣 $\boldsymbol{\Phi}$
error function (loss)	誤差函數(損失函數)	衡量模型與訓練資料不吻合程度
sum-of-squares error	平方和誤差	$\frac{1}{2}\sum_n \{y(x_n,\mathbf{w})-t_n\}^2$
root-mean-square (RMS) error	均方根誤差	與目標變數同尺度的誤差量
normal equations	正規方程	$\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w}=\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}$
closed-form solution	閉式解	可直接以公式求得、無需迭代的解
model selection / comparison	模型選擇／比較	在不同複雜度的模型間做選擇
over-fitting	過度擬合	訓練誤差小但泛化差，擬合到雜訊
regularization	正則化	在誤差函數中加入懲罰項以控制複雜度
weight decay / shrinkage	權重衰減／收縮法	二次正則化在神經網路／統計學中的名稱
ridge regression	脊迴歸	二次正則化的最小平方法
hyperparameter	超參數	訓練時固定、需另行選擇的參數(M、λ)
hold-out (development) set	保留集(開發集)	驗證集的別名
cross-validation	交叉驗證	輪流留出一組資料評估、其餘訓練
leave-one-out	留一法	$S=N$ 的交叉驗證

(續下頁)

英文	中文	簡要說明
neuron / synapse / axon	神經元／突觸／軸突	大腦的基本處理單元及其連結
pre-activation / activation	前激活／激活	$a = \sum_i w_i x_i$ ／ $y = f(a)$
activation function	激活函數	神經元中的非線性函數 f
perceptron	感知器	階梯激活的單層網路（Rosenblatt）
multilayer perceptron (MLP)	多層感知器	現代前饋神經網路的別名
hidden units	隱藏單元	值不出現在訓練集中的中間節點
feed-forward network	前饋網路	資訊單向由輸入流向輸出
error backpropagation	誤差反向傳播	有效率計算誤差梯度的演算法
stochastic gradient descent (SGD)	隨機梯度下降	最常用的梯度式最佳化法
prior knowledge / inductive bias	先驗知識／歸納偏差	學習所依賴的背景假設
feature extraction	特徵萃取	手工設計的前處理
convolutional neural network (CNN)	卷積神經網路	具平移不變歸納偏差的影像網路
kernel methods / SVM / Gaussian process	核方法／支援向量機／高斯過程	2000 年代的神經網路替代方案
GPU	圖形處理器	大規模平行處理器，適合訓練網路
petaflop/s-day	—	以 10^{15} flop/s 持續一天，約 10^{20} 次運算
representation learning	表徵學習	隱藏層學得語意上有意義的內部表徵
foundation model	基礎模型	可微調到多種下游任務的大型網路
residual connection	殘差連結	使極深網路可訓練的跳接結構
automatic differentiation	自動微分	由前向程式碼自動產生梯度程式碼

附錄 B　延伸閱讀與參考文獻

主要教材

- Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. 本講義之依據；全書電子版可於 https://www.bishopbook.com 免費閱讀。
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. 多項式曲線擬合範例的原始出處；第 1、3 章與本章高度對應，並含貝氏曲線擬合的完整處理。
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer. 收縮法、脊迴歸與交叉驗證的統計學觀點。

本章引用之原始文獻

- Esteva, A. et al. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature* 542, 115–118.
- Brinker, T. J. et al. (2019). Deep learning outperformed 136 of 157 dermatologists in a head-to-head dermoscopic melanoma image classification task. *European Journal of Cancer* 113, 47–54.
- Jumper, J. et al. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature* 596, 583–589.

- Bubeck, S. et al. (2023). Sparks of artificial general intelligence: early experiments with GPT-4. arXiv:2303.12712.
- OpenAI (2023). GPT-4 technical report. arXiv:2303.08774.
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics* 5, 115–133.
- Rosenblatt, F. (1962). *Principles of Neurodynamics*. Spartan.
- Minsky, M. and Papert, S. (1969). *Perceptrons*. MIT Press.
- Rumelhart, D. E., Hinton, G. E., and Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature* 323, 533–536.
- Bishop, C. M. (1995b). *Neural Networks for Pattern Recognition*. Oxford University Press.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE* 86, 2278–2324.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *NeurIPS* 25.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature* 521, 436–444.
- Bengio, Y., Courville, A., and Vincent, P. (2012). Representation learning: a review and new perspectives. arXiv:1206.5538.
- He, K., Zhang, X., Ren, S., and Sun, J. (2015a). Deep residual learning for image recognition. arXiv:1512.03385.
- Bommasani, R. et al. (2021). On the opportunities and risks of foundation models. arXiv:2108.07258.
- Sutton, R. (2019). The bitter lesson. http://www.incompleteideas.net/IncIdeas/BitterLesson.html

建議延伸閱讀

- Belkin, M. et al. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS* 116, 15849–15854.（double descent；對應 §9.3.2 與習題 12）
- Kaplan, J. et al. (2020). Scaling laws for neural language models. arXiv:2001.08361.（規模化定律；對應圖 11 與 Sutton 的「苦澀的教訓」）
- Baydin, A. G. et al. (2018). Automatic differentiation in machine learning: a survey. *JMLR* 18, 1–43.
- Vaswani, A. et al. (2017). Attention is all you need. *NeurIPS* 30.（Transformer；LLM 的基礎架構，Ch. 12）

——第一章完——

下一章：機率論（*Probabilities*）——為本章的「不確定性」與「誤差函數」建立嚴格基礎。