深度學習講義

第四章　單層網路：迴歸

Chapter 4: Single-Layer Networks: Regression

授課教師：王和盛　國立臺灣海洋大學通訊與導航工程學系

講義依據 C. M. Bishop & H. Bishop, *Deep Learning: Foundations and Concepts* (Springer, 2024) 第四章整理

版本：2026 年 8 月 26 日

本章學習目標

1. 把第一章的多項式擬合推廣為**線性基底函數模型**，理解它就是「只有單層可學習參數」的神經網路，並認識多項式、高斯、S 形與 Fourier ／小波等基底函數。
2. 從**高斯雜訊的概似函數**出發，推導最大概似解（正規方程、Moore–Penrose 偽反矩陣）、偏置參數與雜訊變異數的解，並掌握最小平方的**幾何投影**詮釋。
3. 掌握**循序學習**（隨機梯度下降、LMS 演算法）、**正則化最小平方**與**多重輸出**的處理方式。
4. 區分**推論階段**與**決策階段**：以變分法證明平方損失下的最佳預測是條件期望值，並理解 Minkowski 損失與條件中位數／眾數的關係。
5. 推導**偏差–變異分解**（期望損失 $=$ 偏差^2 $+$ 變異 $+$ 雜訊），並透過數值實驗理解正則化係數 λ 如何在兩者之間取捨。

目次

引言：用線性迴歸理解神經網路的基本觀念 2

4.1 線性迴歸 2
- 4.1.1 基底函數 . . . 2
- 4.1.2 概似函數 . . . 4
- 4.1.3 最大概似 . . . 5
- 4.1.4 最小平方的幾何 . . . 6
- 4.1.5 循序學習 . . . 7
- 4.1.6 正則化最小平方 . . . 8
- 4.1.7 多重輸出 . . . 8

4.2 決策論 9

4.3 偏差–變異權衡 12
- 4.3.1 分解的推導 . . . 12
- 4.3.2 數值實驗 . . . 14

課後習題 16

附錄 A　中英名詞對照表 19

附錄 B 延伸閱讀與參考文獻 **20**

引言：用線性迴歸理解神經網路的基本觀念

本章以**線性迴歸**（linear regression）為框架討論神經網路背後的一些基本觀念。我們在第一章的多項式曲線擬合中已經短暫接觸過線性迴歸；本章將看到，線性迴歸模型其實對應到一種**只有單層可學習參數**的簡單神經網路。雖然單層網路的實際應用價值非常有限，但它們具有簡單的解析性質，是引入許多核心觀念的絕佳框架，也為後續章節討論深度神經網路奠定基礎。

本章在全書中的定位

第一章用「多項式擬合正弦資料」講故事；本章把同一個例子**嚴格化**：基底函數（§4.1.1）→ 高斯雜訊的概似函數（§4.1.2）→ 最大概似即最小平方（§4.1.3）→ 幾何投影（§4.1.4）→ 循序學習與正則化（§4.1.5–4.1.6）。接著回答兩個更深的問題：「有了 $p(t \mid \mathbf{x})$ 之後，該**輸出哪個數**？」（§4.2 決策論）以及「為什麼模型太複雜會過度擬合？」（§4.3 偏差–變異權衡）。第五章將對**分類**問題做平行的討論；第六章起則把固定的基底函數換成可學習的深度網路。

4.1 線性迴歸

迴歸的目標是：給定 D 維輸入向量 $\mathbf{x}$，預測一個或多個**連續**目標變數 t 的值。典型情況下，我們有一組訓練資料，包含 N 筆觀測 $\{\mathbf{x}_n\}$（$n = 1, \dots, N$）與對應的目標值 $\{t_n\}$，目標是對新的 $\mathbf{x}$ 預測 t。為此，我們建構一個函數 $y(\mathbf{x}, \mathbf{w})$，其在新輸入 $\mathbf{x}$ 上的值即為對 t 的預測，其中 $\mathbf{w}$ 是可從訓練資料學習的參數向量。

最簡單的迴歸模型是輸入變數的線性組合：

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \cdots + w_D x_D, \tag{4.1}$$

其中 $\mathbf{x} = (x_1, \dots, x_D)^{\mathsf{T}}$。「線性迴歸」一詞有時特指這種形式的模型。此模型的關鍵性質是：它是參數 $w_0, \dots, w_D$ 的**線性**函數；然而，它同時也是輸入變數 x_i 的線性函數，這對模型造成了顯著的限制。

4.1.1 基底函數

我們可以擴展 (4.1) 所定義的模型類別，改考慮**輸入變數之固定非線性函數**的線性組合：

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^{M-1} w_j \, \phi_j(\mathbf{x}), \tag{4.2}$$

其中 $\phi_j(\mathbf{x})$ 稱為**基底函數**（basis functions）。把指標 j 的最大值記為 $M - 1$，此模型的參數總數即為 M。

參數 w_0 容許資料中任何固定的偏移量，有時稱為**偏置參數**（bias parameter；勿與統計意義的偏差 bias 混淆，見 §4.3）。通常方便的做法是額外定義一個值恆為 1 的虛擬基底函數 $\phi_0(\mathbf{x}) = 1$，使 (4.2) 成為

$$y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j \, \phi_j(\mathbf{x}) = \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(\mathbf{x}), \tag{4.3}$$

其中 $\mathbf{w} = (w_0, \dots, w_{M-1})^{\mathsf{T}}$、$\boldsymbol{\phi} = (\phi_0, \dots, \phi_{M-1})^{\mathsf{T}}$。模型 (4.3) 可用圖 4.1 的神經網路圖表示。

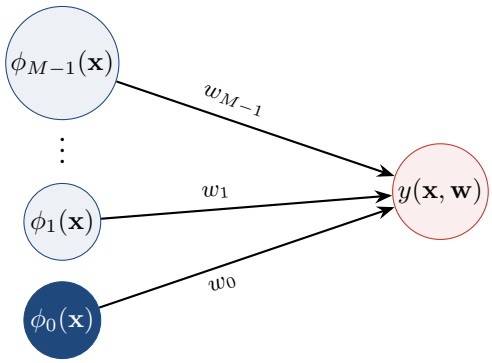


圖 4.1: 線性迴歸模型 (4.3) 可表示為只有單層參數的簡單神經網路圖。每個基底函數 $\phi_j(\mathbf{x})$ 以一個輸入節點表示，實心節點代表「偏置」基底函數 ϕ_0，函數 $y(\mathbf{x}, \mathbf{w})$ 以輸出節點表示；每個參數 w_j 以連接對應基底函數與輸出的一條線表示。

使用非線性基底函數，可讓 $y(\mathbf{x}, \mathbf{w})$ 成為輸入向量 $\mathbf{x}$ 的非線性函數。然而 (4.2) 形式的函數仍稱為**線性模型**，因為它們對 $\mathbf{w}$ 是線性的。正是這種「對參數線性」的性質，大幅簡化了此類模型的分析；但它也導致一些顯著的限制(§6.1)。

深度學習之前 vs. 之後：誰來設計特徵？

在深度學習出現之前，機器學習的常見做法是對輸入 $\mathbf{x}$ 做某種固定的前處理(**特徵萃取**)，以一組基底函數 $\{\phi_j(\mathbf{x})\}$ 表達；目標是選出足夠強大的基底函數，使剩下的學習任務能用簡單的網路模型解決。不幸的是，除了最簡單的應用之外，要**手工**打造合適的基底函數極為困難。深度學習則從資料集本身**學習**所需的非線性轉換，從而迴避了這個問題。

第一章的多項式曲線擬合已是迴歸問題的一例：若考慮單一輸入變數 x，並取 $\phi_j(x) = x^j$，多項式 (1.1) 即可寫成 (4.3) 的形式。基底函數還有許多其他選擇，例如**高斯基底函數**

$$\phi_j(x) = \exp\left\{-\frac{(x-\mu_j)^2}{2s^2}\right\}, \tag{4.4}$$

其中 μ_j 決定基底函數在輸入空間中的位置，s 決定其空間尺度。雖稱為「高斯」，它們並不需要有機率詮釋——特別是正規化係數並不重要，因為這些基底函數會再乘上可學習參數 w_j。另一個可能是 **S 形基底函數**(sigmoidal basis function)

$$\phi_j(x) = \sigma\left(\frac{x-\mu_j}{s}\right), \qquad \sigma(a) = \frac{1}{1+\exp(-a)}, \tag{4.5}$$

其中 $\sigma(a)$ 是**邏輯 S 形函數**(logistic sigmoid)。等價地也可用 $\tanh$ 函數，因為 $\tanh(a) = 2\sigma(2a) - 1$，故邏輯 S 形函數的一般線性組合與 $\tanh$ 函數的一般線性組合能表示同一類輸入–輸出函數(習題 2)。這些基底函數如圖 4.2 所示。

還有一種選擇是 **Fourier 基底**，導出以正弦函數展開的模型：每個基底函數代表一個特定**頻率**，且具有無限的空間範圍。相對地，局限於輸入空間有限區域的基底函數，必然包含一整段不同空間頻率的頻譜。在訊號處理應用中，人們常關心**在空間與頻率上都局部化**的基底函數，這導致稱為**小波**(wavelets)的一類函數(Ogden, 1997；Mallat, 1999；Vidakovic, 1999)。小波也被定義為彼此正交以簡化應用；當輸入值落在規則格點上(如時間序列的連續時間點、影像的像素)時最為適用。

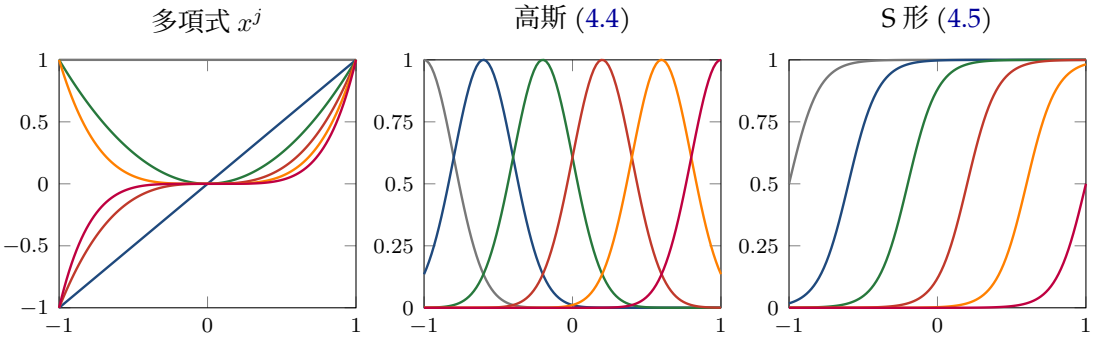


圖 4.2: 基底函數範例：左為多項式，中為 (4.4) 形式的高斯函數（$s = 0.2$），右為 (4.5) 形式的 S 形函數（$s = 0.1$）。

教學補充：基底函數的取捨——來自訊號處理的直覺

- **多項式**：全域、非局部，一處資料變動會影響整條曲線；高階時數值病態（第一章表 1.1 的巨大係數）。
- **高斯（RBF）**：局部，只影響 μ_j 附近；M 個中心要鋪滿輸入空間，維度 D 一高就有**維度災難**（中心數 $\sim$ 指數成長）。
- **Fourier**：頻率上完全局部、空間上完全非局部——正是 GNSS 或電離層 VTEC 建模常用的球諧函數／三角級數的一維版本。
- **小波**：時頻兩者折衷，與測不準原理相呼應；適合非平穩訊號。

本章大多數討論**與基底函數的選擇無關**，因此除數值示例外不指定其形式；為簡化符號，以下聚焦於單一目標變數 t，並在 §4.1.7 概述多目標變數所需的修改。

4.1.2 概似函數

第一章以最小化平方和誤差函數解決多項式擬合，並提到此誤差函數可從**高斯雜訊假設下的最大概似**導出。現在更仔細地討論最小平方法與最大概似的關係。

如前，假設目標變數 t 由確定性函數 $y(\mathbf{x}, \mathbf{w})$ 加上高斯雜訊給出：

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon, \tag{4.6}$$

其中 ϵ 為零均值、變異數 σ^2 的高斯隨機變數。因此

$$p(t \mid \mathbf{x}, \mathbf{w}, \sigma^2) = \mathcal{N}\big(t \mid y(\mathbf{x}, \mathbf{w}),\, \sigma^2\big). \tag{4.7}$$

考慮輸入資料集 $\mathbf{X} = \{\mathbf{x}_1, \ldots, \mathbf{x}_N\}$ 與對應目標值 $t_1, \ldots, t_N$。把目標變數 $\{t_n\}$ 排成行向量 $\mathbf{t}$（字體刻意與多變量目標的單一觀測 $\mathbf{t}$ 區別）。假設資料點是從 (4.7) 獨立抽取，則**概似函數**（likelihood function）——作為可調參數 $\mathbf{w}$ 與 σ^2 的函數——為

$$p(\mathbf{t} \mid \mathbf{X}, \mathbf{w}, \sigma^2) = \prod_{n=1}^{N} \mathcal{N}\big(t_n \mid \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(\mathbf{x}_n),\, \sigma^2\big), \tag{4.8}$$

這裡用了 (4.3)。取對數並利用單變量高斯的標準形式 (2.49)，得

$$\begin{aligned}\ln p(\mathbf{t} \mid \mathbf{X}, \mathbf{w}, \sigma^2) &= \sum_{n=1}^{N} \ln \mathcal{N}\big(t_n \mid \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(\mathbf{x}_n), \sigma^2\big) \\ &= -\frac{N}{2} \ln \sigma^2 - \frac{N}{2} \ln(2\pi) - \frac{1}{\sigma^2} E_D(\mathbf{w}),\end{aligned} \tag{4.9}$$

其中平方和誤差函數定義為

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^{N} \big\{ t_n - \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(\mathbf{x}_n) \big\}^2. \tag{4.10}$$

決定 $\mathbf{w}$ 時，(4.9) 的前兩項與 $\mathbf{w}$ 無關，可視為常數。因此，如前所見，**在高斯雜訊分布下最大化概似函數，等價於最小化平方和誤差函數** (4.10)。

為什麼是「平方」？

平方和誤差不是隨意的選擇，它是「雜訊為高斯」這個假設的**直接後果**：$-\ln \mathcal{N}(t \mid y, \sigma^2) = \frac{(t-y)^2}{2\sigma^2} +$ 常數。若雜訊改為 Laplace 分布，最大概似就變成最小化**絕對值**誤差（習題 9）；若雜訊變異數隨資料點不同，就變成**加權**最小平方（習題 4）。

4.1.3 最大概似

寫下概似函數後，即可用最大概似決定 $\mathbf{w}$ 與 σ^2。先看對 $\mathbf{w}$ 的最大化。對數概似 (4.9) 對 $\mathbf{w}$ 的梯度為

$$\nabla_{\mathbf{w}} \ln p(\mathbf{t} \mid \mathbf{X}, \mathbf{w}, \sigma^2) = \frac{1}{\sigma^2} \sum_{n=1}^{N} \big\{ t_n - \mathbf{w}^{\mathsf{T}} \boldsymbol{\phi}(\mathbf{x}_n) \big\} \boldsymbol{\phi}(\mathbf{x}_n)^{\mathsf{T}}. \tag{4.11}$$

令梯度為零：

$$\mathbf{0} = \sum_{n=1}^{N} t_n \boldsymbol{\phi}(\mathbf{x}_n)^{\mathsf{T}} - \mathbf{w}^{\mathsf{T}} \Big(\sum_{n=1}^{N} \boldsymbol{\phi}(\mathbf{x}_n) \boldsymbol{\phi}(\mathbf{x}_n)^{\mathsf{T}} \Big). \tag{4.12}$$

解出 $\mathbf{w}$ 得

$$\boxed{\mathbf{w}_{\mathrm{ML}} = \big(\boldsymbol{\Phi}^{\mathsf{T}} \boldsymbol{\Phi}\big)^{-1} \boldsymbol{\Phi}^{\mathsf{T}} \mathbf{t}} \tag{4.13}$$

即最小平方問題的**正規方程**（normal equations）。這裡 $\boldsymbol{\Phi}$ 是 $N \times M$ 矩陣，稱為**設計矩陣**（design matrix），元素 $\Phi_{nj} = \phi_j(\mathbf{x}_n)$：

$$\boldsymbol{\Phi} = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{pmatrix}. \tag{4.14}$$

量

$$\boldsymbol{\Phi}^{\dagger} \equiv \big(\boldsymbol{\Phi}^{\mathsf{T}} \boldsymbol{\Phi}\big)^{-1} \boldsymbol{\Phi}^{\mathsf{T}} \tag{4.15}$$

稱為 $\boldsymbol{\Phi}$ 的 **Moore–Penrose 偽反矩陣**（pseudo-inverse；Rao and Mitra, 1971；Golub and Van Loan, 1996），可視為矩陣反矩陣概念對非方陣的推廣。事實上，若 $\boldsymbol{\Phi}$ 為方陣且可逆，利用 $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$ 可知 $\boldsymbol{\Phi}^{\dagger} \equiv \boldsymbol{\Phi}^{-1}$。

推導 (以矩陣形式重推 (4.13))**.** 把 (4.10) 寫成 $E_D(\mathbf{w}) = \tfrac{1}{2}(\mathbf{t}-\boldsymbol{\Phi}\mathbf{w})^{\mathsf{T}}(\mathbf{t}-\boldsymbol{\Phi}\mathbf{w})$，展開得 $\tfrac{1}{2}\mathbf{t}^{\mathsf{T}}\mathbf{t} - \mathbf{w}^{\mathsf{T}}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t} + \tfrac{1}{2}\mathbf{w}^{\mathsf{T}}\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w}$。利用 $\nabla_{\mathbf{w}}(\mathbf{w}^{\mathsf{T}}\mathbf{b}) = \mathbf{b}$ 與 $\nabla_{\mathbf{w}}(\tfrac{1}{2}\mathbf{w}^{\mathsf{T}}\mathbf{A}\mathbf{w}) = \mathbf{A}\mathbf{w}$（$\mathbf{A}$ 對稱），得 $\nabla_{\mathbf{w}} E_D = -\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t} + \boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w}$，令其為零即 (4.13)。這與 (4.12) 完全相同，只是把 $\sum_n \boldsymbol{\phi}(\mathbf{x}_n)\boldsymbol{\phi}(\mathbf{x}_n)^{\mathsf{T}}$ 認出為 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}$、把 $\sum_n t_n \boldsymbol{\phi}(\mathbf{x}_n)$ 認出為 $\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}$。

偏置參數的角色。 把偏置參數明確寫出，誤差函數 (4.10) 成為

$$E_D(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}\Big\{t_n - w_0 - \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}_n)\Big\}^2. \tag{4.16}$$

令對 w_0 的導數為零並解出 w_0：

$$w_0 = \bar{t} - \sum_{j=1}^{M-1} w_j\,\bar{\phi}_j, \qquad \bar{t} = \frac{1}{N}\sum_{n=1}^{N} t_n, \quad \bar{\phi}_j = \frac{1}{N}\sum_{n=1}^{N}\phi_j(\mathbf{x}_n). \tag{4.17}$$

因此，偏置 w_0 **補償了目標值的(訓練集)平均，與基底函數值平均之加權和之間的差距**。

雜訊變異數。 也可對變異數 σ^2 最大化對數概似 (4.9)，得

$$\sigma^2_{\mathrm{ML}} = \frac{1}{N}\sum_{n=1}^{N}\big\{t_n - \mathbf{w}_{\mathrm{ML}}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n)\big\}^2, \tag{4.18}$$

即**雜訊變異數的最大概似值，等於目標值繞迴歸函數的殘差變異數**。

推導 (σ^2_{ML} 的推導)**.** 令 $\beta = 1/\sigma^2$，則 (4.9) $= \frac{N}{2}\ln\beta - \frac{N}{2}\ln 2\pi - \beta E_D(\mathbf{w})$。對 β 微分得 $\frac{N}{2\beta} - E_D = 0$，故 $1/\beta_{\mathrm{ML}} = \sigma^2_{\mathrm{ML}} = \frac{2}{N}E_D(\mathbf{w}_{\mathrm{ML}})$，即 (4.18)。注意此為**有偏**估計(分母是 N 而非 $N-M$)，與第三章單變量高斯的情形相同；在深度學習中 $N \gg M$，此差異可忽略。

4.1.4 最小平方的幾何

考慮最小平方解的幾何詮釋很有啟發性。取一個 N 維空間，其座標軸為 t_n，則 $\mathbf{t} = (t_1,\ldots,t_N)^{\mathsf{T}}$ 是此空間中的一個向量。每個基底函數 $\phi_j(\mathbf{x}_n)$ 在 N 個資料點上的值也可表示為同一空間中的向量，記為 $\boldsymbol{\varphi}_j$(圖 4.3)。注意 $\boldsymbol{\varphi}_j$ 對應到 $\boldsymbol{\Phi}$ 的第 j **行**(column)，而 $\boldsymbol{\phi}(\mathbf{x}_n)$ 對應到 $\boldsymbol{\Phi}$ 第 n **列**(row)的轉置。若基底函數個數 M 小於資料點數 N，則 M 個向量 $\boldsymbol{\varphi}_j$ 會張出一個 M 維線性子空間 $\mathcal{S}$。定義 $\mathbf{y}$ 為 N 維向量，其第 n 個元素為 $y(\mathbf{x}_n,\mathbf{w})$。由於 $\mathbf{y}$ 是 $\boldsymbol{\varphi}_j$ 的任意線性組合，它可以落在 M 維子空間 $\mathcal{S}$ 的任何位置。平方和誤差 (4.10) 則(差一個 $1/2$ 因子)等於 $\mathbf{y}$ 與 $\mathbf{t}$ 之間的歐氏距離平方。因此，$\mathbf{w}$ 的最小平方解對應到**落在子空間 $\mathcal{S}$ 中、且離 $\mathbf{t}$ 最近的 $\mathbf{y}$**。直觀上，這應該是 $\mathbf{t}$ 在 $\mathcal{S}$ 上的**正交投影**；事實正是如此——只需注意 $\mathbf{y}$ 的解為 $\boldsymbol{\Phi}\mathbf{w}_{\mathrm{ML}}$，再驗證它具有正交投影的形式(習題 3)。

推導 (投影矩陣)**.** 令 $\mathbf{P} = \boldsymbol{\Phi}(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}$，則 $\mathbf{y} = \boldsymbol{\Phi}\mathbf{w}_{\mathrm{ML}} = \mathbf{P}\mathbf{t}$。容易驗證 $\mathbf{P}^{\mathsf{T}} = \mathbf{P}$、$\mathbf{P}^2 = \mathbf{P}$(冪等)，且 $\mathbf{P}\boldsymbol{\Phi} = \boldsymbol{\Phi}$：$\mathbf{P}$ 把任何向量投影到 $\boldsymbol{\Phi}$ 的行空間，並保持已在其中的向量不動。殘差 $\mathbf{t}-\mathbf{y} = (\mathbf{I}-\mathbf{P})\mathbf{t}$ 滿足 $\boldsymbol{\Phi}^{\mathsf{T}}(\mathbf{t}-\mathbf{y}) = \boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t} - \boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\mathbf{w}_{\mathrm{ML}} = \mathbf{0}$，即殘差與每個 $\boldsymbol{\varphi}_j$ 正交——這正是正規方程 (4.12) 的幾何意義(「正規」即「法線」)。統計學稱 $\mathbf{P}$ 為**帽子矩陣**(hat matrix)。

實務上，當 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}$ 接近奇異時，直接求解正規方程會引起數值困難。特別是當兩個以上的基底向量 $\boldsymbol{\varphi}_j$ 共線或接近共線時，所得參數值可能非常大。處理真實資料集時，這種接近退化的情

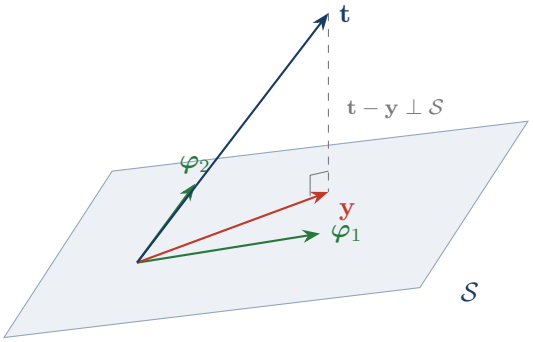


圖 4.3: 最小平方解的幾何詮釋：在座標軸為 $t_1, \ldots, t_N$ 的 N 維空間中，每個基底函數視為長度 N、元素為 $\phi_j(\mathbf{x}_n)$ 的向量 $\boldsymbol{\varphi}_j$；最小平方迴歸函數即為把資料向量 $\mathbf{t}$ 正交投影到 $\boldsymbol{\varphi}_j$ 所張子空間 $\mathcal{S}$ 上的結果 $\mathbf{y}$。

況並不少見。此數值困難可用**奇異值分解**（SVD；Deisenroth, Faisal, and Ong, 2020）處理。注意，加入正則化項可確保矩陣非奇異——即使存在退化。

教學補充：GNSS 定位中的同一個幾何

GNSS 單點定位把虛擬距離觀測線性化為 $\delta\boldsymbol{\rho} = \mathbf{H}\,\delta\mathbf{x} + \boldsymbol{\epsilon}$，其中 $\mathbf{H}$ 的每一列是接收機到衛星的單位視線向量（加上鐘差項的 1）。最小平方解 $\delta\mathbf{x} = (\mathbf{H}^{\mathsf{T}}\mathbf{H})^{-1}\mathbf{H}^{\mathsf{T}}\delta\boldsymbol{\rho}$ 就是 (4.13)——$\mathbf{H}$ 是設計矩陣、四個未知數是「權重」。**幾何精度因子**（DOP）$= \sqrt{\mathrm{tr}(\mathbf{H}^{\mathsf{T}}\mathbf{H})^{-1}}$ 正是本節所說「基底向量接近共線 $\Rightarrow$ 參數變異大」的量化：衛星幾何聚在一起時，$\mathbf{H}$ 的行接近共線，$(\mathbf{H}^{\mathsf{T}}\mathbf{H})^{-1}$ 的元素變大，定位誤差被放大。

4.1.5 循序學習

最大概似解 (4.13) 需要一次處理整個訓練集，稱為**批次**（batch）方法；對大型資料集可能計算成本很高。若資料集夠大，或許值得改用**循序**（sequential）演算法，又稱**線上**（online）演算法：資料點一次考慮一個，每次呈現後就更新模型參數。循序學習也適合**即時應用**——觀測以連續串流到達，必須在看完所有資料點之前就做出預測。

套用**隨機梯度下降**（stochastic gradient descent，Ch. 7；又稱循序梯度下降）即可得到循序學習演算法。若誤差函數是各資料點之和 $E = \sum_n E_n$，則在呈現資料點 n 後，隨機梯度下降以

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta\,\nabla E_n \tag{4.19}$$

更新參數向量，其中 τ 為迭代次數，η 為適當選取的**學習率**參數，$\mathbf{w}$ 初始化為某個起始向量 $\mathbf{w}^{(0)}$。對平方和誤差 (4.10)，這給出

$$\boxed{\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \eta\big(t_n - \mathbf{w}^{(\tau)\mathsf{T}}\boldsymbol{\phi}_n\big)\boldsymbol{\phi}_n} \tag{4.20}$$

其中 $\boldsymbol{\phi}_n = \boldsymbol{\phi}(\mathbf{x}_n)$。這就是**最小均方**（least-mean-squares, LMS）演算法。

教學補充：LMS 即適應性濾波器；Kalman 濾波即「精確」的循序最小平方

(4.20) 正是 Widrow–Hoff 的 LMS 適應性濾波器：把 $\boldsymbol{\phi}_n$ 取為輸入訊號的最近 M 個取樣（tapped delay line），t_n 取為期望輸出，權重就是 FIR 濾波器係數；通道等化、回音消除都是這個式子。LMS 只用「瞬時梯度」，收斂需 $0 < \eta < 2/\lambda_{\max}(\mathbf{R})$，$\mathbf{R} = \mathbb{E}[\boldsymbol{\phi}\boldsymbol{\phi}^{\mathsf{T}}]$。若改為對每筆新資料**精確**地更新最小平方解（利用 Sherman–Morrison 公式遞迴更新 $(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}$），就得到**遞**

迴最小平方（RLS），再加入狀態隨時間演化的模型，就是導航常用的 **Kalman 濾波器**。三者的關係是：LMS（一步梯度）⊂ RLS（精確遞迴）⊂ Kalman（精確遞迴 + 動態模型）。

4.1.6 正則化最小平方

第一章已引入在誤差函數中加入正則化項以控制過度擬合的想法，此時要最小化的總誤差函數為

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w}), \tag{4.21}$$

其中 λ 是控制「資料相依誤差 $E_D(\mathbf{w})$」與「正則化項 $E_W(\mathbf{w})$」相對重要性的**正則化係數**。最簡單的正則化項之一是權重向量元素的平方和：

$$E_W(\mathbf{w}) = \frac{1}{2}\sum_j w_j^2 = \frac{1}{2}\mathbf{w}^\mathsf{T}\mathbf{w}. \tag{4.22}$$

連同平方和誤差 (4.10)，總誤差函數為

$$\frac{1}{2}\sum_{n=1}^{N}\{t_n - \mathbf{w}^\mathsf{T}\boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2}\mathbf{w}^\mathsf{T}\mathbf{w}. \tag{4.23}$$

在統計學中，此正則化項是**參數收縮**（parameter shrinkage）方法的一例，因為它把參數值往零收縮。它的優點是誤差函數仍是 $\mathbf{w}$ 的二次函數，因此其精確最小值可閉式求得：令 (4.23) 對 $\mathbf{w}$ 的梯度為零並如前解出（習題 5），

$$\boxed{\mathbf{w} = \left(\lambda\mathbf{I} + \boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi}\right)^{-1}\boldsymbol{\Phi}^\mathsf{T}\mathbf{t}} \tag{4.24}$$

這是最小平方解 (4.13) 的簡單推廣。

正則化的三種讀法

1. **數值**：$\lambda\mathbf{I} + \boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi}$ 的最小特徵值 $\geq \lambda > 0$，永遠可逆；這是 §4.1.4 末尾「正則化保證非奇異」的意思。
2. **幾何**：在 $\boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi}$ 的特徵基底下，每個方向的解被乘上 $\mu_j/(\mu_j + \lambda)$——資料資訊少（μ_j 小）的方向被壓得最多。
3. **貝氏**：等價於對 $\mathbf{w}$ 放高斯先驗 $\mathcal{N}(\mathbf{0}, \alpha^{-1}\mathbf{I})$ 後取 MAP，$\lambda = \alpha\sigma^2$（第一章補充、§9.2）。

4.1.7 多重輸出

到目前為止只考慮單一目標變數 t。某些應用中我們希望預測 $K > 1$ 個目標變數，合記為目標向量 $\mathbf{t} = (t_1, \ldots, t_K)^\mathsf{T}$。可以對 $\mathbf{t}$ 的每個分量引入不同的基底函數集，形成多個獨立的迴歸問題；但更常見的做法是用**同一組**基底函數為目標向量的所有分量建模：

$$\mathbf{y}(\mathbf{x}, \mathbf{W}) = \mathbf{W}^\mathsf{T}\boldsymbol{\phi}(\mathbf{x}), \tag{4.25}$$

其中 $\mathbf{y}$ 是 K 維行向量，$\mathbf{W}$ 是 $M \times K$ 參數矩陣，$\boldsymbol{\phi}(\mathbf{x})$ 是元素為 $\phi_j(\mathbf{x})$、且 $\phi_0(\mathbf{x}) = 1$ 的 M 維行向量。這同樣可表示為單層參數的神經網路（圖 4.4）。

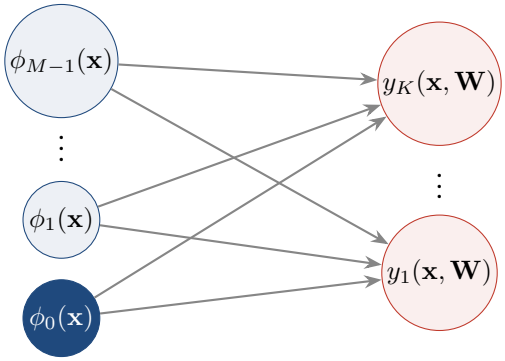


圖 4.4: 把線性迴歸模型表示為只有單層連結的神經網路：每個基底函數以一個節點表示（實心節點為偏置基底函數 ϕ_0），每個輸出 $y_1,\dots,y_K$ 亦以一個節點表示，節點間的連線代表對應的權重與偏置參數。

假設目標向量的條件分布為**等向**（isotropic）高斯

$$p(\mathbf{t}\mid\mathbf{x},\mathbf{W},\sigma^2)=\mathcal{N}\big(\mathbf{t}\mid\mathbf{W}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}),\,\sigma^2\mathbf{I}\big). \tag{4.26}$$

若有觀測 $\mathbf{t}_1,\dots,\mathbf{t}_N$，可合併成 $N\times K$ 矩陣 $\mathbf{T}$，其第 n 列為 $\mathbf{t}_n^{\mathsf{T}}$；同樣把輸入向量合併成矩陣 $\mathbf{X}$。對數概似函數為

$$\begin{aligned}\ln p(\mathbf{T}\mid\mathbf{X},\mathbf{W},\sigma^2)&=\sum_{n=1}^{N}\ln\mathcal{N}\big(\mathbf{t}_n\mid\mathbf{W}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n),\sigma^2\mathbf{I}\big)\\&=-\frac{NK}{2}\ln\big(2\pi\sigma^2\big)-\frac{1}{2\sigma^2}\sum_{n=1}^{N}\big\|\mathbf{t}_n-\mathbf{W}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n)\big\|^2.\end{aligned} \tag{4.27}$$

如前對 $\mathbf{W}$ 最大化，得

$$\mathbf{W}_{\mathrm{ML}}=\big(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\big)^{-1}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{T}, \tag{4.28}$$

其中已把輸入特徵向量 $\boldsymbol{\phi}(\mathbf{x}_1),\dots,\boldsymbol{\phi}(\mathbf{x}_N)$ 合併成矩陣 $\boldsymbol{\Phi}$。對每個目標變數 t_k 分別檢視此結果：

$$\mathbf{w}_k=\big(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi}\big)^{-1}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}_k=\boldsymbol{\Phi}^{\dagger}\mathbf{t}_k, \tag{4.29}$$

其中 $\mathbf{t}_k$ 是分量為 $t_{nk}(n=1,\dots,N)$的 N 維行向量。因此迴歸問題的解在不同目標變數之間**解耦**（decouple），我們只需計算**一個**偽反矩陣 $\boldsymbol{\Phi}^{\dagger}$，由所有 $\mathbf{w}_k$ 共用。

推廣到具有任意共變異數矩陣的一般高斯雜訊分布也很直接（習題 6），同樣會解耦為 K 個獨立的迴歸問題。這個結果並不令人意外：參數 $\mathbf{W}$ 只定義高斯雜訊分布的**均值**，而我們知道多變量高斯之均值的最大概似解與共變異數無關（§3.2.7）。此後為求簡單，只考慮單一目標變數 t。

4.2 決策論

我們已把迴歸任務表述為對條件機率分布 $p(t\mid\mathbf{x})$ 建模，並為此條件機率選定了特定形式——均值 $y(\mathbf{x},\mathbf{w})$ 依賴 $\mathbf{x}$（由參數 $\mathbf{w}$ 決定）、變異數為 σ^2 的高斯 (4.7)。$\mathbf{w}$ 與 σ^2 都可用最大概似從資料學得，結果是**預測分布**（predictive distribution）

$$p\big(t\mid\mathbf{x},\mathbf{w}_{\mathrm{ML}},\sigma^2_{\mathrm{ML}}\big)=\mathcal{N}\big(t\mid y(\mathbf{x},\mathbf{w}_{\mathrm{ML}}),\,\sigma^2_{\mathrm{ML}}\big). \tag{4.30}$$

預測分布表達了我們對新輸入 $\mathbf{x}$ 之 t 值的不確定性。然而，許多實際應用需要預測**一個特定的值**而非整個分布，尤其當我們必須採取特定行動時。例如，若目標是決定治療腫瘤的最佳輻射劑量，而模型給出的是劑量的機率分布，我們仍必須用該分布**決定**實際施用的劑量。因此任務分成兩個階段：

推論階段與決策階段

- **推論階段**(inference stage)：用訓練資料決定預測分布 $p(t \mid \mathbf{x})$。
- **決策階段**(decision stage)：用此預測分布決定一個依賴輸入 $\mathbf{x}$、且依某準則為最佳的特定值 $f(\mathbf{x})$。做法是最小化一個同時依賴預測分布 $p(t \mid \mathbf{x})$ 與 f 的**損失函數**。

直觀上我們可能選條件分布的均值，即 $f(\mathbf{x}) = y(\mathbf{x}, \mathbf{w}_{\mathrm{ML}})$。某些情況下這個直覺是對的，但在其他情況下可能給出很差的結果。因此有必要把它形式化，以理解它何時適用、基於哪些假設——這個框架就是**決策論**(decision theory)。

假設真實值為 t 時，我們選擇 $f(\mathbf{x})$ 作為預測。這麼做會招致某種懲罰或成本，由**損失**(loss) $L(t, f(\mathbf{x}))$ 決定。當然我們不知道 t 的真實值，所以不是最小化 L 本身，而是最小化其平均——**期望損失**(expected loss)

$$\mathbb{E}[L] = \iint L\big(t, f(\mathbf{x})\big)\, p(\mathbf{x}, t)\, \mathrm{d}\mathbf{x}\, \mathrm{d}t, \tag{4.31}$$

即以聯合分布 $p(\mathbf{x}, t)$ 為權重，對輸入與目標變數的分布取平均。迴歸問題中常見的損失函數是**平方損失** $L(t, f(\mathbf{x})) = \{f(\mathbf{x}) - t\}^2$，此時期望損失為

$$\mathbb{E}[L] = \iint \{f(\mathbf{x}) - t\}^2\, p(\mathbf{x}, t)\, \mathrm{d}\mathbf{x}\, \mathrm{d}t. \tag{4.32}$$

不要混淆「平方損失」與「平方和誤差」

誤差函數(error function，如 $E_D(\mathbf{w})$)在**訓練**時用來設定參數，以決定條件機率分布 $p(t \mid \mathbf{x})$；**損失函數**(loss function)則決定**如何使用**該條件分布，以得到對每個 $\mathbf{x}$ 給出預測的函數 $f(\mathbf{x})$。兩者形式可以相同(都是平方)，但角色不同：前者屬於推論階段，後者屬於決策階段。

目標是選 $f(\mathbf{x})$ 使 $\mathbb{E}[L]$ 最小。若假設 $f(\mathbf{x})$ 是完全自由的函數，可用**變分法**(附錄 B)正式求解：

$$\frac{\delta \mathbb{E}[L]}{\delta f(\mathbf{x})} = 2 \int \{f(\mathbf{x}) - t\}\, p(\mathbf{x}, t)\, \mathrm{d}t = 0. \tag{4.33}$$

解出 $f(\mathbf{x})$ 並利用機率的加法與乘法規則，得

$$\boxed{f^\star(\mathbf{x}) = \frac{1}{p(\mathbf{x})} \int t\, p(\mathbf{x}, t)\, \mathrm{d}t = \int t\, p(t \mid \mathbf{x})\, \mathrm{d}t = \mathbb{E}_t[t \mid \mathbf{x}]} \tag{4.34}$$

即 t 在給定 $\mathbf{x}$ 下的**條件平均**，稱為**迴歸函數**(regression function)，如圖 4.5。此結果可直接推廣到以向量 $\mathbf{t}$ 表示的多個目標變數，最佳解為條件平均 $\mathbf{f}^\star(\mathbf{x}) = \mathbb{E}_{\mathbf{t}}[\mathbf{t} \mid \mathbf{x}]$(習題 7)。對 (4.7) 形式的高斯條件分布，條件均值就是

$$\mathbb{E}[t \mid \mathbf{x}] = \int t\, p(t \mid \mathbf{x})\, \mathrm{d}t = y(\mathbf{x}, \mathbf{w}). \tag{4.35}$$

用變分法推導 (4.34) 意味著我們是在**所有可能的函數** $f(\mathbf{x})$ 上最佳化。雖然實務上能實作的任何參數化模型所能表示的函數範圍都有限，但後續章節廣泛討論的深度神經網路框架，提供了

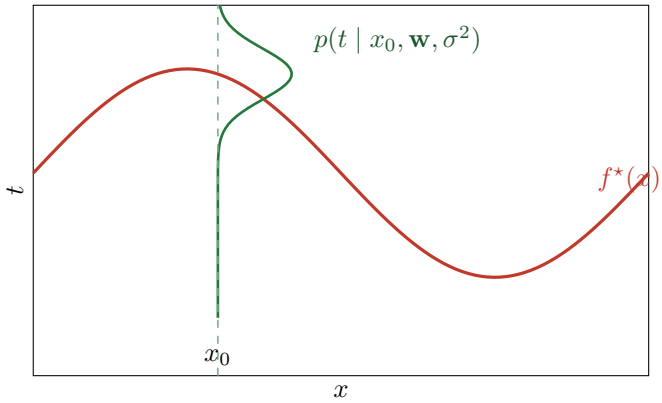


圖 4.5: 最小化期望平方損失的迴歸函數 $f^\star(x)$ 由條件分布 $p(t \mid x)$ 的均值給出。綠線為 $x = x_0$ 處條件分布的形狀（沿 t 軸方向繪製）。

極為靈活的一類函數，對許多實際用途而言可以高精度逼近任何所需函數。

另一種推導。 我們也可用稍微不同的方式推導此結果，並藉此更了解迴歸問題的本質。已知最佳解是條件期望值，把平方項展開：

$$\begin{aligned}\{f(\mathbf{x}) - t\}^2 &= \{f(\mathbf{x}) - \mathbb{E}[t \mid \mathbf{x}] + \mathbb{E}[t \mid \mathbf{x}] - t\}^2 \\ &= \{f(\mathbf{x}) - \mathbb{E}[t \mid \mathbf{x}]\}^2 + 2\{f(\mathbf{x}) - \mathbb{E}[t \mid \mathbf{x}]\}\{\mathbb{E}[t \mid \mathbf{x}] - t\} + \{\mathbb{E}[t \mid \mathbf{x}] - t\}^2,\end{aligned}$$

其中為簡化符號，以 $\mathbb{E}[t \mid \mathbf{x}]$ 表示 $\mathbb{E}_t[t \mid \mathbf{x}]$。代入損失函數 (4.32) 並對 t 積分，交叉項消失（因為 $\int \{\mathbb{E}[t \mid \mathbf{x}] - t\} p(t \mid \mathbf{x})\, \mathrm{d}t = 0$），得到損失函數的表達式

$$\mathbb{E}[L] = \int \{f(\mathbf{x}) - \mathbb{E}[t \mid \mathbf{x}]\}^2 \, p(\mathbf{x})\, \mathrm{d}\mathbf{x} + \int \mathrm{var}[t \mid \mathbf{x}]\, p(\mathbf{x})\, \mathrm{d}\mathbf{x}. \tag{4.36}$$

我們要決定的函數 $f(\mathbf{x})$ 只出現在第一項，當 $f(\mathbf{x}) = \mathbb{E}[t \mid \mathbf{x}]$ 時該項最小（為零）——這正是先前導出的結果，顯示最佳最小平方預測器由條件均值給出。第二項是 t 的分布之變異數對 $\mathbf{x}$ 的平均，代表目標資料的**本質變異性**，可視為**雜訊**；因為它與 $f(\mathbf{x})$ 無關，它代表損失函數**不可縮減**的最小值。

Minkowski 損失。 平方損失並非迴歸問題唯一可能的損失函數。這裡簡短考慮平方損失的一個簡單推廣，稱為 **Minkowski 損失**，其期望為

$$\mathbb{E}[L_q] = \iint |f(\mathbf{x}) - t|^q \, p(\mathbf{x}, t)\, \mathrm{d}\mathbf{x}\, \mathrm{d}t, \tag{4.37}$$

$q = 2$ 時即回到期望平方損失。圖 4.6 畫出不同 q 值下 $|f - t|^q$ 對 $f - t$ 的關係。$\mathbb{E}[L_q]$ 的最小值：$q = 2$ 時為條件**均值**，$q = 1$ 時為條件**中位數**，$q \to 0$ 時為條件**眾數**（習題 9）。

教學補充：損失函數就是對「離群值」的態度

$q = 2$ 對大誤差的懲罰成平方成長，一個離群值就能把預測拉走；$q = 1$（條件中位數）對離群值**穩健**，這是統計學中 LAD 迴歸與 Huber 損失的動機。在 GNSS 多路徑效應或訊號遮蔽造成的粗差（blunder）情境中，用 L_1 型損失或 RANSAC 式的穩健估計，往往比純最小平方更可靠——這與習題 4 的加權最小平方（依仰角給權）是互補的兩種手段。

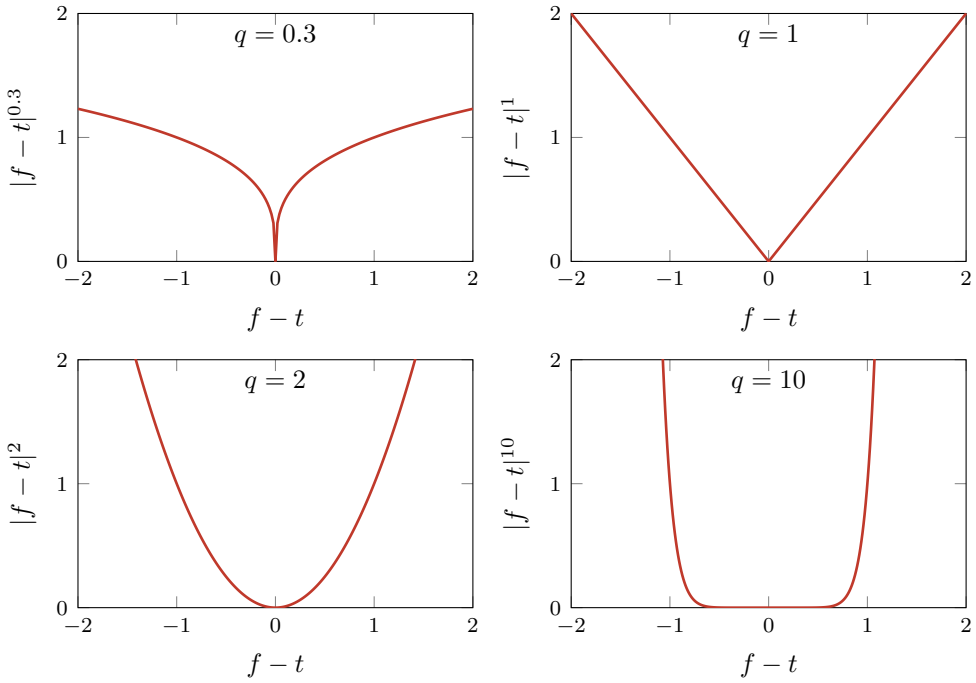


圖 4.6: 不同 q 值下 $L_q = |f-t|^q$ 的圖形。q 小時損失對「小誤差」極敏感、對「大誤差」不敏感（接近 0–1 損失）；q 大時則幾乎只懲罰最大的誤差。

注意高斯雜訊假設隱含「t 在給定 $\mathbf{x}$ 下的條件分布是**單峰**的」，這對某些應用可能不適當。此時平方損失可能導致很差的結果，需要更精巧的方法——例如用**高斯混合**（§6.5）擴展模型以給出多峰的條件分布，這在**逆問題**（inverse problems）的求解中經常出現。本節聚焦於迴歸問題的決策論；下一章將為分類任務發展類似的概念（§5.2）。

4.3 偏差–變異權衡

到目前為止，在討論迴歸的線性模型時，我們假設基底函數的**形式與數量**都已給定。我們也看到，若以有限大小的資料集訓練複雜模型，最大概似可能導致嚴重的過度擬合。然而，為避免過度擬合而限制基底函數的數量，副作用是限制了模型捕捉資料中有趣且重要趨勢的彈性。雖然正則化項可以控制多參數模型的過度擬合，但這引出「如何決定正則化係數 λ 的適當值」的問題——同時對權重向量 $\mathbf{w}$ 與 λ 最小化正則化誤差函數顯然不是正確的做法，因為那會導致 $\lambda = 0$ 的無正則化解。

從**頻率學派**的觀點考慮模型複雜度問題很有啟發性，這就是**偏差–變異權衡**（bias–variance trade-off）。雖然我們在線性基底函數模型的脈絡下引入此概念（因為容易用簡單例子說明），但這個討論具有非常廣泛的適用性。不過要注意：過度擬合其實是**最大概似**的一個不幸性質，在貝氏框架下對參數**邊際化**時並不會出現（Bishop, 2006）。

4.3.1 分解的推導

討論迴歸的決策論時，我們考慮了各種損失函數，每種都在給定條件分布 $p(t \mid \mathbf{x})$ 後對應到一個最佳預測。常用的平方損失下，最佳預測是條件期望值，記為 $h(\mathbf{x})$：

$$h(\mathbf{x}) = \mathbb{E}[t \mid \mathbf{x}] = \int t\, p(t \mid \mathbf{x})\, \mathrm{d}t. \tag{4.38}$$

我們也看到期望平方損失可寫成

$$\mathbb{E}[L] = \int \{f(\mathbf{x}) - h(\mathbf{x})\}^2 \, p(\mathbf{x}) \, \mathrm{d}\mathbf{x} + \iint \{h(\mathbf{x}) - t\}^2 \, p(\mathbf{x}, t) \, \mathrm{d}\mathbf{x} \, \mathrm{d}t. \tag{4.39}$$

回想第二項與 $f(\mathbf{x})$ 無關，來自資料的本質雜訊，代表期望損失可達的最小值。第一項取決於我們對 $f(\mathbf{x})$ 的選擇，我們要尋找使該項最小的 $f(\mathbf{x})$；因為它非負，我們所能期望的最小值是零。若有**無限**的資料供應（與無限的計算資源），原則上可以把迴歸函數 $h(\mathbf{x})$ 求到任意精度，那就是 $f(\mathbf{x})$ 的最佳選擇。然而實務上我們只有一個含**有限** N 個資料點的資料集 $\mathcal{D}$，因此無法精確知道 $h(\mathbf{x})$。

若以參數向量 $\mathbf{w}$ 決定的函數來為 $h(\mathbf{x})$ 建模，則從貝氏觀點，模型的不確定性會透過 $\mathbf{w}$ 的後驗分布表達。頻率學派的處理則是根據資料集 $\mathcal{D}$ 對 $\mathbf{w}$ 做**點估計**，並試圖透過以下**思想實驗**來詮釋此估計的不確定性：假設有大量資料集，每個大小為 N，且各自獨立地從分布 $p(t, \mathbf{x})$ 抽取。對任一給定資料集 $\mathcal{D}$，我們可以執行學習演算法得到預測函數 $f(\mathbf{x}; \mathcal{D})$。系集（ensemble）中不同的資料集會給出不同的函數，因而有不同的平方損失值。一個特定學習演算法的表現，就以**對此資料集系集取平均**來評估。

考慮 (4.39) 第一項的被積函數，對特定資料集 $\mathcal{D}$ 為

$$\{f(\mathbf{x}; \mathcal{D}) - h(\mathbf{x})\}^2. \tag{4.40}$$

因為此量依賴特定的資料集 $\mathcal{D}$，我們對資料集系集取平均。在大括號內加減 $\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]$ 再展開：

$$\begin{aligned} &\{f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] + \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 \\ &\quad = \{f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]\}^2 + \{\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 \\ &\qquad + 2\{f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]\}\{\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}. \end{aligned} \tag{4.41}$$

對 $\mathcal{D}$ 取期望，最後一項消失（因為 $\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]] = 0$，而第二個因子不依賴 $\mathcal{D}$），得

$$\mathbb{E}_{\mathcal{D}}\big[\{f(\mathbf{x}; \mathcal{D}) - h(\mathbf{x})\}^2\big] = \underbrace{\{\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2}_{(\text{偏差})^2} + \underbrace{\mathbb{E}_{\mathcal{D}}\big[\{f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]\}^2\big]}_{\text{變異}}. \tag{4.42}$$

可見 $f(\mathbf{x}; \mathcal{D})$ 與迴歸函數 $h(\mathbf{x})$ 之間的期望平方差，可表為兩項之和。第一項稱為**平方偏差**（squared bias），代表「對所有資料集的平均預測」與「所要的迴歸函數」之間的差距；第二項稱為**變異**（variance），衡量個別資料集的解繞其平均變動的程度，也就是函數 $f(\mathbf{x}; \mathcal{D})$ 對特定資料集選擇的**敏感程度**。

到目前為止只考慮單一輸入值 $\mathbf{x}$。把此展開代回 (4.39)，得到期望平方損失的分解：

$$\boxed{\text{期望損失} = (\text{偏差})^2 + \text{變異} + \text{雜訊}} \tag{4.43}$$

其中

$$(\text{偏差})^2 = \int \{\mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})] - h(\mathbf{x})\}^2 \, p(\mathbf{x}) \, \mathrm{d}\mathbf{x}, \tag{4.44}$$

$$\text{變異} = \int \mathbb{E}_{\mathcal{D}}\big[\{f(\mathbf{x}; \mathcal{D}) - \mathbb{E}_{\mathcal{D}}[f(\mathbf{x}; \mathcal{D})]\}^2\big] \, p(\mathbf{x}) \, \mathrm{d}\mathbf{x}, \tag{4.45}$$

$$\text{雜訊} = \iint \{h(\mathbf{x}) - t\}^2 \, p(\mathbf{x}, t) \, \mathrm{d}\mathbf{x} \, \mathrm{d}t, \tag{4.46}$$

此時偏差與變異項指的是積分後的量。

三個分量各自「怪誰」

分量	來源	如何降低
$(\text{偏差})^2$	模型類別太僵硬，平均起來也逼近不了 $h(\mathbf{x})$	增加模型彈性（更多基底、更小 λ）
變異	模型對「這一份」資料的雜訊太敏感	更多資料、更強正則化、平均多個模型
雜訊	資料本身的 $\mathrm{var}[t \mid \mathbf{x}]$	無法降低（除非加入新的輸入特徵）

目標是最小化期望損失，而我們已把它分解為（平方）偏差、變異與常數雜訊項之和。偏差與變異之間存在**權衡**：非常靈活的模型偏差低、變異高；相對僵硬的模型偏差高、變異低。預測能力最佳的模型，是在偏差與變異之間取得最佳平衡者。

4.3.2 數值實驗

以第一章的正弦資料集說明。獨立產生 $L = 100$ 個資料集，每個含 $N = 25$ 個資料點，皆由正弦曲線 $h(x) = \sin(2\pi x)$ 產生，以 $l = 1, \ldots, L$ 編號。對每個資料集 $\mathcal{D}^{(l)}$，用 $M = 24$ 個高斯基底函數加上一個常數「偏置」基底函數（共 25 個參數）擬合模型，以最小化正則化誤差函數 (4.23) 得到預測函數 $f^{(l)}(x)$，如圖 4.7。

最上列對應大的正則化係數 λ：**變異低**（左圖的紅色曲線看起來彼此相似）但**偏差高**（右圖的兩條曲線差異很大）。相反地，最下列 λ 小：**變異大**（左圖紅色曲線之間變化劇烈）但**偏差低**（右圖中平均模型與原正弦函數吻合良好）。值得注意的是，對 $M = 25$ 的複雜模型把許多解**平均**起來，結果非常貼近迴歸函數——這暗示「平均」可能是有益的程序。事實上，對多個解做加權平均正是貝氏方法的核心，只不過那裡的平均是對參數的**後驗分布**取的，而非對多個資料集。

也可以定量檢視此例的偏差–變異權衡。平均預測估計為

$$\bar{f}(x) = \frac{1}{L} \sum_{l=1}^{L} f^{(l)}(x), \tag{4.47}$$

積分後的平方偏差與變異則為

$$(\text{偏差})^2 = \frac{1}{N} \sum_{n=1}^{N} \left\{ \bar{f}(x_n) - h(x_n) \right\}^2, \tag{4.48}$$

$$\text{變異} = \frac{1}{N} \sum_{n=1}^{N} \frac{1}{L} \sum_{l=1}^{L} \left\{ f^{(l)}(x_n) - \bar{f}(x_n) \right\}^2, \tag{4.49}$$

其中以分布 $p(x)$ 為權重的積分，由從該分布抽取之資料點上的有限和來近似。這些量連同其總和對 $\ln \lambda$ 的圖形見圖 4.8。可見小的 λ 讓模型精細地調到每個資料集的雜訊上，導致大的變異；相反地，大的 λ 把權重參數拉向零，導致大的偏差。

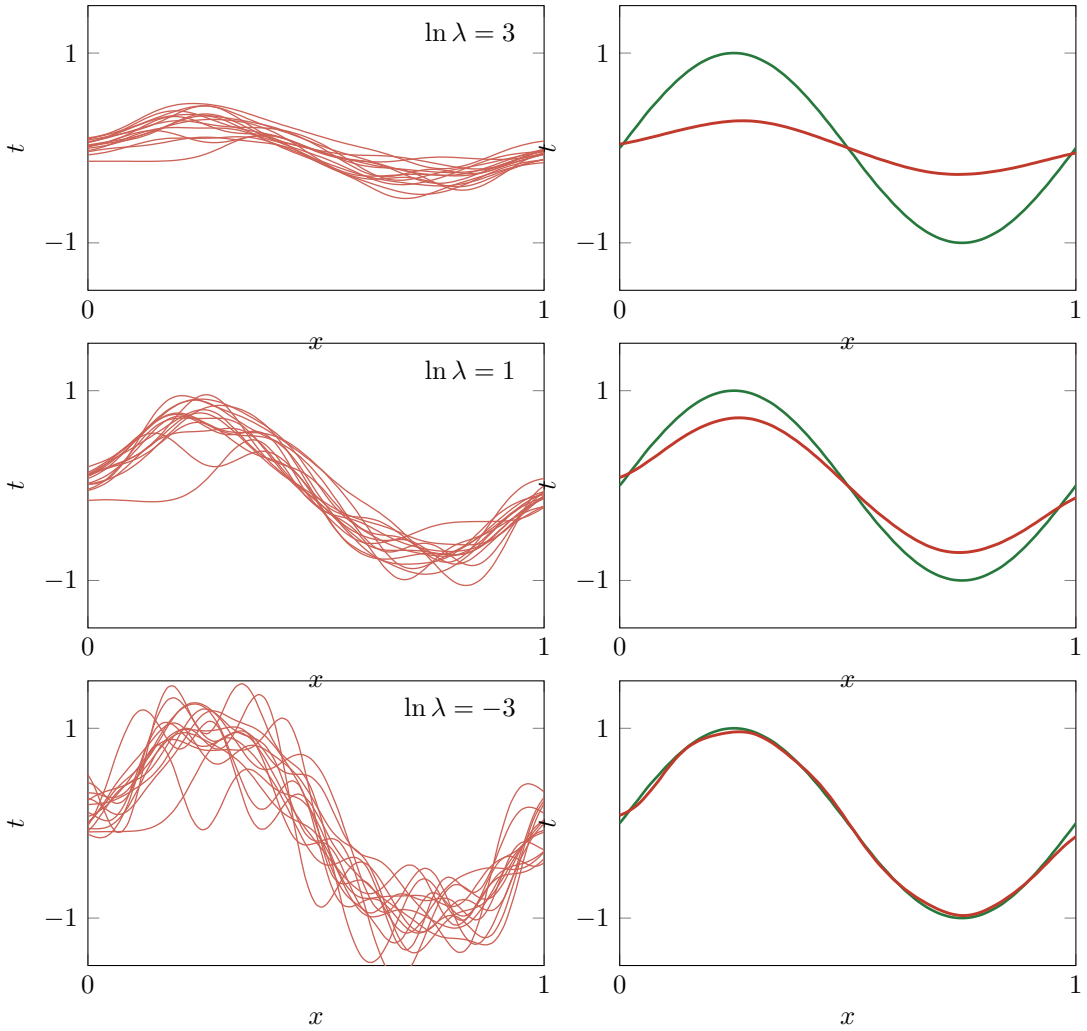


圖 4.7: 偏差與變異隨（由正則化參數 λ 控制的）模型複雜度變化的示意，使用第一章的正弦資料。共 $L = 100$ 個資料集，每個 $N = 25$ 個資料點；模型含 24 個高斯基底函數（$s = 0.05$），連同偏置參數共 $M = 25$ 個參數。左欄為各 $\ln\lambda$ 值下模型對各資料集的擬合結果（為清楚起見只畫出 100 次擬合中的 15 次）；右欄為 100 次擬合的平均（紅）與產生資料的正弦函數（綠）。

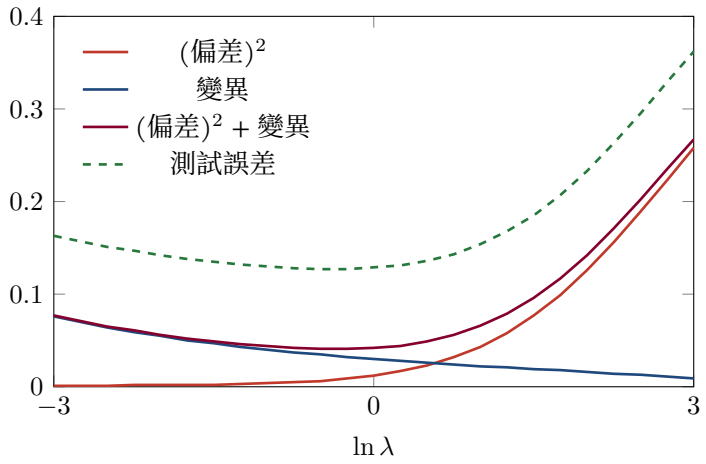


圖 4.8: 對應圖 4.7 結果的平方偏差、變異及其總和，以及在 1,000 點測試集上的平均測試誤差（含雜訊項，故整體高出約 $\sigma^2 = 0.09$）。(偏差)^2 + 變異 的最小值出現在 $\ln\lambda \approx -0.25$，與測試誤差最小處（$\ln\lambda \approx -0.50$）相近。

測試誤差曲線為何「浮」在總和之上？

測試誤差 $\approx$ (偏差)^2 + 變異 + 雜訊，而雜訊 $= \sigma^2 = 0.3^2 = 0.09$ 與 λ 無關。因此綠色虛線大約是紫色曲線向上平移 0.09——這正是 (4.43) 的數值驗證，也說明為何無論怎麼調模型，測試誤差都降不到 0.09 以下。

注意，偏差–變異分解的**實用價值有限**，因為它建立在對資料集系集取平均之上，而實務上我們只有**單一**觀測到的資料集。若真有大量給定大小的獨立訓練集，更好的做法是把它們合併成一個更大的訓練集，這當然會降低給定模型複雜度下的過度擬合程度。儘管如此，偏差–變異分解經常對模型複雜度問題提供有用的洞見；雖然本章從迴歸問題的角度引入它，其底層直覺具有廣泛的適用性。

教學補充：從偏差–變異到現代深度學習

- **系集學習**：圖 4.7 右下的「平均後幾乎完美」，就是 bagging／隨機森林的原理——平均 L 個低偏差高變異的模型，偏差不變、變異約降為 $1/L$（若彼此獨立）。深度學習中的 dropout 與模型平均也可如此理解（§9.6）。
- **雙重下降**（double descent）：古典的 U 形曲線（圖 4.8）描述「參數少於資料」的區域；當參數數量超過資料點數後，測試誤差可能**再次下降**（§9.3.2）。此時最小範數解自帶隱式正則化，變異未如古典預期那樣爆炸。
- **VTEC 預測的啟示**：若以 L 段不同年份的資料各訓練一個模型，模型間預測差異大（高變異）代表資料量不足或模型太自由；若各模型一致但都偏離觀測（高偏差），則代表模型類別（例如球諧階數）不夠。

課後習題

以下習題分為**觀念題**（○）、**推導題**（⋆）與**延伸題**（⋆⋆）。標有「原書 4.x」者改編自教科書習題。推導題請完整寫出過程；延伸題可搭配程式（NumPy 即可）作答。

習題 1 (⋆ 多項式的正規方程（原書 4.1、4.2）)**.** 考慮誤差函數 (1.2)，其中 $y(x, \mathbf{w})$ 為多項式 (1.1)。

(a) 證明使誤差函數最小的係數 $\mathbf{w} = \{w_i\}$ 滿足線性方程組

$$\sum_{j=0}^{M} A_{ij}\, w_j = T_i, \qquad A_{ij} = \sum_{n=1}^{N} (x_n)^{i+j}, \quad T_i = \sum_{n=1}^{N} (x_n)^i\, t_n,$$

其中下標 i, j 為分量指標，$(x)^i$ 表示 x 的 i 次冪。

(b) 寫出正則化誤差函數 (1.4) 的係數所滿足的對應線性方程組。

(c) 說明 (a) 中的 A_{ij} 與 T_i 分別是 $\mathbf{\Phi}^{\mathsf{T}}\mathbf{\Phi}$ 與 $\mathbf{\Phi}^{\mathsf{T}}\mathbf{t}$ 的哪個元素。

習題 2 (⋆ S 形與 tanh 基底的等價性（原書 4.3))**.**

(a) 證明 $\tanh(a) = \dfrac{e^{a} - e^{-a}}{e^{a} + e^{-a}}$ 與邏輯 S 形函數 (4.5) 滿足 $\tanh(a) = 2\sigma(2a) - 1$。

(b) 由此證明 $y(x, \mathbf{w}) = w_0 + \sum_{j=1}^{M} w_j\, \sigma\!\left(\frac{x-\mu_j}{s}\right)$ 等價於 $y(x, \mathbf{u}) = u_0 + \sum_{j=1}^{M} u_j \tanh\!\left(\frac{x-\mu_j}{2s}\right)$，並求出 $\{u_0, \ldots, u_M\}$ 與 $\{w_0, \ldots, w_M\}$ 的關係。

(c) 這個結果對「選擇激活函數是否重要」有何啟示？(提示：兩者張出相同的函數空間，但最佳化的**難易**可能不同。)

習題 3 (⋆⋆ 正交投影(原書 4.4))**.**

(a) 證明矩陣 $\mathbf{P} = \boldsymbol{\Phi}(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}$ 滿足 $\mathbf{P}^{\mathsf{T}} = \mathbf{P}$、$\mathbf{P}^2 = \mathbf{P}$，且對任意向量 $\mathbf{v}$，$\mathbf{P}\mathbf{v}$ 落在 $\boldsymbol{\Phi}$ 的行空間中、$(\mathbf{I} - \mathbf{P})\mathbf{v}$ 與該行空間正交。

(b) 利用此結果證明最小平方解 (4.13) 對應到把 $\mathbf{t}$ 正交投影到子空間 $\mathcal{S}$(圖 4.3)。

(c) 證明 $\operatorname{tr}(\mathbf{P}) = M$，並說明為何統計學把 $\operatorname{tr}(\mathbf{P})$ 稱為模型的**有效自由度**。當加入正則化 λ 時，$\mathbf{P}_\lambda = \boldsymbol{\Phi}(\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi} + \lambda\mathbf{I})^{-1}\boldsymbol{\Phi}^{\mathsf{T}}$ 的跡如何隨 λ 變化？

習題 4 (⋆ 加權最小平方(原書 4.5))**.** 設每個資料點 t_n 附有權重因子 $r_n > 0$，誤差函數成為

$$E_D(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N} r_n \bigl\{t_n - \mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n)\bigr\}^2.$$

(a) 求使此誤差函數最小的解 $\mathbf{w}^\star$(以 $\boldsymbol{\Phi}$、$\mathbf{t}$ 與 $\mathbf{R} = \operatorname{diag}(r_1, \dots, r_N)$ 表示)。

(b) 給出加權平方和誤差的兩種詮釋：(i) 各資料點的雜訊變異數不同；(ii) 資料點被重複出現。

(c) **應用**：GNSS 定位中常依衛星仰角 θ_n 給權 $r_n = \sin^2\theta_n$。用 (b)(i) 解釋這個做法背後對雜訊的假設。

習題 5 (⋆ 正則化最小平方的閉式解(原書 4.6))**.**

(a) 令 (4.23) 對 $\mathbf{w}$ 的梯度為零，證明其精確最小值為 (4.24)。

(b) 設 $\boldsymbol{\Phi}^{\mathsf{T}}\boldsymbol{\Phi} = \mathbf{U}\operatorname{diag}(\mu_1, \dots, \mu_M)\mathbf{U}^{\mathsf{T}}$。證明 (4.24) 可寫成 $\mathbf{w} = \sum_j \frac{\mu_j}{\mu_j + \lambda}\,\frac{\mathbf{u}_j^{\mathsf{T}}\boldsymbol{\Phi}^{\mathsf{T}}\mathbf{t}}{\mu_j}\,\mathbf{u}_j$，並解釋「收縮因子」$\mu_j/(\mu_j + \lambda)$ 的意義。

(c) 若改用正則化項 $E_W = \frac{1}{2}\sum_j |w_j|^q$($q \neq 2$)，閉式解是否仍存在？$q = 1$ 時的解有何特殊性質？

習題 6 (⋆⋆ 一般共變異數下的多輸出迴歸(原書 4.7))**.** 考慮多變量目標 $\mathbf{t}$ 的線性基底函數迴歸模型 $p(\mathbf{t} \mid \mathbf{W}, \boldsymbol{\Sigma}) = \mathcal{N}(\mathbf{t} \mid \mathbf{W}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}), \boldsymbol{\Sigma})$，訓練資料為 $\{\boldsymbol{\phi}(\mathbf{x}_n), \mathbf{t}_n\}_{n=1}^N$。

(a) 寫出對數概似函數。

(b) 證明 $\mathbf{W}$ 的最大概似解 $\mathbf{W}_{\mathrm{ML}}$ 的每一行都具有 (4.13) 的形式(即與 $\boldsymbol{\Sigma}$ 無關)。

(c) 證明 $\boldsymbol{\Sigma}$ 的最大概似解為 $\boldsymbol{\Sigma} = \frac{1}{N}\sum_{n=1}^{N}\bigl(\mathbf{t}_n - \mathbf{W}_{\mathrm{ML}}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n)\bigr)\bigl(\mathbf{t}_n - \mathbf{W}_{\mathrm{ML}}^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_n)\bigr)^{\mathsf{T}}$。

習題 7 (⋆ 多目標變數的期望平方損失（原書 4.8–4.10）)**.** 考慮 $\mathbb{E}[L(\mathbf{t}, \mathbf{f}(\mathbf{x}))] = \iint \|\mathbf{f}(\mathbf{x}) - \mathbf{t}\|^2\, p(\mathbf{x}, \mathbf{t})\,\mathrm{d}\mathbf{x}\,\mathrm{d}\mathbf{t}$。

(a) 用變分法證明使期望損失最小的函數為 $\mathbf{f}(\mathbf{x}) = \mathbb{E}_{\mathbf{t}}[\mathbf{t} \mid \mathbf{x}]$。

(b) 仿照 (4.36) 展開平方，導出類似的分解，並由此再次證明 (a) 的結果。

習題 8 (⋆⋆ 廣義高斯與 L_q 誤差(原書 4.11))**.** 考慮分布

$$p(x \mid \sigma^2, q) = \frac{q}{2(2\sigma^2)^{1/q}\,\Gamma(1/q)}\exp\!\left(-\frac{|x|^q}{2\sigma^2}\right), \qquad \Gamma(z) = \int_0^\infty u^{z-1}e^{-u}\,\mathrm{d}u.$$

(a) 證明此分布已正規化，且 $q = 2$ 時退化為高斯分布。

(b) 設 $t = y(\mathbf{x}, \mathbf{w}) + \epsilon$，$\epsilon$ 服從上述分布。證明對數概似為 $\ln p(\mathbf{t} \mid \mathbf{X}, \mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2}\sum_n |y(\mathbf{x}_n, \mathbf{w}) - t_n|^q - \frac{N}{q}\ln(2\sigma^2) + \text{const}$，並指出作為 $\mathbf{w}$ 的函數，它就是 §4.2 的 L_q 誤差函數。

(c) $q=1$ 時此分布是什麼？由此說明「Laplace 雜訊 $\Leftrightarrow$ 絕對值誤差 $\Leftrightarrow$ 條件中位數」的三角關係。

習題 9 ($\star\star$ Minkowski 損失的最佳預測（原書 4.12））. 考慮 L_q 損失下的期望損失 (4.37)。

(a) 寫出 $f(\mathbf{x})$ 使 $\mathbb{E}[L_q]$ 最小所需滿足的條件。

(b) 證明 $q=1$ 時解為條件**中位數**，即 $f(\mathbf{x})$ 使 $t<f(\mathbf{x})$ 與 $t\geq f(\mathbf{x})$ 的機率質量相等。

(c) 證明 $q\to 0$ 時最小期望損失由條件**眾數**給出，即 $f(\mathbf{x})$ 等於使 $p(t\mid\mathbf{x})$ 最大的 t。（提示：當 $q\to 0$，$|f-t|^q\to 1-\delta(f-t)$ 的意義下。）

習題 10 ($\circ$ 推論 vs. 決策). 一個氣象模型輸出「明日降雨量」的預測分布為雙峰：0.7 的機率為 0 mm（不下雨），0.3 的機率為 $\mathcal{N}(40,5^2)$ mm。

(a) 分別求平方損失、絕對值損失與 $q\to 0$ 損失下的最佳點預測。

(b) 哪一個預測「從未發生過」？這說明了平方損失在多峰分布下的什麼問題？

(c) 若損失是非對稱的（例如漏報暴雨的代價是誤報的 10 倍），最佳預測應如何調整？

習題 11 ($\star$ 偏差–變異分解的細節).

(a) 完整證明 (4.41) 對 $\mathcal{D}$ 取期望後交叉項為零。

(b) 證明 (4.36) 中交叉項的積分為零。

(c) 設模型為常數 $f(\mathbf{x};\mathcal{D})=\bar{t}_{\mathcal{D}}$（訓練集目標值的平均）。對 $h(x)=\sin 2\pi x$、$x\sim U(0,1)$、雜訊變異數 σ^2，解析地求出偏差 ^{2} 與變異（以 N 表示）。當 $N\to\infty$ 時哪一項趨於零？

習題 12 ($\star\star$ 動手重現本章圖形).

(a) 以 NumPy 重現圖 4.7 與圖 4.8（$L=100$、$N=25$、24 個高斯基底、$s=0.05$）。

(b) 把高斯寬度改為 $s=0.2$，觀察變異曲線如何改變；解釋原因。

(c) 把 N 改為 100，找出新的最佳 $\ln\lambda$；它為何往小的方向移動？

(d) 實作 LMS 演算法 (4.20)，對同一資料集畫出 $\|\mathbf{w}^{(\tau)}-\mathbf{w}_{\mathrm{ML}}\|$ 隨 τ 的變化，並試驗三種學習率 η（太小、適中、太大）。

附錄 A　中英名詞對照表

英文	中文	簡要說明
linear regression	線性迴歸	對參數線性的迴歸模型
basis function	基底函數	輸入的固定非線性轉換 $\phi_j(\mathbf{x})$
bias parameter	偏置參數	容許固定偏移的參數 w_0（$\neq$ 統計偏差）
dummy basis function	虛擬基底函數	恆為 1 的 ϕ_0，用以吸收偏置
single-layer network	單層網路	只有一層可學習參數的網路
feature extraction	特徵萃取	深度學習之前的手工前處理
Gaussian basis function	高斯基底函數	以 μ_j 為中心、s 為尺度的局部基底
sigmoidal basis function	S 形基底函數	以邏輯 S 形函數為形狀的基底
logistic sigmoid	邏輯 S 形函數	$\sigma(a) = 1/(1+e^{-a})$
Fourier basis	Fourier 基底	正弦／餘弦基底，頻率局部、空間非局部
wavelet	小波	空間與頻率皆局部化的正交基底
likelihood function	概似函數	參數的函數 $p(\mathbf{t} \mid \mathbf{X}, \mathbf{w}, \sigma^2)$
maximum likelihood (ML)	最大概似	使概似函數最大的參數估計
sum-of-squares error	平方和誤差	$E_D(\mathbf{w}) = \frac{1}{2}\sum_n \{t_n - \mathbf{w}^\mathsf{T}\boldsymbol{\phi}(\mathbf{x}_n)\}^2$
normal equations	正規方程	$\boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi}\mathbf{w} = \boldsymbol{\Phi}^\mathsf{T}\mathbf{t}$
design matrix	設計矩陣	$\Phi_{nj} = \phi_j(\mathbf{x}_n)$ 的 $N \times M$ 矩陣
Moore–Penrose pseudo-inverse	Moore–Penrose 偽反矩陣	$\boldsymbol{\Phi}^\dagger = (\boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^\mathsf{T}$
residual variance	殘差變異數	σ^2_{ML}，目標值繞迴歸函數的變異
orthogonal projection	正交投影	最小平方解的幾何意義
hat matrix / projection matrix	帽子矩陣／投影矩陣	$\boldsymbol{\Phi}(\boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}^\mathsf{T}$
singular value decomposition (SVD)	奇異值分解	處理接近奇異之 $\boldsymbol{\Phi}^\mathsf{T}\boldsymbol{\Phi}$ 的數值方法
batch method	批次方法	一次處理整個訓練集
sequential / online learning	循序／線上學習	資料一次一筆、逐筆更新參數
stochastic gradient descent (SGD)	隨機梯度下降	$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta\nabla E_n$
learning rate	學習率	梯度更新的步長 η
least-mean-squares (LMS)	最小均方演算法	平方和誤差下的 SGD
regularization coefficient	正則化係數	控制 E_D 與 E_W 相對重要性的 λ
parameter shrinkage	參數收縮	把參數往零收縮的正則化（統計學用語）
weight decay	權重衰減	二次正則化在神經網路中的名稱
isotropic Gaussian	等向高斯	共變異數為 $\sigma^2\mathbf{I}$ 的高斯分布
decoupling	解耦	多輸出迴歸拆成獨立的單輸出問題
predictive distribution	預測分布	對新輸入之 t 的分布 $p(t \mid \mathbf{x})$
inference stage / decision stage	推論階段／決策階段	決定 $p(t \mid \mathbf{x})$ ／由其決定點預測 $f(\mathbf{x})$
decision theory	決策論	在不確定性下做最佳決策的框架
loss function	損失函數	預測 $f(\mathbf{x})$ 而真值為 t 時的代價 $L(t, f(\mathbf{x}))$

（續下頁）

英文	中文	簡要說明
expected loss	期望損失	$\mathbb{E}[L] = \int\int L\, p(\mathbf{x}, t)\, \mathrm{d}\mathbf{x}\, \mathrm{d}t$
squared loss	平方損失	$L = \{f(\mathbf{x}) - t\}^2$
calculus of variations	變分法	對「函數」而非「參數」的最佳化
regression function	迴歸函數	條件平均 $\mathbb{E}[t \mid \mathbf{x}]$
conditional mean / median / mode	條件均值／中位數／眾數	L_2 ／ L_1 ／ L_0 損失下的最佳預測
Minkowski loss	Minkowski 損失	$L_q = \lvert f(\mathbf{x}) - t \rvert^q$
unimodal / multimodal	單峰／多峰	條件分布是否只有一個峰
inverse problem	逆問題	由結果反推原因，常有多峰條件分布
bias–variance trade-off	偏差–變異權衡	模型彈性與穩定性之間的取捨
frequentist / Bayesian	頻率學派／貝氏	點估計 + 系集平均／參數的後驗分布
point estimate	點估計	由資料得到參數的單一值
ensemble of data sets	資料集系集	偏差–變異分析中的思想實驗
(squared) bias	(平方)偏差	平均預測與迴歸函數的差距
variance	變異	個別資料集的預測繞平均的變動
noise (irreducible error)	雜訊(不可縮減誤差)	$\mathrm{var}[t \mid \mathbf{x}]$ 的平均，與模型無關

附錄 B　延伸閱讀與參考文獻

主要教材

- Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. 本講義之依據；全書電子版可於 https://www.bishopbook.com 免費閱讀。
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. 第 3 章「Linear Models for Regression」與本章對應，並額外包含**貝氏線性迴歸**、證據近似 (evidence approximation) 與等價核 (equivalent kernel)。
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer. 第 3 章：脊迴歸、LASSO、有效自由度與最小平方的統計性質。
- Deisenroth, M. P., Faisal, A. A., and Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press. SVD 與最小平方的線性代數基礎。

本章引用之文獻

- Rao, C. R. and Mitra, S. K. (1971). *Generalized Inverse of Matrices and Its Applications*. Wiley.
- Golub, G. H. and Van Loan, C. F. (1996). *Matrix Computations* (3rd ed.). Johns Hopkins University Press.
- Ogden, R. T. (1997). *Essential Wavelets for Statistical Applications and Data Analysis*. Birkhäuser.
- Mallat, S. (1999). *A Wavelet Tour of Signal Processing* (2nd ed.). Academic Press.
- Vidakovic, B. (1999). *Statistical Modeling by Wavelets*. Wiley.

建議延伸閱讀

- Widrow, B. and Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, 96–104.(LMS 演算法的原始文獻)

- Haykin, S. (2014). *Adaptive Filter Theory* (5th ed.). Pearson.（LMS、RLS 與 Kalman 濾波器的統一觀點，對應 §4.1.5 補充）
- Geman, S., Bienenstock, E., and Doursat, R. (1992). Neural networks and the bias/variance dilemma. *Neural Computation* 4, 1–58.（偏差–變異分解在神經網路中的經典討論）
- Belkin, M., Hsu, D., Ma, S., and Mandal, S. (2019). Reconciling modern machine-learning practice and the classical bias–variance trade-off. *PNAS* 116, 15849–15854.（雙重下降）
- Huber, P. J. (1964). Robust estimation of a location parameter. *Annals of Mathematical Statistics* 35, 73–101.（穩健損失函數，對應 §4.2 補充）

——第四章完——

下一章：單層網路：分類（*Single-Layer Networks: Classification*）——把本章的框架平行地搬到離散目標變數上。