深度學習講義

第五章　單層網路：分類

Chapter 5: Single-Layer Networks: Classification

授課教師：王和盛　國立臺灣海洋大學通訊與導航工程學系

講義依據 C. M. Bishop & H. Bishop, *Deep Learning: Foundations and Concepts* (Springer, 2024) 第五章整理

版本：2026 年 8 月 31 日

本章學習目標

1. 理解分類問題的三種取徑——**判別函數**、**生成式機率模型**、**判別式機率模型**——及其優缺點與適用時機。
2. 掌握線性判別函數的幾何（權重向量決定方向、偏置決定位置、$y(\mathbf{x})/\|\mathbf{w}\|$ 為帶號距離）、多類別判別的歧義區問題，以及最小平方分類法對離群值不穩健的原因。
3. 以決策論分析分類：最小錯誤分類率準則、損失矩陣與期望損失、拒絕選項、混淆矩陣與精確率／召回率／ ROC 曲線／ AUC ／ F 分數。
4. 推導生成式分類器：共用共變異數的高斯類別條件密度導出 S 形／ softmax 作用在 $\mathbf{x}$ 之線性函數上的後驗機率，並以最大概似求出 π、$\boldsymbol{\mu}_k$、$\boldsymbol{\Sigma}$；理解指數族的一般結果與樸素貝氏模型。
5. 推導判別式分類器：邏輯迴歸與交叉熵誤差、梯度 $\sum_n (y_n - t_n)\boldsymbol{\phi}_n$ 的簡潔形式、多類別 softmax 迴歸、probit 迴歸，以及典則連結函數的一般理論。

目次

引言：分類問題的三種取徑 **2**

5.1 判別函數 **3**
5.1.1 兩類別 . . . 3
5.1.2 多類別 . . . 4
5.1.3 1-of-K 編碼 . . . 4
5.1.4 用最小平方做分類？ . . . 5

5.2 決策論 **6**
5.2.1 錯誤分類率 . . . 7
5.2.2 期望損失 . . . 7
5.2.3 拒絕選項 . . . 8
5.2.4 推論與決策 . . . 8
5.2.5 分類器的準確度 . . . 10
5.2.6 ROC 曲線 . . . 11

5.3 生成式分類器 **12**
5.3.1 連續輸入 . . . 13
5.3.2 最大概似解 . . . 14

5.3.3 離散特徵 15
5.3.4 指數族 16

5.4 判別式分類器 **16**
5.4.1 激活函數 16
5.4.2 固定基底函數 17
5.4.3 邏輯迴歸 17
5.4.4 多類別邏輯迴歸 19
5.4.5 Probit 迴歸 20
5.4.6 典則連結函數 21

課後習題 **22**

附錄 A 中英名詞對照表 **26**

附錄 B 延伸閱讀與參考文獻 **27**

引言：分類問題的三種取徑

上一章探討了一類迴歸模型：輸出變數是模型參數的線性函數，因此可表示為只有單層權重與偏置參數的簡單神經網路。本章轉向**分類**問題，聚焦於一類同樣可表示為單層神經網路的模型。它們讓我們在處理更一般的深度神經網路之前，先引入分類的許多關鍵觀念。

分類的目標是：把輸入向量 $\mathbf{x} \in \mathbb{R}^D$ 指派到 K 個離散類別 $\mathcal{C}_k$（$k = 1, \ldots, K$）之一。最常見的情境中，各類別**互斥**，每個輸入恰好被指派到一個類別；輸入空間因此被劃分為**決策區域**（decision regions），其邊界稱為**決策邊界**（decision boundaries）或**決策面**。本章考慮**線性**分類模型：決策面是輸入向量 $\mathbf{x}$ 的線性函數，即 D 維輸入空間中的 $(D-1)$ 維超平面。類別可被線性決策面精確分開的資料集稱為**線性可分**（linearly separable）；線性分類模型也可用於不可線性分離的資料集，只是無法把所有輸入都分對。

解決分類問題的三種取徑

1. **判別函數**（discriminant function）：直接建構一個把 $\mathbf{x}$ 指派到特定類別的函數，機率完全不出現。（§5.1）
2. **生成式機率模型**（generative probabilistic model）：對類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$ 與先驗 $p(\mathcal{C}_k)$ 建模，再用貝氏定理
$$p(\mathcal{C}_k \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \mathcal{C}_k)\, p(\mathcal{C}_k)}{p(\mathbf{x})} \tag{5.1}$$
計算後驗機率。名稱由來：可以從 $p(\mathbf{x} \mid \mathcal{C}_k)$ **生成**輸入空間中的合成樣本。（§5.3）
3. **判別式機率模型**（discriminative probabilistic model）：在推論階段**直接**以參數化模型表示 $p(\mathcal{C}_k \mid \mathbf{x})$，用訓練集最佳化參數。（§5.4）

把「推論」與「決策」分開處理（§5.2.4）帶來許多好處；本章對三種取徑都會給出實例。

5.1 判別函數

判別函數接受輸入向量 $\mathbf{x}$，將其指派到 K 個類別 $\mathcal{C}_k$ 之一。本章只討論**線性判別函數**——決策面為超平面者。先考慮兩類別，再推廣到 $K > 2$。

5.1.1 兩類別

線性判別函數最簡單的表示，是取輸入向量的線性函數

$$y(\mathbf{x}) = \mathbf{w}^{\mathsf{T}}\mathbf{x} + w_0, \tag{5.2}$$

其中 $\mathbf{w}$ 稱為**權重向量**，w_0 稱為**偏置**（bias；勿與統計意義的偏差混淆）。若 $y(\mathbf{x}) \geq 0$ 則把 $\mathbf{x}$ 指派到 $\mathcal{C}_1$，否則指派到 $\mathcal{C}_2$。對應的決策邊界由 $y(\mathbf{x}) = 0$ 定義，是 D 維輸入空間中的 $(D-1)$ 維超平面。

考慮同在決策面上的兩點 $\mathbf{x}_A$、$\mathbf{x}_B$：由 $y(\mathbf{x}_A) = y(\mathbf{x}_B) = 0$ 得 $\mathbf{w}^{\mathsf{T}}(\mathbf{x}_A - \mathbf{x}_B) = 0$，故 $\mathbf{w}$ **正交於決策面內的每個向量**——$\mathbf{w}$ 決定決策面的**方向**。同理，若 $\mathbf{x}$ 在決策面上則 $y(\mathbf{x}) = 0$，故原點到決策面的法向距離為

$$\frac{\mathbf{w}^{\mathsf{T}}\mathbf{x}}{\|\mathbf{w}\|} = -\frac{w_0}{\|\mathbf{w}\|}. \tag{5.3}$$

因此偏置 w_0 決定決策面的**位置**。更進一步，$y(\mathbf{x})$ 的值給出點 $\mathbf{x}$ 到決策面之垂直距離 r 的**帶號**度量：設 $\mathbf{x}_\perp$ 為 $\mathbf{x}$ 在決策面上的正交投影，則

$$\mathbf{x} = \mathbf{x}_\perp + r\,\frac{\mathbf{w}}{\|\mathbf{w}\|}. \tag{5.4}$$

兩邊同乘 $\mathbf{w}^{\mathsf{T}}$ 並加上 w_0，利用 $y(\mathbf{x}) = \mathbf{w}^{\mathsf{T}}\mathbf{x} + w_0$ 與 $y(\mathbf{x}_\perp) = 0$，得

$$r = \frac{y(\mathbf{x})}{\|\mathbf{w}\|}. \tag{5.5}$$

這些性質在 $D = 2$ 的情形如圖 5.1 所示。

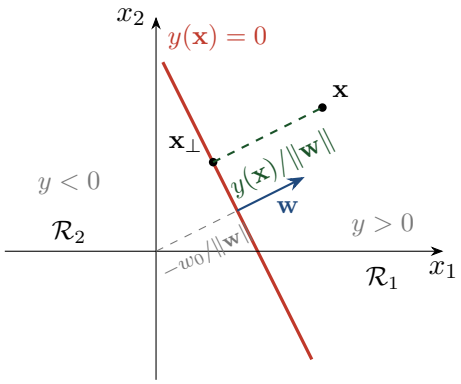


圖 5.1: 二維線性判別函數的幾何。決策面（紅線）垂直於 $\mathbf{w}$，其相對原點的位移由偏置參數 w_0 控制；一般點 $\mathbf{x}$ 到決策面的帶號正交距離為 $y(\mathbf{x})/\|\mathbf{w}\|$。

如同線性迴歸模型，有時使用更精簡的記號較方便：引入虛擬「輸入」$x_0 = 1$，定義 $\widetilde{\mathbf{w}} = (w_0, \mathbf{w})$、$\widetilde{\mathbf{x}} = (x_0, \mathbf{x})$，則

$$y(\mathbf{x}) = \widetilde{\mathbf{w}}^{\mathsf{T}}\widetilde{\mathbf{x}}. \tag{5.6}$$

此時決策面是通過 $(D+1)$ 維擴充輸入空間**原點**的 D 維超平面。

5.1.2 多類別

現在把線性判別函數推廣到 $K > 2$ 類。我們可能想用若干個兩類判別函數拼出 K 類判別器，但這會導致嚴重的困難（Duda and Hart, 1973）：

- **一對其餘**（one-versus-the-rest）：用 $K-1$ 個分類器，各自分開「屬於 $\mathcal{C}_k$」與「不屬於 $\mathcal{C}_k$」的點。如圖 5.2 左，三類的例子中會出現**歧義區域**（同時被判給多類、或不被判給任何類）。
- **一對一**（one-versus-one）：對每一對類別引入一個二元判別函數，共 $K(K-1)/2$ 個，再以多數決分類。如圖 5.2 右，同樣出現歧義區域。

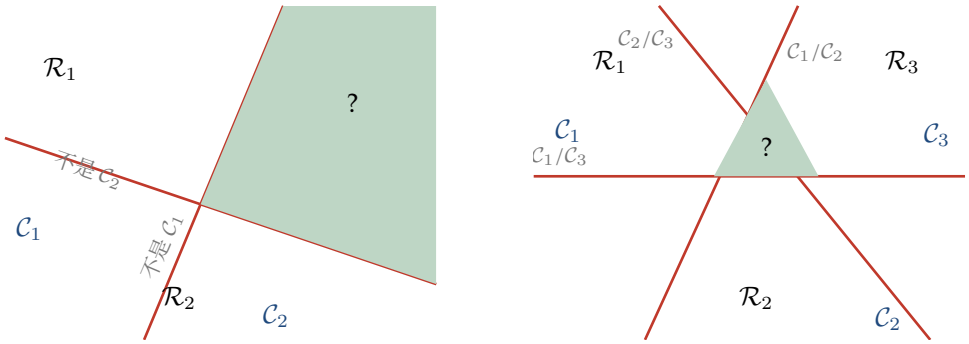


圖 5.2: 以多個兩類判別函數拼湊 K 類判別器會產生歧義區域（綠色）。左：兩個「一對其餘」判別函數（各自分開 $\mathcal{C}_k$ 與非 $\mathcal{C}_k$）的例子；右：三個「一對一」判別函數（各自分開一對類別）的例子。

避免這些困難的方法，是考慮**單一的 K 類判別器**，由 K 個線性函數

$$y_k(\mathbf{x}) = \mathbf{w}_k^{\mathsf{T}}\mathbf{x} + w_{k0} \tag{5.7}$$

組成，並把點 $\mathbf{x}$ 指派到滿足「$y_k(\mathbf{x}) > y_j(\mathbf{x})$，對所有 $j \neq k$」的類別 $\mathcal{C}_k$。類別 $\mathcal{C}_k$ 與 $\mathcal{C}_j$ 之間的決策邊界由 $y_k(\mathbf{x}) = y_j(\mathbf{x})$ 給出，對應超平面

$$(\mathbf{w}_k - \mathbf{w}_j)^{\mathsf{T}}\mathbf{x} + (w_{k0} - w_{j0}) = 0, \tag{5.8}$$

與兩類情形的決策邊界同形，因此類似的幾何性質都適用。

推導 (決策區域是單連通且凸的). 設 $\mathbf{x}_A, \mathbf{x}_B$ 都在決策區域 $\mathcal{R}_k$ 內，考慮連線上任一點 $\hat{\mathbf{x}} = \lambda\mathbf{x}_A + (1-\lambda)\mathbf{x}_B (0 \le \lambda \le 1)$。由判別函數的線性，

$$y_k(\hat{\mathbf{x}}) = \lambda\, y_k(\mathbf{x}_A) + (1-\lambda)\, y_k(\mathbf{x}_B). \tag{5.9}$$

因 $\mathbf{x}_A, \mathbf{x}_B \in \mathcal{R}_k$，對所有 $j \neq k$ 有 $y_k(\mathbf{x}_A) > y_j(\mathbf{x}_A)$ 且 $y_k(\mathbf{x}_B) > y_j(\mathbf{x}_B)$，故 $y_k(\hat{\mathbf{x}}) > y_j(\hat{\mathbf{x}})$，即 $\hat{\mathbf{x}} \in \mathcal{R}_k$。所以 $\mathcal{R}_k$ 是**凸集**，自然也單連通。（注意：兩類時可以用這裡的 y_1, y_2 兩個函數，也可以用等價且更簡單的單一判別函數 $y(\mathbf{x}) = y_1(\mathbf{x}) - y_2(\mathbf{x})$。）

5.1.3 1-of-K 編碼

迴歸問題中，目標變數 $\mathbf{t}$ 就是要預測的實數向量；分類問題中，則有多種以目標值表示類別標籤的方式。兩類問題最方便的是**二元表示**：單一目標變數 $t \in \{0, 1\}$，$t = 1$ 代表 $\mathcal{C}_1$、$t = 0$ 代表 $\mathcal{C}_2$；可把 t 的值詮釋為「類別是 $\mathcal{C}_1$」的機率，只是機率只取 0 與 1 兩個極端值。$K > 2$ 類時，方便的是

1-of-K 編碼（又稱**獨熱編碼**，one-hot encoding）：$\mathbf{t}$ 是長度 K 的向量，若類別為 $\mathcal{C}_j$，則除了第 j 個元素 $t_j = 1$ 之外全為零。例如 $K = 5$ 類時，來自第 2 類的資料點之目標向量為

$$\mathbf{t} = (0, 1, 0, 0, 0)^{\mathsf{T}}. \tag{5.10}$$

同樣可把 t_k 詮釋為「類別是 $\mathcal{C}_k$」的機率。

5.1.4 用最小平方做分類？

線性迴歸模型中，最小化平方和誤差有簡單的閉式解（§4.1.3），因此我們很想把同一套最小平方方法用到分類上。考慮 K 類、目標向量採 1-of-K 編碼的一般分類問題。一個理由是：最小平方近似的是給定輸入下目標值的條件期望 $\mathbb{E}[\mathbf{t} \mid \mathbf{x}]$，而在二元編碼下，此條件期望正是後驗類別機率向量（習題 1）。不幸的是，這些機率通常近似得很差，甚至可能落在 $(0, 1)$ 之外。不過，研究這些簡單模型並理解限制從何而來，仍然很有啟發性。

每個類別 $\mathcal{C}_k$ 有自己的線性模型 $y_k(\mathbf{x}) = \mathbf{w}_k^{\mathsf{T}}\mathbf{x} + w_{k0} (k = 1, \ldots, K)$，合寫成

$$\mathbf{y}(\mathbf{x}) = \widetilde{\mathbf{W}}^{\mathsf{T}}\tilde{\mathbf{x}}, \tag{5.11}$$

其中 $\widetilde{\mathbf{W}}$ 的第 k 行是 $(D+1)$ 維向量 $\tilde{\mathbf{w}}_k = (w_{k0}, \mathbf{w}_k^{\mathsf{T}})^{\mathsf{T}}$，$\tilde{\mathbf{x}} = (1, \mathbf{x}^{\mathsf{T}})^{\mathsf{T}}$ 為擴充輸入向量。新輸入 $\mathbf{x}$ 被指派到輸出 $y_k = \tilde{\mathbf{w}}_k^{\mathsf{T}}\tilde{\mathbf{x}}$ 最大的類別。

以最小化平方和誤差決定參數矩陣 $\widetilde{\mathbf{W}}$：對訓練集 $\{\mathbf{x}_n, \mathbf{t}_n\}$，令 $\mathbf{T}$ 的第 n 列為 $\mathbf{t}_n^{\mathsf{T}}$、$\widetilde{\mathbf{X}}$ 的第 n 列為 $\tilde{\mathbf{x}}_n^{\mathsf{T}}$，則

$$E_D(\widetilde{\mathbf{W}}) = \frac{1}{2}\,\mathrm{Tr}\Big\{(\widetilde{\mathbf{X}}\widetilde{\mathbf{W}} - \mathbf{T})^{\mathsf{T}}(\widetilde{\mathbf{X}}\widetilde{\mathbf{W}} - \mathbf{T})\Big\}. \tag{5.12}$$

令對 $\widetilde{\mathbf{W}}$ 的導數為零並整理（與 §4.1.7 相同的計算），得

$$\widetilde{\mathbf{W}} = (\widetilde{\mathbf{X}}^{\mathsf{T}}\widetilde{\mathbf{X}})^{-1}\widetilde{\mathbf{X}}^{\mathsf{T}}\mathbf{T} = \widetilde{\mathbf{X}}^{\dagger}\mathbf{T}, \tag{5.13}$$

其中 $\widetilde{\mathbf{X}}^{\dagger}$ 是 $\widetilde{\mathbf{X}}$ 的偽反矩陣。判別函數即為

$$\mathbf{y}(\mathbf{x}) = \widetilde{\mathbf{W}}^{\mathsf{T}}\tilde{\mathbf{x}} = \mathbf{T}^{\mathsf{T}}\big(\widetilde{\mathbf{X}}^{\dagger}\big)^{\mathsf{T}}\tilde{\mathbf{x}}. \tag{5.14}$$

多目標最小平方解有一個有趣的性質：若訓練集中每個目標向量都滿足某個線性約束 $\mathbf{a}^{\mathsf{T}}\mathbf{t}_n + b = 0$（$\mathbf{a}, b$ 為常數），則模型對任何 $\mathbf{x}$ 的預測也滿足同一約束 $\mathbf{a}^{\mathsf{T}}\mathbf{y}(\mathbf{x}) + b = 0$（習題 3）。因此，若對 K 類使用 1-of-K 編碼，模型預測的元素對任何 $\mathbf{x}$ 都**加總為 1**。然而，僅有加總約束並不足以把模型輸出詮釋為機率，因為輸出並未被限制在 $(0, 1)$ 之內。

最小平方分類的致命弱點：不穩健

最小平方給出判別函數參數的精確閉式解，但即使只把它當判別函數用（直接做決策、不做機率詮釋），它仍有嚴重的問題。平方和誤差函數可視為**高斯**雜訊假設下的負對數概似（§2.3.4）；若資料的真實分布與高斯相去甚遠，最小平方就可能表現不佳。特別是，最小平方對**離群值**（遠離資料主體的資料點）非常敏感，如圖 5.3 所示：右圖額外加入的資料點使決策邊界大幅移動，儘管這些點本來就會被左圖的原始邊界正確分類。平方和誤差對「離決策邊界很遠、卻已被正確分類」的點給了過大的權重。離群值可能來自罕見事件，也可能只是資料集中的錯誤；對極少數資料點敏感的技術稱為**缺乏穩健性**（lack robustness）。相比之下，§5.4.3 的**邏輯迴歸**對離群值穩健得多。回想二元目標向量的分布顯然遠非高斯，最小平方的失敗並不意

外；採用更合適的機率模型，可以得到性質好得多的分類技術，並能推廣為靈活的非線性神經網路模型。

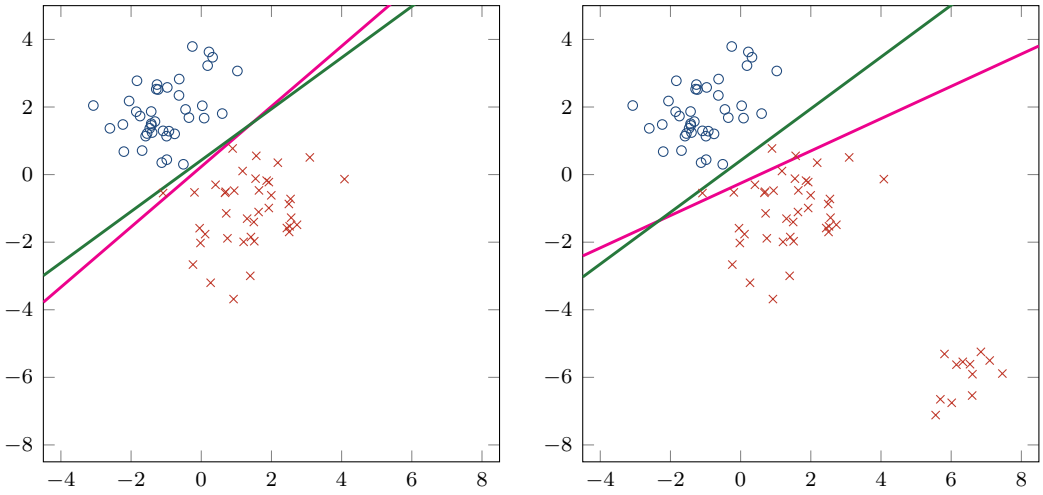


圖 5.3: 左圖：兩類資料（紅叉與藍圈）以及最小平方（洋紅線）與邏輯迴歸模型（綠線）找到的決策邊界。右圖：在右下方加入額外資料點後的結果——最小平方對離群值高度敏感，邏輯迴歸則不然。（本圖依原書程序以模擬資料重製。）

教學補充：「分對還被懲罰」的直觀解釋

最小平方要求 $y_k(\mathbf{x}_n)$ 精確等於 0 或 1。離群的紅叉雖在邊界正確的一側，但其 $y(\mathbf{x})$ 值遠大於 1，平方誤差 $\{y(\mathbf{x}_n)-1\}^2$ 巨大，於是邊界被「拉」過去壓低這些值。邏輯迴歸把輸出先壓進 $(0,1)$（S 形函數飽和），分對且離邊界遠的點誤差趨近零，自然不受影響。同樣的病徵也出現在通訊系統：若把接收訊號的軟值直接做最小平方擬合硬標籤，強訊號樣本反而主導估計；正確做法正是本章的機率式（對數概似）建模。

5.2　決策論

討論線性迴歸時，我們看到機器學習的預測過程可拆成**推論**與**決策**兩個階段（§4.2）。現在專門就分類器，更深入地探討這個觀點。

設輸入向量 $\mathbf{x}$ 有對應的目標變數向量 $\mathbf{t}$，目標是在給定新的 $\mathbf{x}$ 時預測 $\mathbf{t}$。迴歸問題中 $\mathbf{t}$ 是連續變數；分類問題中 $\mathbf{t}$ 代表類別標籤。聯合機率分布 $p(\mathbf{x},\mathbf{t})$ 完整地總結了這些變數的不確定性；從訓練資料決定 $p(\mathbf{x},\mathbf{t})$ 是**推論**的例子，通常非常困難，也是本書大半的主題。但實際應用中，我們常必須對 $\mathbf{t}$ 做出特定預測、或依據對 $\mathbf{t}$ 的理解採取特定行動——這就是**決策論**的主題。

以第一章的醫療診斷為例：$\mathbf{x}$ 是皮膚病灶影像的像素強度，輸出變數 t 表示無癌（類別 $\mathcal{C}_1$，$t=0$）或有癌（類別 $\mathcal{C}_2$，$t=1$）。推論問題是決定聯合分布 $p(\mathbf{x},\mathcal{C}_k)$；但最終必須**決定**治療或不治療，且希望這個選擇依某個適當準則是最佳的（Duda and Hart, 1973）。決策論的目的，就是在給定適當機率後告訴我們如何做最佳決策——而一旦推論問題已解，決策階段通常非常簡單，甚至平凡。取得新影像 $\mathbf{x}$ 後，我們關心的是給定影像下兩類別的機率 $p(\mathcal{C}_k\mid\mathbf{x})$，由貝氏定理

$$p(\mathcal{C}_k\mid\mathbf{x})=\frac{p(\mathbf{x}\mid\mathcal{C}_k)\,p(\mathcal{C}_k)}{p(\mathbf{x})} \tag{5.15}$$

表示。$p(\mathcal{C}_k)$ 是類別 $\mathcal{C}_k$ 的**先驗機率**（拍攝影像**之前**一個人有癌的機率），$p(\mathcal{C}_k\mid\mathbf{x})$ 是根據影像資訊

以貝氏定理修正後的**後驗機率**。直覺上，若要最小化把 $\mathbf{x}$ 分錯類的機會，應選後驗機率較高的類別——以下說明這個直覺是正確的，並討論更一般的決策準則。

5.2.1 錯誤分類率

假設目標就是盡量少犯錯。我們需要一條把每個 $\mathbf{x}$ 指派到某類別的規則；它把輸入空間劃分成決策區域 $\mathcal{R}_k$（每個類別一個，區域不必連通）。先看兩類的情形：錯誤發生在「屬於 $\mathcal{C}_1$ 的輸入被指派到 $\mathcal{C}_2$」或反之，其機率為

$$\begin{aligned} p(\text{mistake}) &= p(\mathbf{x} \in \mathcal{R}_1, \mathcal{C}_2) + p(\mathbf{x} \in \mathcal{R}_2, \mathcal{C}_1) \\ &= \int_{\mathcal{R}_1} p(\mathbf{x}, \mathcal{C}_2)\, \mathrm{d}\mathbf{x} + \int_{\mathcal{R}_2} p(\mathbf{x}, \mathcal{C}_1)\, \mathrm{d}\mathbf{x}. \end{aligned} \tag{5.16}$$

我們可自由選擇決策規則。顯然，要最小化 $p(\text{mistake})$，應把每個 $\mathbf{x}$ 指派到 (5.16) 中被積函數較**小**的那一類：若 $p(\mathbf{x}, \mathcal{C}_1) > p(\mathbf{x}, \mathcal{C}_2)$ 則指派給 $\mathcal{C}_1$。由乘法規則 $p(\mathbf{x}, \mathcal{C}_k) = p(\mathcal{C}_k \mid \mathbf{x}) p(\mathbf{x})$，共同因子 $p(\mathbf{x})$ 可消去，故**最小錯誤分類機率的規則，是把每個 $\mathbf{x}$ 指派到後驗機率 $p(\mathcal{C}_k \mid \mathbf{x})$ 最大的類別**。此結果對單一輸入變數 x 的圖示見圖 5.4。

對更一般的 K 類，最大化「分對」的機率稍微容易些：

$$p(\text{correct}) = \sum_{k=1}^{K} p(\mathbf{x} \in \mathcal{R}_k, \mathcal{C}_k) = \sum_{k=1}^{K} \int_{\mathcal{R}_k} p(\mathbf{x}, \mathcal{C}_k)\, \mathrm{d}\mathbf{x}, \tag{5.17}$$

它在「每個 $\mathbf{x}$ 被指派到 $p(\mathbf{x}, \mathcal{C}_k)$ 最大的類別」時最大。再次消去共同因子 $p(\mathbf{x})$，結論同樣是：**把每個 $\mathbf{x}$ 指派到後驗機率最大的類別**。

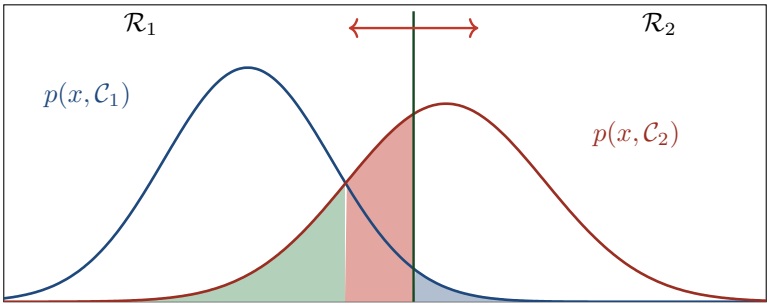


圖 5.4: 兩類的聯合機率 $p(x, \mathcal{C}_k)$ 對 x 的示意圖，決策邊界為 $x = \hat{x}$：$x \geq \hat{x}$ 分到 $\mathcal{C}_2$（區域 $\mathcal{R}_2$），$x < \hat{x}$ 分到 $\mathcal{C}_1$（區域 $\mathcal{R}_1$）。錯誤來自藍、綠、紅三塊區域：$x < \hat{x}$ 的錯誤是 $\mathcal{C}_2$ 的點被誤分為 $\mathcal{C}_1$（紅 + 綠），$x \geq \hat{x}$ 的錯誤是 $\mathcal{C}_1$ 的點被誤分為 $\mathcal{C}_2$（藍）。移動 $\hat{x}$（紅色雙箭頭）時，藍 + 綠的合計面積不變，只有紅色區域會變；當 $\hat{x}$ 取在兩曲線交點 x_0（紅色區域消失）時錯誤最小——這等價於「指派給後驗機率較大的類別」的最小錯誤分類率規則。

5.2.2 期望損失

許多應用的目標比「錯最少」更複雜。回到醫療診斷：把**健康**的人誤診為有癌，代價是精神壓力與後續檢查；把**有癌**的人誤診為健康，代價可能是因延誤治療而過早死亡。兩種錯誤的後果天差地遠，寧可多犯第一種錯，也要少犯第二種。

這類考量可用**損失函數**（loss function，又稱成本函數）形式化：它是對所有可用決策所生損失的單一整體度量，目標是使總損失最小。（有些作者用**效用函數**並使其最大化；若效用取為損失的負值，兩者等價。）設 $\mathbf{x}$ 的真實類別為 $\mathcal{C}_k$，而我們把它指派到 $\mathcal{C}_j$（j 可能等於 k），因此招致的

損失記為 L_{kj}——**損失矩陣**(loss matrix)的第 (k,j) 元素。例如癌症問題的損失矩陣可取為

$$\mathbf{L} = \begin{array}{c} \\ \text{實為正常} \\ \text{實為癌症} \end{array} \begin{array}{c} \begin{array}{cc} \text{判為正常} & \text{判為癌症} \end{array} \\ \begin{pmatrix} 0 & 1 \\ 100 & 0 \end{pmatrix} \end{array}, \tag{5.18}$$

意即：判斷正確不受損失；健康被誤診為癌損失 1；有癌被誤診為健康損失 100。

最佳解是使損失函數最小者，但損失取決於**未知**的真實類別。對給定的 $\mathbf{x}$，真實類別的不確定性由聯合分布 $p(\mathbf{x}, \mathcal{C}_k)$ 表達，因此我們改為最小化**平均(期望)損失**

$$\mathbb{E}[L] = \sum_k \sum_j \int_{\mathcal{R}_j} L_{kj}\, p(\mathbf{x}, \mathcal{C}_k)\, \mathrm{d}\mathbf{x}. \tag{5.19}$$

每個 $\mathbf{x}$ 可獨立指派到某個決策區域 $\mathcal{R}_j$；要最小化 (5.19)，對每個 $\mathbf{x}$ 應最小化 $\sum_k L_{kj}\, p(\mathbf{x}, \mathcal{C}_k)$。同樣用乘法規則消去共同因子 $p(\mathbf{x})$，得：**最小期望損失的決策規則，是把每個新 $\mathbf{x}$ 指派到使**

$$\sum_k L_{kj}\, p(\mathcal{C}_k \mid \mathbf{x}) \tag{5.20}$$

最小的類別 j。一旦選定損失矩陣的元素，這顯然是件很容易做的事。

5.2.3 拒絕選項

分類錯誤來自「最大後驗機率 $p(\mathcal{C}_k \mid \mathbf{x})$ 明顯小於 1」(等價地，聯合分布 $p(\mathbf{x}, \mathcal{C}_k)$ 之值彼此相當)的輸入空間區域——也就是我們對類別歸屬相對不確定的區域。某些應用中，對困難的案例**避免做決策**是恰當的，以期在「有做出分類決策」的樣本上獲得更低的錯誤率——這稱為**拒絕選項**(reject option)。例如在癌症篩檢中，可以讓自動系統只分類把握很大的影像，把較曖昧的案例交給切片檢查。做法是引入閾值 θ，**拒絕**最大後驗機率 $\leq \theta$ 的那些輸入 $\mathbf{x}$(圖 5.5)。$\theta = 1$ 時所有樣本都被拒絕；K 類時 $\theta < 1/K$ 則沒有樣本被拒絕——被拒絕的樣本比例由 θ 控制。給定損失矩陣時，拒絕準則也可輕易推廣為最小化期望損失、並計入做出拒絕決策本身的損失(習題 7)。

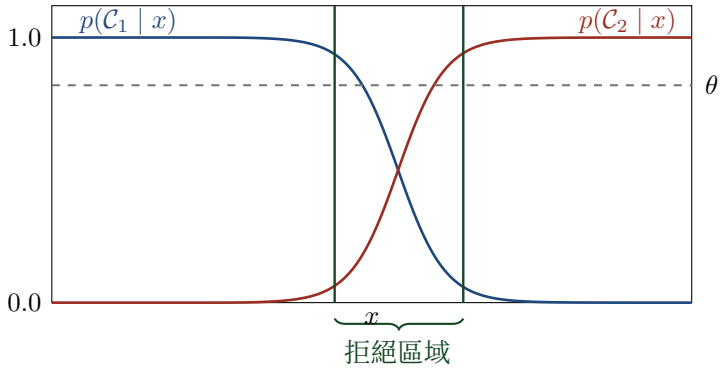


圖 5.5: 拒絕選項的圖示：兩個後驗機率中較大者 $\leq$ 某閾值 θ 的輸入 x 會被拒絕。

5.2.4 推論與決策

我們把分類問題拆成**推論階段**(用訓練資料學得 $p(\mathcal{C}_k \mid \mathbf{x})$ 的模型)與**決策階段**(用後驗機率做最佳類別指派)。另一種可能是把兩個問題一起解掉：直接學一個把輸入映到決策的函數——即判別函數。實務上三種取徑(依複雜度遞減)都有人用：

三種取徑的比較

(a) **生成式**：先對每個類別分別解出類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$，另外推論先驗 $p(\mathcal{C}_k)$，再用貝氏定理 (5.15) 求後驗（分母由 $p(\mathbf{x}) = \sum_k p(\mathbf{x} \mid \mathcal{C}_k)p(\mathcal{C}_k)$ 取得），最後用決策論分類。**最費事**：要找 $\mathbf{x}$ 與 $\mathcal{C}_k$ 的聯合分布，$\mathbf{x}$ 維度高時需要很大的訓練集；但**附帶得到** $p(\mathbf{x})$，可用於**離群偵測**（novelty detection，Bishop, 1994；Tarassenko, 1995）——找出模型下機率很低、預測可能不準的新資料點。

(b) **判別式**：直接推論後驗 $p(\mathcal{C}_k \mid \mathbf{x})$，再用決策論。若只是要分類，找完整聯合分布是浪費——類別條件密度可能包含大量**對後驗機率毫無影響**的結構（圖 5.6）。生成式與判別式的取捨與結合是研究熱點（Jebara, 2004；Lasserre, Bishop, and Minka, 2006）。

(c) **判別函數**：找函數 $f(\mathbf{x})$ 直接把輸入映到類別標籤，推論與決策合併成單一學習問題，機率完全不出現。**最簡單**，但失去後驗機率帶來的所有好處（見下）。

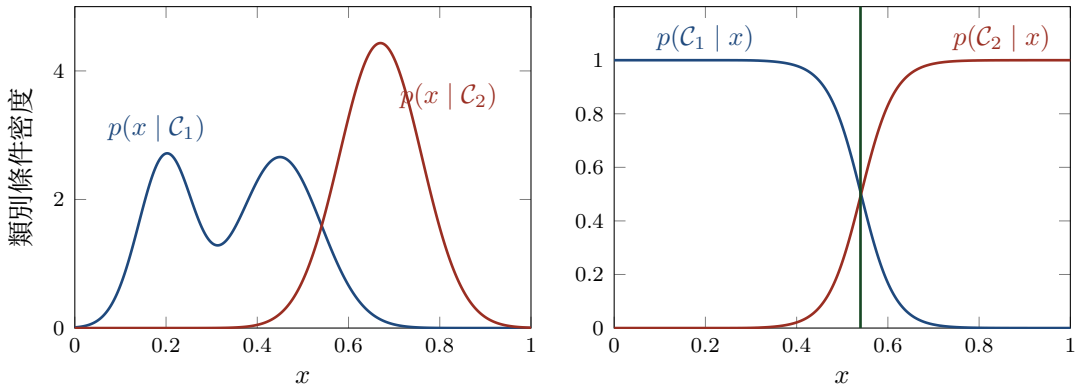


圖 5.6: 單一輸入變數 x 之兩類別的類別條件密度（左）與對應的後驗機率（右）。注意左圖 $p(x \mid \mathcal{C}_1)$（藍）左邊的峰對後驗機率**毫無影響**；右圖綠色垂直線是（先驗相等時）給出最小錯誤分類率的決策邊界。

為什麼仍想要後驗機率？ 即使最終只是拿來做決策，仍有許多強烈的理由要計算 $p(\mathcal{C}_k \mid \mathbf{x})$：

- **風險最小化**：若損失矩陣會不時修訂（如金融應用），有了後驗機率，只需修改 (5.20) 就能立刻更新最小風險準則；只有判別函數的話，損失矩陣一變就得回訓練資料重解推論問題。
- **拒絕選項**：後驗機率讓我們對給定的拒絕比例，決定使錯誤分類率（或期望損失）最小的拒絕準則。
- **補償類別先驗**：癌症篩檢中，若從一般人口收集訓練影像，可能 1,000 張中只有 1 張是癌症。用這種資料訓練會有嚴重困難——把所有點都判為正常就有 99.9% 準確率，模型很難跳出這個平凡解；而且即使資料集很大，癌症影像的樣本仍太少，難以泛化。較好的做法是用各類數量相等的**平衡**資料集訓練，再**補償**我們對訓練資料的修改：由貝氏定理 (5.15)，後驗機率正比於先驗機率（各類點數的比例），因此把平衡資料集得到的後驗**除以**該資料集中的類別比例、再**乘以**目標人口中的類別比例，最後重新正規化使其總和為一即可。這套程序若學的是判別函數而非後驗機率，就無法套用。
- **模型結合**：複雜應用可把問題拆成若干子問題，各自用一個模組處理。例如除皮膚影像 $\mathbf{x}_I$ 外還有血液檢查資料 $\mathbf{x}_B$：與其把異質資訊塞進一個巨大的輸入空間，不如各建一個系統。若兩個模型都輸出類別後驗機率，就能用機率規則系統性地結合輸出。最簡單的方式是假設對每

個類別，影像與血液資料**條件獨立**：

$$p(\mathbf{x}_I, \mathbf{x}_B \mid \mathcal{C}_k) = p(\mathbf{x}_I \mid \mathcal{C}_k)\, p(\mathbf{x}_B \mid \mathcal{C}_k), \tag{5.21}$$

則同時給定兩者的後驗為

$$p(\mathcal{C}_k \mid \mathbf{x}_I, \mathbf{x}_B) \;\propto\; p(\mathbf{x}_I \mid \mathcal{C}_k)\, p(\mathbf{x}_B \mid \mathcal{C}_k)\, p(\mathcal{C}_k) \;\propto\; \frac{p(\mathcal{C}_k \mid \mathbf{x}_I)\, p(\mathcal{C}_k \mid \mathbf{x}_B)}{p(\mathcal{C}_k)}, \tag{5.22}$$

只需再以各類點數比例估計 $p(\mathcal{C}_k)$ 並正規化。條件獨立假設 (5.21) 是**樸素貝氏模型** (naive Bayes，§11.2.3) 的一例；注意聯合邊際 $p(\mathbf{x}_I, \mathbf{x}_B)$ 在此模型下通常**不**因子化。輸出機率（而非決策）的模型還有一個優點：容易對可調參數**可微分**，因而能以梯度式方法組合並聯合訓練 (Ch. 7)。

5.2.5 分類器的準確度

分類器最簡單的效能量度是測試集分類正確的比例。但不同類型的錯誤可以有不同後果（由損失矩陣表達），故我們常不只是想最小化錯誤分類的數目。藉由移動決策邊界，可以在不同種類的錯誤之間取捨。為了更好地刻畫分類器效能，先引入一些定義與術語。

以癌症篩檢為例。對每位受測者，有「是否有癌」的真實標籤，也有分類器的預測。若分類器預測有癌且屬實，稱為**真陽性** (true positive)；若該人其實沒有癌，則為**偽陽性** (false positive，又稱**型一錯誤**)。同樣地，預測沒有癌且正確稱為**真陰性** (true negative)，否則為**偽陰性** (false negative，**型二錯誤**)。以 N 為受測總人數，$N_{\mathrm{TP}}, N_{\mathrm{FP}}, N_{\mathrm{TN}}, N_{\mathrm{FN}}$ 分別為四種情形的數目，

$$N = N_{\mathrm{TP}} + N_{\mathrm{FP}} + N_{\mathrm{TN}} + N_{\mathrm{FN}}, \tag{5.23}$$

可整理成**混淆矩陣** (confusion matrix)：

$$\begin{array}{c} \\ \text{實為正常} \\ \text{實為癌症} \end{array} \begin{array}{c} \begin{array}{cc} \text{判為正常} & \text{判為癌症} \end{array} \\ \begin{pmatrix} N_{\mathrm{TN}} & N_{\mathrm{FP}} \\ N_{\mathrm{FN}} & N_{\mathrm{TP}} \end{pmatrix} \end{array}. \tag{5.24}$$

以正確分類比例度量的**準確率**為

$$\text{Accuracy} = \frac{N_{\mathrm{TP}} + N_{\mathrm{TN}}}{N_{\mathrm{TP}} + N_{\mathrm{FP}} + N_{\mathrm{TN}} + N_{\mathrm{FN}}}. \tag{5.25}$$

類別強烈不平衡時準確率會誤導：若 1,000 人只有 1 人有癌，「宣稱沒有人有癌」的分類器準確率 99.9%，卻毫無用處。由這些數字還可定義若干常見量：

$$\text{精確率 (Precision)} = \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FP}}} \qquad \text{陽性判定中真有癌的比例} \tag{5.26}$$

$$\text{召回率 (Recall)} = \frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}} + N_{\mathrm{FN}}} \qquad \text{有癌者被正確驗出的比例} \tag{5.27}$$

$$\text{偽陽性率 (False positive rate)} = \frac{N_{\mathrm{FP}}}{N_{\mathrm{FP}} + N_{\mathrm{TN}}} \qquad \text{正常人被判為有癌的比例} \tag{5.28}$$

$$\text{偽發現率 (False discovery rate)} = \frac{N_{\mathrm{FP}}}{N_{\mathrm{FP}} + N_{\mathrm{TP}}} \qquad \text{陽性判定中其實無癌的比例} \tag{5.29}$$

移動決策邊界即可改變兩類錯誤之間的取捨。回到圖 5.4 並把各區域標記為 A（$\mathcal{R}_1$ 內 $p(x, \mathcal{C}_1)$

在綠、紅區域以外的部分)、B($\mathcal{R}_2$ 內 $p(x,\mathcal{C}_2)$ 於藍色區域下方以外的部分)、C,E(紅、綠區域)、D($\mathcal{R}_2$ 內 $p(x,\mathcal{C}_2)$ 的主體)，可將各比例與這些面積聯繫起來(在 $N\to\infty$ 之極限下把觀測數目與機率對應)：N_{FP}/N 是 $\mathcal{R}_2$ 中來自 $\mathcal{C}_1$ 的機率質量、N_{TP}/N 是 $\mathcal{R}_2$ 中來自 $\mathcal{C}_2$ 者，依此類推。

5.2.6 ROC 曲線

機率式分類器輸出後驗機率，可設定閾值轉為決策。改變閾值時，可用型二錯誤的增加換取型一錯誤的減少，或反之。為了更好地理解此取捨，常畫**接收者操作特性曲線**(receiver operating characteristic, ROC；Fawcett, 2006——名稱源自雷達接收機效能量測的程序)：**真陽性率對偽陽性率**的圖形(圖 5.7)。

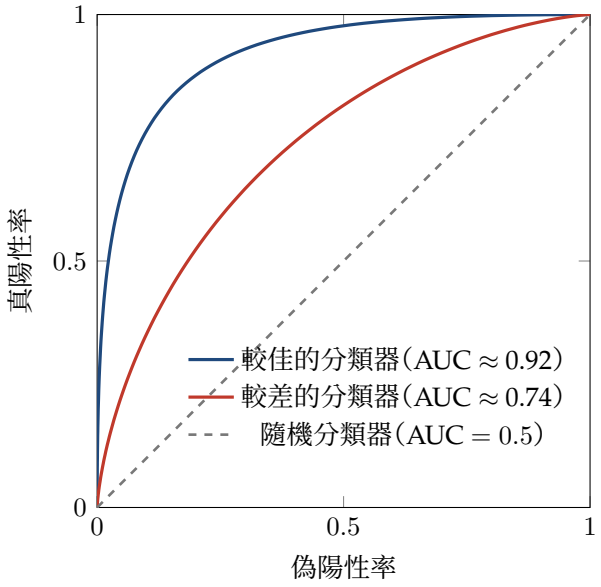


圖 5.7: ROC 曲線：真陽性率對偽陽性率的圖形，刻畫分類問題中型一與型二錯誤的取捨。上方藍色曲線代表比下方紅色曲線更好的分類器；虛線代表簡單隨機分類器的表現。(本圖由兩個單維高斯類別於不同分離度下實際計算。)

把決策邊界從 $-\infty$ 移到 ∞，就描出整條 ROC 曲線；一個特定的混淆矩陣對應曲線上的**一個點**。最佳的分類器對應左上角的點；左下角代表「把所有點都判為正常」(沒有真陽性也沒有偽陽性)，右上角代表「把所有點都判為癌症」(沒有偽陰性也沒有真陰性)。圖中藍色曲線在任何給定偽陽性率下都優於紅色曲線；但曲線也可能交叉，此時孰優取決於工作點的選擇。作為基準，考慮以機率 ρ 把每個點判為癌症的**隨機分類器**：改變 ρ 時它描出對角直線；落在對角線以下的分類器比隨機亂猜還差。

有時希望用單一數字刻畫整條 ROC 曲線。一種做法是**曲線下面積**(area under the curve, AUC)：0.5 代表隨機猜測，1.0 代表完美分類器。另一種度量是 **F 分數**——精確率與召回率的調和平均：

$$F=\frac{2\times\mathrm{precision}\times\mathrm{recall}}{\mathrm{precision}+\mathrm{recall}}=\frac{2N_{\mathrm{TP}}}{2N_{\mathrm{TP}}+N_{\mathrm{FP}}+N_{\mathrm{FN}}} \tag{5.30}$$

(習題 4)。當然，也可把混淆矩陣 (5.24) 與損失矩陣 (5.18) 逐元素相乘後加總，得到期望損失。ROC 曲線可推廣到兩類以上，但類別數一多很快變得繁瑣。

教學補充：ROC 的老家就是偵測理論

ROC 曲線來自二戰雷達：在雜訊中判定「有無目標」正是本節的兩類決策問題。通訊與導航中的譯名是**偵測機率** P_d（真陽性率）對**虛警機率** P_{fa}（偽陽性率），Neyman–Pearson 準則「固定 P_{fa} 最大化 P_d」等價於沿 ROC 曲線選定工作點；概似比檢定則是達成整條最佳 ROC 的檢定統計量——與本章「後驗機率最大」規則在等先驗下一致。GNSS 欺騙（spoofing）偵測、訊號捕獲（acquisition）門檻設定、頻譜感知，全都是在畫這條曲線。值得一提的是，捕獲門檻對應的正是「把 θ 掃過去」的過程。

5.3 生成式分類器

接著從機率的觀點看分類，並說明「線性決策邊界」如何從對資料分布的簡單假設中產生。這裡採**生成式**取徑：對類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$ 與類別先驗 $p(\mathcal{C}_k)$ 建模，再經貝氏定理計算後驗機率 $p(\mathcal{C}_k \mid \mathbf{x})$。

先看兩類的問題。類別 $\mathcal{C}_1$ 的後驗機率可寫成

$$\begin{aligned} p(\mathcal{C}_1 \mid \mathbf{x}) &= \frac{p(\mathbf{x} \mid \mathcal{C}_1)p(\mathcal{C}_1)}{p(\mathbf{x} \mid \mathcal{C}_1)p(\mathcal{C}_1) + p(\mathbf{x} \mid \mathcal{C}_2)p(\mathcal{C}_2)} \\ &= \frac{1}{1 + \exp(-a)} = \sigma(a), \end{aligned} \tag{5.31}$$

其中定義了

$$a = \ln \frac{p(\mathbf{x} \mid \mathcal{C}_1)p(\mathcal{C}_1)}{p(\mathbf{x} \mid \mathcal{C}_2)p(\mathcal{C}_2)}, \tag{5.32}$$

而 $\sigma(a)$ 是**邏輯 S 形函數**（logistic sigmoid）

$$\sigma(a) = \frac{1}{1 + \exp(-a)}, \tag{5.33}$$

如圖 5.8。「sigmoid」意為 S 形；它把整條實數軸壓進有限區間，故也稱「squashing function」。它滿足對稱性

$$\sigma(-a) = 1 - \sigma(a), \tag{5.34}$$

其反函數

$$a = \ln\!\left(\frac{\sigma}{1 - \sigma}\right) \tag{5.35}$$

稱為 **logit** 函數，代表兩類機率比的對數 $\ln[p(\mathcal{C}_1 \mid \mathbf{x})/p(\mathcal{C}_2 \mid \mathbf{x})]$，又稱**對數勝算**（log odds）。

在 (5.31) 中我們只是把後驗機率改寫成等價形式，S 形函數的出現看似人為；但只要 $a(\mathbf{x})$ 具有**受限的函數形式**，它就有意義。我們很快會考慮 $a(\mathbf{x})$ 是 $\mathbf{x}$ 之**線性函數**的情形——此時後驗機率由一個**廣義線性模型**支配。

若有 $K > 2$ 類，則

$$p(\mathcal{C}_k \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \mathcal{C}_k)p(\mathcal{C}_k)}{\sum_j p(\mathbf{x} \mid \mathcal{C}_j)p(\mathcal{C}_j)} = \frac{\exp(a_k)}{\sum_j \exp(a_j)}, \tag{5.36}$$

稱為**正規化指數**（normalized exponential），可視為邏輯 S 形函數的多類別推廣，其中

$$a_k = \ln\!\big(p(\mathbf{x} \mid \mathcal{C}_k)p(\mathcal{C}_k)\big). \tag{5.37}$$

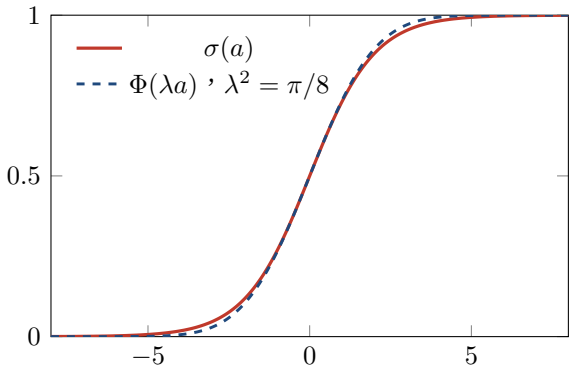


圖 5.8: 由 (5.33) 定義的邏輯 S 形函數 $\sigma(a)$（紅實線），以及縮放後的 probit 函數 $\Phi(\lambda a)$（藍虛線，$\lambda^2 = \pi/8$，Φ 由 (5.68) 定義）。縮放因子 $\pi/8$ 使兩曲線在 $a = 0$ 的導數相等。

正規化指數也稱 **softmax** 函數，因為它是「max」函數的平滑版本：若 $a_k \gg a_j$（對所有 $j \neq k$），則 $p(\mathcal{C}_k \mid \mathbf{x}) \simeq 1$、$p(\mathcal{C}_j \mid \mathbf{x}) \simeq 0$。

教學補充：logit 就是通訊裡的 LLR

式 (5.32) 的 a 在通訊與偵測理論中有個熟悉的名字：**對數概似比**（log-likelihood ratio, LLR）加上先驗項。軟式解碼（如 LDPC、Turbo 碼的訊息傳遞）中傳遞的正是每個位元的 LLR；「LLR 過 S 形函數得到後驗機率」與「後驗機率取 logit 回到 LLR」是同一組轉換。等先驗時 $a = \ln \frac{p(\mathbf{x}|\mathcal{C}_1)}{p(\mathbf{x}|\mathcal{C}_2)}$，Neyman–Pearson 檢定「$a \gtrless$ 門檻」與本章「後驗最大」規則的一致性在此一目了然。

接下來探討為類別條件密度選取特定形式的後果：先看連續輸入 $\mathbf{x}$，再簡短討論離散輸入。

5.3.1 連續輸入

假設類別條件密度為高斯，並先假設**所有類別共用同一個共變異數矩陣 $\boldsymbol{\Sigma}$**：

$$p(\mathbf{x} \mid \mathcal{C}_k) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\Big\{-\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^{\mathsf{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_k)\Big\}. \tag{5.38}$$

先看兩類。由 (5.31) 與 (5.32)，

$$p(\mathcal{C}_1 \mid \mathbf{x}) = \sigma(\mathbf{w}^{\mathsf{T}}\mathbf{x} + w_0), \tag{5.39}$$

其中

$$\mathbf{w} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2), \tag{5.40}$$

$$w_0 = -\tfrac{1}{2}\boldsymbol{\mu}_1^{\mathsf{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_1 + \tfrac{1}{2}\boldsymbol{\mu}_2^{\mathsf{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_2 + \ln\frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)}. \tag{5.41}$$

推導 ((5.40)–(5.41) 的推導)**.** 把 (5.38) 代入 (5.32)：

$$a = -\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_1)^{\mathsf{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_1) + \tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_2)^{\mathsf{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_2) + \ln\frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)}.$$

展開兩個二次式，$\mathbf{x}^\mathsf{T}\boldsymbol{\Sigma}^{-1}\mathbf{x}$ 項**互相抵銷**（因為共變異數矩陣相同），剩下

$$a = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\mathsf{T}\boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_1^\mathsf{T}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_1 + \tfrac{1}{2}\boldsymbol{\mu}_2^\mathsf{T}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_2 + \ln\frac{p(\mathcal{C}_1)}{p(\mathcal{C}_2)},$$

即 $a = \mathbf{w}^\mathsf{T}\mathbf{x} + w_0$。高斯指數中 $\mathbf{x}$ 的二次項因共用共變異數而消去，S 形函數的引數成為 $\mathbf{x}$ 的線性函數。

由此，決策邊界（後驗機率 $p(\mathcal{C}_k \mid \mathbf{x})$ 為常數的面）是 $\mathbf{x}$ 的線性函數：**決策邊界在輸入空間中是線性的**。先驗機率 $p(\mathcal{C}_k)$ 只透過偏置參數 w_0 進入，因此改變先驗的效果是**平行移動**決策邊界（更一般地，平行移動後驗機率的等值線）。

對一般的 K 類，後驗機率由 (5.36) 給出，其中由 (5.37) 與 (5.38)，

$$a_k(\mathbf{x}) = \mathbf{w}_k^\mathsf{T}\mathbf{x} + w_{k0}, \qquad \mathbf{w}_k = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_k, \qquad w_{k0} = -\tfrac{1}{2}\boldsymbol{\mu}_k^\mathsf{T}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_k + \ln p(\mathcal{C}_k). \tag{5.42}$$

$a_k(\mathbf{x})$ 同樣因二次項抵銷而是 $\mathbf{x}$ 的線性函數。最小錯誤分類率的決策邊界出現在（兩個最大的）後驗機率相等處，因此由 $\mathbf{x}$ 的線性函數定義——我們再次得到廣義線性模型。

若放寬「共用共變異數矩陣」的假設，讓每個類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$ 有自己的 $\boldsymbol{\Sigma}_k$，先前的抵銷不再發生，將得到 $\mathbf{x}$ 的**二次**函數——即**二次判別**（quadratic discriminant）。線性與二次決策邊界的圖示見圖 5.9。

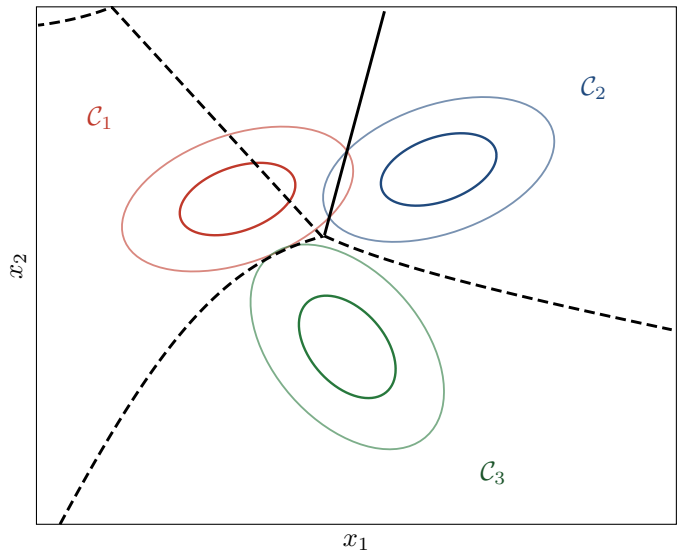


圖 5.9: 三個高斯類別條件密度的等值線（1σ 與 2σ）與對應的（等先驗）決策邊界。紅色（$\mathcal{C}_1$）與藍色（$\mathcal{C}_2$）類別共用同一個共變異數矩陣，故其間的決策邊界為**直線**（實線）；綠色類別 $\mathcal{C}_3$ 的共變異數不同，它與其他兩類之間的邊界為**二次曲線**（虛線）。

5.3.2 最大概似解

為類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$ 指定參數化形式後，即可用最大概似決定參數與先驗 $p(\mathcal{C}_k)$；這需要一組附有類別標籤的觀測資料。

設兩類、高斯類別條件密度、共用共變異數矩陣，資料集 $\{\mathbf{x}_n, t_n\}$（$n = 1, \ldots, N$），$t_n = 1$ 表 $\mathcal{C}_1$、$t_n = 0$ 表 $\mathcal{C}_2$。記先驗 $p(\mathcal{C}_1) = \pi$，故 $p(\mathcal{C}_2) = 1 - \pi$。對來自 $\mathcal{C}_1$ 的點（$t_n = 1$）有 $p(\mathbf{x}_n, \mathcal{C}_1) = \pi\,\mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_1, \boldsymbol{\Sigma})$；對來自 $\mathcal{C}_2$ 的點（$t_n = 0$）有 $p(\mathbf{x}_n, \mathcal{C}_2) = (1 - \pi)\,\mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_2, \boldsymbol{\Sigma})$。概似

函數為

$$p(\mathbf{t}, \mathbf{X} \mid \pi, \boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}) = \prod_{n=1}^{N} \big[\pi\, \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_1, \boldsymbol{\Sigma})\big]^{t_n} \big[(1-\pi)\, \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_2, \boldsymbol{\Sigma})\big]^{1-t_n}. \tag{5.43}$$

照例最大化其對數。

推導 (π、$\boldsymbol{\mu}_k$ 與 $\boldsymbol{\Sigma}$ 的最大概似解)**. (i) 先驗 π。**對數概似中含 π 的項為 $\sum_n \{t_n \ln \pi + (1-t_n)\ln(1-\pi)\}$。對 π 微分並令為零：

$$\pi = \frac{1}{N}\sum_{n=1}^{N} t_n = \frac{N_1}{N} = \frac{N_1}{N_1 + N_2}, \tag{5.44}$$

其中 N_1, N_2 為兩類的點數——π 的最大概似估計就是**屬於 $\mathcal{C}_1$ 的點的比例**，符合預期；此結果可輕易推廣到多類(習題 10)。

(ii) 均值 $\boldsymbol{\mu}_1$。含 $\boldsymbol{\mu}_1$ 的項為 $\sum_n t_n \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_1, \boldsymbol{\Sigma}) = -\frac{1}{2}\sum_n t_n (\mathbf{x}_n - \boldsymbol{\mu}_1)^{\mathsf{T}} \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_1) +$ 常數。微分並令為零：

$$\boldsymbol{\mu}_1 = \frac{1}{N_1}\sum_{n=1}^{N} t_n \mathbf{x}_n, \qquad \boldsymbol{\mu}_2 = \frac{1}{N_2}\sum_{n=1}^{N} (1-t_n)\mathbf{x}_n, \tag{5.45}$$

即**分派到各類之輸入向量的平均**。

(iii) 共變異數 $\boldsymbol{\Sigma}$。挑出含 $\boldsymbol{\Sigma}$ 的項並整理，可寫成

$$-\frac{N}{2}\ln|\boldsymbol{\Sigma}| - \frac{N}{2}\operatorname{Tr}\big(\boldsymbol{\Sigma}^{-1}\mathbf{S}\big), \qquad \mathbf{S} = \frac{N_1}{N}\mathbf{S}_1 + \frac{N_2}{N}\mathbf{S}_2, \tag{5.46}$$

$$\mathbf{S}_k = \frac{1}{N_k}\sum_{n \in \mathcal{C}_k} (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^{\mathsf{T}}. \tag{5.47}$$

利用高斯分布最大概似解的標準結果，得 $\boldsymbol{\Sigma} = \mathbf{S}$：**兩類各自共變異數矩陣的加權平均**。

此結果可輕易推廣到 K 類(習題 10)。注意：以高斯擬合各類別的做法**對離群值不穩健**，因為高斯的最大概似估計本身不穩健(§5.1.4 的教訓再次出現)。

5.3.3 離散特徵

現在考慮離散特徵值 x_i，先看二元特徵 $x_i \in \{0, 1\}$。若有 D 個輸入，完全一般的分布對每個類別需要一張 2^D 個數字的表(因總和限制有 $2^D - 1$ 個獨立變數)——隨特徵數**指數**成長，因此我們尋求更受限的表示。這裡採用**樸素貝氏**(naive Bayes)假設：特徵值在**給定類別 $\mathcal{C}_k$ 的條件下彼此獨立**，得到類別條件分布

$$p(\mathbf{x} \mid \mathcal{C}_k) = \prod_{i=1}^{D} \mu_{ki}^{x_i} (1-\mu_{ki})^{1-x_i}, \tag{5.48}$$

每類只含 D 個獨立參數。代入 (5.37) 得

$$a_k(\mathbf{x}) = \sum_{i=1}^{D} \big\{ x_i \ln \mu_{ki} + (1-x_i)\ln(1-\mu_{ki}) \big\} + \ln p(\mathcal{C}_k), \tag{5.49}$$

仍是輸入值 x_i 的**線性**函數。$K = 2$ 時也可用 (5.31) 的 S 形表述。取 $L > 2$ 個狀態的離散變數有類似結果(習題 11)。

5.3.4 指數族

我們已看到：不論高斯輸入或離散輸入，後驗類別機率都是「S 形（$K=2$）或 softmax（$K\geq 2$）作用在線性函數上」的廣義線性模型。這是一個更一般結果的特例：假設類別條件密度屬於**指數族**（exponential family，§3.4）的下列子集

$$p(\mathbf{x}\mid \boldsymbol{\lambda}_k, s)=\frac{1}{s}\,h\!\left(\frac{1}{s}\mathbf{x}\right)g(\boldsymbol{\lambda}_k)\exp\!\left\{\frac{1}{s}\boldsymbol{\lambda}_k^{\mathsf{T}}\mathbf{x}\right\}, \tag{5.50}$$

其中尺度參數 s 由所有類別共用。對兩類問題，把 (5.50) 代入 (5.32)，後驗機率仍是 S 形作用在線性函數 $a(\mathbf{x})$ 上：

$$a(\mathbf{x})=(\boldsymbol{\lambda}_1-\boldsymbol{\lambda}_2)^{\mathsf{T}}\mathbf{x}+\ln g(\boldsymbol{\lambda}_1)-\ln g(\boldsymbol{\lambda}_2)+\ln p(\mathcal{C}_1)-\ln p(\mathcal{C}_2). \tag{5.51}$$

同理，K 類問題代入 (5.37) 得

$$a_k(\mathbf{x})=\boldsymbol{\lambda}_k^{\mathsf{T}}\mathbf{x}+\ln g(\boldsymbol{\lambda}_k)+\ln p(\mathcal{C}_k), \tag{5.52}$$

仍是 $\mathbf{x}$ 的線性函數。

生成式路線的收穫與代價

收穫：只要類別條件密度屬於（共用尺度的）指數族，後驗**必然**是「線性函數過 S 形／softmax」——這為下一節**直接**假設此形式的判別式模型提供了理論根據。代價：我們花力氣估了完整的 $p(\mathbf{x}\mid\mathcal{C}_k)$（高斯時每類一個 D 維均值加上共用的 $D(D+1)/2$ 個共變異數參數），而分類最終只用到其中的**低維投影**。下一節將看到，直接學 $p(\mathcal{C}_k\mid\mathbf{x})$ 只需 M 個參數。

5.4 判別式分類器

兩類問題中，對指數族內相當廣泛的類別條件分布 $p(\mathbf{x}\mid\mathcal{C}_k)$，類別 $\mathcal{C}_1$ 的後驗機率都可寫成 S 形作用在 $\mathbf{x}$ 的線性函數上；多類情形則是 softmax 作用在線性函數上。生成式做法是：對特定的 $p(\mathbf{x}\mid\mathcal{C}_k)$ 用最大概似估計密度參數與先驗，再以貝氏定理求後驗。**另一條路**是：**直接採用**廣義線性模型的函數形式，以最大概似**直接**決定其參數——即透過條件分布 $p(\mathcal{C}_k\mid\mathbf{x})$ 定義概似函數，這是**判別式機率建模**。其優點：可學習參數通常**少得多**；且當假設的類別條件密度形式與真實分布相差很大時，判別式做法的預測表現往往更好。

5.4.1 激活函數

線性迴歸中，模型預測 $y(\mathbf{x},\mathbf{w})=\mathbf{w}^{\mathsf{T}}\mathbf{x}+w_0$ 是參數的線性函數，輸出為 $(-\infty,\infty)$ 的連續值。分類問題中，我們要預測的是離散類別標籤，或更一般地，落在 $(0,1)$ 的後驗機率。因此考慮此模型的推廣：以非線性函數 $f(\cdot)$ 轉換 $\mathbf{w}$ 與 w_0 的線性函數，

$$y(\mathbf{x},\mathbf{w})=f\!\left(\mathbf{w}^{\mathsf{T}}\mathbf{x}+w_0\right). \tag{5.53}$$

機器學習文獻稱 $f(\cdot)$ 為**激活函數**（activation function），統計文獻稱其反函數為**連結函數**（link function）。決策面對應 $y(\mathbf{x})=$ 常數，即 $\mathbf{w}^{\mathsf{T}}\mathbf{x}=$ 常數——**即使 f 非線性，決策面仍是 $\mathbf{x}$ 的線性函數**。因此 (5.53) 這類模型稱為**廣義線性模型**（generalized linear models；McCullagh and Nelder, 1989）。但與迴歸模型不同，它們因 $f(\cdot)$ 的非線性而**不再對參數線性**，解析與計算性質都更複雜

——雖然相較於後續章節的靈活非線性模型，仍然相對簡單。

5.4.2 固定基底函數

到目前為止，本章的分類模型都直接作用在原始輸入向量 $\mathbf{x}$ 上。其實所有演算法同樣適用於「先以基底函數向量 $\boldsymbol{\phi}(\mathbf{x})$ 對輸入做固定非線性轉換」的情形：所得決策邊界在**特徵空間** $\boldsymbol{\phi}$ 中是線性的，對應到原始 $\mathbf{x}$ 空間中的**非線性**決策邊界（圖 5.10）。在特徵空間 $\boldsymbol{\phi}(\mathbf{x})$ 中線性可分的類別，在原始觀測空間 $\mathbf{x}$ 中不必線性可分。如同迴歸的線性模型，通常取其中一個基底函數為常數 $\phi_0(\mathbf{x}) = 1$，其對應參數 w_0 扮演偏置。

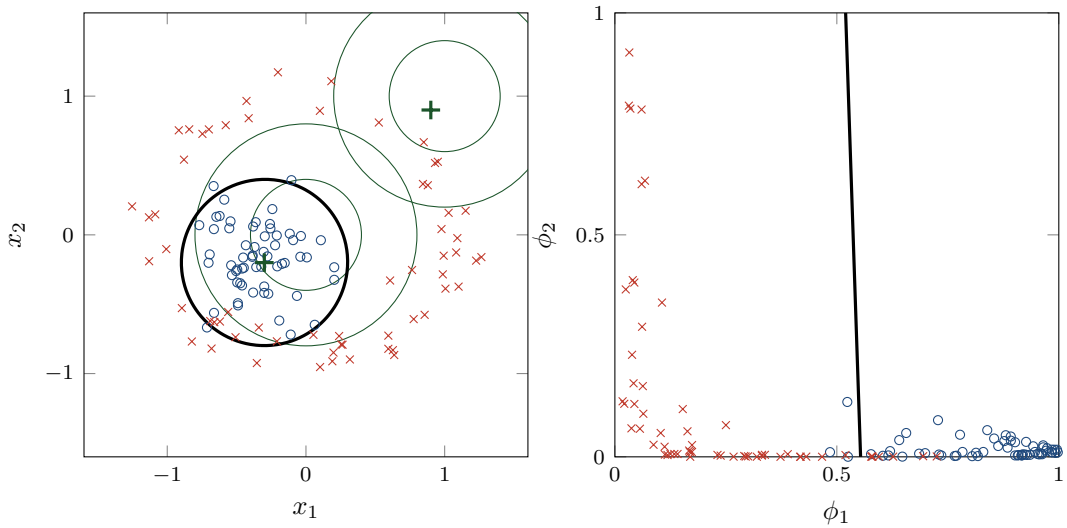


圖 5.10: 非線性基底函數在線性分類模型中的角色。左：原始輸入空間 (x_1, x_2) 與兩類資料點（紅、藍），並定義兩個「高斯」基底函數 $\phi_1(\mathbf{x})$、$\phi_2(\mathbf{x})$，中心以綠色十字、等值線以綠色圓圈表示。右：對應的特徵空間 (ϕ_1, ϕ_2) 與邏輯迴歸模型（§5.4.3）給出的線性決策邊界，其對應到原始輸入空間中的非線性決策邊界（左圖黑色曲線）。

實務上許多問題的類別條件密度 $p(\mathbf{x} \mid \mathcal{C}_k)$ 在 $\mathbf{x}$ 空間中有顯著**重疊**，對應到「後驗機率至少在某些 $\mathbf{x}$ 不是 0 或 1」的情形。此時最佳解是精確地為後驗機率建模，再套用標準決策論。注意非線性轉換 $\boldsymbol{\phi}(\mathbf{x})$ **無法消除**這種類別重疊，甚至可能增加重疊或製造原本沒有的重疊；但適當選取的非線性可讓後驗機率的建模變容易。固定基底函數模型有重要限制（§6.1），後續章節將以「讓基底函數本身向資料調適」來解決——這正是深度學習。

5.4.3 邏輯迴歸

先考慮兩類分類。由 §5.3 的討論，在相當一般的假設下，$\mathcal{C}_1$ 的後驗機率可寫成作用在特徵向量 $\boldsymbol{\phi}$ 之線性函數上的邏輯 S 形函數：

$$p(\mathcal{C}_1 \mid \boldsymbol{\phi}) = y(\boldsymbol{\phi}) = \sigma\big(\mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}\big), \tag{5.54}$$

且 $p(\mathcal{C}_2 \mid \boldsymbol{\phi}) = 1 - p(\mathcal{C}_1 \mid \boldsymbol{\phi})$。統計術語稱此模型為**邏輯迴歸**（logistic regression）——儘管應強調這是**分類**模型，而非連續變數的迴歸模型。

參數數量：M 對 $M(M+5)/2+1$

M 維特徵空間中，邏輯迴歸有 M 個可調參數。相對地，若以最大概似擬合高斯類別條件密度：兩個均值 $2M$ 個參數、(共用的) 共變異數矩陣 $M(M+1)/2$ 個，加上先驗 $p(\mathcal{C}_1)$，共 $M(M+5)/2+1$ 個——隨 M **平方**成長，而邏輯迴歸只**線性**成長。M 大時，直接使用邏輯迴歸模型有明顯優勢。

現在用最大概似決定邏輯迴歸的參數。會用到 S 形函數的導數，它可方便地用自身表示(習題 8)：

$$\frac{\mathrm{d}\sigma}{\mathrm{d}a} = \sigma(1-\sigma). \tag{5.55}$$

對資料集 $\{\boldsymbol{\phi}_n, t_n\}$($\boldsymbol{\phi}_n = \boldsymbol{\phi}(\mathbf{x}_n)$，$t_n \in \{0,1\}$，$n = 1,\dots,N$)，概似函數為

$$p(\mathbf{t} \mid \mathbf{w}) = \prod_{n=1}^{N} y_n^{t_n}\{1-y_n\}^{1-t_n}, \tag{5.56}$$

其中 $\mathbf{t} = (t_1,\dots,t_N)^{\mathsf{T}}$、$y_n = p(\mathcal{C}_1 \mid \boldsymbol{\phi}_n)$。取概似的負對數，得**交叉熵誤差函數** (cross-entropy error function)：

$$E(\mathbf{w}) = -\ln p(\mathbf{t} \mid \mathbf{w}) = -\sum_{n=1}^{N}\big\{t_n \ln y_n + (1-t_n)\ln(1-y_n)\big\}, \tag{5.57}$$

其中 $y_n = \sigma(a_n)$、$a_n = \mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}_n$。

推導 (交叉熵的梯度)**.** 對單一資料點 $E_n = -t_n \ln y_n - (1-t_n)\ln(1-y_n)$，以鏈鎖律：

$$\frac{\partial E_n}{\partial a_n} = \left(-\frac{t_n}{y_n} + \frac{1-t_n}{1-y_n}\right) y_n(1-y_n) = y_n(1-y_n)\cdot\frac{y_n - t_n}{y_n(1-y_n)} = y_n - t_n,$$

其中用了 (5.55)。再由 $\nabla_{\mathbf{w}} a_n = \boldsymbol{\phi}_n$，得

$$\boxed{\nabla E(\mathbf{w}) = \sum_{n=1}^{N}(y_n - t_n)\,\boldsymbol{\phi}_n} \tag{5.58}$$

S 形導數的因子**完全消掉**，梯度化為極簡形式：資料點 n 的貢獻是「誤差」$y_n - t_n$(目標值與模型預測之差)乘上基底函數向量 $\boldsymbol{\phi}_n$。與 (4.12) 比較：這與線性迴歸模型平方和誤差的梯度**形式完全相同**。

最大概似解對應 $\nabla E(\mathbf{w}) = \mathbf{0}$；但由 (5.58)，因 $y(\cdot)$ 的非線性，這不再是線性方程組，**沒有閉式解**。一種做法是隨機梯度下降(以 ∇E_n 為 (5.58) 右式第 n 項)——這也是後續章節訓練高度非線性神經網路的主要方法。不過最大概似方程只是「輕微地」非線性：誤差函數 (5.57) (模型由 (5.54) 定義)是參數的**凸**函數，可用稱為**迭代重加權最小平方** (iterative reweighted least squares, IRLS；Bishop, 2006) 的簡單演算法求最小值——只是它不易推廣到深度神經網路等更複雜的模型。

線性可分資料上的過度擬合

對**線性可分**的資料集，最大概似會嚴重過度擬合：最大概似解出現在「對應 $\sigma = 0.5$ 的超平面 ($\mathbf{w}^{\mathsf{T}}\boldsymbol{\phi} = 0$) 分開兩類、且 $\|\mathbf{w}\| \to \infty$」時。此時 S 形函數在特徵空間中變得無限陡 (趨於

Heaviside 階梯函數），每個訓練點都被指派後驗機率 $p(\mathcal{C}_k \mid \mathbf{x}) = 1$。而且這種解通常有**一整個連續統**——任何分離超平面都在訓練點上給出相同的後驗機率，最大概似無法在其中偏好誰；實際找到哪個解，取決於最佳化演算法與參數初始化。注意：只要訓練集線性可分，即使資料點數遠多於參數個數，問題照樣出現。解法是在誤差函數中加入**正則化**項（Ch. 9）——這也再度呼應第一章與第四章：正則化 = 對權重的先驗。

5.4.4 多類別邏輯迴歸

多類生成式模型的討論告訴我們：對一大類指數族分布，後驗機率是線性函數的 softmax 轉換：

$$p(\mathcal{C}_k \mid \boldsymbol{\phi}) = y_k(\boldsymbol{\phi}) = \frac{\exp(a_k)}{\sum_j \exp(a_j)}, \qquad a_k = \mathbf{w}_k^{\mathsf{T}} \boldsymbol{\phi}. \tag{5.59}$$

那裡是用最大概似分別估計類別條件密度與先驗、再以貝氏定理求後驗，**隱含地**決定 $\{\mathbf{w}_k\}$；這裡改用最大概似**直接**決定 $\{\mathbf{w}_k\}$。需要 y_k 對所有前激活 a_j 的導數（習題 12）：

$$\frac{\partial y_k}{\partial a_j} = y_k(I_{kj} - y_j), \tag{5.60}$$

其中 I_{kj} 為單位矩陣的元素。以 1-of-K 編碼寫下概似函數（$\boldsymbol{\phi}_n$ 屬於 $\mathcal{C}_k$ 時，$\mathbf{t}_n$ 除第 k 元素為 1 外皆為 0）：

$$p(\mathbf{T} \mid \mathbf{w}_1, \dots, \mathbf{w}_K) = \prod_{n=1}^{N} \prod_{k=1}^{K} p(\mathcal{C}_k \mid \boldsymbol{\phi}_n)^{t_{nk}} = \prod_{n=1}^{N} \prod_{k=1}^{K} y_{nk}^{t_{nk}}, \tag{5.61}$$

其中 $y_{nk} = y_k(\boldsymbol{\phi}_n)$，$\mathbf{T}$ 為元素 t_{nk} 的 $N \times K$ 目標矩陣。取負對數，得多類別分類的**交叉熵誤差函數**：

$$E(\mathbf{w}_1, \dots, \mathbf{w}_K) = -\ln p(\mathbf{T} \mid \mathbf{w}_1, \dots, \mathbf{w}_K) = -\sum_{n=1}^{N} \sum_{k=1}^{K} t_{nk} \ln y_{nk}. \tag{5.62}$$

推導 (多類交叉熵的梯度)**.** 對參數向量 $\mathbf{w}_j$ 取梯度，利用 (5.60) 與 $\sum_k t_{nk} = 1$：

$$\nabla_{\mathbf{w}_j} E = -\sum_n \sum_k \frac{t_{nk}}{y_{nk}} y_{nk}(I_{kj} - y_{nj})\, \boldsymbol{\phi}_n = -\sum_n \Big(t_{nj} - y_{nj} \sum_k t_{nk} \Big) \boldsymbol{\phi}_n,$$

$$\boxed{\nabla_{\mathbf{w}_j} E(\mathbf{w}_1, \dots, \mathbf{w}_K) = \sum_{n=1}^{N} (y_{nj} - t_{nj}) \boldsymbol{\phi}_n} \tag{5.63}$$

——再度是「誤差 × 基底函數激活」的形式，可用隨機梯度下降最佳化。

線性分類模型可表示為單層神經網路（圖 5.11）。考慮誤差函數對「連接基底函數 $\phi_i(\mathbf{x})$ 與輸出單元 t_k 的權重 w_{ik}」的導數，由 (5.63)：

$$\frac{\partial E(\mathbf{w}_1, \dots, \mathbf{w}_K)}{\partial w_{ik}} = \sum_{n=1}^{N} (y_{nk} - t_{nk})\, \phi_i(\mathbf{x}_n), \tag{5.64}$$

對每個資料點 n，此梯度是「權重連線**輸入端**的基底函數輸出」乘上「**輸出端**的誤差 $(y_{nk} - t_{nk})$」——這個結構是第八章反向傳播的雛形。

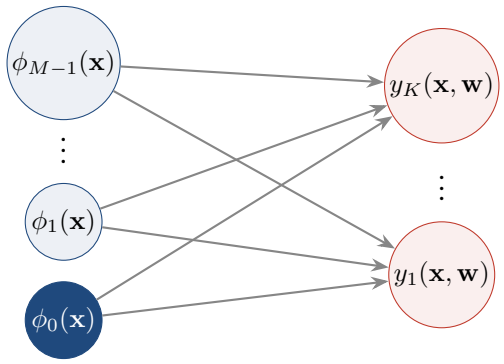


圖 5.11: 把多類別線性分類模型表示為只有單層連結的神經網路：每個基底函數以節點表示（實心節點為「偏置」基底函數 ϕ_0），每個輸出 $y_1,\dots,y_K$ 亦以節點表示，連線代表對應的權重與偏置參數。

5.4.5 Probit 迴歸

指數族描述的廣泛類別條件分布給出「邏輯（或 softmax）轉換作用在線性函數上」的後驗；但**並非所有**類別條件密度的選擇都導致如此簡單的形式，因此值得探索其他判別式機率模型。考慮兩類、仍在廣義線性模型框架內：

$$p(t=1\mid a)=f(a),\qquad a=\mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}. \tag{5.65}$$

一種給出替代連結函數的動機是**雜訊閾值模型**：對每個輸入 $\boldsymbol{\phi}_n$ 計算 $a_n=\mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}_n$，然後

$$\begin{cases} t_n=1, & a_n\ge\theta,\\ t_n=0, & \text{否則}, \end{cases} \tag{5.66}$$

其中閾值 θ 由機率密度 $p(\theta)$ 抽取。此時對應的激活函數是其**累積分布函數**

$$f(a)=\int_{-\infty}^{a} p(\theta)\,\mathrm{d}\theta, \tag{5.67}$$

如圖 5.12。取 $p(\theta)$ 為零均值單位變異數的高斯，對應累積分布函數為

$$\Phi(a)=\int_{-\infty}^{a}\mathcal{N}(\theta\mid 0,1)\,\mathrm{d}\theta, \tag{5.68}$$

稱為 **probit 函數**。它呈 S 形，與邏輯 S 形函數的比較見圖 5.8。（取一般均值與變異數的高斯不會改變模型，因為那等價於線性係數 $\mathbf{w}$ 的重新縮放。）許多數值套件提供密切相關的 **erf 函數**（error function，勿與機器學習模型的誤差函數混淆）：

$$\operatorname{erf}(a)=\frac{2}{\sqrt{\pi}}\int_{0}^{a}\exp(-\theta^2/2)\,\mathrm{d}\theta,\qquad \Phi(a)=\frac{1}{2}\Big\{1+\frac{1}{\sqrt{2}}\operatorname{erf}(a)\Big\} \tag{5.69}$$

（習題 14）。以 probit 激活函數為基礎的廣義線性模型稱為 **probit 迴歸**，其參數同樣可用最大概似決定；實務上其結果與邏輯迴歸相近。

一個實務議題是**離群值**——可能來自輸入向量 $\mathbf{x}$ 的量測錯誤或目標值 t 的**誤標**。此類點可能落在理想決策邊界錯誤的一側很遠處，嚴重扭曲分類器。邏輯與 probit 模型在這方面表現不同：邏輯 S 形函數的尾部在 $|x|\to\infty$ 時如 $\exp(-x)$ 衰減，而 probit 激活函數的尾部如 $\exp(-x^2)$ 衰減，因此 **probit 模型對離群值可能明顯更敏感**。

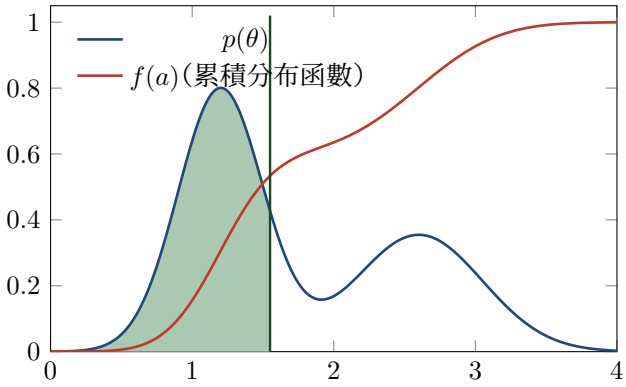


圖 5.12: 機率密度 $p(\theta)$（藍線；此例為兩個高斯的混合）及其累積分布函數 $f(a)$（紅線）的示意。藍線在任一點（如綠色垂直線處）的值等於紅線在該點的斜率；反之紅線在該點的值等於藍線下方綠色陰影區的面積。在隨機閾值模型中，若 $a = \mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}$ 超過閾值則 $t = 1$、否則 $t = 0$；這等價於激活函數取為此累積分布函數。

5.4.6 典則連結函數

高斯雜訊下的線性迴歸模型，誤差函數（負對數概似）對單一資料點之貢獻的導數是「誤差」$y_n - t_n$ 乘以特徵向量 $\boldsymbol{\phi}_n$（其中 $y_n = \mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}_n$）；邏輯 S 形激活配交叉熵誤差 (5.57)、softmax 激活配多類交叉熵 (5.62)，也都得到同樣的簡潔形式。這其實是一個一般結果：**假設目標變數的條件分布來自指數族，並選取對應的激活函數——稱為典則連結函數（canonical link function）**。

考慮目標變數 t 的條件分布（受限形式的指數族，(3.169)）：

$$p(t \mid \eta, s) = \frac{1}{s}\, h\!\left(\frac{t}{s}\right) g(\eta) \exp\!\left\{\frac{\eta t}{s}\right\}. \tag{5.70}$$

循 (3.172) 的論證，t 的條件均值 $y \equiv \mathbb{E}[t \mid \eta] = -s\,\frac{\mathrm{d}}{\mathrm{d}\eta}\ln g(\eta)$，因此 y 與 η 有函數關係，記為 $\eta = \psi(y)$。依 Nelder and Wedderburn (1972)，定義**廣義線性模型**為 y 是輸入（或特徵）變數之線性組合的非線性函數者：

$$y = f(\mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}), \tag{5.71}$$

$f(\cdot)$ 即激活函數，$f^{-1}(\cdot)$ 即統計學的連結函數。

推導 （「誤差 $\times$ 特徵」形式的一般推導）. 此模型的對數概似（設所有觀測共用尺度參數 s）為

$$\ln p(\mathbf{t} \mid \eta, s) = \sum_{n=1}^{N}\left\{\ln g(\eta_n) + \frac{\eta_n t_n}{s}\right\} + \text{常數}.$$

對 $\mathbf{w}$ 微分，用鏈鎖律（$\eta \to y \to a \to \mathbf{w}$）與 $\mathbb{E}[t \mid \eta]$ 的結果：

$$\nabla_{\mathbf{w}} \ln p(\mathbf{t} \mid \eta, s) = \sum_{n=1}^{N}\left\{\frac{\mathrm{d}}{\mathrm{d}\eta_n}\ln g(\eta_n) + \frac{t_n}{s}\right\}\frac{\mathrm{d}\eta_n}{\mathrm{d}y_n}\frac{\mathrm{d}y_n}{\mathrm{d}a_n}\nabla_{\mathbf{w}} a_n = \sum_{n=1}^{N}\frac{1}{s}\{t_n - y_n\}\,\psi'(y_n)\,f'(a_n)\,\boldsymbol{\phi}_n,$$

其中 $a_n = \mathbf{w}^{\mathsf{T}}\boldsymbol{\phi}_n$、$y_n = f(a_n)$。若選取連結函數為

$$f^{-1}(y) = \psi(y), \tag{5.72}$$

則 $f(\psi(y)) = y$，微分得 $f'(\psi)\psi'(y) = 1$；又因 $a = f^{-1}(y) = \psi$，故 $f'(a)\psi'(y) = 1$。此時梯度化

簡為

$$\boxed{\nabla E(\mathbf{w}) = \frac{1}{s}\sum_{n=1}^{N}\{y_n - t_n\}\,\boldsymbol{\phi}_n} \tag{5.73}$$

三組「天生一對」

目標分布（指數族）	激活函數 f	誤差函數	梯度
高斯	恆等	平方和 (4.11)	$\sum_n (y_n - t_n)\boldsymbol{\phi}_n$
Bernoulli	邏輯 S 形	交叉熵 (5.57)	$\sum_n (y_n - t_n)\boldsymbol{\phi}_n$
多項（1-of-K）	softmax	多類交叉熵 (5.62)	$\sum_n (y_{nj} - t_{nj})\boldsymbol{\phi}_n$

「誤差函數與輸出單元激活函數之間存在自然配對」——雖然是在單層網路的脈絡下導出的，同樣的考量也適用於後續章節的深度神經網路：分類網路的最後一層配 softmax + 交叉熵、迴歸網路配線性輸出 + 平方誤差，理由正在於此。

教學補充：本章的一頁地圖

	判別函數（§5.1）	生成式（§5.3）	判別式（§5.4）
建模對象	直接 $\mathbf{x} \mapsto$ 類別	$p(\mathbf{x} \mid \mathcal{C}_k)$、$p(\mathcal{C}_k)$	$p(\mathcal{C}_k \mid \mathbf{x})$
代表模型	最小平方分類	高斯判別、樸素貝氏	邏輯／softmax 迴歸
解的形式	閉式 (5.13)	閉式（§5.3.2）	迭代（SGD／IRLS）
參數量（高斯類比）	$K(M+1)$	$O(M^2)$	$O(KM)$
提供機率？	否	是（含 $p(\mathbf{x})$）	是（僅後驗）
主要弱點	不穩健、無機率	密度假設錯則差	可分資料會發散

課後習題

以下習題分為**觀念題**（○）、**推導題**（⋆）與**延伸題**（⋆⋆）。標有「原書 5.x」者改編自教科書習題。推導題請完整寫出過程；延伸題可搭配程式（NumPy 即可）作答。

習題 1 (⋆ 條件期望與後驗機率（原書 5.1）). 考慮 K 類、目標向量 $\mathbf{t}$ 採 1-of-K 二元編碼的分類問題。證明條件期望 $\mathbb{E}[\mathbf{t} \mid \mathbf{x}]$ 由後驗機率向量給出，即 $\mathbb{E}[t_k \mid \mathbf{x}] = p(\mathcal{C}_k \mid \mathbf{x})$。由此說明：為何「最小平方近似 $\mathbb{E}[\mathbf{t} \mid \mathbf{x}]$」是用最小平方做分類的一個（表面上的）理由，而其輸出卻不能當機率使用？

習題 2 (⋆⋆ 凸包與線性可分（原書 5.2）). 給定資料點集 $\{\mathbf{x}_n\}$，其**凸包**定義為所有形如 $\mathbf{x} = \sum_n \alpha_n \mathbf{x}_n$（$\alpha_n \geq 0$、$\sum_n \alpha_n = 1$）的點。考慮另一點集 $\{\mathbf{y}_n\}$ 及其凸包。兩點集線性可分的定義是：存在 $\tilde{\mathbf{w}}$ 與 w_0 使得對所有 $\mathbf{x}_n$ 有 $\tilde{\mathbf{w}}^{\mathsf{T}}\mathbf{x}_n + w_0 > 0$、對所有 $\mathbf{y}_n$ 有 $\tilde{\mathbf{w}}^{\mathsf{T}}\mathbf{y}_n + w_0 < 0$。證明：若兩者的凸包相交，則兩點集不可線性分離；反之若線性可分，則其凸包不相交。

習題 3 (⋆⋆ 最小平方解保持線性約束（原書 5.3、5.4）). 考慮最小化平方和誤差 (5.12)，並設訓練集中每個目標向量都滿足線性約束 $\mathbf{a}^{\mathsf{T}}\mathbf{t}_n + b = 0$。

(a) 假設某個基底函數為常數（$\phi_0(\mathbf{x}) = 1$，其參數扮演偏置），證明最小平方解 (5.14) 的預測對任意 $\mathbf{x}$ 也滿足 $\mathbf{a}^{\mathsf{T}}\mathbf{y}(\mathbf{x}) + b = 0$。

(b) 推廣：若目標向量同時滿足多個線性約束，證明最小平方預測同時滿足所有約束。

(c) 由此證明：1-of-K 編碼下，最小平方分類器的輸出元素對任何 $\mathbf{x}$ 都加總為 1；並說明為何這仍不足以把輸出當作機率。

習題 4 ($\star$ F 分數與錯誤上界（原書 5.5、5.6）).

(a) 由定義 $F = \dfrac{2\,\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$ 與 (5.26)、(5.27)，導出 (5.30) 的第二個等式。

(b) 對非負數 $a \le b$ 證明 $a \le (ab)^{1/2}$。利用此結果證明：若兩類分類的決策區域取為最小化錯誤分類機率，則

$$p(\text{mistake}) \le \int \{p(\mathbf{x}, \mathcal{C}_1)\, p(\mathbf{x}, \mathcal{C}_2)\}^{1/2} \mathrm{d}\mathbf{x}.$$

（提示：最佳規則下，每點貢獻的錯誤是 $\min\{p(\mathbf{x}, \mathcal{C}_1), p(\mathbf{x}, \mathcal{C}_2)\}$。）

習題 5 ($\star$ 損失矩陣與決策準則（原書 5.7、5.8）).

(a) 給定損失矩陣 L_{kj}，期望風險在對每個 $\mathbf{x}$ 選使 (5.20) 最小的類別時最小。驗證當 $L_{kj} = 1 - I_{kj}$（I_{kj} 為單位矩陣元素）時，此準則退化為「選後驗機率最大的類別」。這種損失矩陣的意義是什麼？

(b) 對一般損失矩陣與一般類別先驗，導出最小期望損失的決策準則，並寫成只含概似比 $p(\mathbf{x} \mid \mathcal{C}_1)/p(\mathbf{x} \mid \mathcal{C}_2)$ 與常數門檻的形式（兩類情形）。

(c) **應用**：以癌症損失矩陣 (5.18) 為例，求出決策門檻對後驗機率 $p(\mathcal{C}_2 \mid \mathbf{x})$ 的臨界值。

習題 6 ($\circ$ 後驗平均趨於先驗（原書 5.9）). 考慮 N 個資料點上後驗機率的平均 $\frac{1}{N}\sum_{n=1}^{N} p(\mathcal{C}_k \mid \mathbf{x}_n)$。取 $N \to \infty$ 的極限，證明此量趨於先驗機率 $p(\mathcal{C}_k)$。（提示：把和視為對 $p(\mathbf{x})$ 的蒙地卡羅估計。）

習題 7 ($\star\star$ 含拒絕選項的最小期望損失（原書 5.10）). 設把 $\mathcal{C}_k$ 的輸入分類為 $\mathcal{C}_j$ 的損失為 L_{kj}，選擇拒絕選項的損失為 λ。

(a) 求出給出最小期望損失的決策準則。

(b) 驗證當 $L_{kj} = 1 - I_{kj}$ 時，此準則退化為 §5.2.3 的拒絕準則，並求 λ 與拒絕閾值 θ 的關係。

習題 8 ($\star$ S 形函數的性質（原書 5.11、5.18）).

(a) 證明邏輯 S 形函數 (5.33) 滿足 $\sigma(-a) = 1 - \sigma(a)$，且其反函數為 $\sigma^{-1}(y) = \ln\{y/(1-y)\}$。

(b) 證明 $\dfrac{\mathrm{d}\sigma}{\mathrm{d}a} = \sigma(1-\sigma)$。

(c) 證明 $\tanh(a) = 2\sigma(2a) - 1$，並說明「以 tanh 為激活的單層模型」與「以 σ 為激活的單層模型」表示同一類函數。

習題 9 ($\star$ 高斯生成模型的後驗（原書 5.12）). 用 (5.31) 與 (5.32) 推導兩類高斯生成模型的後驗機率 (5.39)，並驗證參數 $\mathbf{w}$ 與 w_0 的結果 (5.40)、(5.41)。進一步證明：若兩類共變異數不同（$\boldsymbol{\Sigma}_1 \neq \boldsymbol{\Sigma}_2$），則 $a(\mathbf{x})$ 含二次項，並寫出其一般形式。

習題 10 ($\star$ 生成式模型的最大概似（原書 5.13、5.14）). 考慮 K 類生成式分類模型：先驗 $p(\mathcal{C}_k) = \pi_k$，一般類別條件密度 $p(\boldsymbol{\phi} \mid \mathcal{C}_k)$，訓練集 $\{\boldsymbol{\phi}_n, \mathbf{t}_n\}$（1-of-K 編碼）。

(a) 假設資料點獨立抽取，證明先驗的最大概似解為 $\pi_k = N_k/N$（N_k 為第 k 類點數）。（提示：以 Lagrange 乘子處理 $\sum_k \pi_k = 1$。）

(b) 進一步設 $p(\boldsymbol{\phi} \mid \mathcal{C}_k) = \mathcal{N}(\boldsymbol{\phi} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma})$（共用共變異數）。證明 $\boldsymbol{\mu}_k = \frac{1}{N_k}\sum_n t_{nk}\boldsymbol{\phi}_n$，且

$$\boldsymbol{\Sigma} = \sum_{k=1}^{K} \frac{N_k}{N}\mathbf{S}_k, \qquad \mathbf{S}_k = \frac{1}{N_k}\sum_{n=1}^{N} t_{nk}(\boldsymbol{\phi}_n - \boldsymbol{\mu}_k)(\boldsymbol{\phi}_n - \boldsymbol{\mu}_k)^{\mathsf{T}},$$

即各類共變異數以先驗機率加權的平均。

習題 11 (⋆⋆ 樸素貝氏（原書 5.15–5.17）).

(a) 推導 §5.3.3 中二元特徵樸素貝氏分類器參數 $\{\mu_{ki}\}$ 的最大概似解。

(b) 設特徵向量 $\boldsymbol{\phi}$ 有 M 個分量，每個可取 L 個離散狀態（以 1-of-L 編碼表示），且在給定 $\mathcal{C}_k$ 下各分量獨立。證明 (5.37) 中的 a_k 是 $\boldsymbol{\phi}$ 分量的線性函數。

(c) 推導 (b) 模型參數的最大概似解。

(d) **應用**：說明如何以樸素貝氏結合「影像分類器」與「血檢分類器」的輸出（式 (5.22)），並指出條件獨立假設在什麼情況下會失效。

習題 12 (⋆ softmax 的導數與多類交叉熵（原書 5.21、5.22）).

(a) 由 $y_k = \exp(a_k)/\sum_j \exp(a_j)$ 證明 $\partial y_k/\partial a_j = y_k(I_{kj} - y_j)$。

(b) 利用 (a) 與 $\sum_k t_{nk} = 1$，完整推導多類交叉熵梯度 (5.63)。

(c) 證明 softmax 有「平移不變性」：$a_k \to a_k + c$（對所有 k 加同一常數）不改變 y_k。這對參數的可辨識性有何影響？如何處理？

習題 13 (⋆ 線性可分資料上的發散（原書 5.20）). 設兩類訓練資料線性可分，即存在 $\mathbf{w}_0$ 使 $t_n = 1$ 的點滿足 $\mathbf{w}_0^{\mathsf{T}}\boldsymbol{\phi}_n > 0$、$t_n = 0$ 的點滿足 $\mathbf{w}_0^{\mathsf{T}}\boldsymbol{\phi}_n < 0$。

(a) 證明交叉熵誤差 (5.57) 沿方向 $\mathbf{w} = c\,\mathbf{w}_0$（$c \to \infty$）單調下降趨於 0，故最大概似解在無窮遠處。

(b) 說明此時後驗機率在訓練點上趨於 0 或 1，且任何分離超平面都給出相同的訓練後驗。

(c) 加入正則化項 $\frac{\lambda}{2}\|\mathbf{w}\|^2$ 後，證明誤差函數有唯一有限的最小值。（提示：凸函數 + 強凸函數。）

習題 14 (⋆ probit 與 erf（原書 5.23）). 證明 probit 函數 (5.68) 與 erf 函數的關係 (5.69)。並比較邏輯與 probit 模型對誤標離群值的敏感度：計算兩者在 $a \to -\infty$ 時單點負對數概似 $-\ln f(a)$ 的漸近行為（分別為 $O(|a|)$ 與 $O(a^2)$），據此說明何者較穩健。

習題 15 (⋆⋆ GNSS 欺騙偵測作為兩類決策). 某接收機以檢定統計量 x（如訊號品質監測指標）判斷是否遭受欺騙：$p(x \mid \text{正常}) = \mathcal{N}(x \mid 0, 1)$、$p(x \mid \text{欺騙}) = \mathcal{N}(x \mid d, 1)$，先驗 $p(\text{欺騙}) = 10^{-3}$。

(a) 寫出後驗機率與 LLR，求最小錯誤分類率的決策門檻。

(b) 若漏檢（miss）損失為虛警的 1,000 倍，門檻如何改變？

(c) 對 $d = 2$ 與 $d = 4$ 各畫出（或描述）ROC 曲線並估計 AUC，說明「分離度 d」與 AUC 的關係。

(d) 設計一個拒絕選項：當後驗不確定時改用其他感測器（如 IMU）交叉檢核。應如何選 θ？

習題 16 (⋆⋆ 動手重現本章圖形).

(a) 以 NumPy 重現圖 5.3：產生兩類高斯資料，分別以最小平方（1-of-2 編碼）與邏輯迴歸（梯度下降）求決策邊界；再加入離群點觀察兩者的變化。

(b) 重現圖 5.7：對兩個單維高斯類別掃描決策門檻，畫出 ROC 曲線並以數值積分計算 AUC。

(c) 重現圖 5.10：中心一團與外圍一圈的兩類資料，經兩個高斯基底函數映射後以邏輯迴歸分類，畫出兩個空間中的決策邊界。

(d) **延伸**：對 (c) 的資料直接在 (x_1, x_2) 空間跑邏輯迴歸（不經基底函數），觀察其失敗；再改用 $\boldsymbol{\phi}(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_2^2)$，說明結果為何又變好。

附錄 A　中英名詞對照表

英文	中文	簡要說明
classification	分類	把輸入指派到 K 個離散類別之一
decision region / boundary	決策區域／決策邊界	輸入空間的劃分及其分界面
linearly separable	線性可分	類別可被線性決策面精確分開
discriminant function	判別函數	直接把 $\mathbf{x}$ 映到類別的函數
generative model	生成式模型	對 $p(\mathbf{x} \mid \mathcal{C}_k)$ 與 $p(\mathcal{C}_k)$ 建模
discriminative model	判別式模型	直接對 $p(\mathcal{C}_k \mid \mathbf{x})$ 建模
weight vector / bias	權重向量／偏置	決定決策面的方向／位置
one-versus-the-rest / one-versus-one	一對其餘／一對一	以兩類判別器拼湊多類的兩種(有缺陷的)方式
ambiguous region	歧義區域	拼湊式多類判別器無法一致分類的區域
1-of-K coding (one-hot)	1-of-K 編碼(獨熱)	目標向量僅一個元素為 1
least squares for classification	最小平方分類	以平方和誤差擬合類別指示向量
outlier / robustness	離群值／穩健性	遠離主體的資料點／對其不敏感的性質
prior / posterior probability	先驗／後驗機率	觀測前／後的類別機率
misclassification rate	錯誤分類率	分錯類的機率
loss (cost) matrix	損失(成本)矩陣	L_{kj}：真類 k 判成 j 的代價
expected loss	期望損失	以 $p(\mathbf{x}, \mathcal{C}_k)$ 加權的平均損失
utility function	效用函數	損失的負值，改為最大化
reject option	拒絕選項	對低把握輸入不做分類
inference / decision stage	推論／決策階段	學 $p(\mathcal{C}_k \mid \mathbf{x})$ ／據以指派類別
outlier (novelty) detection	離群(新穎)偵測	以 $p(\mathbf{x})$ 偵測低機率的新資料點
class prior compensation	類別先驗補償	以先驗比例修正平衡資料集訓練的後驗
conditional independence	條件獨立	給定類別後各資訊來源獨立
naive Bayes model	樸素貝氏模型	以條件獨立假設因子化 $p(\mathbf{x} \mid \mathcal{C}_k)$
true/false positive/negative	真／偽陽性／陰性	預測與真實標籤的四種組合
type 1 / type 2 error	型一／型二錯誤	偽陽性／偽陰性
confusion matrix	混淆矩陣	四種計數的 2×2 表
accuracy	準確率	分類正確的比例
precision / recall	精確率／召回率	陽性判定的正確比例／真陽性的檢出比例
false positive rate	偽陽性率	正常樣本被判為陽性的比例
false discovery rate	偽發現率	陽性判定中錯誤的比例
ROC curve	ROC 曲線	真陽性率對偽陽性率的曲線
area under the curve (AUC)	曲線下面積	ROC 的單一數字摘要(0.5 隨機、1 完美)
F-score	F 分數	精確率與召回率的調和平均
logistic sigmoid	邏輯 S 形函數	$\sigma(a) = 1/(1+e^{-a})$
logit / log odds	logit ／對數勝算	$\ln\{\sigma/(1-\sigma)\}$；S 形的反函數
normalized exponential / softmax	正規化指數／softmax	S 形的多類推廣、平滑化的 max

（續下頁）

英文	中文	簡要說明
quadratic discriminant	二次判別	各類共變異數不同時的二次決策邊界
shared covariance matrix	共用共變異數矩陣	使二次項抵銷、邊界為線性的假設
exponential family	指數族	使後驗必為廣義線性模型的分布族
generalized linear model	廣義線性模型	$y = f(\mathbf{w}^\top \boldsymbol{\phi})$，$f$ 非線性
activation / link function	激活函數／連結函數	f ／其反函數 f^{-1}
feature space	特徵空間	基底函數 $\boldsymbol{\phi}(\mathbf{x})$ 映射後的空間
logistic regression	邏輯迴歸	直接以 $\sigma(\mathbf{w}^\top \boldsymbol{\phi})$ 建模後驗的分類模型
cross-entropy error	交叉熵誤差	Bernoulli ／多項概似的負對數
iterative reweighted least squares (IRLS)	迭代重加權最小平方	求解邏輯迴歸的凸最佳化演算法
convex function	凸函數	局部極小即全域極小的函數
multi-class logistic regression	多類別邏輯迴歸	softmax + 多類交叉熵
probit function / probit regression	probit 函數／ probit 迴歸	標準高斯 CDF 作激活的廣義線性模型
erf function	誤差函數 (erf)	與 probit 密切相關的特殊函數
noisy threshold model	雜訊閾值模型	閾值隨機時激活函數為其 CDF
mislabelling	誤標	目標值標錯的離群來源
canonical link function	典則連結函數	使梯度化為「誤差 × 特徵」的連結

附錄 B　延伸閱讀與參考文獻

主要教材

- Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. 本講義之依據；全書電子版可於 https://www.bishopbook.com 免費閱讀。
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. 第 4 章與本章對應，另含 IRLS 的完整推導、貝氏邏輯迴歸與 Laplace 近似。
- Duda, R. O., Hart, P. E., and Stork, D. G. (2001). *Pattern Classification* (2nd ed.). Wiley. 判別函數與貝氏決策理論的經典教材。

本章引用之文獻

- Duda, R. O. and Hart, P. E. (1973). *Pattern Classification and Scene Analysis*. Wiley.
- Berger, J. O. (1985). *Statistical Decision Theory and Bayesian Analysis* (2nd ed.). Springer.
- Bather, J. (2000). *Decision Theory: An Introduction to Dynamic Programming and Sequential Decisions*. Wiley.
- Bishop, C. M. (1994). Novelty detection and neural network validation. *IEE Proceedings: Vision, Image and Signal Processing* 141, 217–222.
- Tarassenko, L. (1995). Novelty detection for the identification of masses in mammograms. *IEE Conference on Artificial Neural Networks* 4, 442–447.
- Jebara, T. (2004). *Machine Learning: Discriminative and Generative*. Kluwer.
- Lasserre, J., Bishop, C. M., and Minka, T. (2006). Principled hybrids of generative and discriminative models. *CVPR* 2006, 87–94.

- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters* 27, 861–874.
- McCullagh, P. and Nelder, J. A. (1989). *Generalized Linear Models* (2nd ed.). Chapman & Hall.
- Nelder, J. A. and Wedderburn, R. W. M. (1972). Generalized linear models. *Journal of the Royal Statistical Society A* 135, 370–384.

建議延伸閱讀

- Kay, S. M. (1998). *Fundamentals of Statistical Signal Processing, Vol. II: Detection Theory*. Prentice Hall.（Neyman–Pearson、概似比檢定與 ROC——本章決策論在訊號偵測中的對應版本）
- Ng, A. Y. and Jordan, M. I. (2001). On discriminative vs. generative classifiers: a comparison of logistic regression and naive Bayes. *NeurIPS* 14.（生成式與判別式的樣本效率比較：小樣本生成式佔優、大樣本判別式佔優）
- Platt, J. (2000). Probabilistic outputs for support vector machines. In *Advances in Large Margin Classifiers*.（把非機率分類器的輸出校準成機率——「Platt scaling」就是對分數再做一次邏輯迴歸）
- Guo, C. et al. (2017). On calibration of modern neural networks. *ICML* 2017.（深度網路的後驗機率常「過度自信」；溫度縮放校準）
- Saerens, M., Latinne, P., and Decaestecker, C. (2002). Adjusting the outputs of a classifier to new a priori probabilities. *Neural Computation* 14, 21–41.（類別先驗補償的系統化處理）

——第五章完——

下一章：深度神經網路（*Deep Neural Networks*）——把本章「固定的基底函數」換成可從資料學習的多層非線性轉換。