深度學習講義

第七章　梯度下降

Chapter 7: Gradient Descent

授課教師：王和盛　國立臺灣海洋大學通訊與導航工程學系

講義依據 C. M. Bishop & H. Bishop, *Deep Learning: Foundations and Concepts* (Springer, 2024) 第七章整理

版本：2026 年 9 月 6 日

本章學習目標

1. 以**誤差曲面**的幾何理解訓練問題：駐點的分類、局部二次近似、Hessian 的特徵分解與正定性，以及等價極小值。
2. 掌握**梯度下降家族**：為何要用梯度（$O(W^2)$ 對 $O(W^3)$）、批次 vs. 隨機梯度下降、小批次的 $\sigma/\sqrt{N}$ 折衷、參數初始化（打破對稱、He 初始化的推導）。
3. 分析**收斂性**：$(1-\eta\lambda_i)$ 因子、$\eta < 2/\lambda_{\max}$ 的上限、條件數如何拖慢收斂，以及動量、Nesterov 動量與學習率排程如何補救。
4. 理解**逐參數自適應學習率**演算法：AdaGrad、RMSProp 到 Adam 的演進與偏差修正。
5. 掌握三種**正規化**：輸入資料正規化、批次正規化（含推論期的移動平均）與層正規化，以及它們與梯度消失／爆炸的關係。

目次

引言：用梯度資訊訓練網路 1

7.1 誤差曲面 2
7.1.1 局部二次近似 . . . 3

7.2 梯度下降最佳化 4
7.2.1 為何要用梯度資訊 . . . 4
7.2.2 批次梯度下降 . . . 4
7.2.3 隨機梯度下降 . . . 5
7.2.4 小批次 . . . 5
7.2.5 參數初始化 . . . 6

7.3 收斂性 7
7.3.1 動量 . . . 8
7.3.2 學習率排程 . . . 9
7.3.3 RMSProp 與 Adam . . . 9

7.4 正規化 11
7.4.1 資料正規化 . . . 11
7.4.2 批次正規化 . . . 12
7.4.3 層正規化 . . . 13

課後習題 14

附錄 A　中英名詞對照表 16

附錄 B　延伸閱讀與參考文獻 17

引言：用梯度資訊訓練網路

上一章看到神經網路是極廣泛而靈活的函數類別，原則上只要隱藏單元夠多就能以任意精度逼近任何函數，且深度網路能編碼對應階層式表徵的歸納偏差。現在回到實際的任務：**根據訓練資料，為網路參數（權重與偏置）找到合適的設定**。

與前幾章的迴歸與分類模型一樣，我們透過最佳化**誤差函數**來選擇模型參數，而誤差函數由最大概似定義（§6.4）。原則上可以只靠反覆「直接求值誤差函數」來做數值最小化，但那極沒效率；深度學習的另一個核心觀念是：**利用梯度資訊**——誤差函數對網路參數的導數——可以大幅提升最佳化效率。這正是我們刻意讓網路函數（以及誤差函數本身）**設計上可微**的原因。所需的導數可用**反向傳播**（第八章）有效率地計算。

現代深度學習的最佳化觀：目標從來不是「精確最佳化」

古典統計以最大概似把參數化模型擬合到有限資料集，資料點數通常遠多於參數數，最佳解就是概似最大的那組參數，其值本身就是關心的對象。現代深度學習相反：模型極為豐富、可學習參數數量巨大，目標從來不是精確最佳化，而是在**測試資料上泛化良好**——學習演算法本身的性質與行為，加上各種正則化方法（Ch. 9），共同決定解的泛化能力（§9.3.2）。讀本章時請記住：我們是在挑「行為好的演算法」，不是在解「精確的最小化問題」。

7.1　誤差曲面

訓練的目標是為網路中的權重與偏置找到能有效預測的值。方便起見把全部參數合成單一向量 $\mathbf{w}$，以選定的誤差函數 $E(\mathbf{w})$ 最佳化。此時把誤差函數想像成**架在「權重空間」上方的曲面**很有幫助（圖 7.1）。

在權重空間中從 $\mathbf{w}$ 走一小步到 $\mathbf{w}+\delta\mathbf{w}$，誤差函數的變化為

$$\delta E \simeq \delta\mathbf{w}^{\mathsf{T}}\nabla E(\mathbf{w}), \tag{7.1}$$

其中向量 $\nabla E(\mathbf{w})$ 指向誤差函數**增加最快**的方向。只要 $E(\mathbf{w})$ 是 $\mathbf{w}$ 的平滑連續函數，其最小值必出現在梯度為零之處：

$$\nabla E(\mathbf{w}) = \mathbf{0}, \tag{7.2}$$

否則沿 $-\nabla E(\mathbf{w})$ 再走一小步就能進一步降低誤差。梯度為零的點稱為**駐點**（stationary points），可再分為極小值、極大值與**鞍點**（saddle points）。

我們希望找到使 $E(\mathbf{w})$ 最小的 $\mathbf{w}$。但誤差函數對權重與偏置通常是高度非線性的，權重空間中會有**許多**梯度為零（或數值上極小）的點。事實上，對任何局部極小值 $\mathbf{w}$，權重空間中通常存在其他**等價**的極小值：例如 M 個隱藏單元的兩層網路，每個點都屬於 $M!\,2^M$ 個等價點構成的家族（§6.2.4）。此外還可能有多個**不等價**的駐點，特別是多個不等價的極小值：對應整個權重空間中誤差最小值的極小值稱為**全域極小值**（global minimum），其餘誤差較高者稱為**局部極小值**（local minima）。深度網路的誤差曲面可以非常複雜，人們曾擔心梯度式方法會困在糟糕的局部極小值；實務上似乎並非如此——大型網路在各種初始條件下都能達到**表現相近**的解（§9.3.2）。

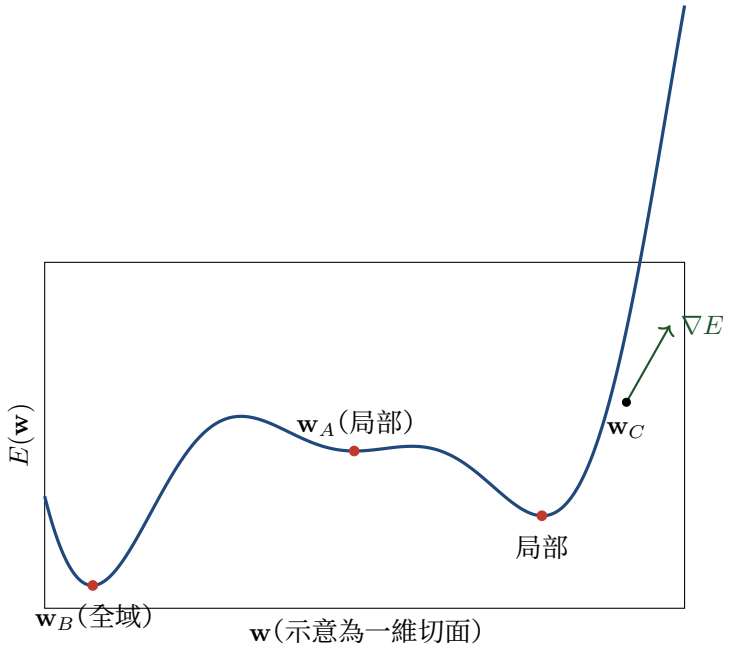


圖 7.1: 把誤差函數 $E(\mathbf{w})$ 視為架在權重空間上的曲面(此處以一維切面示意)。$\mathbf{w}_A$ 是局部極小值、$\mathbf{w}_B$ 是全域極小值($E(\mathbf{w}_A) > E(\mathbf{w}_B)$);在任一點 $\mathbf{w}_C$,誤差曲面的局部梯度由向量 ∇E 給出。

7.1.1 局部二次近似

考慮誤差函數的**局部二次近似**,能為最佳化問題及各種求解技術帶來洞見。$E(\mathbf{w})$ 繞權重空間某點 $\widehat{\mathbf{w}}$ 的 Taylor 展開(略去三次以上項)為

$$E(\mathbf{w}) \simeq E(\widehat{\mathbf{w}}) + (\mathbf{w}-\widehat{\mathbf{w}})^{\mathsf{T}}\mathbf{b} + \frac{1}{2}(\mathbf{w}-\widehat{\mathbf{w}})^{\mathsf{T}}\mathbf{H}(\mathbf{w}-\widehat{\mathbf{w}}), \tag{7.3}$$

其中 $\mathbf{b} \equiv \nabla E\big|_{\mathbf{w}=\widehat{\mathbf{w}}}$ 是在 $\widehat{\mathbf{w}}$ 求值的梯度,**Hessian 矩陣**

$$\mathbf{H}(\widehat{\mathbf{w}}) = \nabla\nabla E(\mathbf{w})\big|_{\mathbf{w}=\widehat{\mathbf{w}}} \tag{7.4}$$

是對應的二階導數矩陣。若網路共有 W 個權重與偏置,$\mathbf{w}$ 與 $\mathbf{b}$ 長度為 W、$\mathbf{H}$ 為 $W \times W$。由 (7.3),梯度的對應局部近似為 $\nabla E(\mathbf{w}) = \mathbf{b} + \mathbf{H}(\mathbf{w}-\widehat{\mathbf{w}})$;對足夠接近 $\widehat{\mathbf{w}}$ 的點,這些表達式給出合理的近似。

考慮繞誤差函數極小值 $\mathbf{w}^\star$ 的局部二次近似。因 $\nabla E = \mathbf{0}$,線性項消失:

$$E(\mathbf{w}) = E(\mathbf{w}^\star) + \frac{1}{2}(\mathbf{w}-\mathbf{w}^\star)^{\mathsf{T}}\mathbf{H}(\mathbf{w}-\mathbf{w}^\star), \tag{7.5}$$

其中 $\mathbf{H}$ 在 $\mathbf{w}^\star$ 求值。幾何詮釋要用 Hessian 的特徵值方程

$$\mathbf{H}\mathbf{u}_i = \lambda_i \mathbf{u}_i, \qquad \mathbf{u}_i^{\mathsf{T}}\mathbf{u}_j = \delta_{ij} \tag{7.6}$$

(特徵向量構成完備正交規範集)。把 $\mathbf{w}-\mathbf{w}^\star$ 以特徵向量展開:

$$\mathbf{w}-\mathbf{w}^\star = \sum_i \alpha_i \mathbf{u}_i, \tag{7.7}$$

可視為座標變換——原點平移到 $\mathbf{w}^\star$、座標軸旋轉到與特徵向量對齊。代入 (7.5) 並用 (7.6)(習題

1)：

$$E(\mathbf{w}) = E(\mathbf{w}^\star) + \frac{1}{2}\sum_i \lambda_i \alpha_i^2. \tag{7.8}$$

駐點的分類與正定性

令 $\alpha_i = 0 (i \neq j)$、只變動 α_j，即沿 $\mathbf{u}_j$ 離開 $\mathbf{w}^\star$：由 (7.8)，$\lambda_j > 0$ 時誤差增加、$\lambda_j < 0$ 時減少。因此：

- 所有 $\lambda_i > 0 \Rightarrow$ 局部**極小值**；所有 $\lambda_i < 0 \Rightarrow$ 局部**極大值**；正負混雜 $\Rightarrow$ **鞍點**。
- 矩陣 $\mathbf{H}$ **正定**的定義是 $\mathbf{v}^\mathsf{T}\mathbf{H}\mathbf{v} > 0$(對所有 $\mathbf{v}$)。以 $\mathbf{v} = \sum_i c_i \mathbf{u}_i$ 展開得 $\mathbf{v}^\mathsf{T}\mathbf{H}\mathbf{v} = \sum_i c_i^2 \lambda_i$，故 $\mathbf{H}$ 正定 $\iff$ 所有特徵值為正(習題 1)。
- 因此 $\mathbf{w}^\star$ 為局部極小值的**充要條件**：梯度在 $\mathbf{w}^\star$ 為零，且 Hessian 在 $\mathbf{w}^\star$ 正定(習題 1)。

在以特徵向量 $\{\mathbf{u}_i\}$ 為基底的新座標系中，等誤差線是以原點為中心、軸與座標對齊的**橢圓**，軸長反比於對應特徵值的平方根(圖 7.2；習題 3)。

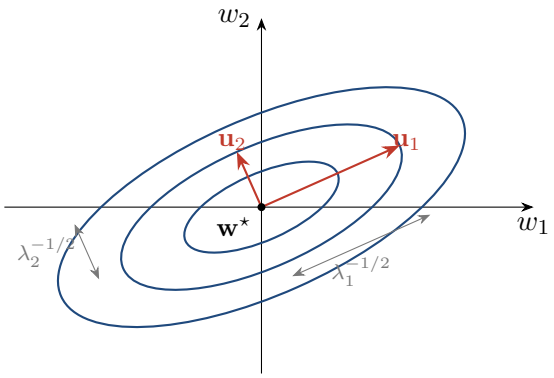


圖 7.2: 在極小值 $\mathbf{w}^\star$ 附近，誤差函數可用二次式近似：等誤差線為橢圓，軸與 Hessian 的特徵向量 $\mathbf{u}_i$ 對齊，長度反比於對應特徵值 λ_i 的平方根。

7.2 梯度下降最佳化

對神經網路這麼複雜的誤差函數，解析地解 $\nabla E(\mathbf{w}) = \mathbf{0}$ 沒有希望，只能訴諸**迭代式數值程序**。連續非線性函數的最佳化是研究透徹的問題，多數技術的形式是：選初始值 $\mathbf{w}^{(0)}$，然後以一連串步驟在權重空間中移動：

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} + \Delta\mathbf{w}^{(\tau-1)}, \tag{7.9}$$

τ 為迭代步的編號；不同演算法對權重更新 $\Delta\mathbf{w}$ 有不同選擇。由於誤差曲面形狀複雜，找到的解會依賴初始值 $\mathbf{w}^{(0)}$ 等因素；要得到夠好的解，可能需要以不同的隨機初始點多次執行梯度式演算法，再以獨立的驗證集比較所得表現。

7.2.1 為何要用梯度資訊

在二次近似 (7.3) 中，誤差曲面由 $\mathbf{b}$ 與 $\mathbf{H}$ 決定，共含 $W(W+3)/2$ 個獨立元素($\mathbf{H}$ 對稱；習題 3)。二次近似的極小值位置因此依賴 $O(W^2)$ 個參數，蒐集到 $O(W^2)$ 條獨立資訊之前不應期望能定位極小值。**不用**梯度資訊的話，需要 $O(W^2)$ 次函數求值、每次 $O(W)$ 步，總計算量 $O(W^3)$。相對地，∇E 是長度 W 的向量，**每次梯度求值帶來 W 條資訊**，可望在 $O(W)$ 次梯度求值內找到

極小值；而由反向傳播(Ch. 8)，每次梯度求值只需 $O(W)$ 步——總計 $O(W^2)$。二次近似雖只在極小值附近成立，效率增益卻是普遍的。這就是**所有**實用網路訓練演算法都以梯度資訊為基礎的原因。

7.2.2 批次梯度下降

利用梯度最簡單的方式：沿負梯度方向走一小步，

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta \nabla E\big(\mathbf{w}^{(\tau-1)}\big), \tag{7.10}$$

參數 $\eta > 0$ 稱為**學習率**(learning rate)。每次更新後對新權重重新求梯度、重複程序。每一步權重都朝誤差下降最快的方向移動，故稱**梯度下降**或**最速下降**。注意誤差函數是對**訓練集**定義的，每一步求 ∇E 都得處理整個訓練集——一次用全部資料的技術稱為**批次**(batch)方法。

7.2.3 隨機梯度下降

深度學習受惠於超大資料集，但批次方法在資料點很多時極沒效率——每次誤差或梯度求值都要處理整個資料集。注意由最大概似(獨立觀測)得到的誤差函數是逐資料點之和：

$$E(\mathbf{w}) = \sum_{n=1}^{N} E_n(\mathbf{w}). \tag{7.11}$$

大資料集最廣泛使用的訓練演算法是梯度下降的循序版本——**隨機梯度下降** (stochastic gradient descent, SGD；Bottou, 2010)：一次用一個資料點更新權重，

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta \nabla E_n\big(\mathbf{w}^{(\tau-1)}\big), \tag{7.12}$$

循環遍歷資料重複更新。完整掃過一遍訓練集稱為一個**訓練週期**(epoch)。此技術也稱**線上**梯度下降，特別是資料來自連續的新資料串流時。

演算法 7.1：隨機梯度下降

輸入：以 $n \in \{1, \ldots, N\}$ 索引的訓練集；單點誤差函數 $E_n(\mathbf{w})$；學習率 η；初始權重 $\mathbf{w}$
輸出：最終權重 $\mathbf{w}$

$n \leftarrow 1$
repeat
  $\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla E_n(\mathbf{w})$ // 更新權重向量
  $n \leftarrow n + 1 \pmod N$ // 遍歷資料
until 收斂
return $\mathbf{w}$

SGD 相對批次梯度下降還有兩個好處。**(i) 更有效處理資料中的冗餘**：極端例子——把資料集每點複製一份使其加倍，誤差函數只是乘以 2(調整學習率即等價於原問題)，批次方法的梯度計算量卻加倍，SGD 則完全不受影響。**(ii) 可能逃離局部極小值**：整體誤差函數的駐點通常**不是**各單點誤差函數的駐點。

7.2.4 小批次

單一資料點算出的梯度是全資料梯度的**極吵雜**估計。折衷做法：每次迭代用一小群資料點——**小批次** (mini-batch)——估計梯度。決定小批次大小時注意：由 N 個樣本估計平均值的誤差為 $\sigma/\sqrt{N}$（σ 為產生資料之分布的標準差；習題 4）——**報酬遞減**：小批次加大 100 倍，誤差只縮小 10 倍。另一考量是硬體效率：某些平台上取 2 的冪次（64、128、256……）效果好。

使用小批次的重要注意事項：**成員應從資料集中隨機抽取**——原始資料中相鄰資料點常因收集方式而相關（按字母序或日期排序等）。常見做法是把整個資料集隨機洗牌後依序切塊；每個 epoch 之間也可重新洗牌，使每個小批次幾乎不曾重複出現，有助逃離局部極小值。（即使用了小批次，演算法通常仍稱「隨機梯度下降」。）

演算法 7.2：小批次隨機梯度下降

輸入：訓練集；批次大小 B；小批次誤差函數 $E_{n:n+B-1}(\mathbf{w})$；學習率 η；初始權重 $\mathbf{w}$
輸出：最終權重 $\mathbf{w}$

$n \leftarrow 1$
repeat
  $\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla E_{n:n+B-1}(\mathbf{w})$ // 權重更新
  $n \leftarrow n + B$
  if $n > N$ **then** 洗牌資料；$n \leftarrow 1$ **end if**
until 收斂
return $\mathbf{w}$

7.2.5 參數初始化

迭代演算法需要為待學參數選初始值。初始化對「多久到達解」與「訓練後網路的泛化表現」都有顯著影響，可惜指導初始化策略的理論相對很少。一個關鍵考量是**打破對稱** (symmetry breaking)：若一組接相同輸入的隱藏（或輸出）單元的參數全部初始化成同一個值（例如全零），它們會**同步更新**、永遠計算同一個函數而互為冗餘。解法是從某個分布**隨機**初始化參數。計算資源允許時，可用不同隨機初始化多次訓練、以保留資料比較結果。

初始化權重的分布通常取 $[-\epsilon, \epsilon]$ 均勻分布或零均值高斯 $\mathcal{N}(0, \epsilon^2)$；$\epsilon$ 的選取很重要。廣泛使用的 **He 初始化**（He et al., 2015b）如下。設第 l 層計算

$$a_i^{(l)} = \sum_{j=1}^{M} w_{ij} z_j^{(l-1)}, \qquad z_i^{(l)} = \mathrm{ReLU}\big(a_i^{(l)}\big), \tag{7.13}$$

M 為送連結給單元 i 的單元數。以 $\mathcal{N}(0, \epsilon^2)$ 初始化權重，並設第 $l-1$ 層輸出 $z_j^{(l-1)}$ 的變異數為 λ^2，則（習題 5）

$$\mathbb{E}\big[a_i^{(l)}\big] = 0, \qquad \mathrm{var}\big[z_j^{(l)}\big] = \frac{M}{2}\epsilon^2\lambda^2 \tag{7.14}$$

（因子 $1/2$ 來自 ReLU 把一半的分布砍掉）。理想上希望前激活的變異數在逐層傳播時**既不衰減為零也不顯著成長**；要求第 l 層也有變異數 λ^2，即得初始化標準差的選擇：

$$\boxed{\epsilon = \sqrt{\frac{2}{M}}} \tag{7.15}$$

圖 7.3 以數值實驗顯示此選擇的效果。也可把初始化尺度 ϵ 當超參數、跨多次訓練探索。偏置通

常設為**小正值**，使多數前激活在學習初期是活的——對 ReLU 特別有幫助（前激活為正才有非零梯度驅動學習）。另一大類初始化技術是採用**在其他任務上訓練所得的值**或利用各種非監督式訓練——屬於遷移學習（§6.3.4）的範疇。

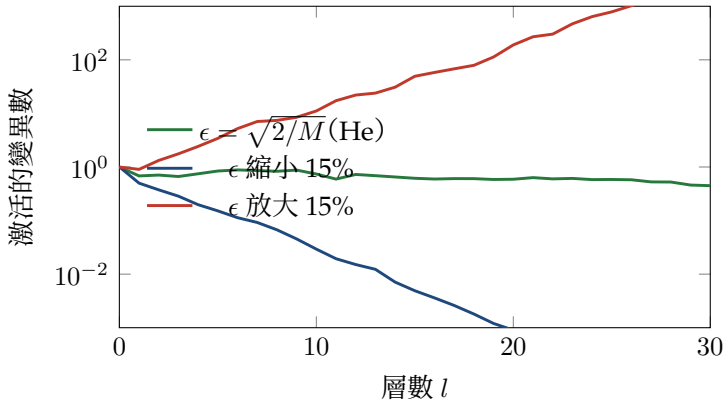


圖 7.3: He 初始化的數值驗證：30 層、每層 400 個 ReLU 單元的網路中，激活變異數隨深度的傳播（縱軸為對數尺度）。取 $\epsilon = \sqrt{2/M}$ 時變異數大致維持（綠）；ϵ 只要偏離 15%，變異數即隨深度指數式衰減（藍）或成長（紅）——深網路對初始化尺度極其敏感。

教學補充：條件數：GNSS 的老朋友

本節的 $O(W^2)$ 對 $O(W^3)$ 論證與下一節的條件數分析，在導航領域有精確的對應：GNSS 最小平方解算中 $\mathbf{H}^{\mathsf{T}}\mathbf{H}$（法方程矩陣）的條件數決定了解對觀測誤差的敏感度，DOP 差 = 幾何造成的病態 = 誤差曲面的「長峽谷」。第四章我們看過 LMS 的收斂條件 $0 < \eta < 2/\lambda_{\max}(\mathbf{R})$——與下一節導出的梯度下降上限一模一樣：適應性濾波器就是在對二次誤差曲面做隨機梯度下降。

7.3 收斂性

實際套用梯度下降時得為學習率 η 選一個值。考慮圖 7.4 的簡單誤差曲面：二維權重空間中 E 的曲率隨方向差異很大，形成一條「峽谷」。曲面上多數點的局部梯度（垂直於等值線）**並不指向極小值**。直覺上加大 η 步伐更大、收斂更快；但連續步驟會在峽谷兩壁間**來回振盪**，η 太大時振盪發散。因為 η 必須壓小以避免橫向發散振盪，沿峽谷方向的進展就極慢——梯度下降淪為許多小步的低效程序。

(a) 梯度下降（η 接近上限） (b) 加入動量（$\mu = 0.8$）

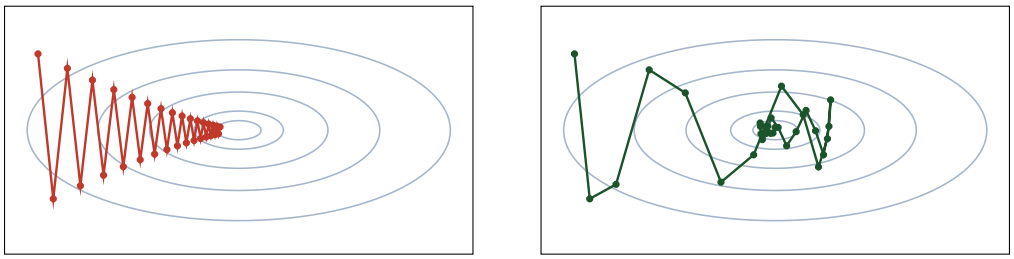


圖 7.4: 曲率沿不同方向差異很大之誤差函數（藍色橢圓為等誤差線；$\lambda_{\max}/\lambda_{\min} = 25$）上的實際最佳化軌跡（各 30 步，同一起點）。(a) 固定步長梯度下降：局部負梯度多半不指向極小值，連續步驟橫越峽谷來回振盪，沿谷底方向進展極慢。(b) 加入動量項後：橫向振盪互相抵消、縱向步伐累積，沿峽谷的進展快得多。

用極小值附近的二次近似深入分析。由 (7.5)、(7.6) 與 (7.7)，此近似下的梯度可寫成

$$\nabla E = \sum_i \alpha_i \lambda_i \mathbf{u}_i, \qquad \Delta \mathbf{w} = \sum_i \Delta\alpha_i \, \mathbf{u}_i. \tag{7.16}$$

結合梯度下降公式 (7.10) 與特徵向量的正交規範性(習題 6)，得每一步各係數的變化：

$$\Delta\alpha_i = -\eta\lambda_i\alpha_i \quad \Longrightarrow \quad \alpha_i^{\text{new}} = (1-\eta\lambda_i)\,\alpha_i^{\text{old}}. \tag{7.17}$$

由 $\mathbf{u}_i^{\mathsf{T}}(\mathbf{w}-\mathbf{w}^\star) = \alpha_i$，$\alpha_i$ 就是**沿方向 $\mathbf{u}_i$ 到極小值的距離**；各距離**獨立**演化，每步乘上因子 $(1-\eta\lambda_i)$。T 步後

$$\alpha_i^{(T)} = (1-\eta\lambda_i)^T \alpha_i^{(0)}. \tag{7.18}$$

只要 $|1-\eta\lambda_i| < 1$，$T \to \infty$ 時 $\alpha_i \to 0$，即 $\mathbf{w} \to \mathbf{w}^\star$——梯度下降在極小值鄰域是**線性收斂**。(收斂也要求所有 $\lambda_i > 0$，即駐點確為極小值。)

學習率上限與條件數

加大 η 使 $(1-\eta\lambda_i)$ 變小、收斂加速；$(1-\eta\lambda_i)$ 可以為負(α_i 振盪)，但必須 $|1-\eta\lambda_i| < 1$ 否則發散——這把學習率限制在

$$\eta < \frac{2}{\lambda_{\max}}.$$

但收斂速率由**最小**特徵值主導：η 取到最大允許值時，沿最小特徵值方向(橢圓長軸)的收斂由因子

$$\left(1 - \frac{2\lambda_{\min}}{\lambda_{\max}}\right)$$

支配。比值 $\lambda_{\min}/\lambda_{\max}$(其倒數稱為 Hessian 的**條件數**)很小——等誤差線高度拉長——時，逼近極小值的進展就極為緩慢。

7.3.1 動量

處理特徵值相差懸殊的簡單技術是在梯度下降公式中加入**動量**(momentum)項——為權重空間中的運動加上「慣性」、抹平圖 7.4(a) 的振盪：

$$\Delta\mathbf{w}^{(\tau-1)} = -\eta\,\nabla E\big(\mathbf{w}^{(\tau-1)}\big) + \mu\,\Delta\mathbf{w}^{(\tau-2)}, \tag{7.19}$$

μ 稱為**動量參數**，權重再以 (7.9) 更新。

推導 (動量的兩種效果)**. 低曲率區(梯度近乎不變)**：把 (7.19) 迭代套用到一長串更新並對等比級數求和，

$$\Delta\mathbf{w} = -\eta\,\nabla E\,\{1+\mu+\mu^2+\cdots\} = -\frac{\eta}{1-\mu}\,\nabla E,$$

動量把**有效學習率**從 η 提升到 $\eta/(1-\mu)$。

高曲率、振盪區：相鄰步的梯度方向交替，動量項的連續貢獻**互相抵消**，有效學習率仍接近 η。因此動量能加速朝極小值收斂，又不引發發散振盪——圖 7.4(b) 正是此效果。由第一式可知 $0 \le \mu \le 1$；實務常用 $\mu = 0.9$。

演算法 7.3：帶動量的隨機梯度下降

輸入：訓練集；批次大小 B；小批次誤差 $E_{n:n+B-1}(\mathbf{w})$；學習率 η；動量參數 μ；初始權重 $\mathbf{w}$
輸出：最終權重 $\mathbf{w}$
$n \leftarrow 1$；$\Delta\mathbf{w} \leftarrow \mathbf{0}$
repeat
  $\Delta\mathbf{w} \leftarrow -\eta \nabla E_{n:n+B-1}(\mathbf{w}) + \mu\,\Delta\mathbf{w}$ // 計算更新項
  $\mathbf{w} \leftarrow \mathbf{w} + \Delta\mathbf{w}$ // 權重更新
  $n \leftarrow n + B$；**if** $n > N$ **then** 洗牌；$n \leftarrow 1$ **end if**
until 收斂；**return** $\mathbf{w}$

動量的代價是引入第二個需要選值的參數 μ。收斂還可用改良版的 **Nesterov 動量**（Nesterov, 2004；Sutskever et al., 2013）進一步加速：傳統做法先在當前位置算梯度、再加上前一步的動量；Nesterov 法**對調順序**——先依前次動量走一步，**在新位置**算梯度決定更新：

$$\Delta\mathbf{w}^{(\tau-1)} = -\eta\,\nabla E\big(\mathbf{w}^{(\tau-1)} + \mu\,\Delta\mathbf{w}^{(\tau-2)}\big) + \mu\,\Delta\mathbf{w}^{(\tau-2)}. \tag{7.20}$$

批次梯度下降時 Nesterov 動量可改善收斂速率；隨機梯度下降時效果可能較差（兩者在低曲率極限下等價，見習題 7）。

7.3.2 學習率排程

SGD (7.12) 需要指定 η：太小學習緩慢，太大導致不穩定（可容忍些許振盪、但不可發散）。實務上最好的結果來自**訓練初期用較大的 η、隨時間降低**——讓 η 成為步數 τ 的函數：

$$\mathbf{w}^{(\tau)} = \mathbf{w}^{(\tau-1)} - \eta^{(\tau-1)} \nabla E_n\big(\mathbf{w}^{(\tau-1)}\big). \tag{7.21}$$

常見排程包括**線性**、**冪次**與**指數**衰減：

$$\eta^{(\tau)} = (1 - \tau/K)\,\eta^{(0)} + (\tau/K)\,\eta^{(K)} \qquad (K \text{ 步內線性降至 } \eta^{(K)} \text{ 後保持}) \tag{7.22}$$

$$\eta^{(\tau)} = \eta^{(0)}\,(1 + \tau/s)^{-c} \qquad (\text{冪次衰減}) \tag{7.23}$$

$$\eta^{(\tau)} = \eta^{(0)}\,c^{\tau/s} \qquad (\text{指數衰減}) \tag{7.24}$$

超參數 $\eta^{(0)}, \eta^{(K)}, K, s, c$ 的好值須由經驗決定（圖 7.5）。實務上監看**學習曲線**——誤差函數隨迭代的演變——確認它以合適速率下降，非常有幫助。

7.3.3 RMSProp 與 Adam

最佳學習率取決於誤差曲面的局部曲率，且曲率隨參數空間的方向而異——這催生了**對網路中每個參數使用各自的學習率**、並在訓練中自動調整的一族演算法。（嚴格說此直覺只在主曲率方向與權重空間座標軸對齊——Hessian 局部近似對角——時成立，實務上未必如此；但這類演算法確實有效且被廣泛使用。）

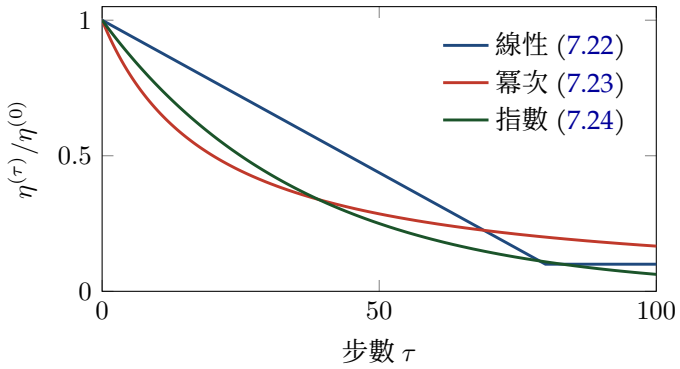


圖 7.5: 三種學習率排程的例子(皆以 $\eta^{(0)}$ 正規化)。

AdaGrad (adaptive gradient；Duchi, Hazan, and Singer, 2011)：以**該參數歷來所有導數的平方累積和**隨時間縮小每個學習率——曲率高的參數縮得最快：

$$r_i^{(\tau)} = r_i^{(\tau-1)} + \Big(\frac{\partial E(\mathbf{w})}{\partial w_i}\Big)^2, \tag{7.25}$$

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \frac{\eta}{\sqrt{r_i^{(\tau)}} + \delta}\Big(\frac{\partial E(\mathbf{w})}{\partial w_i}\Big), \tag{7.26}$$

δ 是保證數值穩定的小常數(如 10^{-8})，$r_i^{(0)} = 0$；$E(\mathbf{w})$ 為當前小批次的誤差。問題：平方梯度從訓練**一開始**就累積，後期權重更新可能變得太小、過度拖慢訓練。

RMSProp (root mean square propagation；Hinton, 2012)：把 AdaGrad 的累積和換成**指數加權移動平均**：

$$r_i^{(\tau)} = \beta\, r_i^{(\tau-1)} + (1-\beta)\Big(\frac{\partial E(\mathbf{w})}{\partial w_i}\Big)^2, \qquad 0 < \beta < 1 \text{ (典型} \beta = 0.9), \tag{7.27}$$

更新式同 (7.26)。

Adam (adaptive moments；Kingma and Ba, 2014)：RMSProp 結合動量——對**梯度**與**平方梯度**各維護一個指數加權移動平均：

$$s_i^{(\tau)} = \beta_1 s_i^{(\tau-1)} + (1-\beta_1)\Big(\frac{\partial E(\mathbf{w})}{\partial w_i}\Big), \tag{7.28}$$

$$r_i^{(\tau)} = \beta_2 r_i^{(\tau-1)} + (1-\beta_2)\Big(\frac{\partial E(\mathbf{w})}{\partial w_i}\Big)^2, \tag{7.29}$$

$$\widehat{s}_i^{(\tau)} = \frac{s_i^{(\tau)}}{1-\beta_1^{\tau}}, \qquad \widehat{r}_i^{(\tau)} = \frac{r_i^{(\tau)}}{1-\beta_2^{\tau}}, \tag{7.30}$$

$$w_i^{(\tau)} = w_i^{(\tau-1)} - \eta\, \frac{\widehat{s}_i^{(\tau)}}{\sqrt{\widehat{r}_i^{(\tau)}} + \delta}. \tag{7.31}$$

因子 $1/(1-\beta_1^{\tau})$、$1/(1-\beta_2^{\tau})$ 修正以零初始化 $s_i^{(0)}, r_i^{(0)}$ 造成的**偏差**(習題 8)；τ 大時偏差趨零，實務上有時省略修正。典型值 $\beta_1 = 0.9$、$\beta_2 = 0.99$。**Adam 是深度學習中採用最廣的學習演算法**。

演算法 7.4：Adam

輸入：訓練集；批次大小 B；小批次誤差 $E_{n:n+B-1}(\mathbf{w})$；學習率 η；衰減參數 β_1, β_2；穩定參數 δ
輸出：最終權重 $\mathbf{w}$

$n \leftarrow 1$；$\mathbf{s} \leftarrow \mathbf{0}$；$\mathbf{r} \leftarrow \mathbf{0}$
repeat
　隨機選取小批次；$\mathbf{g} \leftarrow \nabla E_{n:n+B-1}(\mathbf{w})$ // 求梯度向量
　$\mathbf{s} \leftarrow \beta_1 \mathbf{s} + (1-\beta_1)\mathbf{g}$；　$\mathbf{r} \leftarrow \beta_2 \mathbf{r} + (1-\beta_2)\,\mathbf{g} \odot \mathbf{g}$ // 逐元素平方
　$\hat{\mathbf{s}} \leftarrow \mathbf{s}/(1-\beta_1^{\tau})$；　$\hat{\mathbf{r}} \leftarrow \mathbf{r}/(1-\beta_2^{\tau})$ // 偏差修正
　$\mathbf{w} \leftarrow \mathbf{w} - \eta \hat{\mathbf{s}} \big/ \left(\sqrt{\hat{\mathbf{r}}} + \delta\right)$ // 逐元素運算
　$n \leftarrow n + B$；**if** $n + B > N$ **then** 洗牌；$n \leftarrow 1$ **end if**
until 收斂；**return** $\mathbf{w}$

教學補充：Adam 家族的一張演化地圖

演算法	一階資訊（方向）	二階資訊（尺度）	新增元素
SGD	當前梯度	—	—
＋動量	梯度的移動平均	—	慣性 μ
AdaGrad	當前梯度	平方梯度**累積和**	逐參數學習率
RMSProp	當前梯度	平方梯度**移動平均**	遺忘因子 β
Adam	梯度移動平均	平方梯度移動平均	偏差修正

訊號處理的讀者會認出：$\hat{s}_i/\sqrt{\hat{r}_i}$ 是把梯度**以其 RMS 正規化**——與正規化 LMS（NLMS）以輸入功率正規化步長是同一個念頭；指數加權移動平均 (7.27) 就是一階 IIR 低通濾波器，β 是極點位置。

7.4 正規化

對前向傳播過程中計算的變數做**正規化**，可免除網路處理極大或極小數值的負擔。原則上權重與偏置能適應輸入與隱藏變數的任何取值範圍，但實務上正規化對有效訓練可能**至關重要**。依「對什麼取正規化」分為三種：跨輸入資料、跨小批次、跨層。

7.4.1 資料正規化

有些資料集中不同輸入變數的範圍差異極大：健康資料中身高以公尺計（如 1.8），血小板計數以每微升計（如 300,000）。這使梯度下降困難得多——考慮兩個權重的單層迴歸網路，兩個輸入變數範圍懸殊時，改變其中一個權重對輸出（因而對誤差函數）的影響遠大於另一個：對應的誤差曲面沿不同座標軸曲率懸殊，正是圖 7.4 的病態。

對連續輸入變數，把輸入值**重新縮放到相近範圍**非常有益。做法：先求每個輸入的均值與變異數

$$\mu_i = \frac{1}{N}\sum_{n=1}^{N} x_{ni}, \qquad \sigma_i^2 = \frac{1}{N}\sum_{n=1}^{N}(x_{ni}-\mu_i)^2 \tag{7.32}$$

(訓練開始前算一次即可)，再重新縮放：

$$\widetilde{x}_{ni} = \frac{x_{ni} - \mu_i}{\sigma_i}, \tag{7.33}$$

使 $\{\widetilde{x}_{ni}\}$ 具零均值與單位變異數(習題 10；圖 7.6)。

同一組 μ_i, σ_i 用到底

處理開發、驗證與測試資料時，必須使用**訓練集算出的同一組** μ_i 與 σ_i，確保所有輸入以相同方式縮放。用測試集自己的統計量正規化，是資料洩漏(data leakage)的典型錯誤。

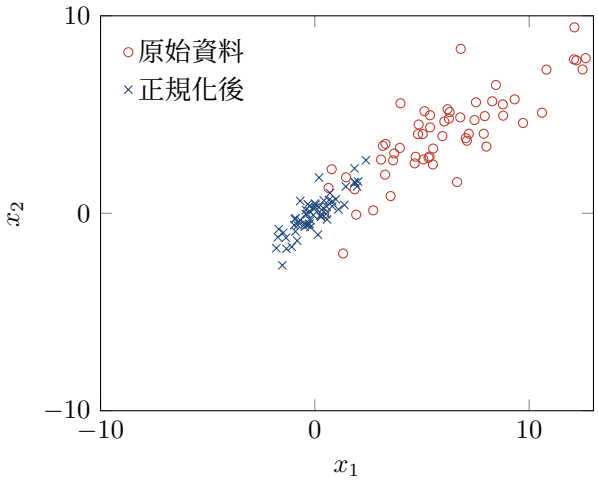


圖 7.6: 輸入資料正規化的效果：紅圈為兩變數資料集的原始資料點，藍叉為正規化後的資料集——每個變數在資料集上具零均值與單位變異數。

7.4.2 批次正規化

輸入正規化的道理同樣適用於深度網路的**每個隱藏層**：若某隱藏層的激活值範圍差異很大，把它們正規化為零均值單位變異數，應能讓下一層的學習問題更容易。差別在於：輸入正規化訓練前做一次即可，隱藏單元值的正規化**每次權重更新後都得重做**——這就是**批次正規化** (batch normalization；Ioffe and Szegedy, 2015)。

另一個動機來自訓練極深網路時的**梯度消失**與**梯度爆炸**。由鏈鎖律，誤差 E 對第一層某參數的梯度為

$$\frac{\partial E}{\partial w_i} = \sum_m \cdots \sum_j \frac{\partial z_m^{(1)}}{\partial w_i} \cdots \frac{\partial z_j^{(K)}}{\partial z_l^{(K-1)}} \frac{\partial E}{\partial z_j^{(K)}}, \tag{7.34}$$

右邊的各偏導數是各層 Jacobian 矩陣(§8.1.5)的元素：大量此類因子的乘積，多數幅度 < 1 時趨於 0、多數 > 1 時趨於 ∞——網路越深，梯度越容易變得極大或極小。批次正規化大致解決了此問題。

做法如下。考慮網路中某一層：每個隱藏單元計算 $z_i = h(a_i)$，可選擇正規化前激活 a_i 或激活 z_i(兩者實務上皆可，此處以前激活為例)。因為權重在每個小批次後更新，正規化就對**每個小**

批次進行：對大小 K 的小批次，

$$\mu_i = \frac{1}{K}\sum_{n=1}^{K} a_{ni}, \qquad \sigma_i^2 = \frac{1}{K}\sum_{n=1}^{K}(a_{ni}-\mu_i)^2, \tag{7.35}$$

$$\widehat{a}_{ni} = \frac{a_{ni}-\mu_i}{\sqrt{\sigma_i^2+\delta}} \tag{7.36}$$

（δ 為避免 σ_i^2 過小時數值問題的小常數）。正規化某層的前激活會減少該層參數的自由度、降低表示能力，因此再以**可學習**的縮放平移補償：

$$\widetilde{a}_{ni} = \gamma_i\,\widehat{a}_{ni} + \beta_i, \tag{7.37}$$

β_i, γ_i 與網路權重、偏置一起由梯度下降學得——這是與輸入資料正規化的關鍵差異。

看似「還原」，其實不然

轉換 (7.37) 表面上把批次正規化的效果又復原了（均值與變異數又能任意調整）。關鍵差異在**參數演化的方式**：原網路中，小批次的均值與變異數是該層所有權重與偏置的**複雜函數**；(7.37) 的表示中，它們由**獨立**參數 β_i, γ_i 直接決定——後者在梯度下降中**容易學得多**。式 (7.35)–(7.37) 對可學習參數可微，可視為網路中的一個**額外層**：每個標準隱藏層後接一個批次正規化層。

訓練完成、要對新資料預測時，已沒有訓練小批次可用，而單一資料點也算不出均值與變異數。原則上可在權重定案後對**整個訓練集**求各層的 μ_i, σ_i^2，但太昂貴；實務上在訓練期間同步計算**移動平均**：

$$\overline{\mu}_i^{(\tau)} = \alpha\,\overline{\mu}_i^{(\tau-1)} + (1-\alpha)\mu_i, \qquad \overline{\sigma}_i^{(\tau)} = \alpha\,\overline{\sigma}_i^{(\tau-1)} + (1-\alpha)\sigma_i, \tag{7.38}$$

$0 \le \alpha \le 1$。移動平均在訓練期間不起作用，僅在**推論階段**用來處理新資料點。

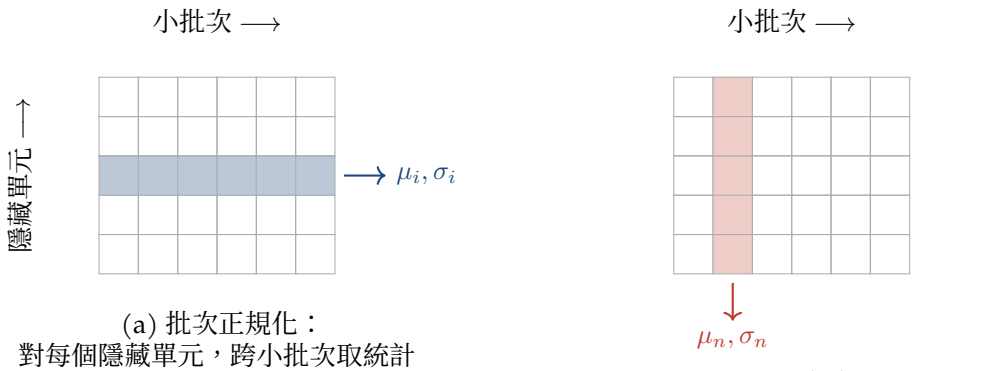
批次正規化實務上非常有效，但**為何**如此有效仍有不確定性：原始動機是「前層權重更新會改變後層看到的數值分布」——所謂**內部共變數偏移**（internal covariate shift）；但後續研究（Santurkar et al., 2018）指出共變數偏移並非顯著因素，改善主要來自**誤差函數地景變得更平滑**。

7.4.3 層正規化

批次正規化在**批次太小**時，均值與變異數的估計太吵；訓練集極大時小批次又可能分散在不同 GPU 上，跨小批次的全域正規化沒效率。替代方案：不對「小批次內的樣本」正規化，改對**每個資料點各自的隱藏單元值**正規化——**層正規化**（layer normalization；Ba, Kiros, and Hinton, 2016）：

$$\mu_n = \frac{1}{M}\sum_{i=1}^{M} a_{ni}, \qquad \sigma_n^2 = \frac{1}{M}\sum_{i=1}^{M}(a_{ni}-\mu_n)^2, \qquad \widehat{a}_{ni} = \frac{a_{ni}-\mu_n}{\sqrt{\sigma_n^2+\delta}}, \tag{7.39}$$

和式取遍該層全部 M 個隱藏單元。與批次正規化一樣，對每個隱藏單元引入 (7.37) 形式的可學習均值與標準差參數。層正規化最初為**遞迴網路**提出（每個時間步分布都變、批次正規化不可行，§12.2.5），在 Transformer（Ch. 12）等架構中也很有用。優點：**訓練與推論可用同一個正規化函數**，無須儲存移動平均。兩者的比較見圖 7.7。



(a) 批次正規化：
對每個隱藏單元，跨小批次取統計

(b) 層正規化：
對每個資料點，跨隱藏單元取統計

圖 7.7: 批次正規化與層正規化的比較（格子的行為小批次中的資料點、列為某層的隱藏單元）。(a) 批次正規化：對每個隱藏單元分別跨小批次計算均值與變異數。(b) 層正規化：對每個資料點分別跨隱藏單元計算均值與變異數。

教學補充：正規化＝接收機裡的 AGC

通訊接收機的**自動增益控制**（AGC）做的正是同一件事：把訊號功率拉到 ADC 與後級電路的適當動態範圍，讓後續處理不必應付幅度懸殊的輸入。批次／層正規化是網路內部的 AGC——每層把「訊號」重新標定，再由可學習的 γ_i, β_i 決定實際想要的增益與偏移。同樣地，GNSS 資料前處理慣例（把虛擬距離殘差、電離層延遲、氣象參數各自標準化再進網路）就是 (7.33)；而「用訓練期統計量處理測試資料」對應接收機校準表的離線標定。

課後習題

以下習題分為**觀念題**（○）、**推導題**（⋆）與**延伸題**（⋆⋆）。標有「原書 7.x」者改編自教科書習題。

習題 1 (⋆ 二次近似的特徵座標（原書 7.1、7.2、7.3）).

(a) 把 (7.7) 代入 (7.5)，利用 (7.6)，證明誤差函數可寫成 (7.8)。

(b) 在 (7.8) 的推導基礎上，取 $\mathbf{v}$ 依次等於各特徵向量 $\mathbf{u}_i$，證明 $\mathbf{H}$ 正定的充要條件是所有特徵值為正。

(c) 由駐點 $\mathbf{w}^\star$ 附近的 Taylor 展開證明：$\mathbf{w}^\star$ 為局部極小值的充要條件是 $\mathbf{H}(\mathbf{w}^\star)$ 正定。

習題 2 (⋆ 一維模型的 Hessian（原書 7.4、7.5）).

(a) 考慮 $y(x, w, b) = wx + b$ 與平方和誤差 $E = \frac{1}{2}\sum_n \{y(x_n, w, b) - t_n\}^2$。導出 2×2 Hessian 的各元素，證明其跡與行列式皆為正，因此兩特徵值皆正、駐點為極小值。

(b) 對 $y(x, w, b) = \sigma(wx + b)$ 與交叉熵誤差重做 (a)。（提示：利用 $\partial E/\partial a_n = y_n - t_n$ 與 $\sigma' = \sigma(1-\sigma)$。）

(c) 兩題的結論說明了單層模型的什麼共同性質？這性質在多層網路為何失效？

習題 3 (⋆ 等誤差線與獨立元素計數（原書 7.6、7.7）).

(a) 由 (7.8) 證明等誤差線是軸與特徵向量對齊的橢圓，軸長反比於 $\sqrt{\lambda_i}$。

(b) 證明由於 $\mathbf{H}$ 對稱，二次誤差函數 (7.3) 的獨立元素個數為 $W(W+3)/2$。

習題 4 (⋆ 樣本平均的誤差（原書 7.8）). 設 $x_1,\dots,x_N$ 抽自均值 μ、變異數 σ^2 的分布，樣本平均 $\bar{x}=\frac{1}{N}\sum_n x_n$。證明 $\mathbb{E}[(\bar{x}-\mu)^2]=\sigma^2/N$，故樣本平均的 RMS 誤差為 $\sigma/\sqrt{N}$。由此說明：小批次大小的報酬遞減，以及為何「把批次加大 4 倍、學習率加大 2 倍」是常聽到的搭配。

習題 5 (⋆ He 初始化（原書 7.9）). 考慮計算 (7.13) 的層。以 $\mathcal{N}(0,\epsilon^2)$ 初始化權重，設第 $l-1$ 層輸出的變異數為 λ^2。

(a) 證明 $\mathbb{E}[a_i^{(l)}]=0$、$\mathrm{var}[a_i^{(l)}]=M\epsilon^2\lambda^2$。

(b) 對零均值對稱分布的 a，證明 $\mathbb{E}[\mathrm{ReLU}(a)^2]=\frac{1}{2}\,\mathrm{var}[a]$，因而 $\mathrm{var}[z_j^{(l)}]\le\mathbb{E}[z_j^{(l)2}]=\frac{M}{2}\epsilon^2\lambda^2$。

(c) 由「逐層變異數不變」的要求導出 $\epsilon=\sqrt{2/M}$。若激活改為 $\tanh$（小訊號近似 $h(a)\simeq a$），對應的選擇（Xavier 初始化）是什麼？

習題 6 (⋆ 收斂因子（原書 7.10）). 利用 (7.5)、(7.6) 與 (7.7)，推導 (7.16) 的兩個展開式；再結合特徵向量正交規範性與批次梯度下降公式 (7.10)，推導 $\Delta\alpha_i=-\eta\lambda_i\alpha_i$。並回答：

(a) 對圖 7.4 的曲面（$\lambda_1=1,\lambda_2=25$），η 的上限是多少？取 $\eta=0.076$ 時兩方向的收斂因子各是多少？

(b) 要使 α_1 縮小到初值的 1%，約需幾步？

習題 7 (⋆ Nesterov 動量（原書 7.11）). 考慮曲率低、梯度隨位置變化緩慢的誤差曲面。證明對小的學習率與動量參數，Nesterov 動量更新 (7.20) 與標準動量更新 (7.19) 等價。（提示：對 ∇E 在 $\mathbf{w}^{(\tau-1)}$ 處展開並保留一階項。）

習題 8 (⋆ 指數移動平均的偏差修正（原書 7.12）). 對序列 $\{x_1,\dots,x_N\}$ 以 $\mu_n=\beta\mu_{n-1}+(1-\beta)x_n$（$0\le\beta\le1$）計算指數加權移動平均。

(a) 利用等比級數和 $\sum_{k=1}^{n}\beta^{k-1}=(1-\beta^n)/(1-\beta)$ 證明：若 $\mu_0=0$，則對常數序列 $x_n=c$ 有 $\mu_n=c(1-\beta^n)$——估計量有偏。

(b) 證明以 $\widehat{\mu}_n=\mu_n/(1-\beta^n)$ 可修正此偏差。

(c) Adam 取 $\beta_2=0.99$ 時，訓練多少步後偏差修正因子與 1 的差距小於 1%？

習題 9 (⋆ 線搜尋（原書 7.13）). 設在方向 $\mathbf{d}$ 上最小化 $E(\mathbf{w}^{(\tau)}+\lambda\mathbf{d})$ 得 $\lambda^\star$ 與新點 $\mathbf{w}^{(\tau+1)}$。證明 E 在 $\mathbf{w}^{(\tau+1)}$ 的梯度**正交**於 $\mathbf{d}$。這是「線搜尋」方法的基礎（Bishop, 1995b）；由此說明為何連續的最速下降線搜尋步互相垂直、在峽谷中呈鋸齒路徑。

習題 10 (⋆ 資料正規化（原書 7.14）). 證明由 (7.33) 定義的重新縮放輸入變數（μ_i,σ_i^2 由 (7.32) 定義）具有零均值與單位變異數。進一步：正規化**不能**消除輸入變數之間的**相關性**；說明對高度相關的兩個輸入，誤差曲面為何仍可能是「斜的峽谷」？哪種前處理（提示：PCA 白化）能同時處理尺度與相關性？

習題 11 (◦ 批次正規化的推論階段).

(a) 為何推論時不能直接用 (7.35)？（考慮單一資料點、以及測試批次組成改變預測值的問題。）

(b) 移動平均 (7.38) 的 α 取太小或太大各有什麼問題？

(c) 層正規化為何沒有這個訓練／推論不一致的問題？

習題 12 (⋆⋆ 動手實驗).

(a) 以 NumPy 重現圖 7.4：在 $E=\frac{1}{2}(\lambda_1 w_1^2+\lambda_2 w_2^2)$、$\lambda_1{=}1,\lambda_2{=}25$ 上執行 30 步梯度下降與動量法，畫出軌跡；再試 η 略超過 $2/\lambda_{\max}$ 觀察發散。

(b) 加入 Adam（$\eta = 0.35$）比較三者。解釋為何 Adam 的軌跡先沿 45° 方向移動。（提示：逐參數正規化使初期各方向步長相同。）

(c) 重現圖 7.3：把 ϵ 偏離 He 值 $\pm 15\%$，觀察激活變異數隨深度的指數行為；再加入批次正規化層，觀察它如何「救回」錯誤的初始化。

(d) **延伸**：對第六章的 1–6–1 迴歸網路，分別以固定 η 的 SGD、動量 SGD 與 Adam 訓練，畫出學習曲線（誤差對 epoch）；再套用指數學習率排程，觀察後期收斂品質的差異。

附錄 A　中英名詞對照表

英文	中文	簡要說明
error surface	誤差曲面	架在權重空間上的 $E(\mathbf{w})$ 幾何圖像
stationary point	駐點	梯度為零之點：極小、極大或鞍點
saddle point	鞍點	Hessian 特徵值正負混雜的駐點
local / global minimum	局部／全域極小值	誤差較高的極小值／全空間最低者
local quadratic approximation	局部二次近似	保留至二階的 Taylor 展開
Hessian matrix	Hessian 矩陣	二階導數矩陣 $\nabla\nabla E$
eigenvalue / eigenvector	特徵值／特徵向量	$\mathbf{H}\mathbf{u}_i = \lambda_i \mathbf{u}_i$
positive definite	正定	$\mathbf{v}^{\mathsf{T}}\mathbf{H}\mathbf{v} > 0$；所有特徵值為正
condition number	條件數	$\lambda_{\max}/\lambda_{\min}$；大則收斂慢
learning rate	學習率	步長參數 η；上限 $2/\lambda_{\max}$
gradient (steepest) descent	梯度(最速)下降	沿負梯度小步移動
batch method	批次方法	每步用整個訓練集
stochastic gradient descent (SGD)	隨機梯度下降	一次用一個資料點更新
online gradient descent	線上梯度下降	資料為連續串流時的 SGD
training epoch	訓練週期	完整掃過訓練集一遍
mini-batch	小批次	以一小群資料點估計梯度
shuffle	洗牌	隨機打亂資料以去除順序相關
symmetry breaking	打破對稱	隨機初始化避免單元冗餘
He initialization	He 初始化	ReLU 網路取 $\epsilon = \sqrt{2/M}$
linear convergence	線性收斂	每步誤差乘上固定因子 $(1-\eta\lambda_i)$
momentum	動量	累積過往更新的慣性項 μ
Nesterov momentum	Nesterov 動量	先走動量步、再於新位置取梯度
learning rate schedule	學習率排程	η 隨步數衰減(線性／冪次／指數)
learning curve	學習曲線	誤差隨訓練進程的曲線
AdaGrad	—	以平方梯度累積和調整逐參數學習率
RMSProp	—	平方梯度的指數移動平均
Adam (adaptive moments)	—	RMSProp + 動量 + 偏差修正
exponentially weighted moving average	指數加權移動平均	$\mu_n = \beta\mu_{n-1} + (1-\beta)x_n$
bias correction	偏差修正	除以 $(1-\beta^{\tau})$ 修正零初始化偏差
normalization	正規化	把變數標定為零均值單位變異數
data normalization	資料正規化	對輸入變數、訓練前一次完成
batch normalization	批次正規化	對每個隱藏單元跨小批次正規化
layer normalization	層正規化	對每個資料點跨隱藏單元正規化
vanishing / exploding gradients	梯度消失／爆炸	深層 Jacobian 連乘的兩種病態
internal covariate shift	內部共變數偏移	批次正規化的原始(後受質疑的)動機

（續下頁）

英文	中文	簡要說明
moving average (inference)	移動平均（推論用）	批次正規化在推論期使用的統計量
data leakage	資料洩漏	誤用測試集資訊（如其統計量）於訓練

附錄 B　延伸閱讀與參考文獻

主要教材

- Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. 本講義之依據；電子版見 https://www.bishopbook.com。
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. 第 8 章「Optimization for Training Deep Models」。
- Nocedal, J. and Wright, S. J. (2006). *Numerical Optimization* (2nd ed.). Springer. 數值最佳化的標準參考（線搜尋、共軛梯度、擬牛頓法）。

本章引用之文獻

- Bottou, L. (2010). Large-scale machine learning with stochastic gradient descent. *COMPSTAT* 2010, 177–186.
- He, K., Zhang, X., Ren, S., and Sun, J. (2015b). Delving deep into rectifiers. *ICCV* 2015.（He 初始化）
- Nesterov, Y. (2004). *Introductory Lectures on Convex Optimization*. Springer.
- Sutskever, I. et al. (2013). On the importance of initialization and momentum in deep learning. *ICML* 2013.
- Duchi, J., Hazan, E., and Singer, Y. (2011). Adaptive subgradient methods for online learning and stochastic optimization. *JMLR* 12, 2121–2159.（AdaGrad）
- Hinton, G. (2012). Neural networks for machine learning, Lecture 6.5.（RMSProp）
- Kingma, D. P. and Ba, J. (2014). Adam: a method for stochastic optimization. arXiv:1412.6980.
- Ioffe, S. and Szegedy, C. (2015). Batch normalization. *ICML* 2015.
- Santurkar, S. et al. (2018). How does batch normalization help optimization? *NeurIPS* 31.
- Ba, J. L., Kiros, J. R., and Hinton, G. E. (2016). Layer normalization. arXiv:1607.06450.

建議延伸閱讀

- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. *ICLR* 2019.（AdamW——Adam 與權重衰減的正確結合，當今預設）
- Smith, L. N. (2017). Cyclical learning rates for training neural networks. *WACV* 2017.（循環學習率與 warm-up）
- Goh, G. (2017). Why momentum really works. *Distill*. https://distill.pub/2017/momentum/（動量的可視化解析）
- Haykin, S. (2014). *Adaptive Filter Theory* (5th ed.). Pearson.（LMS ／ NLMS 步長條件與本章收斂分析的對應）

——第七章完——

下一章：反向傳播（*Backpropagation*）——以 $O(W)$ 的代價取得本章所需的梯度。