深度學習講義

第六章　深度神經網路

Chapter 6: Deep Neural Networks

授課教師：王和盛　國立臺灣海洋大學通訊與導航工程學系

講義依據 C. M. Bishop & H. Bishop, *Deep Learning: Foundations and Concepts* (Springer, 2024) 第六章整理

版本：2026 年 9 月 6 日

本章學習目標

1. 理解**固定基底函數的限制**：維度災難、高維空間的反直覺幾何(超球殼、高斯分布的薄殼集中)，以及「真實資料落在低維流形上」為何是深度學習可行的關鍵。
2. 掌握**多層網路**的數學形式(前激活、隱藏單元、參數矩陣)、通用近似定理的意義與侷限、各種隱藏單元激活函數(tanh、softplus、ReLU 家族)的取捨，以及權重空間對稱性。
3. 理解**深度**帶來的歸納偏差：階層式表徵、分散式表徵、表徵學習、遷移學習／多任務／元學習，以及對比式學習(InfoNCE、CLIP)。
4. 依目標變數的條件分布推導**誤差函數與輸出激活函數的配對**(迴歸、二元、多重二元、多類別)，並理解 $\partial E/\partial a_k = y_k - t_k$ 的一般性。
5. 以**混合密度網路**處理多峰條件分布(逆問題)：模型建構、誤差函數、輸出層梯度推導與預測分布的使用。

目次

引言：讓基底函數自己學 2

6.1 固定基底函數的限制 2
- 6.1.1 維度災難 . . . 3
- 6.1.2 高維空間 . . . 3
- 6.1.3 資料流形 . . . 4
- 6.1.4 資料相依的基底函數 . . . 5

6.2 多層網路 6
- 6.2.1 參數矩陣 . . . 7
- 6.2.2 通用近似 . . . 7
- 6.2.3 隱藏單元激活函數 . . . 8
- 6.2.4 權重空間對稱性 . . . 10

6.3 深度網路 10
- 6.3.1 階層式表徵 . . . 10
- 6.3.2 分散式表徵 . . . 11
- 6.3.3 表徵學習 . . . 11
- 6.3.4 遷移學習 . . . 11
- 6.3.5 對比式學習 . . . 12

6.3.6 一般網路架構 13
6.3.7 張量 14

6.4 誤差函數 **14**
6.4.1 迴歸 14
6.4.2 二元分類 15
6.4.3 多類別分類 16

6.5 混合密度網路 **16**
6.5.1 機器人運動學的例子 16
6.5.2 條件混合分布 17
6.5.3 梯度最佳化 18
6.5.4 預測分布 19

課後習題 **20**

附錄 A 中英名詞對照表 **24**

附錄 B 延伸閱讀與參考文獻 **25**

引言：讓基底函數自己學

近年來，神經網路已成為實際應用中**最重要**的機器學習技術。前面各章已鋪好許多基礎：由固定非線性基底函數之線性組合構成的線性迴歸模型，可表示為只有單層權重與偏置參數的神經網路（Ch. 4）；以基底函數線性組合為基礎的分類模型亦然（Ch. 5）。只要基底函數的數量足夠、選得合適，這類線性模型原則上能以任意精度逼近任何輸入到輸出的非線性轉換，看似已足以應付任何實際應用。然而它們有一些嚴重的限制。本章先探討這些限制、理解**為何必須使用從資料中學得的基底函數**，自然引出具有多於一層可學習參數的神經網路——即**前饋網路**（feed-forward networks）或**多層感知器**（multilayer perceptrons）——並討論多層處理的好處，導向如今主宰整個領域的**深度神經網路**。

6.1 固定基底函數的限制

分類的線性基底函數模型形如

$$y(\mathbf{x}, \mathbf{w}) = f\Big(\sum_{j=1}^{M} w_j \phi_j(\mathbf{x}) + w_0\Big), \tag{6.1}$$

其中 $f(\cdot)$ 為非線性的輸出激活函數；迴歸的線性模型形式相同，只是 $f(\cdot)$ 換成恆等函數。基底函數 $\{\phi_j(\mathbf{x})\}$ 可以任意選取，故這類模型**原則上**可解任何迴歸或分類問題——平凡的意義下這是顯然的：若某個基底函數恰好就是所要的輸入–輸出轉換，可學習的線性層只需把它抄到輸出即可。更一般地，夠大夠豐富的基底函數集應能以任意精度近似任何函數。看似萬用的框架，問題出在**基底函數是固定的、與訓練資料無關**。要理解此限制，先看輸入變數增多時線性模型的行為。

6.1.1 維度災難

考慮單一輸入變數的 M 階多項式迴歸模型(§1.2)。若改成 D 個輸入變數 $\{x_1, \ldots, x_D\}$，係數到 3 階為止的一般多項式為

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{i=1}^{D} w_i x_i + \sum_{i=1}^{D}\sum_{j=1}^{D} w_{ij} x_i x_j + \sum_{i=1}^{D}\sum_{j=1}^{D}\sum_{k=1}^{D} w_{ijk} x_i x_j x_k. \tag{6.2}$$

隨 D 增加，獨立係數的個數以 $O(D^3)$ 成長；M 階多項式則是 $O(D^M)$(Bishop, 2006)。在高維空間中，多項式很快變得笨重而缺乏實用價值。

高維空間帶來的嚴重困難有時稱為**維度災難**(curse of dimensionality；Bellman, 1961)，且絕不限於多項式迴歸。考慮用線性模型解分類問題：圖 6.1 是 Iris 資料集的示意圖，三種鳶尾花各 50 筆觀測，這裡只取花萼長度與寬度兩個變數。給定這 150 筆訓練資料，目標是把圖中「×」標示的新測試點分到三個品種之一。× 靠近數個紅點，我們可能猜它屬紅類；但附近也有綠點，也許屬綠類；屬藍類則似乎不太可能。這裡的直覺是：測試點的身分應**較強地由訓練集中鄰近的點決定**、較弱地由遠處的點決定——而這個直覺是合理的。

把直覺變成學習演算法的一個極簡方式：把輸入空間切成規則的**格子**(圖 6.1 中的網格)。對測試點，先判定它落在哪個格子，再找出落在同一格的所有訓練資料點，預測其類別為該格中訓練點數最多的類別(平手隨機打破)。這可視為一種基底函數模型：每個格子對應一個基底函數 $\phi_i(\mathbf{x})$，在格外回傳零、格內回傳該格訓練點的多數類別，模型輸出是所有基底函數輸出之和。

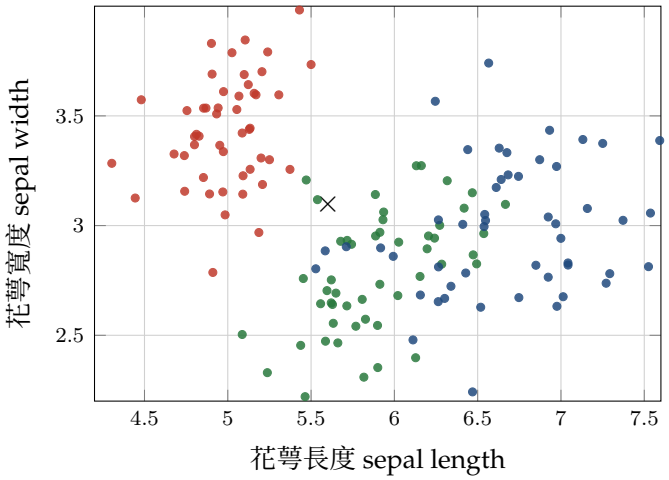


圖 6.1: Iris 型資料的示意(紅、綠、藍代表三種鳶尾花；本圖以與原資料統計相近的模擬資料重製)，座標軸為花萼長度與寬度。目標是分類新測試點「×」。疊上的網格顯示「切格子」分類法：測試點的類別取同格中訓練點的多數決——注意有些格子完全沒有訓練點。

這個天真做法問題很多，最嚴重的一個在輸入變數增多時現形：把空間切成規則格子，**格子數隨空間維度指數成長**(圖 6.2)。格子數指數暴增的挑戰在於：需要**指數量級的訓練資料**才能保證格子不空——圖 6.1 中已有一些格子沒有任何訓練點，落在這種格子的測試點便無從分類。顯然，超過幾個變數的空間就別指望這種技術了。多項式迴歸與 Iris 分類的困難都源自**基底函數的選取與所解的問題無關**；要繞過維度災難，基底函數的選擇必須更聰明(§6.1.4)。

6.1.2 高維空間

先更仔細地看看高維空間的性質——我們一輩子活在三維空間裡養成的幾何直覺，在那裡可能**錯得離譜**。一個簡單例子：D 維空間中半徑 $r = 1$ 的超球，其體積有多少比例落在半徑 $1 - \epsilon$ 到 1

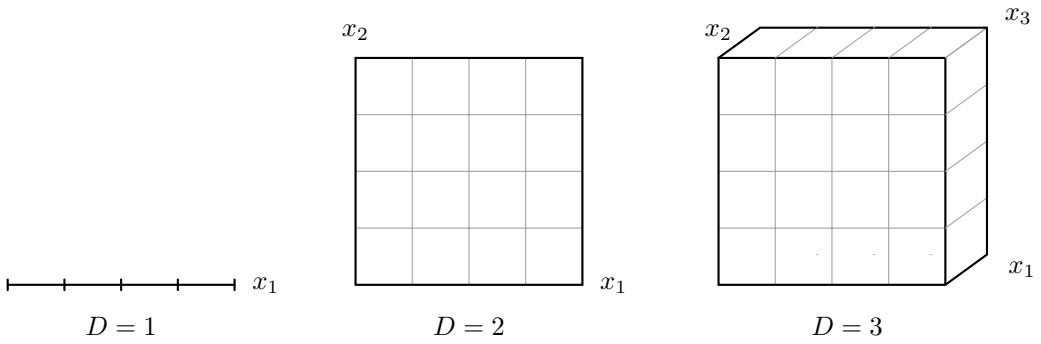


圖 6.2: 維度災難的圖示：規則網格的區域數隨空間維度 D 指數成長(每維切 n 格共 n^D 個區域)。為清楚起見，$D = 3$ 只畫出部分立方體區域。

之間？由「半徑 r 的超球體積必按 r^D 縮放」可寫 $V_D(r) = K_D r^D$(常數 K_D 只依賴 D；習題 1)，故所求比例為

$$\frac{V_D(1) - V_D(1-\epsilon)}{V_D(1)} = 1 - (1-\epsilon)^D, \tag{6.3}$$

如圖 6.3 左。當 D 很大時，即使 ϵ 很小，此比例也趨近 1：**高維超球的體積幾乎全部集中在表面附近的薄殼裡**！

另一個與機器學習直接相關的例子是高維空間中的高斯分布。把直角座標換成極座標並把方向變數積掉，可得密度對半徑 r 的表達式 $p(r)$($p(r)\,\delta r$ 是位於半徑 r、厚度 δr 之薄殼內的機率質量；習題 2)。如圖 6.3 右：D 大時，高斯的機率質量集中在**特定半徑處的薄殼**內——儘管機率**密度**的最大值明明在原點(原點密度比薄殼處大 $e^{D/2}$ 倍)。

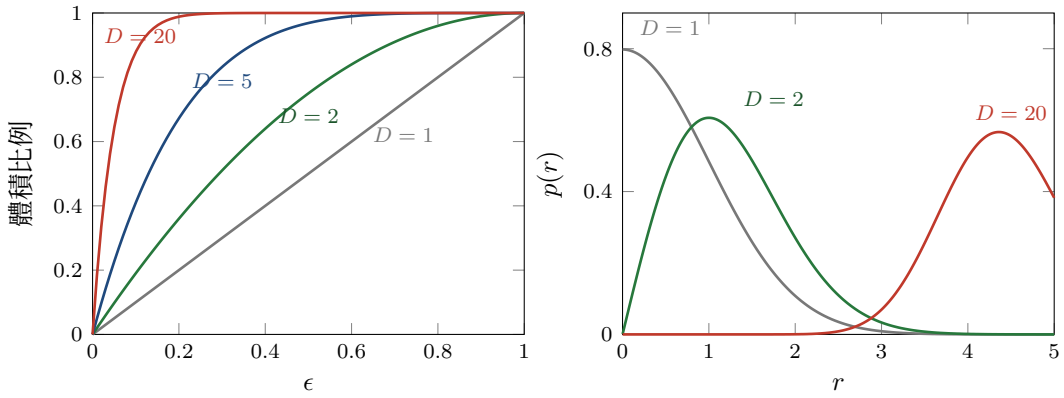


圖 6.3: 高維空間的反直覺幾何。左：單位超球中落在半徑 $1-\epsilon$ 到 1 之薄殼內的體積比例 (6.3)。右：高斯分布($\sigma = 1$)對半徑的機率密度 $p(r)$——高維時機率質量集中在 $r \simeq \sqrt{D}\,\sigma$ 附近的薄殼。

本書大量使用一、兩個變數的示意圖，因為容易視覺化；但讀者務必記得：**低維空間養成的直覺，不見得能推廣到高維**。另外，雖然一直在講維度災難，高維空間也可能有**好處**。考慮圖 6.4 的情形：資料點由成對數值 (x_1, x_2) 組成時線性可分，但若只觀測 x_1，兩類就強烈重疊——分類問題在**較高維**的空間中反而容易得多。

6.1.3 資料流形

多項式迴歸與格子分類器的基底函數數量都隨維度暴增，使這些方法連幾十個變數都應付不了，更別提影像處理動輒數百萬個輸入。問題在於基底函數**事先固定**、不依賴資料，甚至不依賴所解的問題。維度災難固然重要，但它並不妨礙我們找到適用於高維空間的有效技術，原因之一是：**真實資料通常局限在資料空間中「有效維度」低得多的區域裡**。

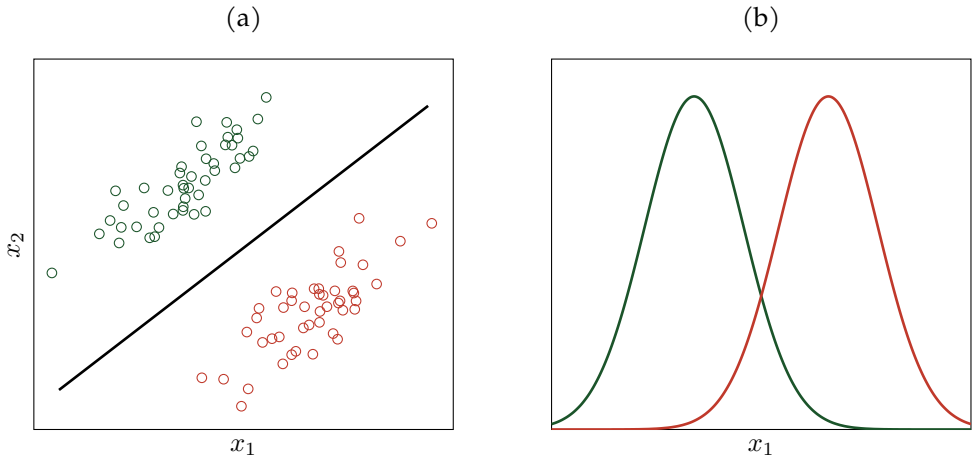


圖 6.4: 二維資料集 (x_1, x_2) 中，綠、紅兩類可被線性決策面分開(a)；但若只量測變數 x_1，兩類(此處畫出其分布)就不再可分(b)。

想像一批手寫數字影像：同一個數字可以出現在影像中不同的水平、垂直位置與不同的旋轉角度，因此影像之間有**三個**變異自由度；一組這樣的影像在以像素數為維度的高維空間中，一階近似下就落在一個**三維流形**(manifold)上。由於物體位置／方向與像素強度之間的複雜關係，這個流形高度非線性。事實上，「像素數」只是影像產生過程的人為產物——它們是對連續世界的量測；用更高解析度拍同一張影像，資料空間維度 D 增加，但影像仍然活在三維流形上。若能把**局部化的基底函數安置在資料流形上**而非整個高維資料空間中，所需基底函數的數量將隨**流形**維度(而非資料空間維度)指數成長——流形維度通常低得多，這是巨大的改進。神經網路實際上就是在**學習一組適應資料流形的基底函數**；而且對特定應用而言，流形上未必所有方向都重要(例如只要判斷方向、不管位置，相關自由度只剩一個)，神經網路也能學出**流形上哪些方向與預測目標相關**。

另一個看出真實資料局限於低維流形的方式，是考慮**隨機產生影像**：對每個像素的 R、G、B 值獨立地從均勻分布取樣，產生的合成影像**沒有一張**看起來像自然影像——因為它們缺乏自然影像中極強的像素間相關性(自然影像中相鄰兩個像素顏色相同或非常接近的機率遠高於隨機影像)。每張影像都是高維空間中的一點，但自然影像只佔這個空間的**極小**一部分。

教學補充：VTEC 建模裡的「資料流形」

全球電離層 VTEC 圖若以格點表示是數千維的向量，但實際變化主要由少數物理因素驅動：地方時、季節、太陽活動(F10.7 ／太陽黑子數)、地磁活動等——資料其實落在低維、近似可參數化的流形附近。這正是球諧展開只需幾十個係數就能描述全球 TEC 的原因，也是神經網路能以少量隱藏單元學會 VTEC 動態的原因：網路學的不是「每個格點各自怎麼變」，而是流形的座標。同樣的觀點也適用於陣列訊號(訊號子空間 = 低維流形)與多路徑通道。

6.1.4 資料相依的基底函數

與問題無關的簡單基底函數在高維空間會遇到重大限制。一種辦法是靠專家知識為每個應用**手工打造**基底函數——多年來這是機器學習的主流做法：基底函數(常稱**特徵**)由領域知識與反覆試誤共同決定。但此路成效有限，終被**資料驅動**的做法取代——基底函數從訓練資料中**學**出來。領域知識在現代機器學習中仍有角色，但層次更定性：用於設計網路架構、以編碼合適的歸納偏差(§9.1)。

既然高維資料可能局限於低維流形，基底函數不必鋪滿整個輸入空間，而可與資料流形本

身連結。做法之一是讓**每個訓練資料點**對應一個基底函數，自動貼合底層流形。**徑向基底函數**（radial basis functions；Broomhead and Lowe, 1988）即是一例——每個基底函數只依賴到中心向量的（通常為歐氏）徑向距離；取中心為輸入資料值 $\{\mathbf{x}_n\}$，每個資料點有一個基底函數

$$\phi_n(\mathbf{x}) = \exp\Big\{-\frac{\|\mathbf{x}-\mathbf{x}_n\|^2}{s^2}\Big\}, \tag{6.4}$$

其中 s 控制寬度。這種模型架起來快，但大資料集時計算笨重，且需小心正則化以避免嚴重過度擬合。相關做法**支援向量機**（SVM；Vapnik, 1995；Schölkopf and Smola, 2002；Bishop, 2006）同樣以訓練點為中心定義基底函數，但在訓練中**自動選出其中一個子集**，有效基底數通常遠小於訓練點數——雖然仍偏大、且往往隨訓練集成長。SVM 不輸出機率，也不自然推廣到兩類以上。徑向基底函數與 SVM 都已被深度神經網路取代：後者更能有效利用超大資料集，且能學到對複雜應用的高預測精度至關重要的**深層階層式表徵**。

6.2 多層網路

要把 (6.1) 形式的線性模型用於大規模資料與高維空間，必須找到**針對所解問題調校**的基底函數。神經網路的關鍵想法是：讓基底函數 $\phi_j(\mathbf{x})$ **本身帶有可學習參數**，並在訓練時把這些參數連同係數 $\{w_j\}$ 一起調整——對定義在**全體**參數上的誤差函數，用梯度式最佳化（如隨機梯度下降，Ch. 7）整體最佳化模型。

建構參數化非線性基底函數的方式很多，關鍵要求是它們必須是可學習參數的**可微**函數，才能套用梯度式最佳化。最成功的選擇是讓基底函數**沿用** (6.1) **的形式**：每個基底函數本身是「輸入之線性組合」的非線性函數，線性組合的係數即可學習參數。此建構顯然可以**遞迴地**延伸出多層的階層式模型——深度神經網路的基礎。

考慮具有**兩層**可學習參數的基本神經網路。先建構輸入變數 $x_1,\dots,x_D$ 的 M 個線性組合：

$$a_j^{(1)} = \sum_{i=1}^{D} w_{ji}^{(1)} x_i + w_{j0}^{(1)}, \qquad j = 1,\dots,M, \tag{6.5}$$

上標 (1) 表示對應參數位於網路的第一「層」；$w_{ji}^{(1)}$ 稱為**權重**、$w_{j0}^{(1)}$ 稱為**偏置**，a_j 稱為**前激活**（pre-activations）。每個 a_j 再經可微的非線性**激活函數** $h(\cdot)$ 轉換：

$$z_j^{(1)} = h\big(a_j^{(1)}\big), \tag{6.6}$$

即 (6.1) 中基底函數的輸出——在神經網路的語境中稱為**隱藏單元**（hidden units）。只要 $h'(\cdot)$ 可求值，整體網路函數就可微。依 (6.1)，這些值再被線性組合：

$$a_k^{(2)} = \sum_{j=1}^{M} w_{kj}^{(2)} z_j^{(1)} + w_{k0}^{(2)}, \qquad k = 1,\dots,K, \tag{6.7}$$

K 為輸出總數。此轉換對應網路的第二層，$w_{k0}^{(2)}$ 亦為偏置參數。最後 $\{a_k^{(2)}\}$ 經適當的**輸出單元激活函數** $f(\cdot)$ 轉為網路輸出 y_k。兩層神經網路的圖示見圖 6.5。

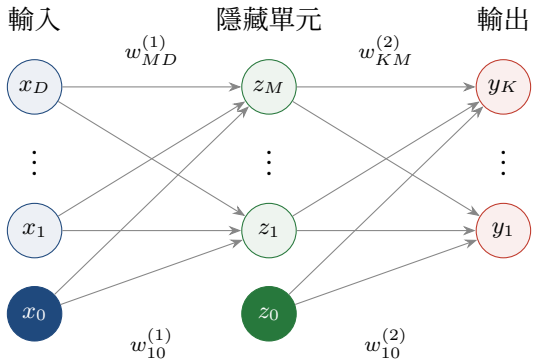


圖 6.5: 兩層神經網路的網路圖。輸入、隱藏與輸出變數以節點表示，權重參數以節點間的連線表示；偏置參數以來自額外變數 x_0、z_0（實心節點，值固定為 1）的連線表示。箭頭標示前向傳播時資訊在網路中流動的方向。

6.2.1 參數矩陣

如線性迴歸模型的做法（§4.1.1），(6.5) 的偏置可藉由引入固定為 $x_0 = 1$ 的額外輸入變數併入權重：$a_j = \sum_{i=0}^{D} w_{ji}^{(1)} x_i$；第二層偏置同樣併入第二層權重，整體網路函數成為

$$y_k(\mathbf{x}, \mathbf{w}) = f\left(\sum_{j=0}^{M} w_{kj}^{(2)}\, h\Big(\sum_{i=0}^{D} w_{ji}^{(1)} x_i \Big) \right). \tag{6.8}$$

另一個之後常用的記號：把輸入寫成行向量 $\mathbf{x}$、把權重與偏置收進矩陣，得

$$\mathbf{y}(\mathbf{x}, \mathbf{w}) = f\Big(\mathbf{W}^{(2)}\, h\big(\mathbf{W}^{(1)} \mathbf{x} \big) \Big), \tag{6.9}$$

其中 $f(\cdot)$ 與 $h(\cdot)$ 逐元素作用。

6.2.2 通用近似

兩層網路能表示極廣泛函數的能力如圖 6.6 所示——四個不同的目標函數，各以 $N = 50$ 個資料點訓練一個只有**三個** tanh 隱藏單元、線性輸出的兩層網路，並顯示個別隱藏單元如何**協力**湊出最終函數。隱藏單元在簡單分類問題中的角色見圖 6.7。

兩層前饋網路的近似性質在 1980 年代被廣泛研究，多個定理顯示：對相當廣泛的激活函數，此類網路能以任意精度逼近定義在 $\mathbb{R}^D$ 連續子集上的任何函數（Funahashi, 1989；Cybenko, 1989；Hornik, Stinchcombe, and White, 1989；Leshno et al., 1993）；由任何有限維離散空間到另一個的函數也有類似結果。因此神經網路被稱為**通用近似器**（universal approximators）。

通用近似定理不能告訴你的事

定理只保證所需的網路**存在**：(i) 它可能需要**指數量級**的隱藏單元；(ii) 定理完全沒說學習演算法**找不找得到**這個網路；(iii) **沒有免費午餐定理**（§9.1.2）說我們永遠找不到真正萬用的機器學習演算法；(iv) 兩層雖已萬用，實務上**多於兩層**、能學習階層式內部表徵的網路好處巨大。這些都指向深度學習。

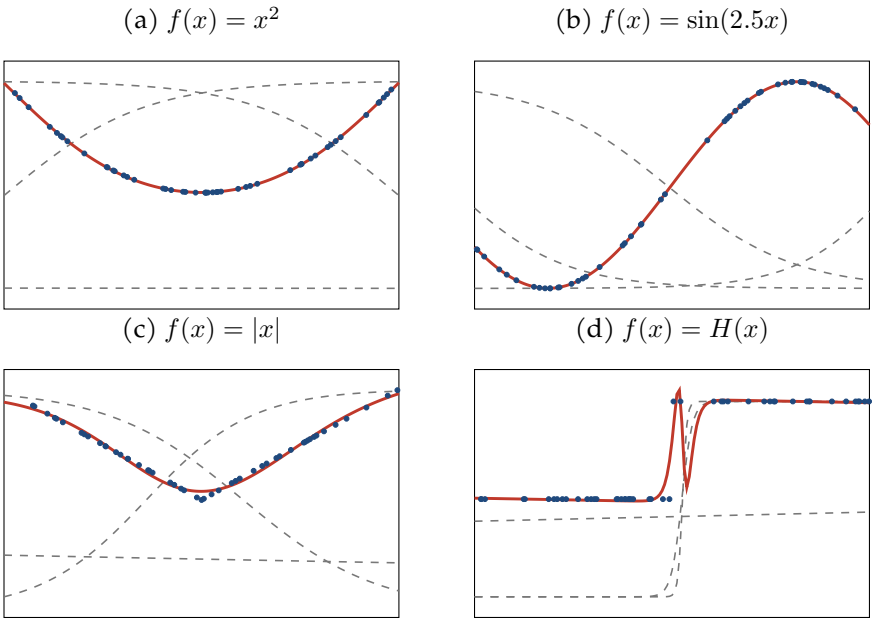


圖 6.6: 兩層神經網路逼近四種不同函數的能力：(a) $f(x) = x^2$、(b) $f(x) = \sin(2.5x)$、(c) $f(x) = |x|$、(d) $f(x) = H(x)$(Heaviside 階梯函數)。每個例子在 $(-1, 1)$ 均勻取樣 $N = 50$ 個資料點(藍點)，用以訓練具有三個 tanh 隱藏單元與線性輸出的兩層網路。紅線為所得網路函數，三條灰色虛線為三個隱藏單元的輸出。(本圖為實際以 NumPy 訓練所得。)

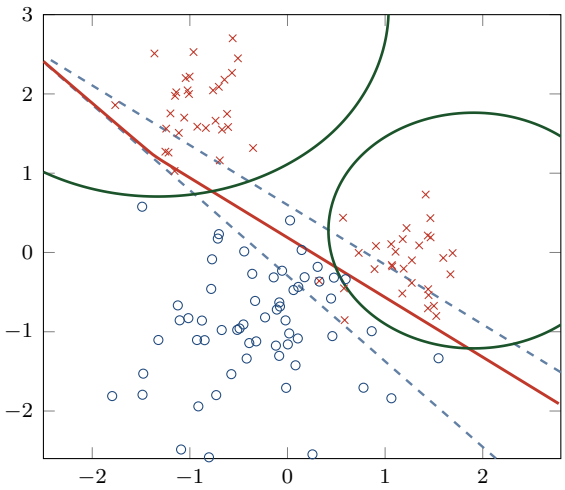


圖 6.7: 以神經網路解簡單兩類分類問題(合成資料)的例子：網路有兩個輸入、兩個 tanh 隱藏單元、一個邏輯 S 形輸出。藍色虛線為兩個隱藏單元的 $z = 0$ 等值線，紅線為網路的 $y = 0.5$ 決策面；綠線為由產生資料的真實分布計算出的最佳決策邊界。(實際訓練所得，訓練正確率約 96%。)

6.2.3 隱藏單元激活函數

輸出單元的激活函數由所建模的分布類型決定(§6.4)；隱藏單元則只需**可微**，選擇很寬。多數情況下全網路的隱藏單元用同一種激活函數，原則上不同部位也可不同。各種常見選擇見圖 6.8。

線性激活。 最簡單的選擇是恆等函數——所有隱藏單元變成線性。但對任何這種網路，都能找到**沒有隱藏單元**的等價網路：連續線性轉換的合成仍是線性轉換，表示能力不超過單一線性層。不過，若隱藏單元數 M 小於輸入數 N 或輸出數 K，此網路產生的轉換就不是最一般的線性映射(維度縮減損失了資訊)：它有 $M(N + K)$ 個參數、對應**秩虧**的轉換，而直接線性映射有 NK 個參數。這種線性單元的「瓶頸」網路對應標準的資料分析技術——**主成分分析**(Ch. 16)。一般而言，

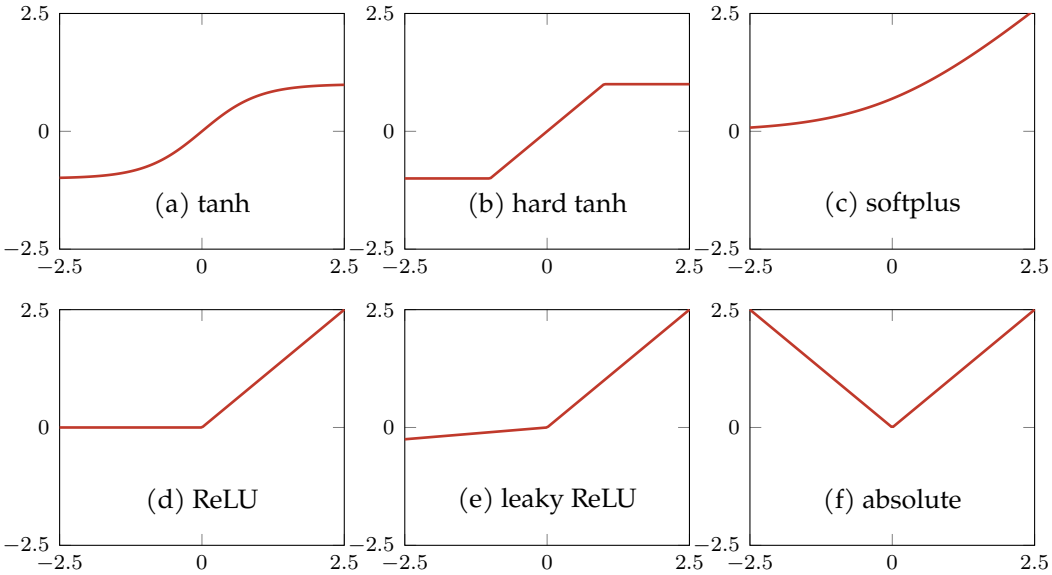


圖 6.8: 各種非線性激活函數。

線性單元的多層網路乏人問津，因為整體函數仍是線性的。

S 形家族。 簡單的非線性可微函數是邏輯 S 形 $\sigma(a) = 1/(1+e^{-a})$，早年廣泛使用，部分靈感來自生物神經元。密切相關的 tanh（圖 6.8a）與邏輯 S 形只差輸入輸出的線性轉換，故任何用邏輯 S 形隱藏單元的網路都有等價的 tanh 網路（習題 3）——但**訓練**時兩者不必等價：梯度式最佳化需要初始化權重，激活函數換了，初始化方案也得跟著調。tanh 的「硬」版本（Collobert, 2004）為 $h(a) = \max(-1, \min(1, a))$（圖 6.8b）。

梯度消失：S 形函數的原罪

邏輯 S 形與 tanh 的共同大缺點：輸入為大正值或大負值時，**梯度呈指數式趨零**（§7.4.2 的「梯度消失」問題）。一般而言，最好使用（至少在輸入為大正值時）梯度非零的激活函數。

softplus 與 ReLU 家族。 **softplus** 定義為

$$h(a) = \ln\bigl(1 + \exp(a)\bigr) \tag{6.10}$$

（圖 6.8c）：$a \gg 1$ 時 $h(a) \simeq a$，輸入大而正時梯度仍不為零，緩解梯度消失（其優雅性質見習題 4）。更簡單的是**整流線性單元**（rectified linear unit, ReLU）

$$h(a) = \max(0, a) \tag{6.11}$$

（圖 6.8d）——經驗上表現最好的激活函數之一，使用極廣。（嚴格說 $a = 0$ 處導數未定義，實務上可放心忽略。）softplus 可視為 ReLU 的平滑版，故也稱 soft ReLU。ReLU 在負輸入處梯度為零，可能使某些隱藏單元在訓練中收不到「誤差訊號」；**leaky ReLU** 試圖避免此問題：

$$h(a) = \max(0, a) + \alpha \min(0, a), \qquad 0 < \alpha < 1 \tag{6.12}$$

（圖 6.8e），在 $a < 0$ 也有非零梯度以驅動訓練。取 $\alpha = -1$ 得 $h(a) = |a|$（圖 6.8f）；另一變體讓每個隱藏單元有自己的 α_j、隨權重一起由梯度學得。ReLU 的引入使訓練效率大幅超越先前的 S 形

激活（Krizhevsky, Sutskever, and Hinton, 2012）：能有效訓練更深的網路、對權重隨機初始化較不敏感、適合低精度實作（如 8 位元定點）、計算便宜。許多實際應用把 ReLU 當預設。

6.2.4 權重空間對稱性

前饋網路有一個性質：**多組不同的權重向量 $\mathbf{w}$ 可以給出完全相同的輸入–輸出映射**（Chen, Lu, and Hecht-Nielsen, 1993）。考慮圖 6.5 的兩層網路、M 個 tanh 隱藏單元、兩層全連接：

- **變號對稱**：把餵入某隱藏單元的所有權重與偏置變號，該單元的前激活與激活都反號（tanh 是奇函數）；再把**離開**該單元的所有權重變號即可完全補償。M 個隱藏單元有 M 個獨立的變號，貢獻因子 2^M。
- **交換對稱**：把進出某隱藏單元的所有權重（與偏置）跟另一個隱藏單元的整組交換，映射函數不變。M 個單元的排列共 $M!$ 種。

因此任一權重向量屬於一個 $M!\,2^M$ 個等價權重向量的集合；多於兩層時，總對稱因子是各隱藏層因子的乘積。可以證明（除特定權重值造成的偶然對稱外）這些就是權重空間**全部**的對稱性，且不限於 tanh，適用於廣泛的激活函數（Kůrková and Kainen, 1994）。實務上影響不大（訓練只要找到**一組**參數即可），但在以貝氏方法評估不同大小網路的機率分布時，權重空間對稱性就必須計入（Bishop, 2006）。

6.3 深度網路

我們以「讓線性迴歸／分類模型的基底函數本身帶可學習參數」引出了圖 6.5 的兩層網路。多年來這是最廣泛使用的架構——主要因為超過兩層的網路難以有效訓練。然而把網路擴展到兩層以上——即**深度神經網路**——好處很多，而近年的訓練技術（Ch. 7）對多層網路也確實有效。

兩層架構 (6.9) 可輕易延伸到任意有限的 L 層：第 $l = 1, \dots, L$ 層計算

$$\mathbf{z}^{(l)} = h^{(l)}\big(\mathbf{W}^{(l)}\mathbf{z}^{(l-1)}\big), \tag{6.13}$$

其中 $h^{(l)}$ 是第 l 層的激活函數、$\mathbf{W}^{(l)}$ 是對應的權重與偏置矩陣，$\mathbf{z}^{(0)} = \mathbf{x}$ 為輸入向量、$\mathbf{z}^{(L)} = \mathbf{y}$ 為輸出向量。

「幾層」怎麼數？

文獻中對層數的稱呼有些混亂：圖 6.5 的網路有人稱三層（數單元層、把輸入也算單元），有人稱單隱藏層網路（數隱藏單元的層數）。本書建議稱它為**兩層**網路——因為決定網路性質的是**可學習權重的層數**。

兩層網路已具通用近似能力，但多於兩層的網路有時能以**少得多**的參數表示同一函數。Montúfar et al. (2014) 證明：網路函數把輸入空間劃分成的區域數，隨**深度**呈指數成長、隨隱藏層**寬度**僅呈多項式成長；用兩層網路表示同一函數，需要指數量級的隱藏單元。

6.3.1 階層式表徵

上述結果雖有趣，但探索深度網路更有力的理由是：**網路架構本身編碼了一種歸納偏差——輸出透過階層式表徵與輸入空間相連**。以影像物體辨識為例：像素與「貓」這種高階概念之間的關係高度複雜且非線性，對兩層網路是極端困難的問題；深度網路則可在**前段層**學會偵測**低階特徵**（如

邊緣），再於後續層組合成**較高階特徵**（如眼睛、鬍鬚），更後面的層再組合以偵測貓的存在。這可視為**組合式**歸納偏差：高階物體（貓）由低階物體（眼睛）組成，低階物體再由更低階元素（邊緣）組成。反過來想像產生影像的過程：從邊緣出發、組合成圓圈等簡單形狀、再組合成貓等高階物體——每一階段都有多種組合方式，可能性隨深度**指數**增加。

6.3.2 分散式表徵

神經網路還能利用另一種組合性——**分散式表徵**（distributed representation）。概念上，隱藏層的每個單元可視為該層級的一個「特徵」偵測器：激活高代表特徵存在、低代表不存在。某層有 M 個單元，看似只能表示 M 種特徵；但網路可以學到不同的表徵——由**單元的組合**代表特徵——讓 M 個單元潛在地表示 2^M 種特徵，隨單元數指數成長。例如處理人臉影像的網路：一張臉可能戴或不戴眼鏡、戴或不戴帽子、有或沒有鬍子，共八種組合。可以用八個單元各自對應一種組合，也可以只用**三個**單元、每個屬性一個，更精簡地表示（屬性可獨立存在，儘管統計上可能相關）。第十章將詳細探討深度網路在訓練中自行發現的內部表徵。

6.3.3 表徵學習

深度網路的連續各層可視為對資料做一連串**轉換**，使目標任務更容易解。例如成功學會分類皮膚病灶良性／惡性的網路，必然已學會把原始影像資料轉換到「最後一層隱藏單元的輸出」所代表的新空間，使網路的最後一層能區分兩類——最後一層可視為簡單的**線性**分類器，因此在最後隱藏層的表徵中，兩類必須被線性面良好分開。這種「發現使後續任務更容易的非線性資料轉換」的能力稱為**表徵學習**（representation learning；Bengio, Courville, and Vincent, 2012）。學得的表徵（有時稱**嵌入空間**，embedding space）由某個隱藏層的輸出給出：任何輸入向量都可經前向傳播轉換到此表徵。

表徵學習特別強大之處在於能利用**無標籤資料**。無標籤資料常易大量收集，取得標籤卻困難得多——車上的攝影機可在城市中收集大量街景影像，但標注行人、路標需要昂貴耗時的人工。從無標籤資料學習稱為**非監督式學習**。例如可訓練網路以影像為輸入、**重建同一張影像**為輸出；讓隱藏層單元數少於像素數使任務不平凡，迫使網路學會某種壓縮。每張影像既是輸入也是目標，故只需無標籤資料——這類網路稱為**自編碼器**（autoencoders，§19.1），目的是逼出對其他任務（如影像分類）有用的內部表徵。

歷史上，非監督式學習在讓（卷積網路以外的）第一批深度網路成功訓練上扮演過要角：先對每一層做非監督式**預訓練**，再以梯度式監督訓練整個網路；後來發現在適當條件下可以省略預訓練、純監督式從頭訓練。但預訓練與表徵學習在其他脈絡仍是深度學習的核心——最著名的是自然語言處理：Transformer 模型在大量文本上訓練，學到極精緻的語言內部表徵，支撐了達到甚至超越人類水準的廣泛能力（Ch. 12）。

6.3.4 遷移學習

為某任務學到的內部表徵，對**相關任務**也可能有用。例如在大型日常物體標註資料集上訓練的網路，學會了把影像轉換成更適合物體分類的表徵；之後只需用較小的皮膚病灶標註資料集**重新訓練最後的分類層**，就得到病灶分類器。這是**遷移學習**（transfer learning；Hospedales et al., 2021）的例子：因為網路能利用自然影像共通的性質，準確率比只用病灶資料訓練更高（圖 6.9）。

一般地，遷移學習用資料充裕的相關任務 B 改善資料短缺的任務 A 的表現：兩任務的輸入類型要相同，且需有共通性，使從 B 學到的低階特徵或內部表徵對 A 有用。卷積網路（Ch. 10）中許多影像任務需要類似的低階特徵（對應網路前段層），後段層才較專門化，因此特別適合遷移學習。任務 A 資料極少時只重訓最後一層；資料多一點就可重訓多層。用一個任務學參數再用於

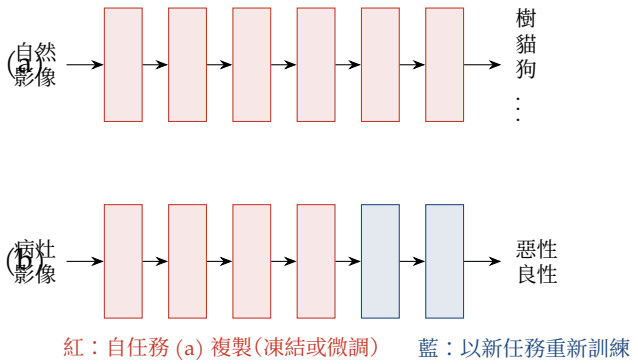


圖 6.9: 遷移學習的示意。(a) 先在資料充足的任務(如自然影像物體分類)上訓練網路；(b) 網路的前段層(紅)自第一個任務複製，最後幾層(藍)再以資料較稀少的新任務(如皮膚病灶分類)重新訓練。

其他任務的過程稱為**預訓練**(pre-training)。實作提示：對新任務不必對整個網路跑 SGD——把新訓練資料**過一次**固定的預訓練網路、算出新表徵下的輸入，再只對最後幾層的小網路做迭代最佳化，效率高得多。也可進一步**微調**(fine-tuning)：以極小的學習率、有限的迭代次數調整整個網路，避免對新任務的小資料集過度擬合。

相關做法還有：

- **多任務學習**(multitask learning；Caruana, 1997)：同時聯合學習多個相關任務。例如為不同使用者客製垃圾郵件過濾器：單一使用者樣本少、各訓各的效果差；改用合併資料訓練一個大網路，前段層共享、後段層各使用者有自己的參數——跨任務共享資料讓網路利用任務間的共通性，所有使用者的準確率都提升。
- **元學習**(meta-learning，又稱 learning to learn)：多任務學習針對**固定**的任務集合做預測；元學習的目標是對**訓練時沒見過**的未來任務做預測——不只學跨任務共享的內部表徵，連**學習演算法本身**也學(Hospedales et al., 2021)。
- **少樣本學習**(few-shot learning)：新類別只有極少數標註樣本時的泛化；只用單一樣本稱 **one-shot learning**。

6.3.5 對比式學習

最常用且強大的表徵學習方法之一是**對比式學習**(contrastive learning；Gutmann and Hyvärinen, 2010；Oord, Li, and Vinyals, 2018；Chen, Kornblith, et al., 2020)。想法是學一個表徵，使指定的**正對**(positive pairs)在嵌入空間中靠近、**負對**(negative pairs)遠離：若正對語意相似、負對語意相異，就能學到「相似輸入彼此靠近」的表徵空間，使分類等下游任務容易許多。與其他表徵學習一樣，通常不直接用網路輸出，而以某個較早層的激活作為嵌入空間。對比式學習與多數機器學習任務不同：**單一輸入的誤差函數是相對其他輸入定義的**，沒有逐輸入的標籤或目標。

設資料點 $\mathbf{x}$(稱**錨點**，anchor)與指定的 $\mathbf{x}^+$ 構成正對，另指定 $\{\mathbf{x}_1^-, \dots, \mathbf{x}_N^-\}$ 各與 $\mathbf{x}$ 構成負對。需要一個損失函數獎勵 $\mathbf{x}$ 與 $\mathbf{x}^+$ 的表徵接近、懲罰 $\mathbf{x}$ 與各 $\mathbf{x}_n^-$ 接近。最常用的是 **InfoNCE 損失**(NCE = noise contrastive estimation)：設神經網路 $f_{\mathbf{w}}(\mathbf{x})$ 把輸入映到**正規化**($\|f_{\mathbf{w}}(\mathbf{x})\| = 1$)的表徵空間，則

$$E(\mathbf{w}) = -\ln \frac{\exp\{f_{\mathbf{w}}(\mathbf{x})^\top f_{\mathbf{w}}(\mathbf{x}^+)\}}{\exp\{f_{\mathbf{w}}(\mathbf{x})^\top f_{\mathbf{w}}(\mathbf{x}^+)\} + \sum_{n=1}^{N} \exp\{f_{\mathbf{w}}(\mathbf{x})^\top f_{\mathbf{w}}(\mathbf{x}_n^-)\}}. \tag{6.14}$$

餘弦相似度 $f_{\mathbf{w}}(\mathbf{x})^\top f_{\mathbf{w}}(\mathbf{x}^+)$ 度量正對在學得空間中的接近程度，同一度量也評估錨點與負例的接

近程度。注意此函數**很像分類的交叉熵**：正對的餘弦相似度是「正確類別」的 logit，各負對的是「錯誤類別」的 logit。負對**不可或缺**：沒有它們，嵌入會退化成把所有點映到同一表徵的平凡解。

一個對比式學習演算法主要由**正負對怎麼選**定義——這正是我們用先驗知識指定「好表徵」的方式：

三種對比式學習範式

- **實例判別**（instance discrimination）：以「保留語意、大改像素」的**擾動**（旋轉、平移、色偏等，與資料增強密切相關，§9.1.3）產生正對；資料集中其他影像作負對（Wu et al., 2018；He et al., 2019；Chen, Kornblith, et al., 2020）。
- **監督式對比學習**（supervised contrastive learning；Khosla et al., 2020）：有類別標籤時，同類影像作正對、異類作負對——不再依賴指定增強方式，也避免把兩張語意相近的影像當負對；效果常勝過直接用交叉熵分類學表徵。
- **CLIP**（contrastive language–image pre-training；Radford et al., 2021）：正負對可以**跨模態**——正對是影像與其文字說明，兩個獨立的映射函數（影像的 $f_{\mathbf{w}}$、文字的 $g_{\boldsymbol{\theta}}$）把兩種模態映到**同一**表徵空間；負對是錯配的影像與說明。稱為**弱監督**，因為帶說明的影像可由網路爬取、比人工標類容易。損失是對稱的兩項：

$$E(\mathbf{w}) = -\frac{1}{2}\ln\frac{\exp\{f_{\mathbf{w}}(\mathbf{x}^+)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}^+)\}}{\exp\{f_{\mathbf{w}}(\mathbf{x}^+)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}^+)\} + \sum_{n=1}^{N}\exp\{f_{\mathbf{w}}(\mathbf{x}_n^-)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}^+)\}} - \frac{1}{2}\ln\frac{\exp\{f_{\mathbf{w}}(\mathbf{x}^+)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}^+)\}}{\exp\{f_{\mathbf{w}}(\mathbf{x}^+)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}^+)\} + \sum_{m=1}^{M}\exp\{f_{\mathbf{w}}(\mathbf{x}^+)^{\mathsf{T}} g_{\boldsymbol{\theta}}(\mathbf{y}_m^-)\}}, \tag{6.15}$$

分別要求「影像的表徵相對其他影像更接近其文字說明的表徵」與「文字說明的表徵相對其他說明更接近其影像的表徵」。任何具有成對模態的資料集都可如此學表徵。

6.3.6 一般網路架構

到目前為止的架構都是「全連接層的序列」。但由於**網路圖與其數學函數一一對應**，考慮更複雜的網路圖就能得到更一般的網路映射——唯一限制是必須維持**前饋**架構（有向圖無閉合迴路），以確保輸出是輸入的確定性函數。此時每個（隱藏或輸出）單元計算

$$z_k = h\left(\sum_{j\in\mathcal{A}(k)} w_{kj} z_j + b_k\right), \tag{6.16}$$

其中 $\mathcal{A}(k)$ 為節點 k 的**祖先**集合（送連結給單元 k 的單元），b_k 為其偏置。給定輸入值，逐次套用 (6.16) 即可算出包含輸出單元在內的所有激活（圖 6.10）。

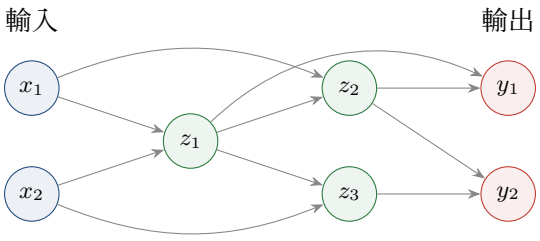


圖 6.10: 具有一般前饋拓樸的神經網路例子：允許跨層連結，但不允許閉合的有向迴路。每個隱藏與輸出單元都有對應的偏置參數（圖中省略）。

6.3.7 張量

線性代數在神經網路中居於核心：資料集、激活、參數以純量、向量、矩陣表示。但也會遇到更高維的變數。例如 N 張 $I \times J$ 像素的彩色影像資料集：一個特定強度值可以用四維陣列 X 表示，元素 x_{ijkn} 中 i, j 索引影像內的列與行、$k \in \{1, 2, 3\}$ 索引 R、G、B 強度、n 索引資料集中的影像。這類高維陣列稱為**張量**(tensors)，純量、向量、矩陣都是特例。之後討論更精緻的網路架構時會看到許多張量；GPU 等大規模平行處理器特別適合處理張量。

教學補充：深度、表徵與可解釋性的張力

本節的三個「指數」值得放在一起看：深度使輸入空間的分割區域數**指數**成長(Montúfar)、分散式表徵使可表示特徵數隨單元數**指數**成長、階層組合使可產生的物件種類隨深度**指數**成長。這是深度學習威力的來源，也是它難以解釋的根源——單一單元不再對應單一概念。對照之下，符號迴歸尋找的是「淺而明確」的表達式；兩者的取捨正是可解釋 AI 的核心議題。在 VTEC 預測中，一條務實的路線是：用深度網路確立可達到的精度上限，再用符號迴歸在可接受的精度損失內找出可解釋的公式。

6.4 誤差函數

前面各章為迴歸與分類的線性模型導出了合適的誤差函數與對應的輸出單元激活函數；同樣的考量原封不動地適用於多層神經網路，這裡把要點整理一遍。

6.4.1 迴歸

先考慮單一實值目標變數 t。循單層網路迴歸的討論(§2.3.4、§4.1.2)，假設 t 服從均值依賴 $\mathbf{x}$(由網路輸出給出)的高斯分布：

$$p(t \mid \mathbf{x}, \mathbf{w}) = \mathcal{N}\big(t \mid y(\mathbf{x}, \mathbf{w}),\, \sigma^2\big), \tag{6.17}$$

σ^2 為高斯雜訊變異數。(這個假設有些侷限，某些應用需要推廣到更一般的分布——見 §6.5。)對 (6.17) 的條件分布，輸出激活函數取**恆等**即可，因為這種網路已能逼近從 $\mathbf{x}$ 到 y 的任何連續函數。給定 N 筆 i.i.d. 觀測 $\mathbf{X} = \{\mathbf{x}_1, \ldots, \mathbf{x}_N\}$ 及目標值 $\mathbf{t}$，取概似函數的負對數(機器學習慣例是最小化誤差函數而非最大化概似)，得

$$\frac{1}{2\sigma^2} \sum_{n=1}^{N} \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2 + \frac{N}{2} \ln \sigma^2 + \frac{N}{2} \ln(2\pi), \tag{6.18}$$

可用來學 $\mathbf{w}$ 與 σ^2。對 $\mathbf{w}$ 而言，最大化概似等價於最小化**平方和誤差**

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^{N} \{y(\mathbf{x}_n, \mathbf{w}) - t_n\}^2 \tag{6.19}$$

(丟掉加法與乘法常數)。所得的解記為 $\mathbf{w}^\star$。

$\mathbf{w}^\star$ 通常不是全域最佳解——而且沒關係

網路函數 $y(\mathbf{x}_n, \mathbf{w})$ 的非線性使 $E(\mathbf{w})$ **非凸**，找全域最佳解一般不可行；而且誤差函數常會加上正則化項、訓練程序也常有其他修改，最終的網路參數可能與最大概似解相去甚遠。這與第四、五章「凸且有閉式解或唯一解」的世界是本質的不同——也是第七章(最佳化)整章存在

的理由。

找到 $\mathbf{w}^\star$ 後，σ^2 由最小化 (6.18) 得（習題 7）

$$\sigma^{2\star} = \frac{1}{N}\sum_{n=1}^{N}\{y(\mathbf{x}_n, \mathbf{w}^\star) - t_n\}^2, \tag{6.20}$$

即殘差變異數——注意它可以在找 $\mathbf{w}^\star$ 的迭代最佳化**完成之後**一次算出。

若有多個目標變數，並假設它們在給定 $\mathbf{x}$ 與 $\mathbf{w}$ 下條件獨立、共用雜訊變異數 σ^2，則

$$p(\mathbf{t} \mid \mathbf{x}, \mathbf{w}) = \mathcal{N}\big(\mathbf{t} \mid \mathbf{y}(\mathbf{x}, \mathbf{w}),\, \sigma^2\mathbf{I}\big), \tag{6.21}$$

同樣的論證給出平方和誤差 $E(\mathbf{w}) = \frac{1}{2}\sum_n \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}) - \mathbf{t}_n\|^2$ 與 $\sigma^{2\star} = \frac{1}{NK}\sum_n \|\mathbf{y}(\mathbf{x}_n, \mathbf{w}^\star) - \mathbf{t}_n\|^2$（$K$ 為目標維度）。放掉條件獨立假設也可以，代價是稍複雜的最佳化（習題 7）。迴歸中輸出激活為恆等（$y_k = a_k$），對應的平方和誤差滿足

$$\frac{\partial E}{\partial a_k} = y_k - t_k. \tag{6.22}$$

6.4.2 二元分類

單一目標變數 $t \in \{0, 1\}$（$t = 1$ 表 $\mathcal{C}_1$、$t = 0$ 表 $\mathcal{C}_2$）。循典則連結函數的討論（§5.4.6），取單一輸出、邏輯 S 形激活，$0 \le y(\mathbf{x}, \mathbf{w}) \le 1$ 詮釋為 $p(\mathcal{C}_1 \mid \mathbf{x})$。目標的條件分布為 Bernoulli：

$$p(t \mid \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \,\{1 - y(\mathbf{x}, \mathbf{w})\}^{1-t}. \tag{6.23}$$

對獨立觀測的訓練集，負對數概似即**交叉熵誤差**

$$E(\mathbf{w}) = -\sum_{n=1}^{N}\big\{t_n \ln y_n + (1 - t_n)\ln(1 - y_n)\big\}, \qquad y_n = y(\mathbf{x}_n, \mathbf{w}). \tag{6.24}$$

Simard, Steinkraus, and Platt (2003) 發現：分類問題用交叉熵取代平方和誤差，**訓練更快、泛化更好**。

注意 (6.23) 中沒有雜訊變異數 σ^2 的類比，因為假設了目標值標註正確。但模型很容易推廣以容納**標註錯誤**：引入目標值 t 被翻錯的機率 ϵ（Opper and Winther, 2000），得

$$p(t = 1 \mid \mathbf{x}, \mathbf{w}) = (1 - \epsilon)\, y(\mathbf{x}, \mathbf{w}) + \epsilon\,\{1 - y(\mathbf{x}, \mathbf{w})\}, \tag{6.25}$$

ϵ 可事先設定，或當作由資料推論的超參數；此誤差函數使模型對誤標資料**穩健**（習題 8）。

若要做 K 個**互相獨立**的二元分類，可用 K 個各配邏輯 S 形激活的輸出，各自對應二元標籤 $t_k \in \{0, 1\}$。假設給定輸入後各標籤條件獨立：

$$p(\mathbf{t} \mid \mathbf{x}, \mathbf{w}) = \prod_{k=1}^{K} y_k(\mathbf{x}, \mathbf{w})^{t_k}\,[1 - y_k(\mathbf{x}, \mathbf{w})]^{1-t_k}, \tag{6.26}$$

負對數概似為

$$E(\mathbf{w}) = -\sum_{n=1}^{N}\sum_{k=1}^{K}\big\{t_{nk}\ln y_{nk} + (1 - t_{nk})\ln(1 - y_{nk})\big\}. \tag{6.27}$$

誤差函數對特定輸出單元前激活的導數同樣是 (6.22) 的形式(習題 10)。

6.4.3 多類別分類

標準的多類別問題中，每個輸入屬於 K 個互斥類別之一：二元目標變數 $t_k \in \{0,1\}$ 採 1-of-K 編碼，網路輸出詮釋為 $y_k(\mathbf{x},\mathbf{w}) = p(t_k = 1 \mid \mathbf{x})$，誤差函數為 (5.80)：

$$E(\mathbf{w}) = -\sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk} \ln y_k(\mathbf{x}_n,\mathbf{w}), \tag{6.28}$$

對應典則連結的輸出激活是 softmax：

$$y_k(\mathbf{x},\mathbf{w}) = \frac{\exp\{a_k(\mathbf{x},\mathbf{w})\}}{\sum_j \exp\{a_j(\mathbf{x},\mathbf{w})\}}, \tag{6.29}$$

滿足 $0 \le y_k \le 1$、$\sum_k y_k = 1$。注意對所有 a_k 加同一常數不改變 y_k，使誤差函數沿權重空間某些方向為常數；加入適當的正則化項(Ch. 9)即可移除此退化。誤差對輸出前激活的導數再度是熟悉的 (6.22)。

總結：問題類型 $\Rightarrow$ 輸出激活 + 誤差函數

問題	目標分布	輸出激活	誤差函數
迴歸	高斯	恆等(線性)	平方和 (6.19)
二元分類	Bernoulli	邏輯 S 形	交叉熵 (6.24)
K 個獨立二元分類	Bernoulli 乘積	K 個邏輯 S 形	(6.27)
多類別分類	多項(1-of-K)	softmax	多類交叉熵 (6.28)

兩類問題可用單一 S 形輸出，也可用兩個輸出配 softmax。此程序完全一般：考慮其他形式的條件分布，其負對數概似就是對應的誤差函數——下一節的多峰輸出即為一例。

6.5 混合密度網路

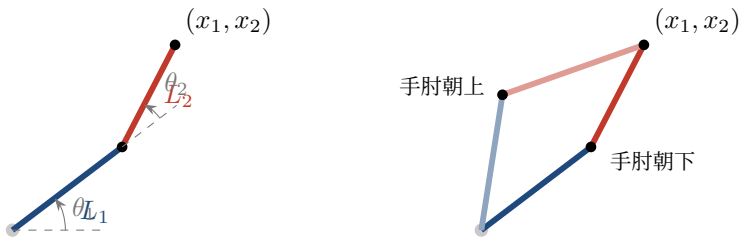
到目前為止，網路輸出代表的都是簡單的機率分布——連續變數的高斯或離散變數的二元分布。本章最後說明：把網路輸出當作**更複雜分布的參數**(此處為高斯混合模型)，神經網路就能表示更一般的條件機率——這就是**混合密度網路**(mixture density network)，我們將定義其誤差函數與對應的輸出單元激活函數。

6.5.1 機器人運動學的例子

監督式學習的目標是為條件分布 $p(\mathbf{t} \mid \mathbf{x})$ 建模；許多簡單迴歸問題取其為高斯，但實際問題的分布可能顯著非高斯。典型情境是**逆問題**(inverse problems)：分布可能**多峰**，高斯假設會導致非常差的預測。

簡單的例子是二連桿機械臂的運動學(圖 6.11)。**正向問題**——給定關節角求末端執行器位置——有唯一解；但實務上我們要把末端移到**指定位置**，必須反過來求關節角，這個**逆問題有兩個**

解：「手肘朝上」與「手肘朝下」。正向問題通常對應物理系統中的因果關係、一般有唯一解（例如特定疾病導致特定症狀型態）；機器學習中要解的往往是逆問題（由症狀推測疾病），若正向映射是多對一，逆問題就有多重解（多種疾病可能產生相同症狀）。



(a) 正向運動學　　(b) 逆向運動學：兩個解

圖 6.11: (a) 二連桿機械臂：末端執行器的直角座標 (x_1, x_2) 由兩個關節角 θ_1, θ_2 與（固定的）臂長 L_1, L_2 **唯一**決定——正向運動學。(b) 實務上要找的是達成指定末端位置的關節角——逆向運動學有「手肘朝上」與「手肘朝下」兩個解。

機器人例子中的多峰性由幾何方程式明白呈現；許多機器學習問題（尤其高維空間）中的多峰性則不那麼顯眼。為了便於視覺化，考慮一個玩具問題：在 $(0, 1)$ 均勻取樣 x_n，以 $x_n + 0.3\sin(2\pi x_n)$ 加上 $(-0.1, 0.1)$ 的均勻雜訊得到 t_n；**逆問題**則是保留同一批資料點、把 x 與 t 的角色互換。圖 6.12 顯示兩個資料集，以及以「六個 tanh 隱藏單元、單一線性輸出」的兩層網路最小化平方和誤差的擬合結果——最小平方對應高斯假設下的最大概似：正向問題擬合良好，**高度非高斯的逆問題**則擬合得很糟——網路試圖以單值函數逼近條件**均值**，在多峰區域給出落在各分支**之間**、不屬於任何分支的預測。

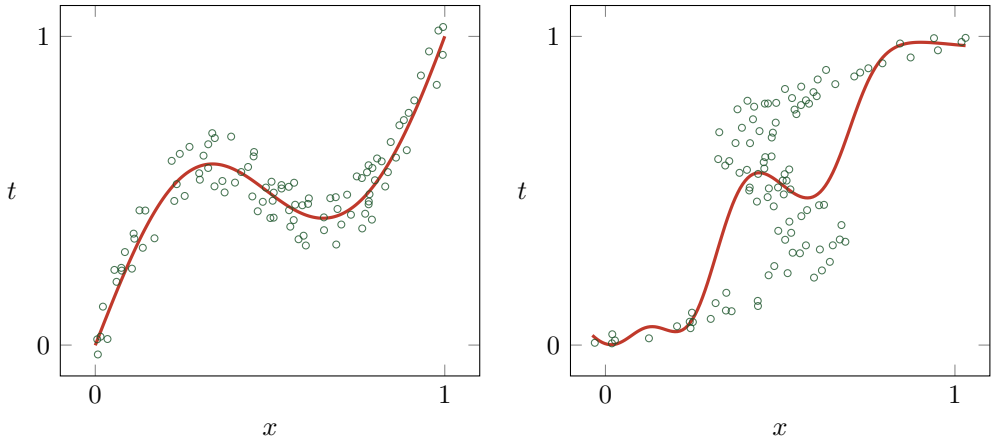


圖 6.12: 左：簡單正向問題的資料集，紅線為兩層神經網路（六個 tanh 隱藏單元）最小化平方和誤差的擬合結果。右：把 x 與 t 角色互換所得的逆問題——同樣的網路、同樣的訓練方式，因資料的多峰性而擬合極差。（實際訓練所得。）

6.5.2 條件混合分布

因此我們尋求為條件機率分布建模的一般框架：對 $p(\mathbf{t} \mid \mathbf{x})$ 使用**混合模型**，其**混合係數與成分密度都是輸入 $\mathbf{x}$ 的靈活函數**——混合密度網路。只要網路夠靈活，此框架就能逼近任意的條件分布。這裡以高斯成分明確展開：

$$p(\mathbf{t} \mid \mathbf{x}) = \sum_{k=1}^{K} \pi_k(\mathbf{x})\, \mathcal{N}\big(\mathbf{t} \mid \boldsymbol{\mu}_k(\mathbf{x}),\, \sigma_k^2(\mathbf{x})\big). \tag{6.30}$$

這是**異質變異**(heteroscedastic)模型的一例——資料的雜訊變異數是輸入 $\mathbf{x}$ 的函數。成分也可改用其他分布(目標為二元時可用 Bernoulli);這裡限定等向共變異數,但可用 Cholesky 分解表示一般共變異數矩陣(Williams, 1996)。注意即使成分等向,混合分布使 $p(\mathbf{t}\mid\mathbf{x})$ **不**對 $\mathbf{t}$ 的分量因子化——這點與標準平方和迴歸模型不同。

混合模型的參數——混合係數 $\pi_k(\mathbf{x})$、均值 $\boldsymbol{\mu}_k(\mathbf{x})$、變異數 $\sigma_k^2(\mathbf{x})$——全部由**一個**以 $\mathbf{x}$ 為輸入的神經網路輸出決定(圖 6.13)。混合密度網路與**專家混合**(mixture of experts;Jacobs et al., 1991)密切相關,主要差異是:專家混合中每個成分模型有獨立參數,混合密度網路則用同一個函數預測所有成分密度的參數與混合係數——非線性隱藏單元由各輸入相依函數**共享**。

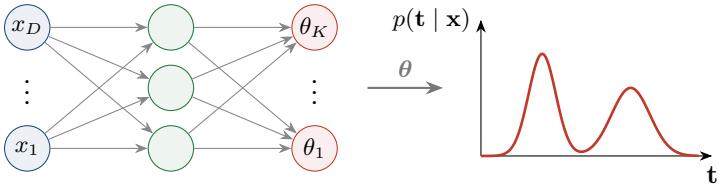


圖 6.13: 混合密度網路:以 $\mathbf{x}$ 為輸入的神經網路輸出一個參數化混合模型的參數 $\boldsymbol{\theta}$(混合係數、均值、變異數),從而表示一般的條件機率密度 $p(\mathbf{t}\mid\mathbf{x})$。

網路可以是(例如)tanh 隱藏單元的兩層網路。若混合模型 (6.30) 有 K 個成分、$\mathbf{t}$ 有 L 個分量,網路需要:決定混合係數的 K 個前激活 a_k^π、決定標準差的 K 個 a_k^σ、決定均值分量 $\mu_{kj}(\mathbf{x})$ 的 $K\times L$ 個 a_{kj}^μ——共 $(L+2)K$ 個輸出(相較之下,只預測條件均值的一般網路只有 L 個輸出)。各參數的約束由輸出激活函數實現:

$$\text{混合係數}\Big(\textstyle\sum_k \pi_k = 1,\ 0\le\pi_k\le 1\Big):\qquad \pi_k(\mathbf{x}) = \frac{\exp(a_k^\pi)}{\sum_{l=1}^{K}\exp(a_l^\pi)}\qquad(\text{softmax})\tag{6.31}$$

$$\text{標準差}(\sigma_k\ge 0):\qquad \sigma_k(\mathbf{x}) = \exp(a_k^\sigma)\qquad(\text{指數})\tag{6.32}$$

$$\text{均值(實數)}:\qquad \mu_{kj}(\mathbf{x}) = a_{kj}^\mu\qquad(\text{恆等})\tag{6.33}$$

可學習參數是網路的權重與偏置向量 $\mathbf{w}$,以最大概似(等價地,最小化負對數概似)設定;對獨立資料,誤差函數為

$$E(\mathbf{w}) = -\sum_{n=1}^{N}\ln\left\{\sum_{k=1}^{K}\pi_k(\mathbf{x}_n,\mathbf{w})\,\mathcal{N}\big(\mathbf{t}_n\mid\boldsymbol{\mu}_k(\mathbf{x}_n,\mathbf{w}),\,\sigma_k^2(\mathbf{x}_n,\mathbf{w})\big)\right\}.\tag{6.34}$$

6.5.3 梯度最佳化

最小化 (6.34) 需要 $E(\mathbf{w})$ 對 $\mathbf{w}$ 各分量的導數;第八章會介紹如何自動計算,但**明確導出誤差對輸出前激活的導數**很有啟發性,因為它凸顯了這些量的機率詮釋。誤差是各資料點之和,考慮單一資料點 $(\mathbf{x}_n,\mathbf{t}_n)$ 的 E_n。方便起見引入

$$\gamma_{nk} = \gamma_k(\mathbf{t}_n\mid\mathbf{x}_n) = \frac{\pi_k\,\mathcal{N}_{nk}}{\sum_{l=1}^{K}\pi_l\,\mathcal{N}_{nl}},\qquad \mathcal{N}_{nk}\equiv\mathcal{N}\big(\mathbf{t}_n\mid\boldsymbol{\mu}_k(\mathbf{x}_n),\sigma_k^2(\mathbf{x}_n)\big).\tag{6.35}$$

它們有自然的詮釋:把 $\pi_k(\mathbf{x})$ 視為與 $\mathbf{x}$ 相依的**先驗**機率時,γ_{nk} 是混合成分的**後驗**機率(習題 12)。

推導 (三組輸出前激活的梯度). **(i) 混合係數。** $E_n = -\ln\sum_l \pi_l\mathcal{N}_{nl}$,而 π_k 經 softmax 依賴各 a_j^π:

$\partial \pi_k / \partial a_j^\pi = \pi_k(I_{kj} - \pi_j)$。故

$$\frac{\partial E_n}{\partial a_k^\pi} = -\sum_j \frac{\mathcal{N}_{nj}}{\sum_l \pi_l \mathcal{N}_{nl}} \pi_j (I_{jk} - \pi_k) = -\gamma_{nk} + \pi_k \sum_j \gamma_{nj} \implies \boxed{\frac{\partial E_n}{\partial a_k^\pi} = \pi_k - \gamma_{nk}}$$

（用了 $\sum_j \gamma_{nj} = 1$）——又是「模型值減目標值」的形式，只是「目標」換成了成分後驗。

(ii) 均值。 $\mu_{kl} = a_{kl}^\mu$，且 $\partial \mathcal{N}_{nk} / \partial \mu_{kl} = \mathcal{N}_{nk}\,(t_{nl} - \mu_{kl})/\sigma_k^2$，故

$$\boxed{\frac{\partial E_n}{\partial a_{kl}^\mu} = \gamma_{nk} \frac{\mu_{kl} - t_{nl}}{\sigma_k^2}}$$

——成分 k 的「加權殘差」：後驗 γ_{nk} 決定這筆資料歸咎於哪個成分。

(iii) 變異數。 $\sigma_k = \exp(a_k^\sigma)$，$\ln \mathcal{N}_{nk} = -\frac{L}{2}\ln(2\pi) - L \ln \sigma_k - \frac{\|\mathbf{t}_n - \boldsymbol{\mu}_k\|^2}{2\sigma_k^2}$，對 a_k^σ 微分（注意 $\partial \sigma_k / \partial a_k^\sigma = \sigma_k$）：

$$\boxed{\frac{\partial E_n}{\partial a_k^\sigma} = \gamma_{nk}\Big(L - \frac{\|\mathbf{t}_n - \boldsymbol{\mu}_k\|^2}{\sigma_k^2}\Big)}$$

——殘差大於 $\sqrt{L}\,\sigma_k$ 時梯度為負（把 σ_k 調大），反之調小。

對整體誤差 E 的導數由所有資料點加總，或直接把單點梯度用於梯度式最佳化演算法（Ch. 7）。

6.5.4 預測分布

回到圖 6.12 的逆問題玩具例。圖 6.14 是實際訓練一個三成分混合密度網路的結果：混合係數 $\pi_k(x)$、均值 $\mu_k(x)$、條件密度 $p(t \mid x)$ 的等值線，以及近似條件眾數。網路輸出（因而混合模型的參數）必然是輸入的**連續單值**函數；但由圖 6.14(c) 可見，模型透過調節混合成分的幅度 $\pi_k(x)$，能在某些 x 產生單峰、在其他 x 產生三峰的條件密度。

訓練完成後，混合密度網路能對任何輸入預測目標資料的**完整條件密度**——就預測輸出而言，這是資料產生器的完整描述，由它可再算出各應用關心的量。最簡單的是**條件均值**

$$\mathbb{E}[\mathbf{t} \mid \mathbf{x}] = \int \mathbf{t}\, p(\mathbf{t} \mid \mathbf{x})\, \mathrm{d}\mathbf{t} = \sum_{k=1}^{K} \pi_k(\mathbf{x})\, \boldsymbol{\mu}_k(\mathbf{x}), \tag{6.36}$$

可見以最小平方訓練的標準網路（逼近條件均值）是混合密度網路的**特例**。也可求密度繞條件均值的變異數（習題 13）：

$$s^2(\mathbf{x}) = \mathbb{E}\big[\|\mathbf{t} - \mathbb{E}[\mathbf{t} \mid \mathbf{x}]\|^2 \,\big|\, \mathbf{x}\big] = \sum_{k=1}^{K} \pi_k(\mathbf{x}) \Big\{ \sigma_k^2(\mathbf{x}) L + \Big\| \boldsymbol{\mu}_k(\mathbf{x}) - \sum_{l=1}^{K} \pi_l(\mathbf{x}) \boldsymbol{\mu}_l(\mathbf{x}) \Big\|^2 \Big\}, \tag{6.37}$$

比最小平方的結果更一般——變異數是 $\mathbf{x}$ 的函數。

對多峰分布，條件均值可能是很差的代表：控制圖 6.11 的機械臂時，必須**擇一**採用兩組關節角之一，兩個解的**平均**本身不是解！此時**條件眾數**更有價值；混合密度網路的條件眾數沒有簡單解析解、需數值迭代，簡單的替代方案是取各 x 處**最可能成分**（混合係數最大者）的均值——即圖 6.14(d)。

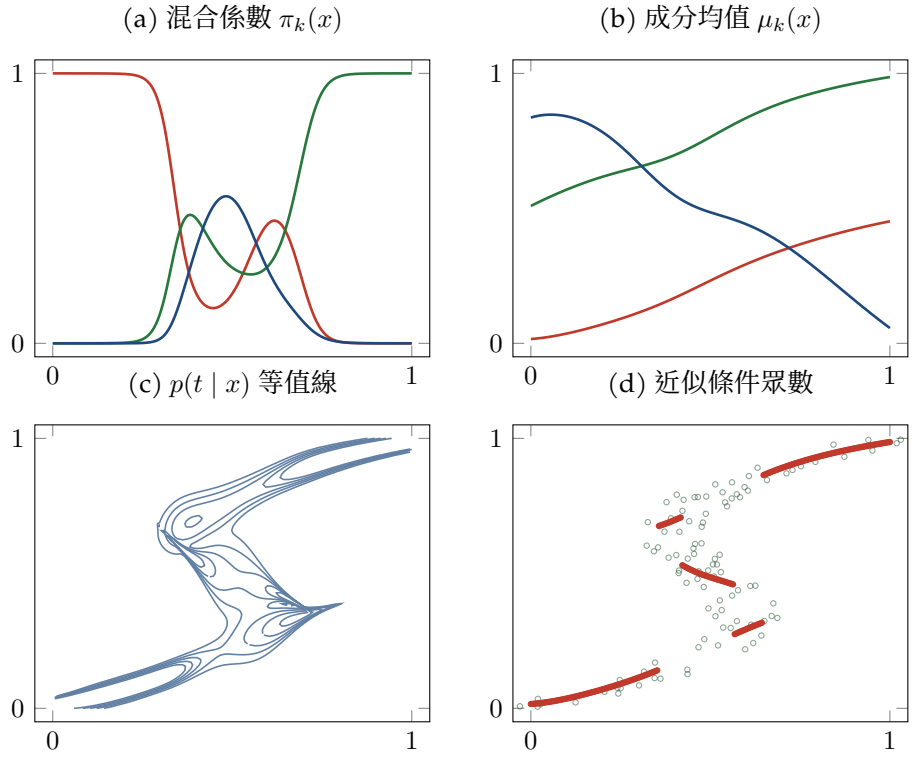


圖 6.14: 對圖 6.12 右的逆問題資料訓練三成分混合密度網路（八個 tanh 隱藏單元、九個輸出）的結果（實際訓練所得）。(a) 三個混合係數 $\pi_k(x)$：在條件密度為單峰的小 x 與大 x 區域，只有一個成分有高先驗；在三峰的中段，三個係數量值相當。(b) 對應（同色）的成分均值 $\mu_k(x)$。(c) 條件機率密度 $p(t \mid x)$ 的等值線。(d) 近似條件眾數（紅點）：取各 x 處混合係數最大之成分的均值。

教學補充：導航與訊號處理中的多峰逆問題

「正向唯一、逆向多解」在本系領域俯拾皆是：GNSS 載波相位的**整數模糊值**——給定模糊值算相位是唯一的，由相位反推模糊值有格點狀的多重解；到達方向估計中的**鏡像模糊**（線性陣列分不清前後）；由 TEC 反演電子密度剖面（多種剖面給出同一積分值）。這些問題若用最小平方網路硬回歸，得到的正是圖 6.12 右那種「落在兩解之間」的災難。混合密度網路提供了機率式的出路：輸出所有候選解及其機率，決策（選哪個峰）留給後端——這正是第五章「推論與決策分離」原則在迴歸問題上的體現。

課後習題

以下習題分為**觀念題**（○）、**推導題**（⋆）與**延伸題**（⋆⋆）。標有「原書 6.x」者改編自教科書習題。推導題請完整寫出過程；延伸題可搭配程式（NumPy 即可）作答。

習題 1 (⋆⋆ 超球的表面積與體積（原書 6.1、6.2）).

(a) 利用高斯積分把 $\prod_{i=1}^{D}\int_{-\infty}^{\infty} e^{-x_i^2}\,\mathrm{d}x_i$ 轉成極座標 $S_D\int_0^\infty e^{-r^2} r^{D-1}\,\mathrm{d}r$，配合 Gamma 函數 $\Gamma(x)=\int_0^\infty t^{x-1}e^{-t}\,\mathrm{d}t$，證明 D 維單位超球的表面積為 $S_D=\dfrac{2\pi^{D/2}}{\Gamma(D/2)}$，體積為 $V_D=S_D/D$。

(b) 驗證 $D=2,3$ 時退化為熟悉的 πr^2、$\frac{4}{3}\pi r^3$（利用 $\Gamma(1)=1$、$\Gamma(3/2)=\sqrt{\pi}/2$）。

(c) 考慮半徑 a 的超球與邊長 $2a$ 的同心超立方體。證明兩者體積比為 $\pi^{D/2}\big/\big(D2^{D-1}\Gamma(D/2)\big)$，並用 Stirling 公式證明 $D\to\infty$ 時此比趨於零。再證明立方體「中心到角」與「中心到面」距離

之比為 $\sqrt{D}$——高維立方體的體積幾乎全在又多又長的「尖刺」(角落)裡！

習題 2 ($\star\star$ 高維高斯的薄殼(原書 6.3))**.** 考慮 D 維高斯 $p(\mathbf{x}) = (2\pi\sigma^2)^{-D/2}\exp\{-\|\mathbf{x}\|^2/2\sigma^2\}$。

(a) 證明對半徑的密度為 $p(r) = \dfrac{S_D r^{D-1}}{(2\pi\sigma^2)^{D/2}}\exp\!\Big(-\dfrac{r^2}{2\sigma^2}\Big)$。

(b) 證明 $p(r)$ 有唯一駐點，且 D 大時位於 $\hat{r} \simeq \sqrt{D}\,\sigma$。

(c) 對 $\epsilon \ll \hat{r}$ 證明 $p(\hat{r}+\epsilon) = p(\hat{r})\exp\{-3\epsilon^2/2\sigma^2\}$($D$ 大時)，故機率質量集中在半徑 $\hat{r}$、厚度 $\sim\sigma$ 的薄殼。

(d) 證明密度在原點比在 $\hat{r}$ 處大 $\exp(D/2)$ 倍。由 (c)(d) 說明：「機率密度最高的地方」與「機率質量所在的地方」在高維可以完全不同。

習題 3 ($\star$ 邏輯 S 形與 tanh 網路的等價(原書 6.4、6.6))**.**

(a) 由 $\tanh(a) = 2\sigma(2a) - 1$ 證明：對任何以邏輯 S 形為隱藏激活的兩層網路 (6.8)，存在計算完全相同函數、但以 tanh 為隱藏激活的等價網路，並寫出兩組參數之間的線性轉換。

(b) 導出 tanh 的導數以自身表示的公式(類比 $\sigma' = \sigma(1-\sigma)$)。

(c) 既然函數空間相同，為何實務上仍在意用哪一個？(提示：初始化、輸出均值與梯度尺度。)

習題 4 ($\star$ softplus 的性質(原書 6.7))**.** 證明 softplus 函數 $\zeta(a) = \ln(1+e^a)$ 滿足：

$$\zeta(a) - \zeta(-a) = a, \qquad \ln\sigma(a) = -\zeta(-a), \qquad \frac{\mathrm{d}\zeta}{\mathrm{d}a} = \sigma(a), \qquad \zeta^{-1}(a) = \ln\!\big(e^a - 1\big),$$

其中 $\sigma(a)$ 為邏輯 S 形函數。並說明第三式如何佐證「softplus 是 ReLU 的平滑版」。

習題 5 ($\star$ swish 激活函數(原書 6.5))**.** swish 函數(Ramachandran, Zoph, and Le, 2017)定義為 $h(x) = x\,\sigma(\beta x)$，$\beta$ 可為可學習參數。

(a) 畫出(或以軟體繪出)$\beta = 0.1,\ 1,\ 10$ 時的 swish 及其一階導數。

(b) 證明 $\beta \to \infty$ 時 swish 趨於 ReLU；$\beta \to 0$ 時趨於什麼？

(c) swish 在 $x < 0$ 有一段**非單調**區域。與 leaky ReLU 相比，這對梯度訊號有何潛在意義？

習題 6 ($\circ$ 權重空間對稱性)**.** 考慮 $D = 3$ 輸入、$M = 4$ 個 tanh 隱藏單元、$K = 2$ 輸出的兩層全連接網路。

(a) 此網路共有幾個可學習參數(含偏置)？

(b) 與任一權重向量等價的權重向量共有幾個？

(c) 若改成三層網路、兩個隱藏層各有 $M_1 = 4$、$M_2 = 3$ 個單元，總對稱因子是多少？

(d) 為何 ReLU 網路沒有「變號對稱」、卻多了另一種連續的「縮放對稱」？(提示：$\max(0,\lambda a) = \lambda\max(0,a)$，$\lambda > 0$。)

習題 7 ($\star$ 迴歸誤差函數(原書 6.8–6.10))**.**

(a) 證明對 σ^2 最小化 (6.18) 得 (6.20)。

(b) 對多輸出網路與條件分布 (6.21)，證明最大概似等價於最小化 $\frac{1}{2}\sum_n \|\mathbf{y}(\mathbf{x}_n,\mathbf{w}) - \mathbf{t}_n\|^2$，且雜訊變異數為 $\sigma^{2\star} = \frac{1}{NK}\sum_n \|\mathbf{y}(\mathbf{x}_n,\mathbf{w}^\star) - \mathbf{t}_n\|^2$。

(c) 改設 $p(\mathbf{t}\mid\mathbf{x},\mathbf{w}) = \mathcal{N}(\mathbf{t}\mid\mathbf{y}(\mathbf{x},\mathbf{w}),\boldsymbol{\Sigma})$，$\boldsymbol{\Sigma}$ 為一般共變異數。寫出 $\boldsymbol{\Sigma}$ 已知時要最小化的誤差函數；再寫出 $\boldsymbol{\Sigma}$ 也要從資料估計時其最大概似解，並說明為何此時 $\mathbf{w}$ 與 $\boldsymbol{\Sigma}$ 的最佳化互相**耦合**。

習題 8 (⋆ 誤標穩健的交叉熵（原書 6.11）). 二元分類中設標籤以機率 ϵ 被翻錯，即實際觀測的目標服從 (6.25)。

(a) 寫出對應的負對數概似誤差函數，並驗證 $\epsilon = 0$ 時退化為 (6.24)。

(b) 說明為何此誤差函數對誤標資料穩健：當 $y \to 0$ 而 $t = 1$ 時，兩種誤差函數各發生什麼事？

(c) 若 ϵ 當作超參數，你會如何用驗證集選它？

習題 9 (⋆ 目標值 ± 1 的二元分類（原書 6.12）). 設網路輸出 $-1 \le y(\mathbf{x}, \mathbf{w}) \le 1$，目標 $t = 1$ 表 $\mathcal{C}_1$、$t = -1$ 表 $\mathcal{C}_2$。導出對應的誤差函數，並指出合適的輸出激活函數。（提示：$p(t \mid \mathbf{x}) = \{(1+y)/2\}^{(1+t)/2}\{(1-y)/2\}^{(1-t)/2}$，激活可取 $\tanh$。）

習題 10 (⋆ 誤差對前激活的導數（原書 6.13–6.15）).

(a) 證明多類別網路（輸出詮釋為 $y_k = p(t_k = 1 \mid \mathbf{x})$）的最大概似等價於最小化 (6.28)。

(b) 對邏輯 S 形輸出配交叉熵 (6.24)，證明 $\partial E / \partial a_k = y_k - t_k$。

(c) 對 softmax 輸出配多類交叉熵 (6.28)，證明同樣的結果。

(d) 綜合本章與 §5.4.6：這個「巧合」的共同根源是什麼？

習題 11 (⋆ 機械臂的正向運動學（原書 6.16）). 寫出圖 6.11 機械臂末端座標 (x_1, x_2) 以關節角 θ_1, θ_2 與臂長 L_1, L_2 表示的方程組（原點取下臂的固定端）。給定 (x_1, x_2)，用餘弦定理求出 θ_2 的兩個解，並說明它們分別對應「手肘朝上／朝下」。

習題 12 (⋆ 混合密度網路的梯度（原書 6.17–6.20）).

(a) 證明 (6.35) 定義的 γ_{nk} 可視為混合分布 (6.30) 中成分的後驗機率 $p(k \mid \mathbf{t})$，其中 $\pi_k(\mathbf{x})$ 視為與 $\mathbf{x}$ 相依的先驗 $p(k)$。

(b) 完整推導 $\partial E_n / \partial a_k^{\pi} = \pi_k - \gamma_{nk}$。

(c) 完整推導 $\partial E_n / \partial a_{kl}^{\mu} = \gamma_{nk}(\mu_{kl} - t_{nl}) / \sigma_k^2$。

(d) 完整推導 $\partial E_n / \partial a_k^{\sigma} = \gamma_{nk}\big(L - \|\mathbf{t}_n - \boldsymbol{\mu}_k\|^2 / \sigma_k^2\big)$。

習題 13 (⋆⋆ 混合密度網路的均值與變異數（原書 6.21）). 驗證條件均值 (6.36) 與條件變異數 (6.37)。（提示：對混合分布，$\mathbb{E}[\|\mathbf{t}\|^2 \mid \mathbf{x}] = \sum_k \pi_k \{L\sigma_k^2 + \|\boldsymbol{\mu}_k\|^2\}$。）並說明為何 (6.37) 可拆讀成「成分內變異」加「成分間變異」——與偏差–變異分解（§4.3）的結構相似之處何在？

習題 14 (⋆ InfoNCE 與交叉熵). 考慮 InfoNCE 損失 (6.14)。

(a) 說明它形式上等同於「$N+1$ 類 softmax 分類」的交叉熵：類別是「哪一個才是正例」，logit 是餘弦相似度。

(b) 若拿掉所有負對（$N = 0$），證明損失恆為 0 且與 $\mathbf{w}$ 無關——對應把所有點映到同一表徵的退化解為何無法被排除？

(c) 表徵被正規化到單位球面上（$\|f_{\mathbf{w}}(\mathbf{x})\| = 1$）。若不正規化，最小化 (6.14) 會發生什麼事？

習題 15 (⋆⋆ 動手實驗).

(a) 以 NumPy 重現圖 6.6：對四個目標函數各訓練一個 1–3–1 tanh 網路（自行實作前向與反向傳播），畫出網路函數與三個隱藏單元的輸出。把隱藏單元數降為 2 或升為 10，觀察並解釋變化。

(b) 重現圖 6.12：對正向與逆向資料各訓練 1–6–1 網路，最小化平方和誤差。

(c) 重現圖 6.14：實作三成分混合密度網路（可直接使用習題 12 的輸出層梯度公式，隱藏層用鏈鎖律），畫出 $\pi_k(x)$、$\mu_k(x)$ 與條件密度。

(d) **延伸**：把 (c) 的做法套用到一個一維 GNSS 式問題——由「殘差相位」$\phi \in (-0.5, 0.5)$ 週波推「整數模糊值 $+$ 相位」的雙峰玩具資料，觀察混合密度網路如何同時輸出兩個候選解及其機率。

附錄 A　中英名詞對照表

英文	中文	簡要說明
curse of dimensionality	維度災難	格子／係數數量隨維度指數成長的困難
hypersphere	超球	高維空間中的球；體積集中在表面薄殼
data manifold	資料流形	真實資料所在的低維非線性子集
radial basis function (RBF)	徑向基底函數	只依賴到中心之距離的基底函數
support vector machine (SVM)	支援向量機	自動選取訓練點子集為基底的分類器
feature	特徵	手工設計時代對基底函數的稱呼
feed-forward network	前饋網路	無閉合有向迴路的網路
multilayer perceptron (MLP)	多層感知器	前饋網路的別名
pre-activation / activation	前激活／激活	a_j ／ $z_j = h(a_j)$
hidden unit	隱藏單元	可學習的基底函數
activation function	激活函數	隱藏或輸出單元的非線性 h、f
universal approximator	通用近似器	兩層網路可逼近任意連續函數
logistic sigmoid / tanh	邏輯 S 形／雙曲正切	早期常用、會梯度消失的激活
hard tanh	硬雙曲正切	$\max(-1, \min(1, a))$
vanishing gradients	梯度消失	飽和激活使梯度指數式趨零
softplus	—	$\ln(1 + e^a)$；ReLU 的平滑版
rectified linear unit (ReLU)	整流線性單元	$\max(0, a)$；實務預設
leaky ReLU	洩漏 ReLU	負區斜率 α，保留誤差訊號
weight-space symmetry	權重空間對稱性	$M!\,2^M$ 組等價權重
deep neural network	深度神經網路	多於兩層可學習參數的網路
hierarchical representation	階層式表徵	邊緣 $\to$ 部件 $\to$ 物體的組合式偏差
distributed representation	分散式表徵	特徵由單元組合表示，2^M 種可能
representation learning	表徵學習	學習使任務變容易的資料轉換
embedding space	嵌入空間	隱藏層輸出構成的表徵空間
autoencoder	自編碼器	以重建輸入為目標的非監督網路
pre-training / fine-tuning	預訓練／微調	先在他處學參數／小學習率整體調整
transfer learning	遷移學習	以資料充裕任務改善資料稀少任務
multitask learning	多任務學習	多個相關任務聯合訓練、共享前段層
meta-learning	元學習	學習「學習演算法」以應付未見任務
few-shot / one-shot learning	少樣本／單樣本學習	新類別僅極少（一個）標註樣本
contrastive learning	對比式學習	拉近正對、推遠負對的表徵學習
anchor / positive / negative pair	錨點／正對／負對	對比損失的三種角色
InfoNCE loss	InfoNCE 損失	以餘弦相似度為 logit 的類交叉熵
instance discrimination	實例判別	以資料增強產生正對
supervised contrastive learning	監督式對比學習	同類為正對、異類為負對

（續下頁）

英文	中文	簡要說明
CLIP	—	影像–文字跨模態對比預訓練
data augmentation	資料增強	保留語意的輸入擾動
ancestor (of a node)	(節點的)祖先	送出連結到該節點的單元集合
tensor	張量	高維陣列；純量／向量／矩陣的推廣
sum-of-squares error	平方和誤差	高斯目標分布的負對數概似
cross-entropy error	交叉熵誤差	Bernoulli ／多項目標的負對數概似
non-convex	非凸	網路誤差函數的性質；全域最佳不可求
labelling error	標註錯誤	以翻轉機率 ϵ 建模可增穩健性
mixture density network (MDN)	混合密度網路	網路輸出＝混合模型的參數
inverse problem	逆問題	正向多對一 $\Rightarrow$ 逆向多重解
forward / inverse kinematics	正向／逆向運動學	關節角 $\to$ 位置／位置 $\to$ 關節角
multimodal distribution	多峰分布	逆問題中常見；高斯假設失效
heteroscedastic	異質變異	雜訊變異數依賴輸入 $\mathbf{x}$
mixture of experts	專家混合	各成分有獨立參數的相關模型
posterior responsibility γ_{nk}	成分後驗(責任值)	資料點歸屬各成分的後驗機率
conditional mode	條件眾數	多峰分布下比均值更有用的預測

附錄 B　延伸閱讀與參考文獻

主要教材

- Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. 本講義之依據；全書電子版可於 https://www.bishopbook.com 免費閱讀。
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. 第 5 章與本章對應；MDN 之細節見其 §5.6。
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. 深度前饋網路、激活函數與表徵學習的另一標準參考。

本章引用之文獻

- Bellman, R. (1961). *Adaptive Control Processes*. Princeton University Press.(維度災難)
- Broomhead, D. S. and Lowe, D. (1988). Multivariable functional interpolation and adaptive networks. *Complex Systems* 2, 321–355.(RBF)
- Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer.(SVM)
- Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems* 2, 303–314.(通用近似)
- Hornik, K., Stinchcombe, M., and White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks* 2, 359–366.
- Montúfar, G. et al. (2014). On the number of linear regions of deep neural networks. *NeurIPS* 27.(深度的指數優勢)
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *NeurIPS* 25.(ReLU 的實證效益)

- Bengio, Y., Courville, A., and Vincent, P. (2012). Representation learning: a review and new perspectives. arXiv:1206.5538.
- Hospedales, T. et al. (2021). Meta-learning in neural networks: a survey. *IEEE PAMI* 44, 5149–5169.
- Caruana, R. (1997). Multitask learning. *Machine Learning* 28, 41–75.
- Oord, A. van den, Li, Y., and Vinyals, O. (2018). Representation learning with contrastive predictive coding. arXiv:1807.03748.（InfoNCE）
- Chen, T., Kornblith, S., et al. (2020). A simple framework for contrastive learning of visual representations. *ICML* 2020.（SimCLR）
- Khosla, P. et al. (2020). Supervised contrastive learning. *NeurIPS* 33.
- Radford, A. et al. (2021). Learning transferable visual models from natural language supervision. *ICML* 2021.（CLIP）
- Jacobs, R. A. et al. (1991). Adaptive mixtures of local experts. *Neural Computation* 3, 79–87.
- Bishop, C. M. (1994). Mixture density networks. Technical Report NCRG/94/004, Aston University.（MDN 原始文獻）
- Williams, P. M. (1996). Using neural networks to model conditional multivariate densities. *Neural Computation* 8, 843–854.
- Opper, M. and Winther, O. (2000). Gaussian processes and SVM: mean field and leave-one-out. In *Advances in Large Margin Classifiers*.（標註錯誤模型）
- Simard, P., Steinkraus, D., and Platt, J. (2003). Best practices for convolutional neural networks applied to visual document analysis. *ICDAR* 2003.

建議延伸閱讀

- Ramachandran, P., Zoph, B., and Le, Q. V. (2017). Searching for activation functions. arXiv:1710.05941.（swish；對應習題 5）
- Nair, V. and Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *ICML* 2010.（ReLU 的早期文獻）
- LeCun, Y. et al. (1998). Efficient backprop. In *Neural Networks: Tricks of the Trade*.（激活函數選擇與初始化的實務智慧）
- Zhang, C. et al. (2017). Understanding deep learning requires rethinking generalization. *ICLR* 2017.（深度網路為何能泛化——與 §6.3 的表徵觀點互補）
- Siemuri, A. et al. (2022). A systematic review of machine learning techniques for GNSS use cases. *IEEE Trans. Aerospace and Electronic Systems* 58, 5043–5077.（GNSS 中的機器學習應用綜述）

——第六章完——

下一章：梯度下降（*Gradient Descent*）——非凸誤差曲面上的最佳化：*SGD*、動量、*Adam* 與學習率排程。